

박 사 학 위 논 문

고장함수 기반의 해군 전투함정 야전정비 시스템

Failure function based Intermediate level maintenance system for
Naval battleships

2022년 12월

국 방 대 학 교
국방관리대학원 국방경영전공
최 진 우

국 문 초 록

스마트 네이비(Smart Navy)의 목표에는 상태기반정비(Condition based maintenance)가 포함된다. 상태기반정비는 함정을 모니터링하고 장비의 상태에 따라 정비를 수행하는 정비방법이다. 스마트 네이비팀은 상태기반정비 구현을 위해 4차 산업 혁명의 신기술 도입에만 힘쓰고 있다. 도입 가능성 있는 기술들을 병렬적으로 검토하여 우선순위가 고려되지 않고 있다. 해군을 시스템적 시각에서 본다면 중심에는 핵심 전력인 함정이 위치한다. 함정이 잘 운용되지 못한다는 것은 유사시 전투에 투입되기 위한 전비태세를 유지하지 못함을 의미한다. 전투에 투입되지 못하는 이유는 고장의 발생 때문이다. 고장을 미연에 방지하거나 신속하게 수리하기 위한 것이 보조 수단이 상태기반정비와 같은 정비 정책인 것이다. 결국 해군의 시스템은 함정을 잘 운용하기 위해 고장을 방지하는 것이 핵심이 된다.

해군 시스템의 중심인 고장을 파악하기 위해 고장함수에 대한 연구가 필요하다. 해군 전투함의 추진용 디젤엔진 고장 데이터를 활용하여 총수명간 고장의 패턴을 그려낸 것이 고장함수이다. 본 연구의 고장함수에는 2가지가 있다. 일반고장함수는 발생해도 작전 수행이 가능한 고장들에 대한 패턴이다. 일반고장은 계획정비 수행시 수리된다. 긴급 고장함수는 발생 즉시 임무 실패로 판단하고 모항에 입항하여 정비해야 하는 고장의 패턴이다.

시스템 다이나믹스는 피드백 루프로 구성된 복잡한 시스템을 시각적으로 표현하고 시뮬레이션하는 방법이다. 고장함수를 시스템 다이나믹스에 도입하면 해군의 정비 시스템을 시뮬레이션할 수 있다. 고장함수를 정비 시스템에 도입하면 일정수준 고장이 축적되었을 때 정비를 수행할 수 있다. 다시 말하면 함정의 상태에 따라 계획정비를 수행할 수 있게 된다. 총수명간의 고장패턴이 고장함수에 포함되므로 고장함수를 반영한 정비 정책은 상태기반정비인 동시에 예측정비가 된다. 해군 시스템의 주요 변수들을 시스템 다이나믹스에 반영하면 실제 해군의 시스템과 유사해진다. 실제의 변수들을 많이 반영 할수록 시스템 다이나믹스는 디지털 트윈스(Digital twins)화 된다고 할 수 있다.

해군은 정비를 수행하면 완전히 수리되어 새것과 같은 상태가 된다고 가정한다. 이를 완전정비라고 한다. 완전정비는 실제로 이루어질 수 없다. 아무리 뛰어난 정비사가 있어도 자연의 풍파에 의한 마모를 매번 정비할 수는 없기 때문이다. 불완전 정비된 일반고

장은 함정에 그대로 남아 다음 계획정비시 다시 정비요청된다. 본 연구에서는 정비부대의 정비능력이 완전정비 100% 대비 몇 %되는지 추정하여 시스템 다이나믹스에 반영한다.

고장함수와 완전 정비율을 포함한 시스템 다이나믹스 모델은 실제 해군의 시스템과 매우 유사해진다. 단 이를 상태기반정비라고는 할 수 없다. 상태기반정비에서는 일정한 정비일수를 부여하지 않는다. 상태를 확인한 동시에 정비에 걸리는 시간과 필요한 수리부속, 정비원의 수까지 자동으로 선정된다. 상태기반정비 구현을 위해서는 정비일수도 유동적으로 변경가능해야 한다. 정비일수는 정비원의 능력에 따라 결정된다. 정비원의 능력은 정비수행 속도와 연관된다. 많은 정비를 빠르게 수행하면 능력이 좋다고 할 수 있다. 과거의 연구에서 업무속도는 쌓여있는 정비량에 따라 결정된다고 하였다. 함정의 일반고장이 많이 축적되어 정비량이 많은 상황이라면 정비원들의 업무속도는 빠르고, 반대의 경우라면 느리게 된다. 과거의 연구 결과를 시스템 다이나믹스에 반영한다.

시스템 다이나믹스의 주요 변수들인 일반고장함수는 계층형 베이지안으로 추정하고, 긴급고장함수는 단계형 분포로 적합되어 몬테카를로 시뮬레이션된다. 정비부대의 완전정비율은 설문조사 데이터를 사전분포로 구성한 베이지안 모델로 추정한다. 정비원의 정비속도는 과거의 연구내용을 구현한다. 시스템 다이나믹스 모델은 상가대 2척이 함정 6척을 정비하는 해군 시스템이다. 함정들의 정비시기가 중첩되면 대기가 발생하여 추가적인 작전 임무를 수행하기도 한다. 시뮬레이션을 수행하고 개선 가능한 정비정책들을 제안하여 효과를 분석한다. 시뮬레이션에서 도출된 종속변수들의 선형적 관계를 분석하여 정비정책들의 최적값을 도출한다.

연구모델은 해군의 정비시스템과의 유사성이 매우 높다. 함정의 운용과 정비중에 발생하는 대부분의 요소들을 모두 포함하고 있다. 그러므로 실무적 활용가치가 크다. 해군은 정비정책들의 효과 검증을 위해 즉시 연구모델을 활용할 수 있다. 한편 산업계에서는 고장함수를 포함한 변수들의 추정과정과 시스템 다이나믹스 모델링 절차를 참고하여 해당 산업에 맞는 모델을 구현할 수 있다.

주제어(Keywords): 고장함수(Failure function), 정비정책(Maintenance policy), 시스템 다이나믹스(System dynamics), 베이지안 추정(Bayesian inference), 단계형 분포(Phase-type distribution), 대기행렬(Queueing)

목 차

제1장 서론	1
제1절 연구의 배경	1
제2절 연구 목적 및 범위	5
제2장 고장함수	10
제1절 긴급고장함수 추정	12
1. 긴급고장 데이터	15
2. 긴급고장 추세 적합	18
3. 긴급고장 확률 적합	20
4. 긴급고장 고장함수와 몬테카를로 시뮬레이션	22
제2절 일반고장 고장함수 추정	24
1. 일반고장 데이터와 계층적 구조	26
2. 계층형 베이지안 모델 구축	29
3. 일반고장 고장함수 추정 결과	32
4. 일반고장 고장함수 비교 분석	35
5. 일단위 일반고장 고장함수 도출	39
제3장 야전정비 정책	41
제1절 고장함수의 야전정비 적용 효과	42
1. 간격 최적화 정비(IOM) 모델 구축	43
2. 간격 최적화 정비(IOM) 정책 효과 분석	45
3. 고장량 고정형 정비(FFM) 모델 구축	48
4. 고장량 고정형 정비(FFM) 정책 효과 분석	51

제2절 대기현상을 고려한 정비정책 효과 분석	54
1. 대기행렬을 적용한 시스템 다이나믹스 정비모델 구축	56
2. 정비모델 시뮬레이션 결과 분석	60
 제4장 정비부대 정비능력	65
제1절 정비부대의 완전 정비율 추정	67
1. 고장확률 사전분포 추정	68
2. 정비율 사전분포 추정	70
3. 완전 정비율 추정 모델 구축	73
4. 완전 정비율 추정 결과 분석	75
5. 완전 정비율을 활용한 일반고장함수 재도출	79
제2절 정비원의 유동적 정비능력 추정	80
1. 정비소요시간 추정 모델 구축과 결과	82
2. 업무속도의 변화에 관한 문헌 연구	86
3. 실 정비소요시간을 고려한 시스템 다이나믹스 모델 구축 ..	89
 제5장 해군 야전정비 시스템 모델 설계	93
제1절 해군 야전정비 시스템 다이나믹스 모델 구축	96
1. 야전정비 모델 구축	97
2. 고장함수 모듈 탑재	100
3. 정비부대 정비율과 정비원 정비능력 모듈 탑재	104
제2절 모델의 타당성 평가	108
1. 현실성 평가	109
2. 강건성 평가	110
 제6장 해군 야전정비 모델 시뮬레이션 결과분석	112

제1절 시뮬레이션 결과 분석	113
1. PFM_FRP 모델 시뮬레이션 결과	114
2. FFM_NRP 모델 시뮬레이션 결과	122
3. FFM_FRP 모델 시뮬레이션 결과	129
4. FFM_NRP 모델 시뮬레이션 결과	134
제2절 변수들의 선형관계 분석 및 최적화	139
1. 변수간 선형관계 분석	143
2. 최적 독립변수 추정	147
 제7장 결론	151
제1절 연구결과 요약과 의의	151
제3절 연구의 한계 및 향후 연구방향	154
 참 고 문 헌	156
부 록	165
1 PFM_FRP 모델의 NOLH 시뮬레이션 결과	165
2 PFM_NRP 모델의 NOLH 시뮬레이션 결과	169
3 FFM_FRP 모델의 NOLH 시뮬레이션 결과	173
4 FFM_NRP 모델의 NOLH 시뮬레이션 결과	177
영 문 초 록	181

< 표 목 차 >

<표 1-1> 연구의 구성	9
<표 2-1> 긴급고장 추세 모델별 적합결과	19
<표 2-2> 긴급고장 확률 모델별 적합결과	21
<표 2-3> 일반고장함수(Layer1) 정확도 비교	35
<표 2-4> 실적함이 있는 상황의 정확도 비교	37
<표 2-5> 실적함이 없는 상황의 정확도 비교	37
<표 2-6> 함정 타입별 고장함수간 거리(Euclidean distance)	38
<표 3-1> 간격 최적화 정비(IOM) 모델 구분 기준	44
<표 3-2> IOM 모델들의 계획정비 간격 최적화 결과	46
<표 3-3> 모델의 성과 비교	44
<표 3-4> 정비부대 입고시 고장량의 통계값	49
<표 3-5> 총 정비횟수 통일후 정비부대 입고시 고장량의 통계값	53
<표 3-6> 정비부대 입고시 고장량의 통계값(6척 기준)	60
<표 3-7> 함정 운용가용도(6척 기준)	62
<표 3-8> FFM 함정 운용가용도와 정비부대 운용률	63
<표 4-1> 설문 대상자 현황	66
<표 4-2> 설문 응답 결과	72
<표 4-3> 설문 응답 내용의 비율 수정 결과	83
<표 5-1> 이전모델(3장)과의 비교	94
<표 5-2> NOLH 샘플링된 33개 시뮬레이션 시나리오	95

<표 5-3> 모델 구성	96
<표 6-1> 시뮬레이션 도출 변수	112
<표 6-2> PFM_FRP 모델의 상관관계 해석	120, 121
<표 6-3> PFM_NRP 모델의 상관관계 해석	127, 128
<표 6-4> FFM_FRP 모델의 상관관계 해석	133
<표 6-5> PFM_NRP 모델의 상관관계 해석	137, 138
<표 6-6> PFM_FRP 모델의 선형회귀 p_value	140
<표 6-7> FFM_NRP(독립변수 4종) 모델 적합결과	141
<표 6-8> FFM_NRP(독립변수 2종) 모델 적합결과	142
<표 6-9> 모델들의 회귀계산 결과 최적값	150

< 그 림 목 차 >

<그림 1-1> 스마트 네이비 비전과 목표	2
<그림 1-2> 해군 함정운용 시스템	3
<그림 1-3> 해군 시스템 개략도	4
<그림 2-1> 육조함수	10
<그림 2-2> 베이지안 추정과 베이지안 역추정	13
<그림 2-3> Prophet의 퓨리에 분할과 결합모델	14
<그림 2-4> 해군 함정 운용의 추세와 계절성 분할	14
<그림 2-5> 긴급고장함수 추정과정	15
<그림 2-6> 전체 함정대비 긴급고장 발생 비율	16
<그림 2-7> 일자별 긴급고장 발생횟수	17
<그림 2-8> 긴급고장 추세 적합 결과	19
<그림 2-9> 긴급고장 확률 적합 결과	21
<그림 2-10> 단계형 분포 적합된 연단위 긴급고장 확률	22
<그림 2-11> 총수명간 긴급고장 발생 기대값	23
<그림 2-12> 긴급고장 몬테카를로 시뮬레이션 결과	23
<그림 2-13> 일반고장 고장함수 추정 절차	26
<그림 2-14> 함정 99척의 일반고장 데이터 존재 구역	27
<그림 2-15> 해군 전투함 추진용 엔진의 계층형 구조	28
<그림 2-16> 수명별/계층별 고장량	28
<그림 2-17> 데이터 변환과 정규성 검정 결과	30

<그림 2-18> HMC 샘플링 종합진단 결과	31
<그림 2-19> $\bar{\alpha}_e$ 의 ESS 진단	31
<그림 2-20> $\bar{\alpha}_e$ 의 trace plot과 커널 밀도	31
<그림 2-21> $\bar{\alpha}_e$ 의 BFMI	31
<그림 2-22> 사후예측분포 진단	31
<그림 2-23> 일반고장 고장함수	33
<그림 2-24> G-prophet	33
<그림 2-25> Prophet	34
<그림 2-26> ARIMA	34
<그림 2-27> 신규함정 도입 상황을 고려한 Cross-validation	36
<그림 2-28> 일단위 일반고장함수	39
<그림 2-29> 일반고장함수의 표준편차 분포 적합	40
<그림 3-1> NP(Naval policy) 모델	43
<그림 3-2> DP(Divided by period) 모델	43
<그림 3-3> DF(Divided by failure) 모델	43
<그림 3-4> 모델간 계획정비량 비교	46
<그림 3-5> FFM(상단), PFM(하단) 모델 구축	49
<그림 3-6> 일반고장함수의 시스템 다이나믹스 적용	50
<그림 3-7> PFM의 총수명간 정비횟수	50
<그림 3-8> 함정에 누적된 고장량의 변화	51
<그림 3-9> 총 정비횟수 통일시 함정에 누적된 고장량의 변화	53
<그림 3-10> PFM, IOM, FFM의 총수명간 정비주기 변화	54
<그림 3-11> 대기행렬을 고려한 정비 시스템	56

<그림 3-12> 대기행렬이 반영된 시스템 다이나믹스 정비모델	57
<그림 3-13> OO부대 정비 시스템 구현	58
<그림 3-14> PFM의 평균 정비횟수	59
<그림 3-15> PFM Repair shop 작동현황	59
<그림 3-16> 6척 함정들의 총수명간 고장 발생	59
<그림 3-17> 함정들의 정비 입고시 고장량	60
<그림 3-18> FFM 모델의 자연 현상	61
<그림 4-1> 고장 데이터의 Cullen and Frey 그래프	69
<그림 4-2> 고장확률 사전분포	70
<그림 4-3> 정비율 데이터의 Cullen and Frey 그래프	72
<그림 4-4> 정비율 사전분포	68
<그림 4-5> 고장과 정비 프로세스	74
<그림 4-6> 고장확률 샘플링의 발산 진단	75
<그림 4-7> 고장확률 사후 예측 분포	75
<그림 4-8> 정비율 사후분포 추정결과	75
<그림 4-9> 고장확률 사후분포 추정결과(0 ~ 15년)	76
<그림 4-10> 고장확률 사후분포 추정결과(16 ~ 30년)	77
<그림 4-11> 연차별 고장량 예측결과	78
<그림 4-12> 고장 관련 변수들의 사후 예측 결과	79
<그림 4-13> PFM 정비효과가 제거된 일반고장함수	80
<그림 4-14> 상위계급과 해당계급의 사전분포 추정결과	84
<그림 4-15> 해당계급, 상위계급, 정비 소요시간의 HMC 샘플링 결과	85
<그림 4-16> 해당계급, 상위계급, 정비 소요시간의 사후분포	86

<그림 4-17> 일정압력과 업무속도의 관계	88
<그림 4-18> 일정압력을 반영한 정비부대 모델	90
<그림 4-19> 잔여 고장량과 정비 완료량	91
<그림 5-1> 시스템 다이나믹스 모듈 탑재 순서	97
<그림 5-2> 야전정비 모델	98
<그림 5-3> 야전과 정비부대간 이동	98
<그림 5-4> 함정 6척을 반영한 야전정비 모델	99
<그림 5-5> 함정들과 정비부대의 저량변수 변화	99
<그림 5-6> 적합된 분산과 시뮬레이션 결과	100
<그림 5-7> 분산 적용된 일반고장함수	101
<그림 5-8> 긴급고장 시뮬레이션 결과	101
<그림 5-9> 긴급고장 발생 시 함정 입고 및 퇴창	101
<그림 5-10> 일반/긴급고장함수 모듈 탑재 모델	102
<그림 5-11> 1번함의 일반고장량 변화	103
<그림 5-12> 1~6번함의 긴급고장 발생	104
<그림 5-13> 2번함의 일반정비와 긴급정비 시점	104
<그림 5-14> 정비부대 정비율 시뮬레이션 결과	105
<그림 5-15> 최종 연구모델	106
<그림 5-16> 최종 모델의 일반고장량 변화	107
<그림 5-17> 잔여 정비량과 정비원 업무량 변화	108
<그림 5-18> 총수명간 총 계획정비 횟수	109
<그림 5-19> 총수명간 누적 대기일수	110
<그림 5-20> 정비효과의 강건성 평가 결과	111

<그림 6-1> 함정 운용가용도와 총수명 비용(PFM_FRP 모델)	115
<그림 6-2> 함정들의 평균 정비횟수(PFM_FRP 모델)	115
<그림 6-3> 평균 누적 대기기간(PFM_FRP 모델)	116
<그림 6-4> 4번 함정의 누적 고장량 변화(PFM_FRP 모델)	116
<그림 6-5> PFM_FRP 모델의 변수간 상관관계	119
<그림 6-6> 함정 운용가용도와 총수명 비용(PFM_NRP 모델)	122
<그림 6-7> 함정들의 평균 정비횟수(PFM_NRP 모델)	123
<그림 6-8> 3번 함정의 누적 고장량 변화(PFM_NRP 모델)	123
<그림 6-9> 평균 누적 대기기간(PFM_NRP 모델)	124
<그림 6-10> PFM_NRP 모델의 변수간 상관관계	126
<그림 6-11> 함정 운용가용도와 총수명 비용(FFM_FRP 모델)	129
<그림 6-12> 함정들의 평균 정비횟수(FFM_FRP 모델)	130
<그림 6-13> 정비기간 단축시 함정에 축적된 일반고장량의 변화	130
<그림 6-14> FFM_FRP 모델의 변수간 상관관계	132
<그림 6-15> 함정 운용가용도와 총수명 비용(FFM_NRP 모델)	134
<그림 6-16> FFM_NRP 모델의 변수간 상관관계	132
<그림 6-17> 시뮬레이션 결과 분석 절차	143
<그림 6-18> 정비원 수와 함정 운용가용도의 선형관계	144
<그림 6-19> 임무 실패율과 함정 운용가용도의 선형관계	145
<그림 6-20> 함정 축적 일반고장량과 운용가용도의 선형관계	145
<그림 6-21> 임무실패율과 함정 축적 일반고장량의 선형관계	146
<그림 6-22> 총수명 비용과 함정 운용가용도의 선형관계	147

제 1장 서 론

제 1절 연구의 배경

2020년도 국방부의 주요추진 과제 핵심목표는 ‘총수명주기 개념을 적용한 국방획득 및 운영관리 강화’였다. 세부 추진과제는 ‘전 무기체계, 주요장비 수명주기간 효율적 운영관리개념 장착’, ‘수리부속 수요예측 정확도 향상 및 재고자산 감축’ 이었다. 국방부는 머신러닝, 딥러닝 등의 4차 산업혁명 기술을 적용하겠다고 발표하였다. 해군은 국방부 과제 달성을 위해 스마트 네이비(Smart Navy) 테스크 포스(Task force)를 출범하였다. 스마트 네이비팀은 100여종의 추진과제를 선정하여 해군의 각 부서에 할당하였다. 2021년 11월에 개최한 해군 군수 발전세미나에서는 스마트 팩토리(Smart factory) 과제가 인프라 부족으로 난항을 겪고 있다고 발표되었다.

<그림 1-1>은 스마트 네이비의 개념을 도식화 한 것이다. 우측 중간에 위치한 스마트 팩토리는 IOT 상태기반정비, IOT 군수관리체계 등으로 구성된다. 상태기반정비(CBM: Condition based maintenance)는 함정에 탑재된 장비들을 실시간으로 감시하여 시스템의 상태에 따라 정비하는 방법이다. 스마트 네이비팀은 함정 상태를 감시하여 정비가 필요할 것으로 판단하면 정비부대로 입고시키고, 군수관리체계를 통해 필요한 수리부속을 조달하여 적절한 시기에 정비하는 시스템을 목표로 한다. 스마트 팩토리 과제는 다음과 같은 이유들로 난항을 겪고 있다. 첫째, 함정장비의 상태를 감시할 수 없다는 문제이다. 해군 함정의 수명은 31년이다. 상태기반정비는 센서를 통해 장비상태를 수집하는 것을 기본으로 한다. 노후한 대부분의 함정들은 운용중 감시를 위한 센서가 부착되어 있으나 자료의 저장기능은 없다. 즉 자료 축적을 통한 장비상태 감시가 불가능하다. 승조원이 수기로 장비상태를 기록하지만 일정기간 후 보안문제로 파기한다. 최신형 함정들은 센서를 통한 장비상태 진단과 자료 축적이 가능하지만 기능을 활용하지 않는다. 과거부터 수행되던 수기 형식의 기록 후 일정기간이 지나면 파

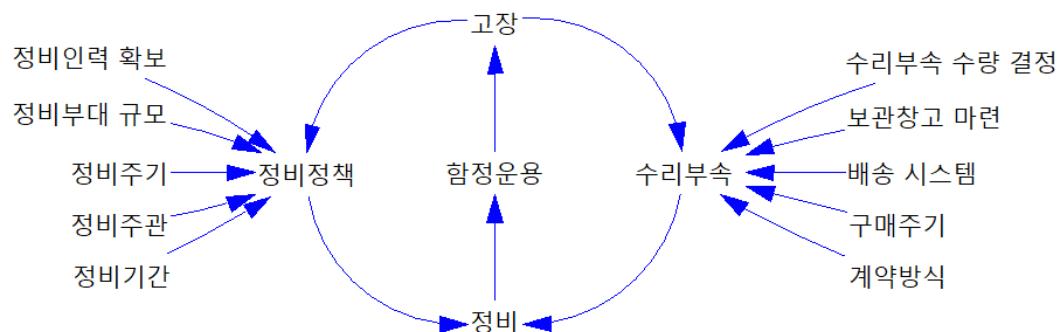


<그림 1-1> 스마트 네이비 비전과 목표

기한다. 정리하면 해군은 장비상태 기록을 장기간 저장하지 않는다. 둘째, 설치의 문제이다. 최근에는 노후된 함정의 장비라도 장비의 신호를 전기신호로 변환하여 전송할 수 있는 장치들이 개발되었다. 그러나 이 장치들은 해군 장비에 설치하기 힘들다. 신호수집이나 저장, 전송장치 설치를 위해서는 장비의 일부 개조가 필요하다. 개조 후 발생하는 고장에 대해 장비 제작사는 정비를 거부할 수 있다. 장비 제작사의 원천기술력을 확보하지 못한 이상 장비상태 감시 장치는 설치가 불가하다. 셋째, 스마트 네이비 과제의 병렬적 추진이다. 스마트 네이비 팀은 신기술들을 적용하기 위한 노력에만 치중하고, 기술적용을 위한 인프라에 대해서는 연구가 미진하다. 스마트 네이비 과제는 각 부서에 할당되어 병렬적으로 검토중이다. 병렬적 검토는 인프라의 우선순위 설정에 방해가 된다. 모두가

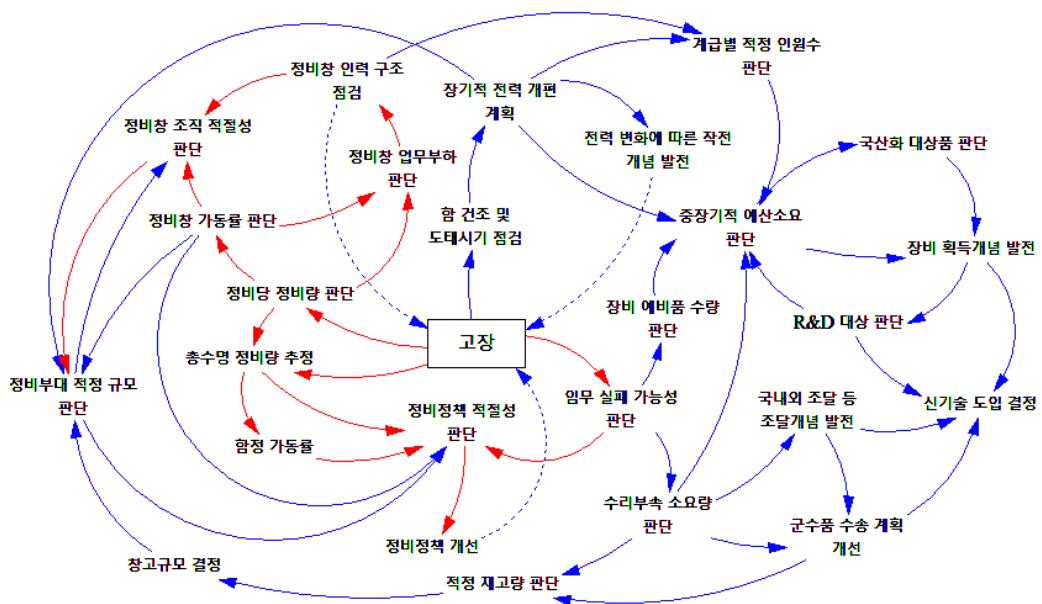
같은 우선순위에 있기 때문이다.

최우선 인프라 선정을 위해서는 해군을 시스템적 관점에서 바라보아야 한다. 해군은 ‘Fight tonight’이라는 슬로건을 강조한다. 언제든 즉시 싸울수 있도록 전비태세를 유지하고자 한다. 함정의 운용가용도(Ao: operational availability)가 높아야한다는 의미이다. 즉시 싸울 수 없는 상태란 함정의 고장상태이다. 고장상태를 최소화하기 위해 해군은 주기적으로 계획정비를 수행한다. 고장날 개소를 예측하여 정비시 수리부속을 조달하기 위해 재고수준을 결정한다. 정비를 마친 함정은 다시 정상적인 운용이 가능하다. 이와 같은 해군 함정운용 시스템을 도식화하면 <그림 1-2>와 같다.



함정운용 → 고장 → 정비로 이어지는 루프가 반복되면서 함정이 운용된다. 상태기반정비나 군수관리체계는 고장상태를 최소화하기 위한 정책들이다. 스마트네이비팀의 과제에는 새로운 정책 도입을 위한 과제는 많으나, 정책이 필요한 근본적인 원인인 고장에 대한 연구는 미진하다. 해군은 정책들의 도입에 앞서 고장에 대한 연구를 선행해야한다.

함정의 고장은 정비나 수리부속 정책 외에도 인원, 작전, 획득, 연구, 시설, 수송 등 해군의 모든 분야에 영향을 미친다. <그림 1-3>은 해군 시스템을 개략적으로 표현한 것이다. 화살표는 연결된 요소간의 인과관계를 표현한다. 화살표의 꼬리가 머리의 결정에 영향을 준다는 의미이다. 해군은 수리부속 소요 산출 등



<그림 1-3> 해군 시스템 개략도

의 업무에 예측 알고리즘(이동평균법, 지수평활법 등)을 활용하고 있다. 알고리즘의 예측 정확도가 매우 낮다는 사실은 과거로부터 지속적으로 문제가 되었다. 정확도가 낮은 이유는 2가지이다. 예측 알고리즘 자체가 다량의 데이터를 활용하지 않는 과거의 통계기법으로 구축되어 있기 때문이다. 빅데이터 기반의 예측 알고리즘에 비하면 정확도가 현저히 낮다. 또 다른 이유는 Top-down 형식의 예측을 하지 않기 때문이다. 수리부속은 정비를 위해 필요하다. 정비는 고장 방지하거나 수리하기 위해 수행된다. 필연적으로 수리부속 소요 예측에는 고장에 대한 정보가 필요함에도 불구하고 이들의 연관성이 배제되어있다. 해군의 시스템은 <그림 1-3>과 같이 고장에서 출발하는 인과관계로 대부분을 설명할 수 있다. 인과관계를 고려하여 수리부속 예측에도 근본 요소인 고장을 고려해야한다. 스마트 네이비는 상태기반정비에 대한 검토도 고장에 대한 연구에서 출발해야 한다. 상태기반정비에서는 장비의 상태가 일정 한계점을 넘으면 고장이 발생할 수 있다고 진단하고, 한계점에 도달하게 되면 정비가 수행된다(Mechefske,

2005). 여기서 한계점은 장비상태자료의 수집과 통계를 통해 결정되므로 한계점 선정을 위한 모델의 구축이 중요시된다(Parajapati et al., 2012; Tsang et al., 2006). Zonta et al.(2020)은 고장/예방정비에서 장비상태 감시 기술을 통해 상태기반정비로 발전하고, 상태자료의 축적을 통해 예측정비로 발전한다고 하였다. 자료 축적과 진단은 다음 고장의 예측을 위한 선행단계이며, 예측 기반의 정비가 가장 진보된 정비정책이라고 할 수 있다(Goossens and Basten, 2015; Zonta et al., 2020).

예측 정비는 축적된 상태자료를 바탕으로 구축된 통계 모델을 기반으로 수행된다. 과거 자료를 통해 미래에는 언제 장비상태가 악화되고 고장이 발생할 것인지 예측한다. 해군은 위에서 기술한 3가지의 문제로 상태기반정비 실현이 어려우며 문제들이 해결되어도 상태자료 축적을 위한 기간이 필요하다는 잠재적인 문제가 있다. 스마트 네이비가 상태기반정비 구현을 위한 현안에만 집중한다면 정비정책의 발전은 장기적으로 지연될 수밖에 없다.

스마트 네이비팀은 상태기반정비에서 예측정비로 이어지는 일반적인 흐름을 따르면 안된다. 문제들이 해결된 후 상태기반정비에서 예측정비로 발전하기 위해서는 또 다른 문제가 발생할 수 있고, 수집 대상 데이터 선정이 잘못되어 다시 자료 수집 단계로 돌아갈 수도 있다. 정비제도 발전이 고장의 분석에서 시작하고 마지막에는 통계모델 기반의 예측정비에 도달한다는 점에 집중해야한다. 현재 보유중인 소량의 데이터를 이용하여 통계모델을 먼저 구축하면 필요한 데이터가 무엇인지 식별되고, 데이터 수집을 위해 우선적으로 해야할 일이 무엇인지 판단할 수 있다. 모델이 먼저 구축되면 점진적으로 수집되는 데이터를 활용하여 정확도 높은 모델로 발전시킬 수 있다.

제 2절 연구 목적 및 범위

본 연구는 현실과 유사한 해군 시스템의 기초 모델을 구축하는데 가장 큰 목적이다. 세부적으로 함정의 운용, 고장을 포함한 정비 시스템을 구현한다. 정비

시스템은 부대에서 수행하는 야전정비(Intermediate level maintenance)를 대상으로 한정한다. 창정비(Overhaul, Depot level maintenance)는 고려하지 않는다. 창정비는 민간 조선소에서 수행되며 총수명간 함정당 2 ~ 3회 입고되므로 야전정비에 비해 입고된 기록이 적다. 세부적인 정비 기록도 조선소에서 관리하며 해군에 자세히 제공되지 않는다.

제안모델은 시스템 다이나믹스 시뮬레이션으로 구축한다. 범위는 정비분야에 국한되나 해군 시스템의 중심인 고장함수가 포함되므로 향후 인원, 작전 등의 해군 전분야로 확장이 가능하다. 시스템 다이나믹스는 시각적인 툴로 구현 가능하여 직관적이며, 변수간의 인과관계를 확장시켜 여러개의 루프(loop)를 가진 복잡한 시스템 구현이 가능하다(Azar, 2012; Karnopp, 2012). 변수간 인과관계의 구성은 모델의 모듈식 확장이 가능함을 의미한다. 본 연구는 크게 고장함수, 야전정비 정책, 정비부대 정비능력 3가지의 분야로 구성된다. 분야들은 본문의 각 챕터에서 모듈들로 구현되고 최종적으로 통합되어 제안모델이 된다. 필요 모듈을 구현하여 추가하는 것으로 해군 전체 모델로 확장시킬 수 있다.

해군은 일반장비, 무기, 탄약, 수리부속, 피복, 유류 등 다양한 분야의 복잡한 시스템이다. 복잡한 시스템 이해를 위해 시스템적 사고는 필수적이다(Rowland and Adams, 1999). 모듈들의 추가와 실제 데이터를 반영할수록 시스템 다이나믹스 모델 시뮬레이션은 현실의 문제를 그대로 구현하고 해결할 수 있다 (Sterman, 2000). 현실의 다양한 인과변수들을 반영하여 모델을 확장하면 디지털 트윈스(Digital twins)의 수준의 모델을 구축할 수 있다. 디지털 트윈스는 현실의 문제를 디지털에 동일하게 구현하여 문제를 해결하는 시뮬레이션 방법으로 4차 산업혁명의 핵심 기술중 하나이다. 본 연구의 제안모델 주요 변수들은 머신러닝을 활용하여 별도의 통계모델로 구현되어 현실성을 높인다.

본 연구에서는 함정의 고장을 분석하여 유의미한 통계모델을 구축한다. 통계모델은 총수명간 발생할 수 있는 고장발생을 예측하는 모델이며 일반적으로 고장 함수(Failure function)이라고 부른다. 함정의 고장은 두 가지로 구분할 수 있다. 하나는 작전 성패와 무관한 일반고장이다. 일반고장은 함정에 축적되어 계획정비 수행시 수리된다. 다른 하나는 고장즉시 임무수행이 불가능한 긴급고장

(CASREP: Casualty report)이다. 긴급고장은 발생즉시 임무수행을 중단하고 모항으로 입항하여 정비한다. 일반고장과 긴급고장은 독립적이며 각각의 고장함수가 필요하다. 2장에서는 해군 전투함정의 추진용 디젤엔진 고장 데이터를 활용하여 고장함수를 추정한다.

3장에서는 MTBF(Mean time between failure) 기반의 현행 정비정책 모델과 고장함수 기반의 정비 모델을 비교한다. 디젤엔진의 MTBF는 현재 해군에서 수행하고 있는 계획정비의 수행기준이 된다. 해군은 장비 제작사의 MTBF 기준에 따라 반년에 한번 야전정비를 수행하고 있다. 디젤엔진의 고장함수를 추정하면 현 야전정비 수행기준의 적절성을 판단할 수 있고, 최적화된 야전정비 수행기준을 마련할 수 있다. 야전정비 수행기준에 따라 정비부대의 인력구조를 점검하고, 함정 가동률을 재산출하는 것 등이 가능하다.

4장에서는 정비부대의 정비능력을 추정한다. 해군은 야전정비의 효과를 100% 완전정비라고 가정한다. 기술력이나 정비원의 능력에 따라 불완전한 정비가 이루어질 수 있음을 고려하지 않는다. 따라서 정비부대의 정비능력은 총수명 관점에서 다음고장을 시기를 앞당기거나, 정비부대의 업무량을 증가시키는 등의 영향을 미칠 수 있다. 또 누적된 고장량의 증가로 작전 중 장비의 성능 발휘가 제한될 수 있고, 불필요 고장의 증가로 이어져 수리부속 소요량이 많아질 수 있다. 한편 과거의 연구에서는 업무량이 많을 때 사람의 업무속도가 최대 25% 증가할 수 있다는 연구가 있었다. 업무속도가 25% 증가할 수 있다는 것은 정비기간이 25% 단축될 있다는 것과 같다. 정비부대 정비능력과 정비원의 업무속도는 정비 시스템의 효율성에 영향을 미칠 수 있으므로 정비정책 분석에 고려되어야 한다.

5, 6장에서는 2, 4장에서 추정된 변수들과 3장에서 구축된 모델을 통합하고 분석한다. 시스템 다이나믹스 모델에 반영된 각 변수들의 인과관계를 통해 정비정책들의 임무 실패 가능성, 정비부대의 업무부하, 함정 운용가용도, 총수명 운영비용 등을 도출할 수 있다. 본 연구에서는 현 정비정책을 포함한 4가지 정비정책을 비교한다.

7장에서는 본 연구의 요약과 의의, 한계와 향후 연구방향을 제시한다.

<그림 1-3>의 빨강색 화살표로 표시된 부분은 본 연구의 범위이며 세부구성은 <표 1-1>과 같다.

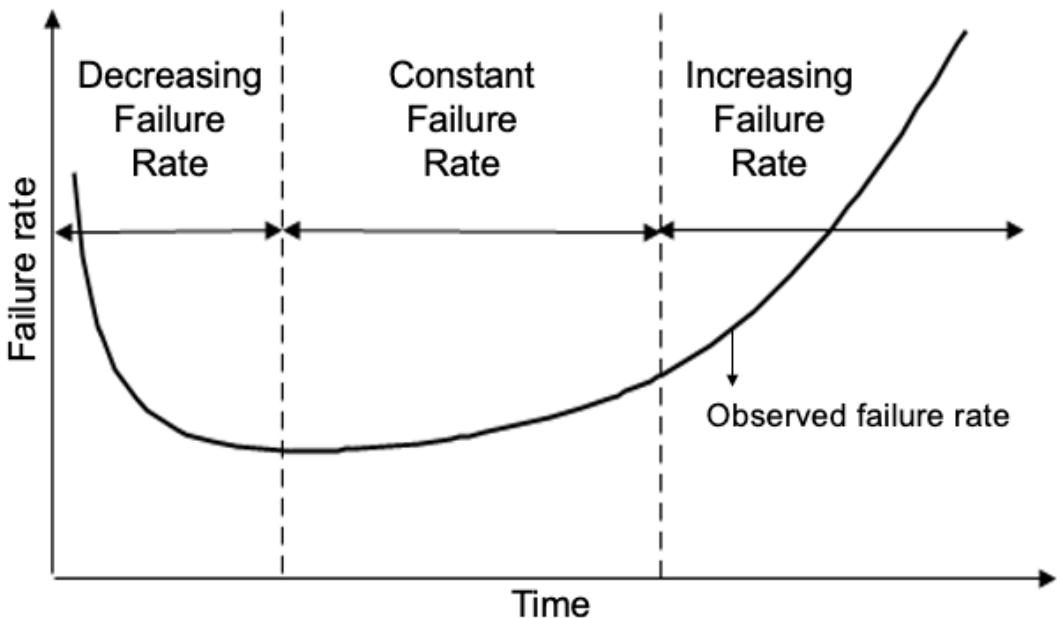
<표 1-1> 연구의 구성

분 야	연구내용 및 목적	연구방법	구현방법
Chapter 2 고장함수 (Failure function)	<ul style="list-style-type: none"> • 긴급고장함수 추정 <ul style="list-style-type: none"> - 작전임무 수행 불가 수준의 고장 발생 패턴 추정 • 일반고장함수 <ul style="list-style-type: none"> - 작전임무 수행 가능한 수준의 고장 발생 패턴 추정 	<ul style="list-style-type: none"> • Phase type distribution • B-spline curve fitting • Linear / Polynomial regression • Interpolation • Cross validation • Hierarchical bayesian inference • B-spline curve fitting • Fourier decomposition & GAM(Generalized additive model) • ARIMA(Auto regressive integrated moving average) • LOOCV(Leave one out cross validation) 	<ul style="list-style-type: none"> • Python • Julia <ul style="list-style-type: none"> • Python • Stan
Chapter 3 야전정비 정책 (Maintenance policy)	<ul style="list-style-type: none"> • 고장함수의 야전정비 적용 효과 <ul style="list-style-type: none"> - 간격 최적화 정비(IOM) 모델 구축 및 효과분석 - 고장량 고정형 정비(FFM) 모델 구축 및 효과분석 • 대기현상을 고려한 정비정책 효과 분석 <ul style="list-style-type: none"> - 고장함수 적용에 따른 효과분석 	<ul style="list-style-type: none"> • MINLP(Mixed integer non linear problem) • System dynamics • System dynamics(Queueing) 	<ul style="list-style-type: none"> • Python • Vensim <ul style="list-style-type: none"> • Vensim
Chapter 4 정비부대 정비능력 (Maintenance effectiveness)	<ul style="list-style-type: none"> • 정비부대 완전 정비율 추정 <ul style="list-style-type: none"> - 성능저하 개소 대비 정비가능 범위 추정 - 일반 고장함수 개선(정비효과 제거 고장함수 추정) • 정비원 정비능력 추정 <ul style="list-style-type: none"> - 정비부대 능력 유연 확보 범위 추정 	<ul style="list-style-type: none"> • Survey analysis • Bayesian inference • Bayesian inference • Survey analysis • Literature research 	<ul style="list-style-type: none"> • Python • Stan <ul style="list-style-type: none"> • Vensim • Python • Julia • R
Chapter 5, 6 (Proposed model)	<ul style="list-style-type: none"> • 야전정비(모델 1, 2, 3, 4) 모델 구축 <ul style="list-style-type: none"> - 정비부대 규모, 가동률, 인력구조 적절성 판단 - 총수명 정비량, 합정가동률, 정비정책 적절성 판단 - 운용가용도 및 총수명 운영유지비 기반 정책제언 	<ul style="list-style-type: none"> • System dynamics(Queueing + Failure functions + Maintenance effectiveness) • Phase type distribution • Linear regression and Correlation analysis 	<ul style="list-style-type: none"> • Vensim • Python

제 2장 고장함수

2장에서는 일반고장과 긴급고장의 고장함수를 각각 추정한다. 일반적으로 장비의 고장은 총수명간 욕조모양을 띠어 욕조함수(Bathtub function)라고 불린다. <그림 2-1>에서 초반부분은 고장이 점차 줄어든다. 장비 도입 초기에는 신규 장비간의 호환성 문제나 안정화로 인해 많은 고장이 발생하고 정비를 통해 해결된다. 수명 중반기에는 비교적 일정한 수준의 고장이 발생한다. 노후화된 장비는 점차 고장이 많아진다. 해군은 장비 제작사의 권고인 MTBF를 기준으로 정비를 수행한다. 4.5개월 함정을 운용하고, 1.5개월간 정비하는 패턴을 규정화하여 운용중이다(ROK Navy, 2018). 장비의 고장 발생량이 <그림 2-1>과 같이 계속 변한다면 일정기간마다 수행하는 계획정비는 비효율적이다. 수명 초반과 후반에 고장이 많이 발생하면 자주 정비하고, 수명 중반에는 드물게 정비를 수행하는 것이 효율적이다. 함정의 효율적인 정비방법을 찾기 위해서는 <그림 2-1>과 같은 총수명간 함정의 고장 발생 패턴에 대한 연구가 선행되어야한다. 총수명간의 고장 패턴을 표현한 것이 고장함수이다.

고장발생이 총수명간 변하기 때문에 고장함수는 시계열 모델(time series)로 분석된다. 시계열 모델의 구축 방법은 ARIMA, 지수평활법, 주기 및 추세분할법 등이 있다(Hyndman and Athanasopoulos, 2018). 과거의 연구들은 이 방법론들을 기본으로



<그림 2-1> 욕조함수(Bathtub function)

개선, 보완시킨 경우가 많았다. 고장발생이 육조모양으로 발생한다는 이론에 기초하여 육조함수의 모수를 찾는 연구들이 있었다. 육조함수가 Poisson이나(Sherbrooke, 2006) Weibull을 따른다고(Zammori et al., 2020) 가정하고 적합한 연구는 분석에 활용된 데이터에는 적합하였으나 일반화된 고장함수로 발전하는데는 한계가 있었다. 모수는 해당 데이터에 적합되므로 일반화된 값을 추정하기 힘들다는 한계가 있다.

Wang and Yin(2019)의 연구에서도 같은 문제가 있다. 이 연구에서는 원자로의 총 수명간 고장데이터를 바탕으로 연구를 수행하였다. 고장이 육조형태의 추세와 임의의 발생확률로 구성된다고 가정하였다. 고장의 추세를 초기, 중기, 말기로 구분하여 각 구간의 Weibull 분포의 모수를 적합하였다. 임의의 고장확률은 ARIMA를 활용하여 예측하였다. 예측결과는 ETS(Exponential smoothing)이나 인공신경망(Neural network)보다 정확도가 높았다. 단, ARIMA 알고리즘은 연속시간을 기반으로 추정하므로 데이터의 결측이 존재하는 경우 모수 추정이 불가하며 고정 모수로 인해 일반화된 모수로는 사용이 불가하다는 한계가 있다. 일반화의 측면만 본다면 인공신경망의 최적 은닉층(Hidden layer)의 수를 결정하는 방법이 더 적합했을 것이다.

육조함수의 모수를 추정하는 것 외에도 고장 데이터가 시계열이라는 특성을 활용하는 연구들이 있었다. Dagum and Bianconcini(2016)은 시계열 데이터에서 자주 발생하는 계절성에 집중하였다. 일정구간마다 유사한 패턴이 반복될 것이라는 가정을 기반으로 한다. 이는 신호공학의 푸리에 분할(Fourier decomposition)을 기초로 한다. 푸리에 분할은 신호 데이터를 추세, 주기로 분할하여 각각의 패턴을 파악한 후 합치거나 제거하는 방법으로 신호 데이터를 정제한다. Taylor and Letham(2018)은 푸리에 분할을 시계열 데이터 분석에 적용하여 Prophet이라는 알고리즘을 개발하였다. 세계적인 SNS 기업 Facebook에서 일자별 모바일 앱 사용패턴을 파악하는데 활용되었다.

본 연구의 일반고장과 긴급고장함수는 과거의 연구들에서 활용된 방법을 차용하기 힘들다. 고장 자체가 발생할 가능성이 적기 때문이다. 또 군의 보안 문제로 데이터를 축적하지 않아 확보할 수 있는 데이터가 일부분뿐이라는 문제도 있다.

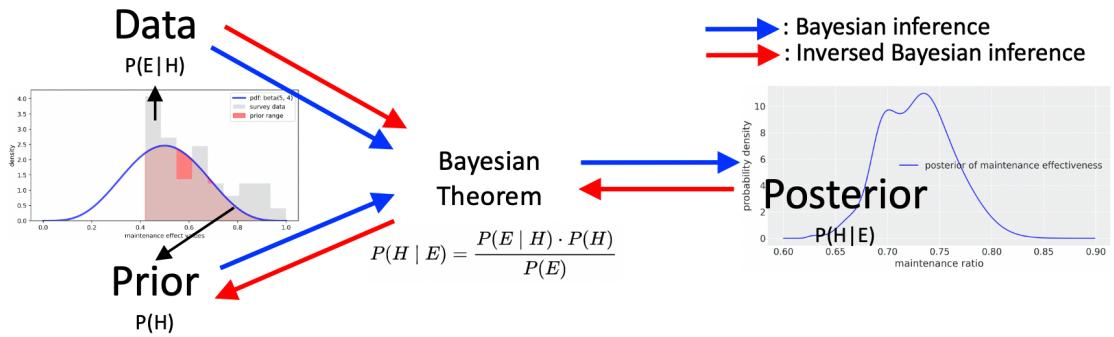
2장에서는 일반고장과 긴급고장의 데이터 형태를 분석하고 고장함수 모델을 구축한다. 고장함수는 해군 시스템에 적용되어 장기간 활용하기 위해 일반화된 알고리즘일 필요가 있다. 스마트 네이비팀은 상태기반정비를 위해 데이터를 축적하게될 것이다. 이때 과거의 연구방법들을 활용하면 데이터가 추가될 때마다 초모수(Hyper parameter)를 변경하거나 추세나 주기를 새로 도출해야하는 문제가 생긴다. 데이터가 축적될수록 시스템적으로 과한 부하를 요구하게 된다. 따라서 데이터의 축적시 모델 변경 소요가 적어야한다. 한편 고장함수는 해군의 여러 가지 변수들에 영향을 주

기 때문에 Black box가 존재하는 모델을 지양해야한다. 일반적으로 딥러닝의 문제점은 은닉층간 발생하는 상호작용을 분석할 수 없다는 점이 많이 언급된다. 고장은 해군 시스템 전반에 영향을 미치는 만큼 추정과정에서 어떤 요소가 어떤 상호작용을 하는지 파악할 수 있어야 한다.

제 1절 긴급고장함수 추정

긴급고장(CASREP: Casualty report)은 고장 즉시 작전임무를 취소하고 모항으로 입항하여 정비해야하는 고장이다. 긴급고장은 극히 드물게 발생한다. 10년 이상을 근무한 해군함정 승조원도 한번도 경험해보지 못한 승조원부터 10회 이상 경험했다는 승조원까지 다양하다. 10년 동안 5회의 긴급고장을 경험했다고 가정해보자. 3650일의 운용중 5회 발생할 확률은 0.0014이다(특별한 경우를 제외하면 긴급고장은 하루만에 정비된다). 해군함정의 총수명은 31년이고 일반과 긴급고장을 합쳐 예상되는 추진용 디젤엔진의 총 고장량은 1,050건이다(2.2절에서 자세히 기술한다). 함정에서 장비를 다루는 부서는 엔진파트를 담당하는 기관부를 포함하여 크게 5가지로 분류된다. 기관부 장비 외에도 유사한 수준으로 고장이 발생한다고 가정하면 함정 1척의 총수명간 총 고장량은 5,250건이다. 5,250건이 매년 동일하게 발생한 고장의 누적값이라고 가정하면 10년이면 1,694건이 발생했다고 할 수 있다. 이중 5건이 발생할 확률은 0.0029이다. 희귀사건(Rare event)은 사건의 빈도와 심각성을 고려하여 희귀사건인지의 여부를 판별해야한다(Rubino and Tuffin, 2009). 함정의 긴급고장은 전체 고장중의 비율(0.0029)이나 운영 기간 중 발생 비율(0.0014) 모두 충분히 작은 값이다. 함정의 긴급고장은 임무실패로 이어진다. 긴급고장 정비는 비계획적인 정비이며, 정비비용도 일반고장에 비해 약 4.2배 크다. 또한 위급상황의 긴급고장은 전투불가로 이어지므로 치명적이다. 긴급고장은 희귀사건의 특징을 보인다고 할 수 있다.

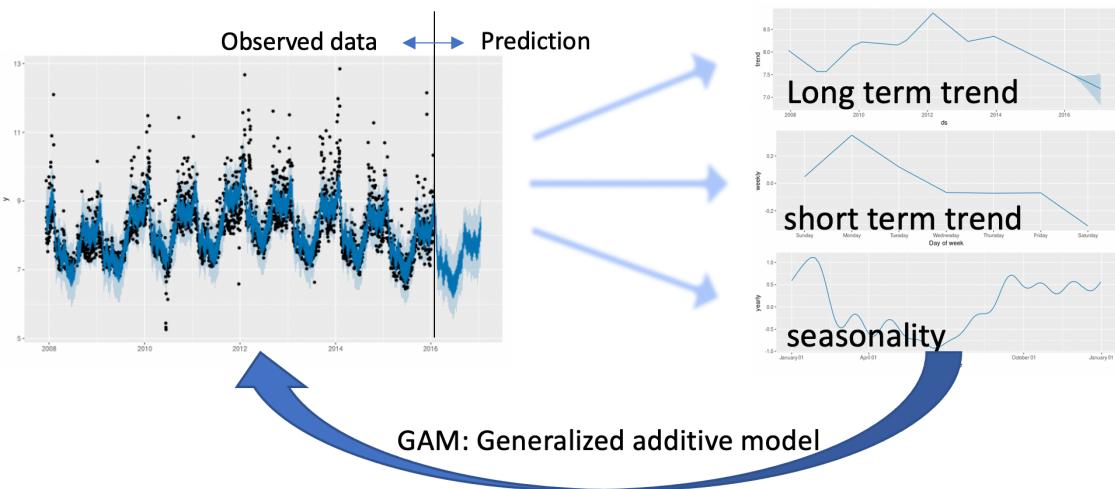
과거의 연구에서 희귀사건의 확률 추정에는 실증적 베이지안 추정(Empirical Bayesian inference)이 많이 활용되었다(Straub et al., 2016; Wahal and Biros., 2019). 베이지안 추정에서는 사전지식과 데이터의 형태를 바탕으로 희귀사건 발생 확률의 분포를 가늠한 뒤(사전분포, prior) 희귀사건 데이터를 활용(우도, likelihood)하여 희귀사건 발생 확률 분포를 업데이트(사후분포, posterior)한다(Straub et al., 2016). Straub et al.(2016)의 연구는 모니터링과 센서를 통한 많은 양의 데이터를 바탕으로 베이지안 추정이 가능하였다. 데이터가 충분하다면 사전분포의 영향을 감소시키고, 우도의 영향을 높여 데이터에 적합한 사후분포(희귀사건 확률분포)를 도출할 수 있다(Gajewski et al., 2008; Kruschke., 2014; Jiang et al., 2015).



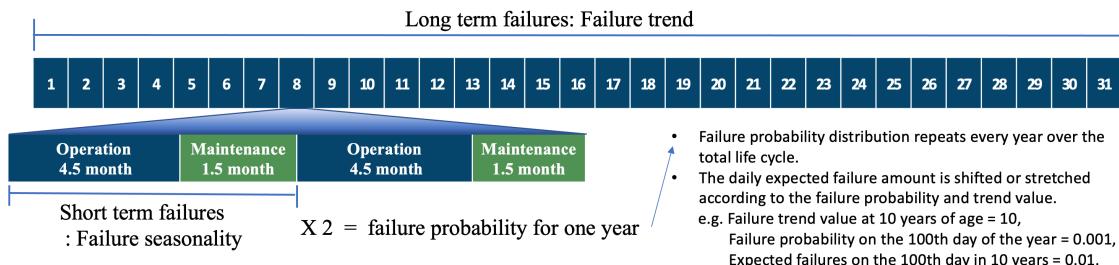
<그림 2-2> 베이지안 추정과 베이지안 역추정

그러나 희귀사건은 발생확률이 매우 낮으므로 데이터가 적은 경우가 많다. 이런 경우 관측 데이터를 사후분포로 가정하고 베이지안 역추정(Inversed Bayesian inference)을 한다(Wagner et al., 2021; Wahal and Biros., 2019; Rao et al., 2020). 사후분포와 우도를 바탕으로 사전분포를 추정한다. 추정된 사전분포는 희귀사건 주변분포이며, 데이터 기록은 없어도 희귀사건이 발생할 수 있는 모든 범위를 표현한다. <그림 2-2>는 일반적인 베이지안 추정과 베이지안 역추정을 비교한 것이다. 사전분포는 정규분포에 가까운 반면 사후분포는 봉우리가 두 개이면서 비스듬한 (skewed) 분포이다. 사전분포가 데이터의 영향을 받아 분포의 범위가 수축 (shrinkage)된 것이 사후분포이다. 보통 사전분포는 가우시안(Gaussian), 감마 (Gamma), 베타(Beta), 분포 등 일반적으로 널리 알려진 분포를 활용한다. 베이지안 역추정은 사후분포에 적합시킨 분포를 바탕으로 사전분포를 도출한다. 이 경우 사후 분포 적합은 어렵다. <그림 2-2>와 같이 사후분포는 특정분포로 정의하기 어렵다. 베이지안 역추정을 활용한 희귀사건의 연구는 사후분포의 적합 방법에 초점이 맞춰져 있다. 양상블 칼만필터(Ensemble Kalman filter)를 활용(Wagner et al., 2021)하거나, 중요도 샘플링(importance sampling)을 통한 머신러닝 기법을 활용(Rao et al., 2020)한 연구들이 있었다. 베이지안 추정은 확률분포를 추정한다. 따라서 최소한 확률분포로 표현할만한 양의 데이터를 필요로 한다.

해군 함정의 긴급고장 데이터는 매우 적어 분포 표현이 불가하므로 베이지안 추정은 불가하다. 본 연구에서는 퓨리에 분할의 추세(trend)와 계절성(seasonality) 분할 아이디어를 차용하여 긴급고장함수를 추정한다. <그림 2-3>은 Prophet 알고리즘을 표현한 것이다. 관측 데이터를 학습하여 추세와 계절성 특성(feature)를 추출한다. 추출된 특성들은 미래에도 지속적으로 결합되어 발생할 것으로 보고 시계열에 따라 결합 시킨다. 해군 함정의 운영패턴은 퓨리에 분할과 같이 추세와 계절성으로 분류 가능하다. <그림 2-4>에서 해군 함정은 총수명 31년의 추세와 반년주기의 주기성을 가진다. 6개월의 주기성은 총수명동안 반복된다. 연단위의 고장 추세값과 매일의 고장확률을



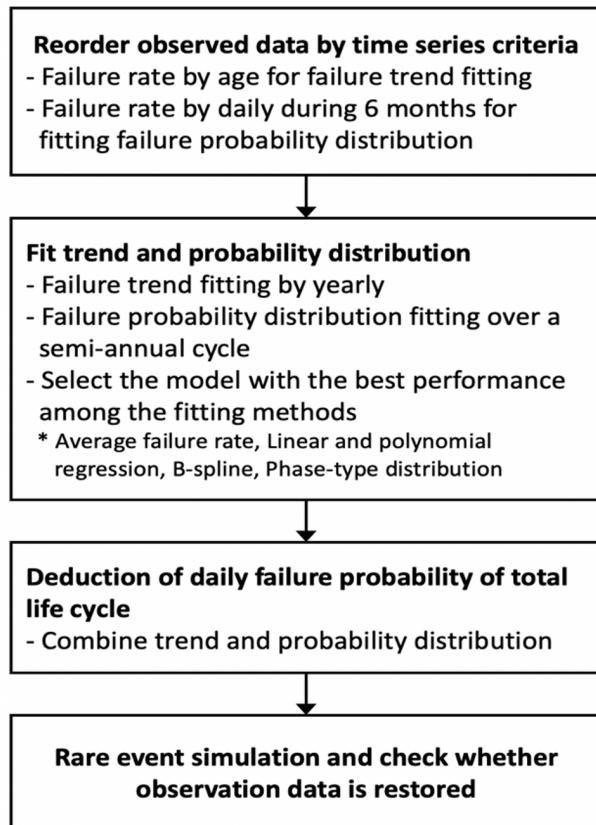
<그림 2-3> Prophet의 퓨리에 분할과 결합 모델



<그림 2-4> 해군 함정 운용의 추세와 계절성 분할

추정하여 곱하면 총수명의 일일단위 고장 기대값을 추정할 수 있다. 예를들어 10년차 함정의 고장 추세값이 10건이고 연중 100일차의 고장확률이 0.001이라면 10년 100 일차 함정의 예측 고장량은 0.01건으로 기대할 수 있다. 총수명의 예측 고장량을 추정하여 긴급고장함수를 도출한다.

0.01건이라는 긴급고장은 현실적으로 있을 수 없다. 긴급고장함수는 몬테카를로 시뮬레이션(Monte-Carlo simulation)을 통해 활용가능하다. 긴급고장함수는 몬테카를로 시뮬레이션의 기준점(threshold)으로 활용되어 발생과 미발생으로 구분할 수 있게 한다. 해군 전체 함정의 수가 100척이고 1월 1일의 긴급고장함수 값이 0.01이라고 가정해보자. 몬테카를로 시뮬레이션의 발생분포(Uniform(0, 1))에서 추출한 임의의 값이 0.005일 때 긴급고장은 발생한 것으로 본다. 반면 0.01보다 큰 값이 추출되면 긴급고장이 발생하지 않은 것으로 본다. 전체 함정이 100척이므로 몬테카를로 시뮬레이션을 100회 반복한다. 100회 반복 동안 긴급고장 발생이 3회였다면, 해군 함정 100 척 중 1월 1일 긴급고장은 3척 발생한다는 의미가 된다. 즉 긴급고장은 해군 함정 전체의 관점의 시뮬레이션에 활용 가능하다. <그림 2-5>는 긴급고장함수의 추정과정을



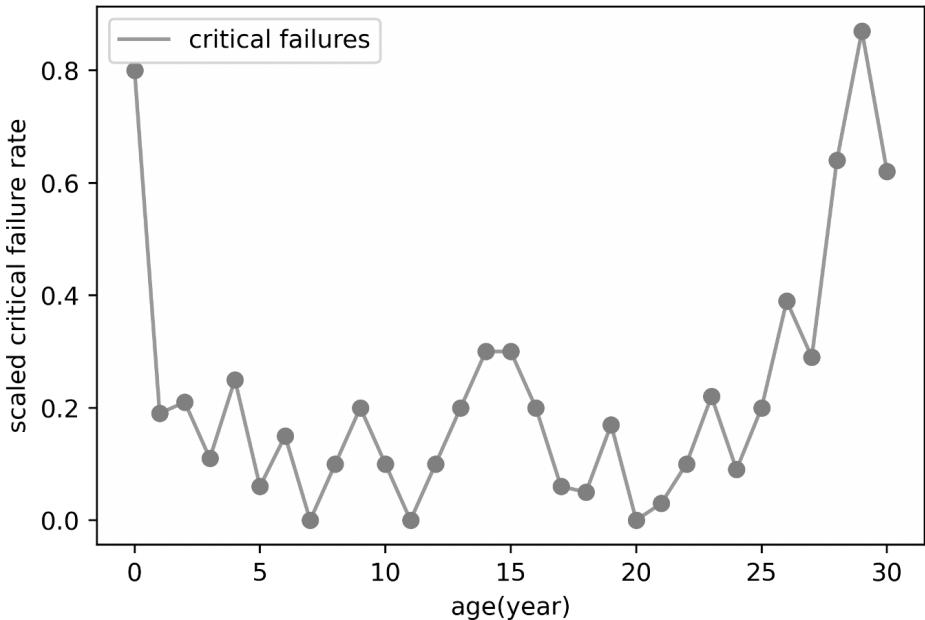
<그림 2-5> 긴급고장함수 추정과정

정리한 것이다.

긴급고장함수 추정에 대한 보다 자세한 내용은 Choi and Moon(2021)에서 확인할 수 있다. * 투고(IEMS, SCOPUS) 후 2차 심사 진행중

1. 긴급고장 데이터

해군 함정의 긴급고장은 2012 ~ 2019년 동안 발생한 전투함 66척의 191건에 대한 데이터가 보존되어 있다. 데이터에는 고장발생 함정명, 함정 도입년도, 고장 발생일자, 최종 계획정비일이 포함된다. 66척의 함정들의 긴급고장은 8년간 최소 1건에서 최대 9건까지 발생하였다. 각 함정들은 도입년도가 모두 다르므로 수명이 모두 다르다. 2012년에 발생한 긴급고장의 경우 도입년도가 2012년인 함정은 수명 1년차에 고장이 발생한 것이나, 2010년에 도입된 함정은 3년차에 발생한 고장이 된다. 따라서 총수명간 수명별 고장발생의 추이를 파악하기 위해 함정을 도입년도 기준의 수명으로 정리하였다. 정리된 수명별 고장량은 해당년도 해군 전체 전투함정 수의 비율로 나눠 주어야한다. 긴급고장은 모든 기록이 공식자료로 보존된다. 확보한 2012 ~ 2019년의

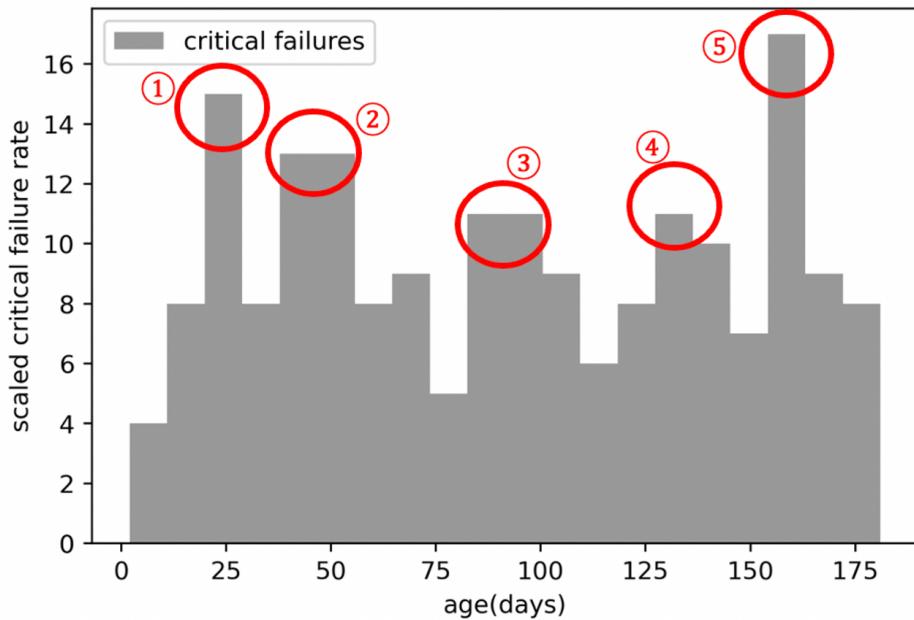


<그림 2-6> 전체 함정대비 긴급고장 발생 비율

데이터에는 해군 전체 전투함정 중에서 발생한 모든 긴급고장이 포함되어 있다. 예를 들어 데이터에서 수명 1년차에 3척에서 총 6건이 발생했다고 가정하자. 6건을 3척으로 나누어 수명 1년차의 긴급고장은 평균 2건이 발생했다고 계산하면 안된다. 2012 ~ 2019년 기간에 수명 1년차가 포함된 함정의 수로 나눠주어야 한다. 본 연구에서는 군 자료의 보안상의 문제로 실제 데이터의 수치는 공개하지 않고, 비율 전환(scaled) 된 수치만을 공개한다. 본 연구의 결과를 활용시에는 비율 환원(unscaling)을 통해 실제값으로 복구할 수 있다. 수명별 전체 함정 대비 긴급고장의 발생비율이 산출되며 결과는 <그림 2-6>과 같다.

<그림 2-6>은 과거의 연구와 유사하게 총수명간 긴급고장 발생 패턴이 육조함수와 유사하다. 데이터의 수명별 나열과 전체함정 대비 비율을 산출하여 <그림 2-4>의 장기적 고장 추세(Long term failure trend)를 산출하였다. 곡선 적합(curve fitting)을 통해 총수명의 긴급고장 추세를 도출할 수 있다.

한편 단기적 고장 확률(Short term failure probability) 산출을 위한 데이터 정렬 방법은 다르다. 데이터에는 최종 계획정비 일자와 긴급고장 발생일자가 기록된다. 최종계획정비 일자가 12월 31일인 경우 1월 31일의 긴급고장은 계획정비 후 31일차의 고장이다. 함정은 6개월의 주기성을 가지므로 최종 계획정비에서 긴급고장 발생일은 최대 183일을 넘지 않는다. 장기 임무 수행으로 191일차에 발생한 긴급고장 데이터 1개를 제거하였다. 계획정비 종료에서 긴급고장 발생일까지의 일자별 긴급고장 발생



<그림 2-7> 일자별 긴급고장 발생비율

량을 정리하면 <그림 2-7>과 같다.

히스토그램(histogram)으로 표현할 때 긴급고장 발생은 5개의 봉우리를 가진다. 봉우리 ① ~ ④는 0 ~ 140일 사이에 위치한다. 일반적으로 함정의 6개월 주기는 138일 운용 후 45일 정비하는 것으로 구성된다. 45일의 정비기간은 잘 지켜진다. 운용기간은 138일을 넘는 경우가 많다. 정비부대의 업무부하나 긴급

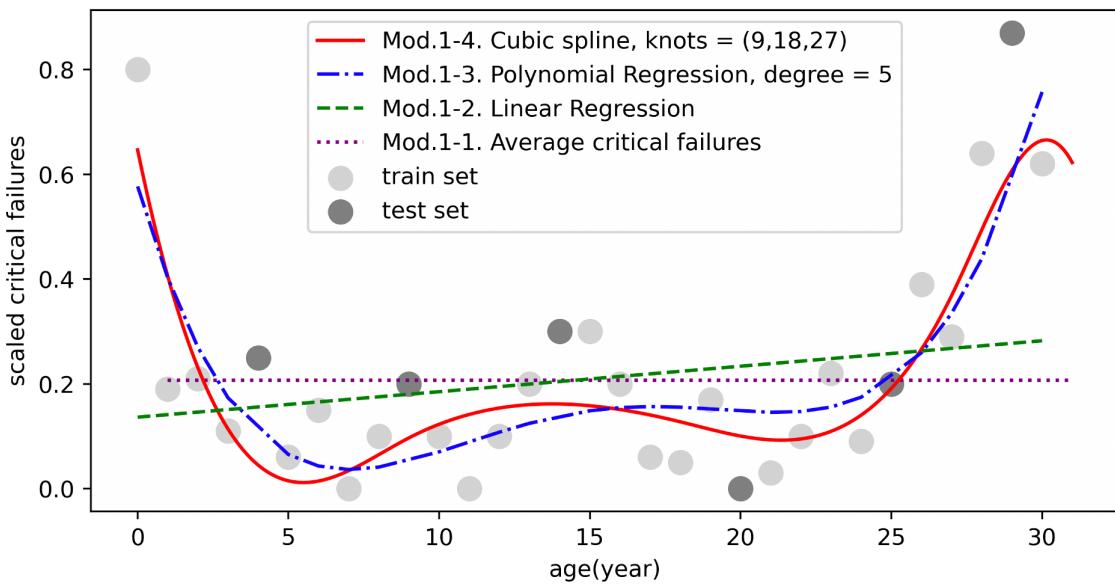
연속으로 이어붙이는 것으로 1년간의 운용주기를 산출할 수 있다.

2. 긴급고장 추세 적합

긴급고장 추세 적합에 회귀를 적용하였다. 회귀는 크게 선형회귀(Linear regression)와 비선형회귀(Non-linear regression)로 구분할 수 있다. 본 연구에서는 고장확률이 일정하다고 가정하는 MTBF를 포함하여 총 4가지의 방법을 적용하였다.

- *Model 1-1. Average critical failures*
- *Model 1-2. Linear regression*
- *Model 1-3. Polynomial regression*
- *Model 1-4. B-spline curve fitting*

Model 1-1은 전체 긴급고장의 평균값을 적용하는 것이다. 군에서 제작사 권고에 따라 일정한 간격으로 정비할 때의 고장률(λ)을 구하는 방법이다. 평균값은 총수명기간의 고장률이 되므로 역수를 취하면 MTBF($=1/\lambda$)가 된다. Model 1-2 ~ Model 1-4는 MTBF가 총수명에 따라 계속 변한다는 가정을 바탕으로 한다. Model 1-2는 단순선형회귀를 적용하여 기울기와 절편을 도출한다. Model 1-3의 다항회귀는 머신러닝에서 적용하는 데이터 분할(train-test split) 방식을 적용한다. 차수(dimension)가 높아 질수록 데이터에 과적합(overfit)되기 때문이다. 훈련셋(train set)과 시험셋(test set)으로 데이터를 구분하면, 과적합을 방지하고 모든 데이터를 설명할 수 있는 최적 차수와 모수들을 구할 수 있다. 차수를 2 ~ 31까지 상승시키면서 반복 시험했다. 훈련셋은 8:2의 비율로 구분하였다. 31개의 총수명값 중 6개를 임의로 추출하여 시험셋으로 적용하였다. 차수별 임의추출과 적합을 1,000회씩 반복하여 적합한 곡선과 시험셋 데이터의 평균 RMSE(Root mean square error)를 구한다. RMSE가 가장 낮을때의 차수가 가장 일반화된 적합차수가 된다. Model 1-4는 노트(knot) 구분을 통한 구간별 가중치(weight)를 기저함수(Basis function) 형태로 도출하고, 구간내에서 다항회귀를 적합하는 방법으로 Piece-wise polynomial regression에 해당한다(McElreath, 2020). 일반적인 다항회귀는 전체 데이터를 대상으로 전체 최적화(Global optimize)되는 반면 B-spline은 노트를 기준으로 구분된 구간내의 최적화이므로 지역 최적화(Local optimize)된다. 따라서 차수를 높이지 않아도 전체에 데이터를 설명할 수 있고, 데이터 일부의 변화가 전체 곡선에 미치는 영향이 작다(Moon. and Choi.,



<그림 2-8> 긴급고장 추세 적합 결과

<표 2-1> 긴급고장 추세 모델별 적합결과

Model	Average of RMSE
Model 1-1 Average critical failures	9.97
Model 1-2 Linear regression	7.39
Model 1-3 Polynomial regression	3.59
Model 1-4 Cubic B-spline	2.25

2021). B-spline에서 일반적으로 다항회귀는 3차를 적용하므로 Cubic B-spline으로 불린다. 노트는 오버홀(OVHL)을 수행하는 9, 18, 27년을 기준으로 하였다.

각 모델의 적합결과는 <그림 2-8>과 같고 RMSE는 <표 2-1>과 같다. <그림 2-8>의 훈련, 시험셋은 다항회귀 시 반복 시험된 데이터 분할의 예시이다. Model 1-1은 고장률 λ 를 상수값으로 고정시키는 군의 시스템

이다. 4가지 모델 중 가장 성능이 좋지 않다. 총수명간의 고장은 계속 변하기 때문이다. 선형회귀는 수명 후반에서 고장이 더 많이 발생하는 데이터를 일부 반영하였으나 초반과 후반의 급격한 상승을 반영하지 못하였다. 다항회귀와 B-spline은 유연하게 곡선으로 적합하였다. 다항회귀의 최적 차수는 5였다. B-spline의 31년차는 최고점에서 일부 아래로 하향되어 있다. 31년차 데이터의 영향이다. 해군에서 노후되어 퇴역을 앞둔 함정은 작전임무 수행 횟수가 상대적으로 적다. 따라서 긴급고장이 적게 나타날 수 있다.

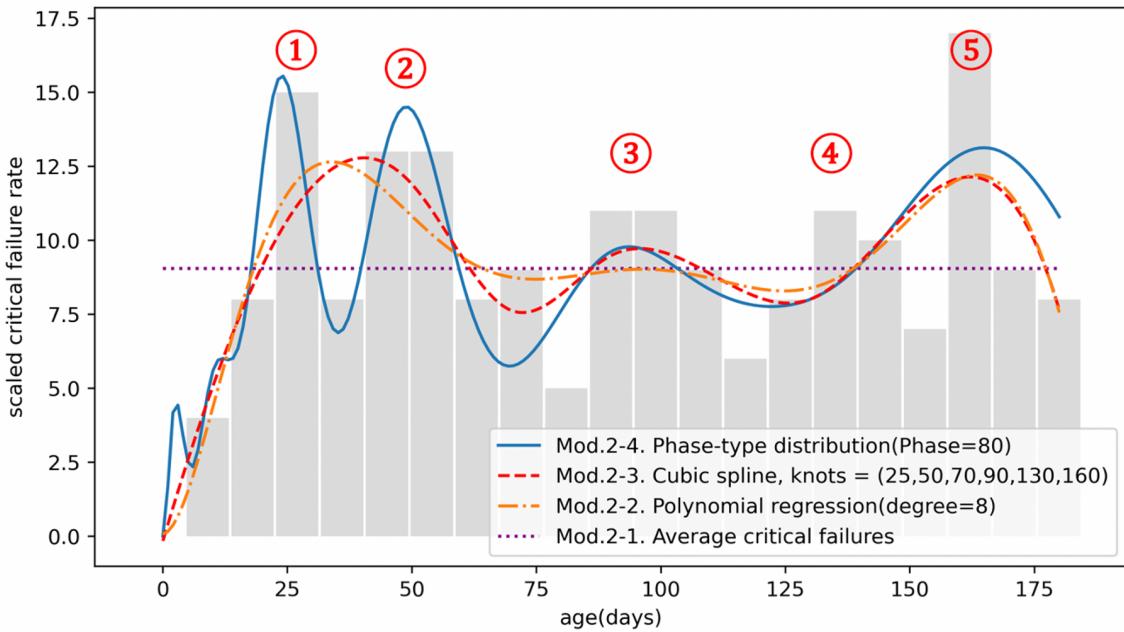
RMSE가 가장 낮은 Cubic B-spline을 긴급고장 추세 모델로 선정하였다.

3. 긴급고장 확률 적합

6개월 주기의 긴급고장 확률은 확률분포로 적합한다. 확률분포를 선형회귀로 적합하는 것은 평균 고장을 λ 를 구하는 것과 동일하다. 긴급고장 확률 적합에 선형회귀는 제외하였다. 확률분포의 적합에는 추가적으로 단계형 분포(Phase-type distribution)을 적용하였다. 단계형 분포는 얼랑분포(Erlang distribution)의 개선형태로 Neuts(1981)가 고안한 유한 연속시간 흡수 마코프체인의 확률분포이다(Okamura et al., 2011; 2013; Osogami and Harchol., 2006). 본 연구에서는 단계형 분포의 표현 다양성(versatility)의 특징과 단순성(simplicity)의 특성을 활용하여 확률분포를 적합하였다. 지수분포들의 지수행렬의 합(Kronecker sum of matrix exponential)으로 구성되어 대부분의 확률현상을 설명할 수 있다(Bhat, 1990). 복잡한 수리적 계산을 EM-algorithm을 통한 프로그램적 접근으로 대체 가능하다(Asmussen et al., 1996). 이때 적합 분포의 형태를 모수 한 개로 통제 가능하다(Faddy, 1995). 단계형 분포는 이런 특징으로 고장, 예비품 최적화, 대기행렬 등의 연구에 다방면으로 활용되었다 (Asumussen et al., 2019; Yoon and Choi., 2021; Kim and Kim., 2014; Ko and Yoon., 2020; Jo and Yoon., 2019). 단계형 분포는 지수적 특성으로 인해 꼬리가 상승하는 형태의 표현에 한계가 있다. 고장 추세는 수명말기에 상승하기 때문에 단계형 분포 적합은 부적절하였다. 고장확률 적합에는 다음의 4개 모델을 비교하였다.

- Model 2-1. Average critical failures
- Model 2-2. Polynomial regression
- Model 2-3. B-spline curve fitting
- Model 2-4. Phase-type distribution

6개월 주기의 긴급고장 분포 적합결과는 <그림 2-9>, <표 2-2>와 같다. 긴급고장 확률분포는 5개의 봉우리를 잘 표현해야한다. 항해 작전중의 높은 고장확률을 반영해야하기 때문이다. B-spline 노트는 히스토그램의 굴곡에 맞춰 설정하였다. 노트가 25, 50, 70, 90, 130, 160인 경우 가장 RMSE가 낮았다. 단계형 분포의 모수 phase 는 10 ~ 100 중 80이 가장 적합했다. 굴곡이 많은 분포의 경우 phase를 높게 설정 해야 봉우리를 잘 표현한다. phase가 80이 넘어가면 과적합되어 봉우리의 수가 더 많은 분포가 도출된다. 공통적으로 ④의 봉우리는 ⑤까지 이어지는 증가의 현상을 표현하였다. 히스토그램의 형태와 다소 차이가 있다. ④의 봉우리에서 함정은 계획정비에 입고되어야한다. 이때 입고되지 못한 함정은 추가적인 작전 임무를 수행하며 고장 확률이 증가한다. 따라서 ④ ~ ⑤사이는 지속 증가하는 형태로 적합되어도 실제 고장



<그림 2-9> 긴급고장 확률 적합 결과(데이터와 비교하기 위해 비율 조정되었다)

<표 2-2> 긴급고장 확률 모델별 적합결과

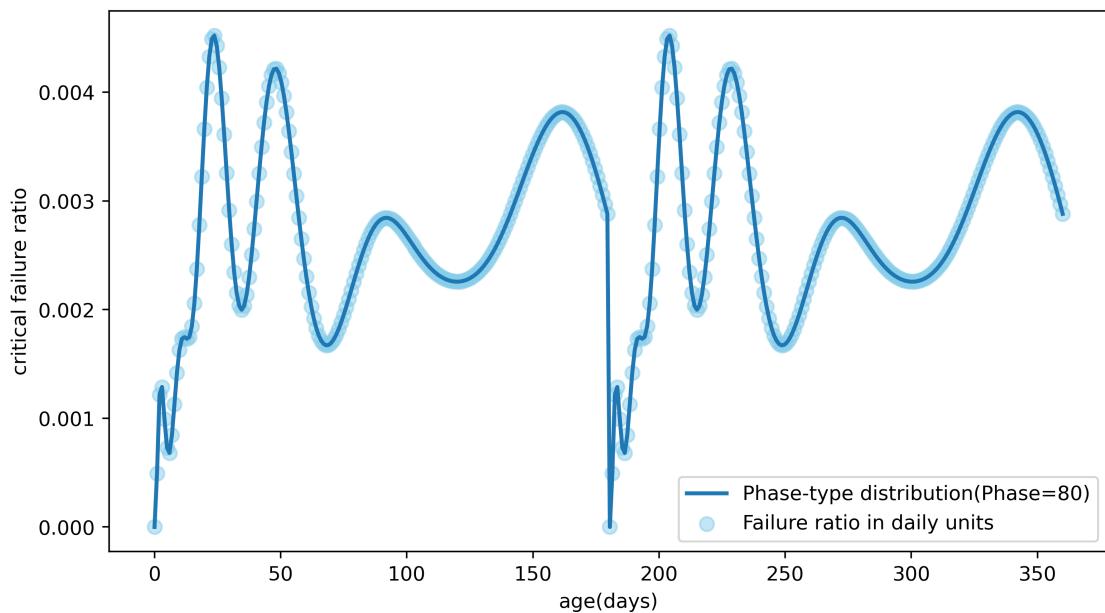
Model	Average of RMSE
Model 2-1 Average critical failures	3.68
Model 2-2 Polynomial regression	2.42
Model 3-3 Cubic B-spline	2.36
Model 4-4 Phase-type distribution	2.12

확률을 설명하는데 문제없다고 판단하였다.

RMSE에 따라 반년주기의 고장확률 분포는 단계형 분포를 선정하였다. 적합된 고장분포는 반년주기의 분포이고, 고장추세는 연단위의 이산형 데이터이다. 추세의 연도별 고장량을 확률로 분할하기 위해서는 1년 단위의 고장확률이 필요하다. 확률분포는 총수명간 독립적으로 반복되며 1년 간 2회 연속으로 발생한다고 가정하

였으므로 연속으로 이어붙이는 것으로 1년간의 고장확률분포를 도출할 수 있다. 독립적인 발생이므로 긴급고장 확률분포의 합을 1/2로 축소하여 이어 붙였다. 최종적으로 도출된 1년 단위의 긴급고장 확률분포는 <그림 2-10>과 같다.

<그림 2-10>의 0일과 182.5일의 확률은 0이다. 반년주기의 계획정비가 종료되는 날이다. 실제 상황에서는 계획정비가 종료되는 날에도 긴급고장이 발생한다. 이 경우 긴급고장으로 분류되지 않고 하자정비로 분류된다. 공식적으로 작전운용 기간에 포함되지 않는다. 따라서 고장확률이 0인 경우가 실제발생할 수 있다. 단, 계획정비를 수행



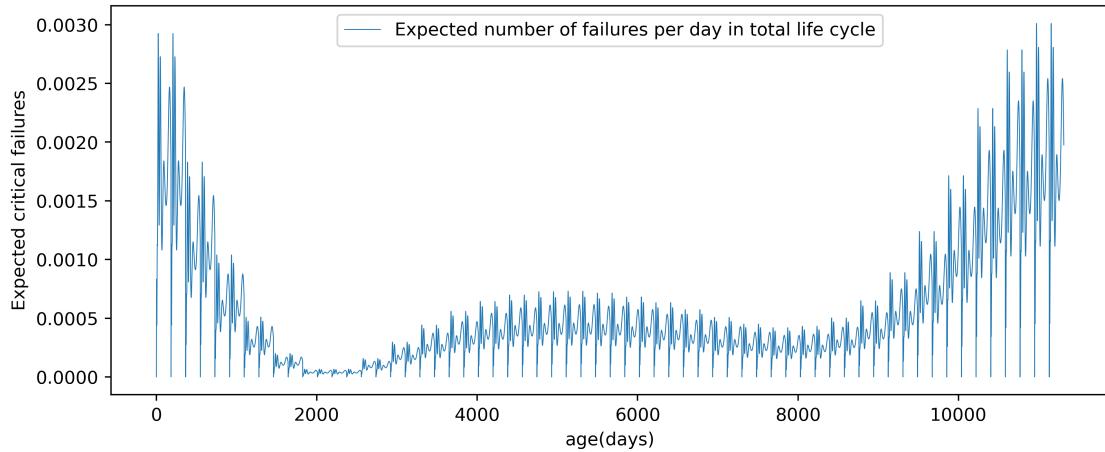
<그림 2-10> 단계형 분포 적합된 연단위의 긴급고장 확률

하지 않고 연속적으로 임무를 수행했을 때의 확률은 0이 아니다. 이 경우의 확률에 대해서는 좀 더 많은 데이터의 분석이 필요하다. 본 연구에서는 일반적인 경우만을 고려하였다. 모든 함정은 반년에 1회 계획정비를 수행하며, 운용과 정비의 주기는 최대 반년을 초과하지 않는다.

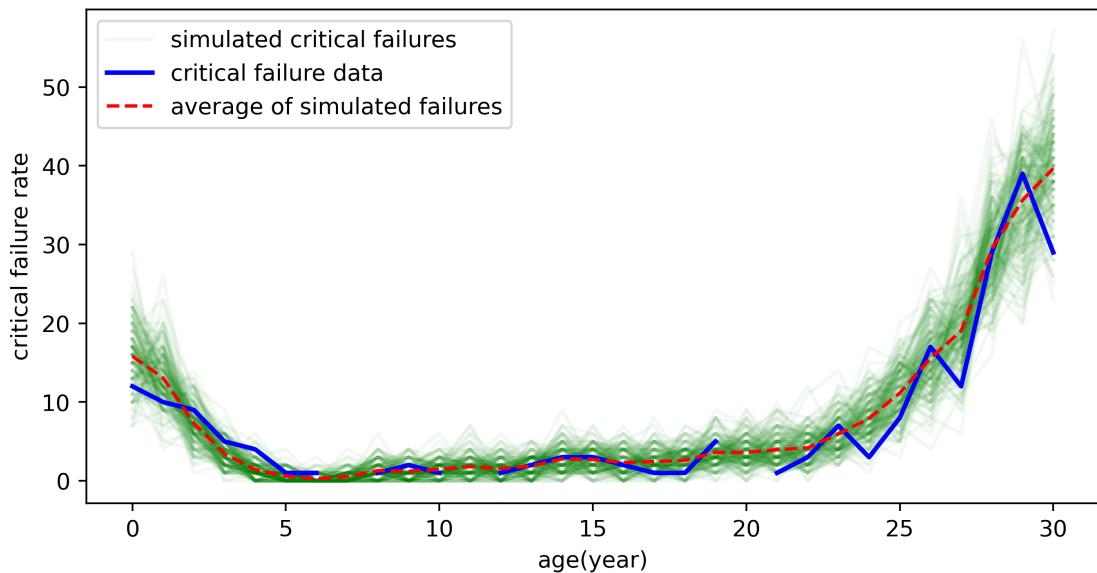
4. 긴급고장함수와 몬테카를로 시뮬레이션

총수명의 긴급고장 추세와 1년 주기의 긴급고장 확률을 곱하면 긴급고장함수를 <그림 2-11>과 같이 도출할 수 있다. 총수명간 매일의 긴급고장 발생 기댓값을 구할 수 있다. 동시에 디젤엔진 한 대 단위의 고장 기댓값이므로 긴급고장이 발생할 확률이 된다. 긴급고장함수를 활용하여 긴급고장의 발생과 미발생을 구분하기 위해서는 시뮬레이션적 접근이 필요하다. 각 일자의 확률값은 몬테카를로 시뮬레이션의 기준 확률(threshold)로 활용 가능하다. 사건 발생에 특정 확률의 가중치를 둘 수 없으므로 확률 생성은 일양분포(Uniform(0, 1))를 활용하였다. 0 ~ 1 사이의 임의의 값을 생성한다. 생성된 값이 긴급고장함수 값보다 작으면 긴급고장이 발생한 것으로 측정한다.

해군 전체 함정의 수는 A대이므로, 몬테카를로 시뮬레이션을 A회 반복하였다. 고장의 경우는 1, 미고장은 0으로 이진분류하였다. 기록된 고장들을 연단위로 합하여, 1년 단위의 긴급고장 발생량을 기록하였다. 위와 같은 과정을 1,000회 반복하여 수명별 발생하는 평균 긴급고장량을 측정하였다. <그림 2-12>의 초록색 선은 A회 반복시



<그림 2-11> 총수명간 긴급고장 발생 기대값



<그림 2-12> 긴급고장 몬테카를로 시뮬레이션 결과

발생한 긴급고장 횟수들이다. 1,000회 반복 시뮬레이션 하였으므로 1,000개의 선이 도식화되었다. 빨강색 선은 1,000회 반복 시뮬레이션된 결과의 수명별 평균값이다. 파랑색 선은 연구에 활용된 수명별 긴급고장 데이터이며 <그림 2-6>을 비율 조정한 값이다. 전체적으로 파랑색 선은 초록색 선들의 발생 범위 내에 포함된다. 이는 시뮬레이션을 통해 실제의 긴급고장 패턴을 재현할 수 있음을 의미한다.

본 절에서는 긴급고장함수를 도출하고 시뮬레이션을 통해 실제 데이터의 발생을 구현하였다. 과거의 연구에서 주축을 이루는 베이지안 통계가 적용 불가한 상황에 데이

터 구조를 활용하여 희귀사건을 재현하였다. 희귀사건은 고장 외에도 지질학(Ager and Ager., 1995), 유전공학(Marcais et al., 2010), 인간 행동의 학습분야(Said et al., 2015) 등 다양한 분야에서 발생한다. 규모가 큰 기업들을 제외하면 대부분 긴급 고장에 대한 데이터 수집 상황이 좋지 않다. 이와 같은 경우 본 절의 방법을 활용하여 긴급고장함수를 도출하고 시뮬레이션할 수 있다. 즉, 본 절의 연구는 데이터가 매우 적은 상황에서 비교적 쉬운 방법론들을 활용하여 치명적인 희귀사건을 분석할 수 있다는 의미를 가진다.

제 2절 일반고장함수 추정

긴급고장은 확률이 높은가보다는 사건이 발생하는가가 중요한 요소가 된다. 따라서 확률적 결과를 발생과 미발생인 이진형 결과로 변경하였다. 일반고장은 긴급고장과는 다르다. 실제 상황에서는 어느 정도 성능이 저하될 수 있겠으나 작전임무 수행이 가능한 고장들이다. 일반고장은 함정에 누적되고, 계획정비 시 수리된다. 일반고장은 긴급고장과 같은 이진분류가 불필요하다. 고장 기댓값을 누적시키는 것으로 항해중 고장에 얼마나 노출되는지 산출할 수 있다.

모수 추정법을 적용한 과거 연구들의 공통적 한계는 데이터에 적합된 모수로 인해 일반화가 어렵다는 점이다. 함정 한척의 고장함수를 모수 추정법으로 구축한다면 다른 함정에는 적용할 수 없다는 의미이다. 본 연구의 일반고장함수는 모수 추정법을 활용하였음에도 불구하고 제한적으로 일반화 가능하다. 계층형 베이지안 추정법(Hierarchical Bayesian inference)을 활용하기 때문이다. 계층형 베이지안 모델은 상위 계층의 모수와 하위계층의 모수가 정보를 공유(Information pooling)하며 적정 모수를 추정한다(Gelman et al., 2013; Taieb et al., 2017). 모수가 결정되면 하위 계층의 데이터가 추가되거나 제거되어도 상위 계층의 모수(Hyper parameter)는 큰 변동이 없다(Gelman, 2006). 즉, 계층형 베이지안 모델을 활용하여 일반고장함수 모델을 구축하면 고장데이터를 지속적으로 축적시켜도 모델이 크게 변하지 않는다는 장점이 있다. 특히 함정의 고장과 같이 데이터가 비균일하면서 계층적 구조 구축이 가능한 경우 모수공유로 정확도를 높일 수 있다(Gelman et al., 2015). 계층형 베이지안 추정은 적합과정에서 수많은 MCMC(Markov chain Monte carlo)를 통해 과대/과소적합을 피할 수 있다. 이와 같은 장점으로 교육, 생태학, 경영, 역학 등 다양한 분야에서 데이터의 계층적 구조화를 통해 정확도 높은 추정을 수행하고 있다(Rubin, 1981; McElreath, 2020).

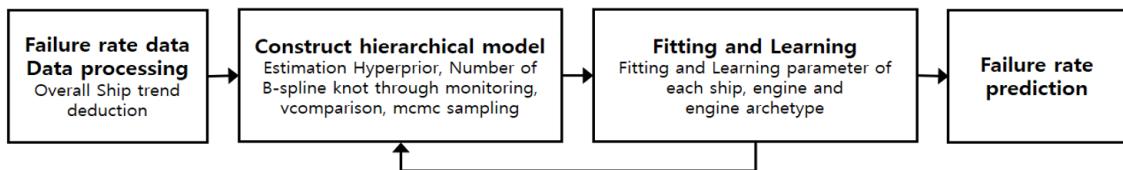
현대의 베이지안 추정과정은 프로그래밍에 초점이 맞춰져 있다. 수많은 시뮬레이션을 기반으로 사후분포를 추정하기 때문이다. 여기에 활용되는 시뮬레이션이 MCMC이다. MCMC 시뮬레이팅 과정은 복잡하여 수리적으로 연산과정을 추적하기 힘들기 때문에 컴퓨터 프로그래밍으로 작동하는 방법이 많이 개발되었다. Winbugs, PYMC 등 여러 가지 프로그래밍 기법들이 알려져 있으나 세계적으로 Stan을 많이 활용한다. Stan은 베이지안 추정의 기본 요소인 사전분포, 우도와 데이터를 정의하면 연동 프로그래밍 (Python, R, Julia 등)에서 결과를 확인할 수 있다(Carpenter et al., 2017). 본 연구에서는 Stan을 활용한 계층형 베이지안 모델을 프로그래밍 언어 Python으로 연동하여 고장함수를 추정한다. Stan은 MCMC 중의 하나인 HMC(Hamiltonian Monte carlo) 샘플링 알고리즘을 활용한다. HMC는 Gibbs 샘플러 등 이전의 방법들에 비해 빠르고 강건하게 체인들을 수렴시킨다. 또 Stan에는 많은 자체적 진단법을 내장하고 있어 간편한 결과도출이 가능하다(Betancourt and Girolami., 2015; Vehtari et al., 2021; Betancourt, 2016).

사후분포의 결과를 활용하여 MCMC 과정의 이상유무를 진단하는 연구가 많이 이루어졌다. 모델의 정확도 측정에는 일반적으로 WAIC(Widely applicable information criterion)이나 LOOCV(Leave one out cross validation)이 많이 활용된다. 이들은 AIC(Akaike information criterion)이나 DIC(Deviance information criterion)을 베이지안 통계에 더 적합하도록 개선된 형태이다(Vehtari and Lampinen: 2002 Vehtari et al., 2017). 본 연구에서는 LOOCV의 일종인 ELPD(Expected log pointwise density)를 활용한다. ELPD는 사후분포 전체범위에 대해 적용된 개별 데이터(pointwise)가 설명하는 log값을 합산하는 개념이다. 사후분포의 평균값이 아닌 분포가 표현하는 전체 범위에 대한 설명력을 표현한다는 점에서 베이지안 추정에서 널리 사용된다(Bürkner et al., 2020).

긴급고장함수의 데이터는 매우 적어 분포로 표현하는 것이 불가능하였다. 일반고장 데이터 역시 일반적인 데이터 분석업무에 사용되는 데이터에 비해 매우 적으나, 긴급 고장함수에 비해 많은 편이다. 따라서 일반고장함수 성능 비교를 위한 비교모델을 선정하였다. 첫 번째는 프로핏(Prophet) 알고리즘이다. 2장의 서두에 기술한 바와 같이 프로핏은 비교적 최근에 개발된 알고리즘이며, 퓨리에 분할과 특성요소 통합을 통해 높은 정확도를 보인다고 알려져있다. 계층형 베이지안 구조는 상위층의 모수를 하위 층과 공유하는 형식으로 전역 최적화(global optimization)가 이루어져있다. 반면 프로핏은 계층을 별도로 구분하지 않으므로 지역 최적화(local optimization)에 해당한다. 프로핏 알고리즘의 작동 과정은 <그림 2-3>과 같다. 본 연구에서는 계층구조의 효과를 확인하기 위해 두 번째 비교모델로 프로핏을 전역 최적화 알고리즘으로 개선

한 G-prophet(global prophet)을 구축하였다(Moon and Choi., 2021). G-prophet은 상위층의 퓨리에 분할 특성요소(분산)를 하위층과 공유하는 형식으로 작동한다. 마지막 비교모델은 아리마(ARIMA, Auto regressive integrated moving average) 알고리즘이다. 아리마는 차분(differencing)과정을 통해 주기적 요소를 데이터에서 제거한다. 제거된 순수한 변동성을 이동평균을 통해 예측하여 정확도를 향상시킨다. 아리마는 비교적 오래전부터 활용된 알고리즘임에도 정확도가 높아 최근까지도 보험(Kumar et al., 2020; Mohammadi and Rich., 2013), 금융(Pai and Lin., 2005; Siami and Namin., 2018) 등 여러 산업에서 활발히 연구되고 있다. 또 아리마는 과거의 연구에서 고장함수 예측에 활용된 바 있으므로 비교모델로 선정하였다(Wang and Yin., 2019).

일반고장함수 추정과정은 <그림 2-13>과 같다. 먼저 데이터 정제를 통해 99척의 전투함정 추진용 디젤엔진 고장 데이터를 수명별로 재구성한다. 함정의 특성을 파악하고 계층형 베이지안 모델을 구축한다. 계층형 베이지안 모델의 연도별 굴곡 가중치는 B-spline으로 적합하여 기저함수(B-spline)를 적용한다. 샘플링을 통해 도출된 사후분포 모수들을 진단한다. 이때 진단기준에 미달한 모수들이 있는 경우 베이지안 모델의 사전분포를 수정하여 샘플링을 반복한다.

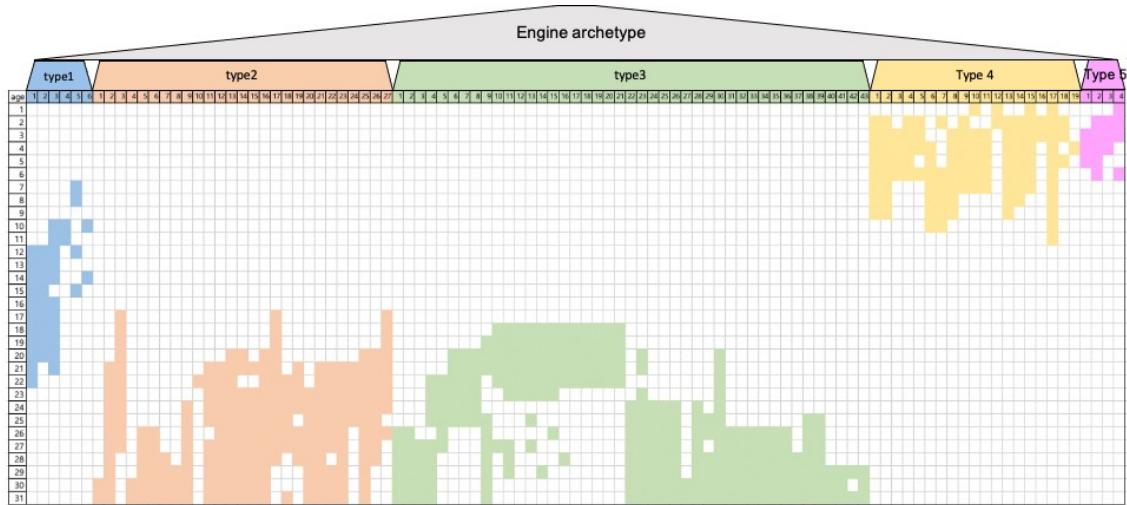


<그림 2-13> 일반고장함수 추정 절차

일반고장함수에 대한 보다 자세한 내용은 Moon and Choi(2021)을 통해 확인 가능하다.

1. 일반고장 데이터와 계층적 구조

함정의 정비기록은 장비정비정보체계에 입력된다. 장비정비정보체계에서 확보한 일반고장 데이터는 2010 ~ 2019년의 해군 전투용 함정 110척의 추진용 디젤엔진 고장 데이터이다. 일반고장 데이터는 긴급고장 데이터와 다르게 매 건의 기록이 남아있지 않다. 일반고장은 작전 임무의 성패에 영향이 없는 고장으로 함정에 축적되고, 반년 주기의 계획정비시 정비되기 때문에 비교적 덜 중요하게 다루고 있는 것으로 판단된다. 일반고장 데이터는 계획정비시 정비된 항목들이다. 110척의 고장 중에는 누락정



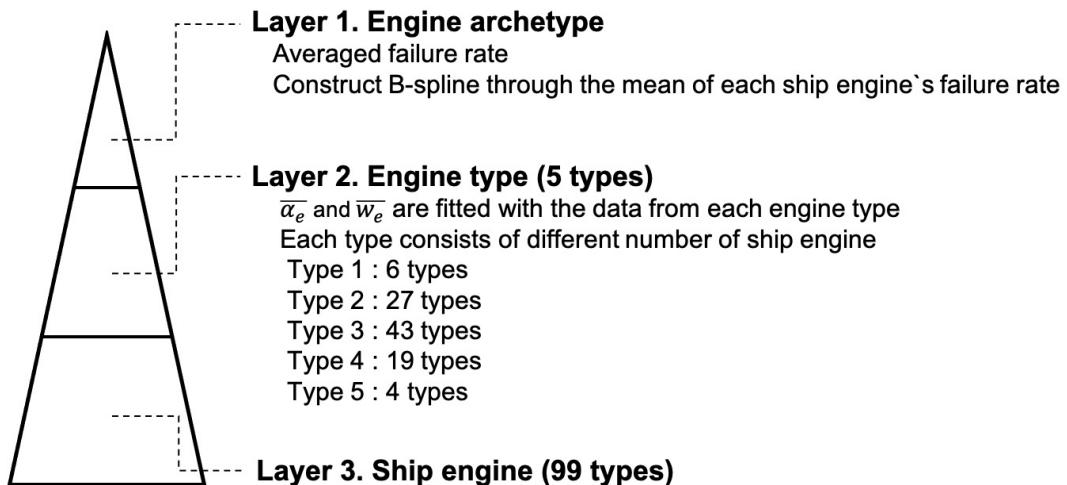
<그림 2-14> 함정 99척의 일반고장 데이터 존재 구역

도가 심하고 왜곡된 데이터들도 포함되어 있다. 장비정비정보체계에서는 정비자가 직접 입력하는 방식을 취하고 있어, 입력 오류가 다수 발생할 수 있다는 점을 고려하여 일부 데이터를 삭제하였다. 최종 99척의 데이터를 분석대상으로 결정하였다.

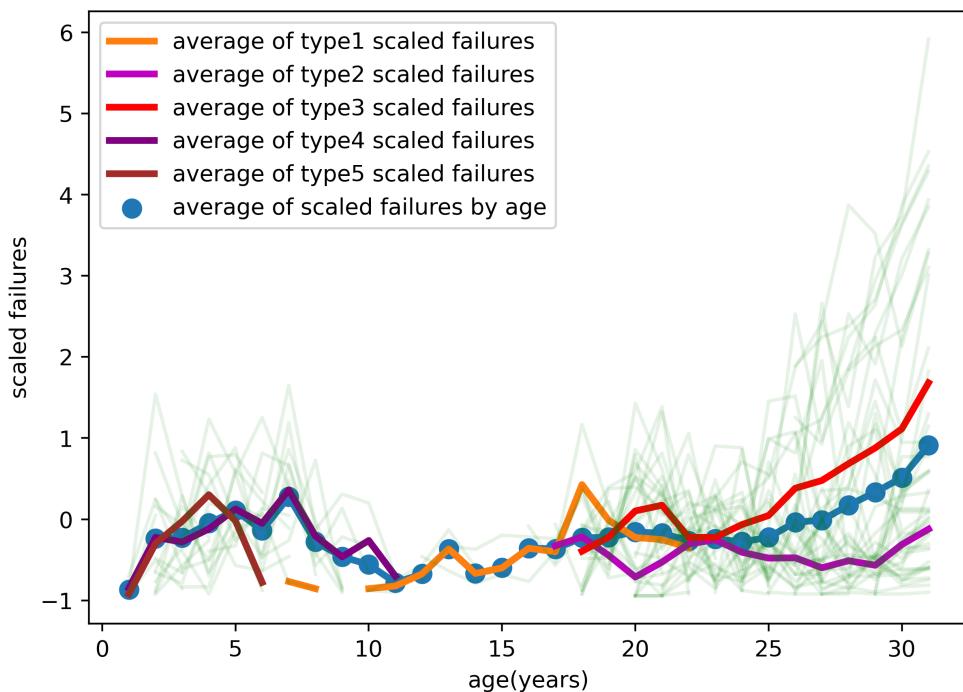
31년 이후의 노후 함정들에 대한 정비기록은 거의 존재하지 않는다. 함정의 폐선이 약 31년차에 이루어지는 경우가 많다는 의미이다. 함정의 총수명을 31년으로 구성하고 도입년도 기준으로 재정렬하였다.

<그림 2-14>의 가로축은 함정이고 세로축은 수명이다. 음영구역은 각 함정의 고장 기록이 존재하는 구간이다. 보안상의 문제로 구체적인 데이터 수치는 공개하지 않는다. 가로축 첫 번째는 type1의 1번 함정이다. 이 함정은 수명 12 ~ 22년차까지의 데이터가 존재한다. type은 함정 엔진의 종류가 된다. DDH, FF 등 함정의 종류는 여러 가지이며 함정의 목적과 크기에 따라 추진용 엔진의 출력, 배기량 등 제원이 다르다. 타입이 같은 엔진은 설계상 동일한 엔진이나 서로 다른 함정에 탑재된 경우이다. 해군은 배치(batch) 형식으로 같은 타입의 함정을 연속적으로 건조한다. 각 타입들의 수명위치가 다른 이유이다. type1 함정은 7년차에서 22년차까지 데이터가 존재한다. 2010년부터의 고장기록이 남아있으므로 type1 함정의 최초 도입은 약 2003년임을 알 수 있다. type 4, 5는 비교적 최근에 건조된 함정으로 수명구간에서 데이터가 앞쪽에 위치하고, type 2, 3은 상대적으로 노후된 함정이다.

계층형 베이지안을 적용하기 위해서는 데이터의 구조를 살피고 공통적인 특징으로 그룹화해야 한다. <그림 2-14>의 타입은 설계상 동일한 엔진이라는 공통적인 특징으로 그룹화된 것이다. 5개 타입의 상단에는 Engine archetype이라는 층이 있다. 이는 해군 전투함정의 추진용 엔진이라면 가지는 공통적인 특징에 관한 층이다. 전투함은



<그림 2-15> 해군 전투함 추진용 엔진의 계층형 구조



<그림 2-16> 수명별/계층별 고장량

유사시 저속에서 고속까지 빠르게 가속하고 감속할 수 있어야 한다. 고부하에서 장시간 운전이 가능해야하고 위급한 경우에는 한계를 초과한 부하로도 어느 정도 운전이 가능해야 한다. 최종적으로 데이터는 <그림 2-15>와 같이 총 3개의 층으로 구분된다. 수명별/계층별 고장량은 <그림 2-16>과 같다. 데이터는 연단위로 묶인 이산형 데이터이다. 파랑색 점은 계층을 구분하지 않은 수명별 고장량의 평균값이고, 파랑색 선은

점을 연결하여 수명별 고장의 패턴을 표현한 것이다. 타입별/수명별 평균 고장량들은 데이터가 존재하는 수명구간에 표시되었다. 초록색 얇은 선들은 99척의 데이터 구간을 표현한 것이다. 평균값에 비해 실제 함정들의 평균값은 분산이 크다. 10 ~ 17년 구간에는 초록색 선의 개수가 상대적으로 적다. 이는 해당 수명에 위치한 데이터가 적기 때문이다.

일반고장 데이터는 수명별 데이터의 수가 모두 다르고, 수명의 위치도 다르다. 이와 같은 데이터의 특징을 비균일하다고 한다. 데이터는 비균일적인 특징을 가진 반면 설계기준과 엔진 사용 용도의 특징적인 요소들로 계층화할 수 있다. 2.2절의 서두에 설명한 바와 같이 구조화가 가능한 비균일적 데이터는 계층형 베이지안 추정을 통해 강건한 모델로 구축가능하다.

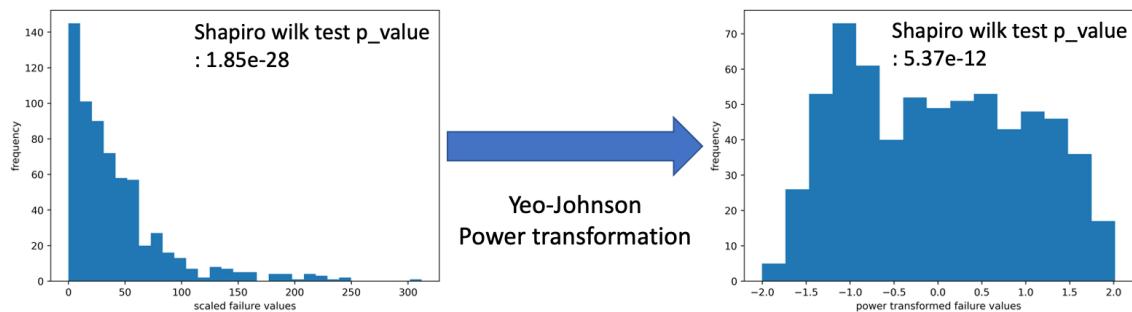
2. 계층형 베이지안 모델 구축

<그림 2-15>의 각 층을 식(1)과 같이 계층형 베이지안 모델로 구축하였다.

$$\begin{aligned}
 Y_s &\sim Normal(\mu_s, \sigma_y) \\
 \mu_s &= \alpha_s + \sum_{k=1}^K w_{k,s} B_k \\
 \alpha_s &\sim Normal(\bar{\alpha}_e, \sigma_\alpha) \\
 w_s &\sim Normal(\bar{w}_e, \sigma_w) \\
 \bar{\alpha}_e &\sim Normal(\bar{\alpha}_0, \sigma_{\bar{\alpha}}) \\
 \bar{w}_e &\sim Normal(\bar{w}_0, \sigma_{\bar{w}}) \\
 \sigma_\alpha &\sim Gamma(10, 10) \\
 \sigma_w &\sim Gamma(10, 10) \\
 \sigma_{\bar{\alpha}} &\sim Exponential(1) \\
 \sigma_{\bar{w}} &\sim Exponential(1) \\
 \sigma_y &\sim Exponential(1)
 \end{aligned} \tag{식(1)}$$

본 연구에서 확보한 데이터는 고장 데이터의 샘플에 해당한다. 샘플의 수가 많아질 때 중심극한정리에 의해 평균값들은 정규분포 형태가 된다. 고장함수 모델의 장기적 활용을 고려하여 각 계층의 분포를 정규분포로 가정하였다. Y_s 는 계층의 최하층 (Layer 3)에 해당하는 각 함정의 고장분포이다. 아래첨자 s는 1~99번의 함정 번호이다. 개별 함정 엔진은 평균 μ_s , 표준편차 σ_y 를 따른다. μ_s 는 중간층(Layer 2)인 엔진타입의 평균(α_s)에 B-spline의 기저함수 행렬 B_k 와 가중치 $w_{k,s}$ 가 합쳐진다. B_k 는

B-spline의 수명별 기저함수 행렬이다. 각 엔진타입의 평균 α_s 는 엔진전체(Layer 1)의 평균 $\bar{\alpha}_e$ 를 따르는 정규분포이다. $\bar{\alpha}_e$ 와 \bar{w}_0 는 B-spline을 엔진전체의 수명별 평균값(<그림 2-16>의 파랑색 그래프)을 선형(Simple linear regression) 적합시켜 도출한 절편(intercept)과 수명별 가중치(weight)이다. σ 들은 각 층 분포들의 표준편차이다. 데이터 비율(data scale) 고려 모수 1의 지수분포를 가정하여 HMC 샘플링시 충분한 공간을 탐색하도록 설정하였다. σ_α 와 σ_w 는 감마분포에 적합시킨다. <그림 2-13>의 과정에 따라 지수분포 가정시 모수공간 탐색이 불안정하여 감마분포로 변경한 경우이다.

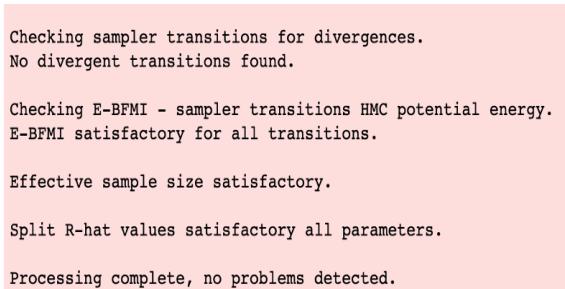


<그림 2-17> 데이터 변환과 정규성 검정 결과

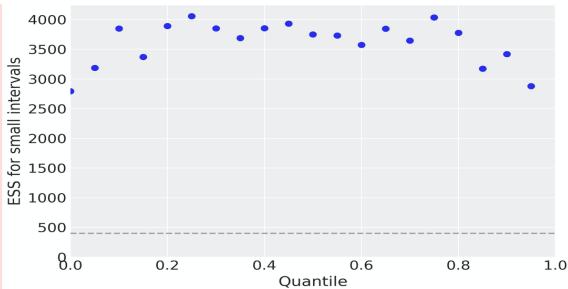
각 계층을 정규분포로 가정했으므로 데이터 스케일 변환은 파워 트랜스포메이션(power transformation)을 활용하였다. 파워 트랜스포메이션은 데이터를 정규분포 형태로 변환하기 위한 비율전환(scaling) 방법이다. Box-Cox transform(Sakia., 1992)과 달리 여-존슨 변환(Yeo-Johnson transform)은 음수의 범위까지 정규분포화 대상에 포함시킬 수 있어 널리 사용된다(Weisberg., 2001). <그림 2-17>은 일반고장 데이터를 여-존슨 변환한 것이다. 변환 후의 Shapiro-wilk test(Razali and Wah., 2011) p value 값은 0.05 이하이다. 귀무가설(H_0)을 기각하지 못하므로 정규분포를 따른다고 할 수 없다. 베이지안 통계에서 데이터를 정규화하는 이유는 일반적인 모수 통계와 다르다. 식(1)의 정규분포 가정들은 모두 사전분포이다. 베이지안 추론의 사전 분포는 분석가의 믿음을 반영한다. 데이터가 쌓일수록 비율전환 결과는 정규분포를 따를 것이라는 믿음을 반영한 것이다. 베이지안 추정에서 사전분포는 데이터를 효과적으로 탐색하기 위한 공간을 사전에 정의하는 것이다. 베이지안 추정은 일반적으로 많은 양의 데이터를 기반으로 한다. 사전분포의 영향력은 데이터의 양에 따라 축소되기 때문이다(Efron et al., 2001; Jiang and Zhang, 2010; Wipf and Rao, 2007). 데이터의 양이 충분하다면 사전분포가 부적절한 경우에도 적절한 사후분포가 도출된다(Bolstad and Curran, 2007; Gelman et al., 2013). 실증적 베이지안 추정

(Empirical Bayesian inference)에서 데이터의 형태를 확인하고 유사한 수준의 약한 사전분포를 설정하는 이유는 데이터에 맞춰 사후공간이 축소되기 때문이다(Zhang and Long, 2010; Gelman et al., 2013). 본 연구의 데이터는 충분하다고 할 수 없으나 사전분포로 인해 추정에 문제가 생길 정도는 아니다. 따라서 <그림 2-17> 정도의 데이터 변환으로 사후분포 모수 추정에 문제가 발생하지 않는다.

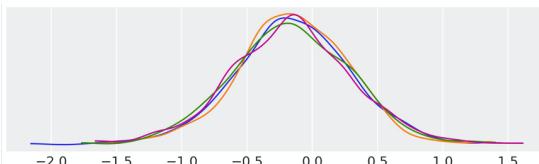
식(1)을 Stan을 활용하여 프로그래밍하고 HMC 샘플링을 수행하였다. Stan의 진단(dianose)기능을 활용하여 샘플링 결과를 확인하였다.



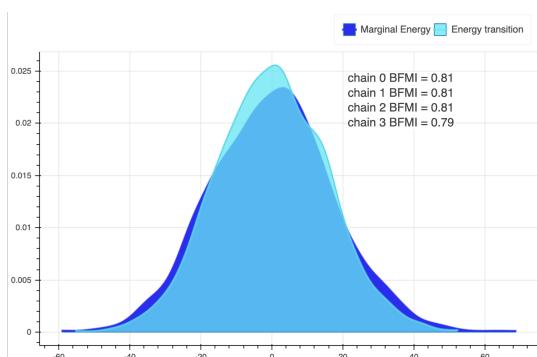
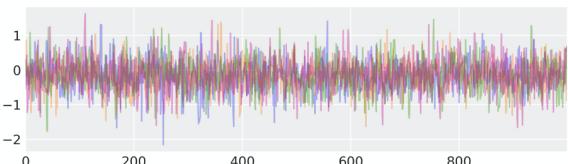
<그림 2-18> HMC 샘플링 종합진단 결과



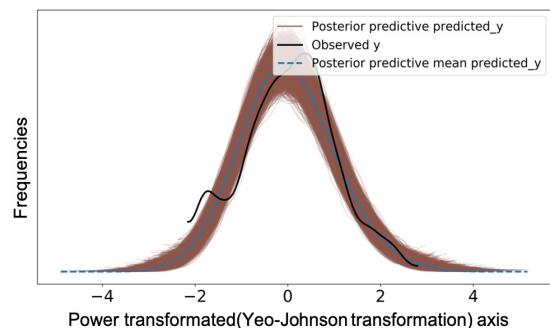
<그림 2-19> $\bar{\alpha}_e$ 의 ESS 진단



<그림 2-20> $\bar{\alpha}_e$ 의 trace plot과 커널 밀도



<그림 2-21> $\bar{\alpha}_e$ 의 BFMI



<그림 2-22> 사후예측분포 진단

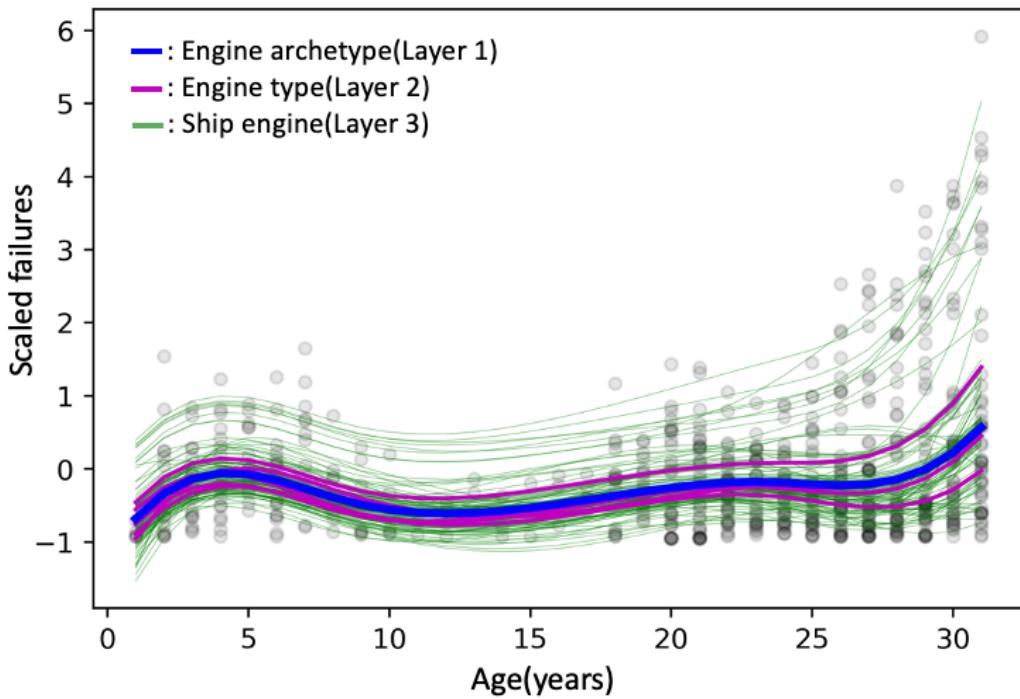
<그림 2-18>에서 <그림 2-22>는 베이지안 통계 진단 패키지 arviz를 통해 확인한 Stan 모델의 진단 결과이다. <그림 2-18>은 종합적인 HMC 수렴 결과를 요약한다. 진단내용은 4가지로 구성된다. 샘플러의 발산(divergence) 진단결과 이상없고, 세부

결과는 <그림 2-20>과 같다. $\bar{\alpha}_e$ 는 계층형 모델의 최상위층(해군 함정 추진용 디젤엔진 전체의 특징) 정규분포의 평균이다. <그림 2-20>의 좌측은 사후분포의 커널밀도(Kernel density)이다. HMC 4개의 체인을 고정값(default)으로 샘플링된다. 4개의 체인이 모두 정규분포 형태를 보임을 확인할 수 있다. 우측 그림은 trace plot이며 샘플링 횟수가 증가하여도 $-1 \sim 1$ 사이를 크게 넘지 않는 범위에서 수렴하고 있음을 시각적으로 확인할 수 있다. 진단 요약의 두 번째 항목은 BFMI(Bayesian fraction of missing information)이며 <그림 2-21>과 같이 시각화 되었다. BFMI는 HMC 체인이 사후공간을 효과적으로 탐색했는지 진단한다. Stan에서는 BFMI 값이 0.2 이하이면 모델의 모수를 재검토하라고 추천한다. 일반고장함수 모델의 체인들은 모두 기준을 만족하였다. 세 번째 진단항목은 ESS(Effective sample size)이며 <그림 2-19>와 같다. ESS는 HMC 샘플링 결과 유의미하다고 판단되는 샘플의 수를 나타내며 Stan은 체인당 100개 이상의 샘플을 추천한다. 연구모델의 ESS는 400(4개의 체인이므로 400이 기준이 된다)을 넘어 기준을 만족한다. R-hat은 체인과 샘플값들간의 분산을 진단한다. Stan은 1.1이하를 권장하며, 모든 모수들의 진단결과 이상 없음을 알 수 있다. <그림 2-22>는 사후예측분포(Posterior predictive check)이다. 사후예측분포는 사후분포에서 다시 샘플링을 수행하여 데이터가 사후분포의 범위에 포함되는지 확인한다. 관측 데이터는 검정색으로 표시되었다. 여-존슨 변환된 사전분포에서 샘플링된 사후분포는 정규분포의 형태를 보이고 있으며, 사후분포에서 샘플링된 값들의 범위 내에 관측데이터의 대부분이 포함된다. 각 진단 방법에 대한 더 자세한 설명은 Betancourt(2017)에서 확인할 수 있다.

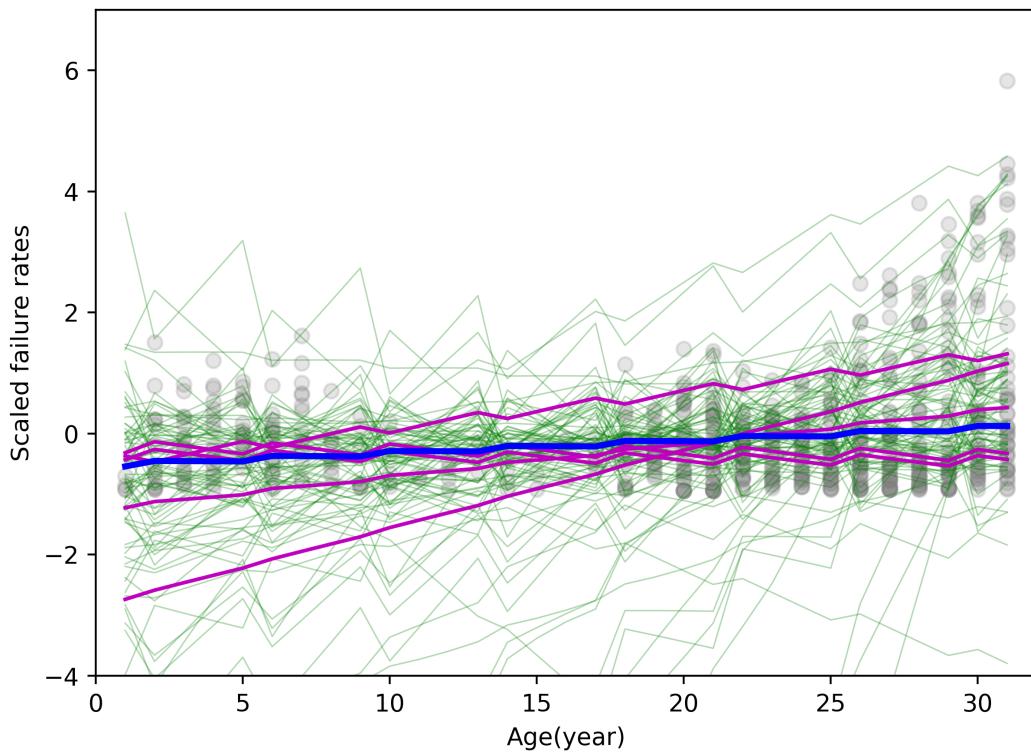
3. 일반고장함수 추정 결과

HMC 샘플링을 통해 추정된 일반고장함수는 <그림 2-23>과 같다. 파랑색 선은 함정 엔진 전체에 대한 고장함수(Layer1)이다. 자주색은 5개의 엔진 타입(Layer2)의 고장함수들이다. 초록색은 99척의 각각의(Layer3) 고장함수들이다. 배경의 점들은 고장함수 도출에 사용된 데이터들이다. 일반고장함수는 육조모양과 유사하다. 수명 1 ~ 5년은 육조형태와 다르다. 이는 확보 가능한 데이터의 범위와 관련있다. 함정 건조 초반에는 대부분의 고장을 조선소나 장비 제작사의 하자수리기간에 포함된다. 하자정비는 군에서 별도로 세부적인 정비내용을 보관하지 않으며 조선소에서 정비결과를 제공할 의무도 없다. 경험적으로 함정 인수 초반에 발생하는 많은 하자건수를 고려한다면 긴급고장함수와 유사하게 육조형태를 보일 것이다.

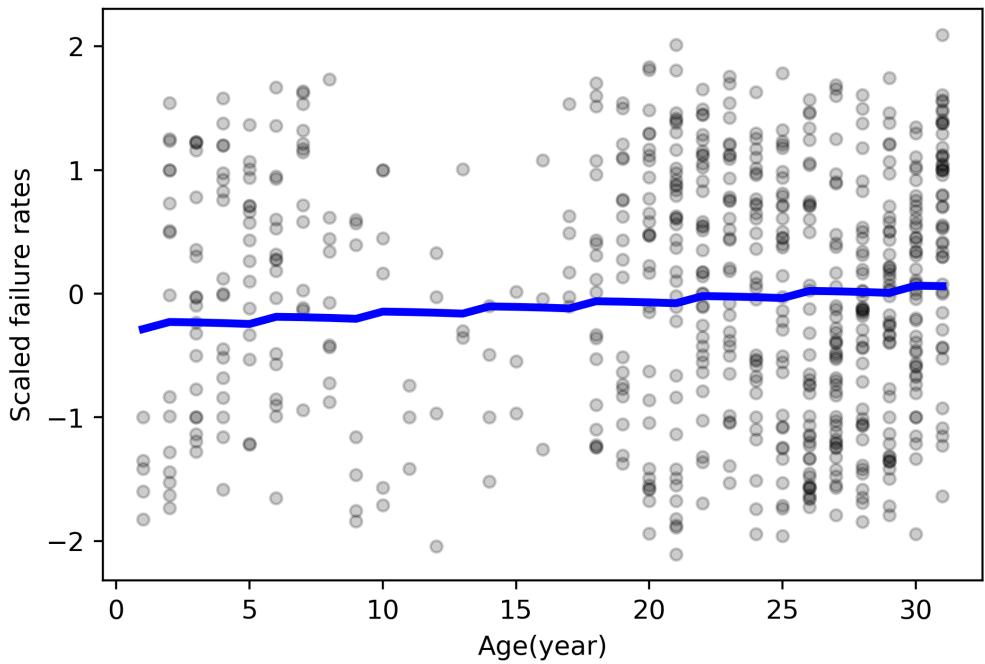
비교모델인 G-prophet, Prophet, ARIMA의 적합결과는 각각 <그림 2-24>, <그림



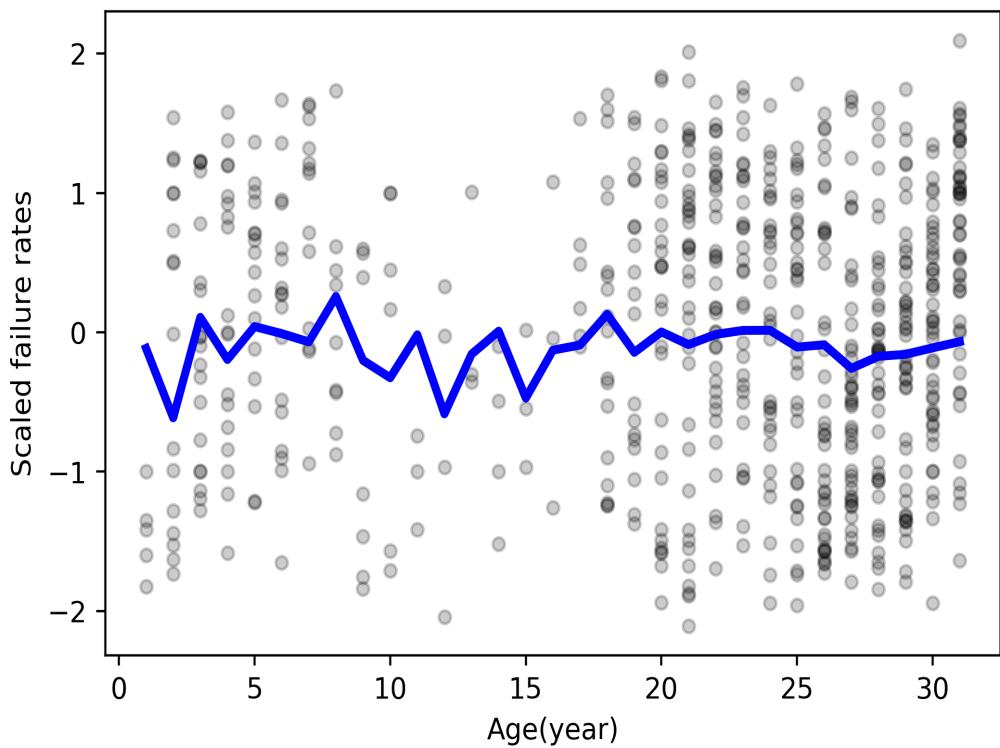
<그림 2-23> 일반고장함수



<그림 2-24> G-prophet



<그림 2-25> Prophet



<그림 2-26> ARIMA

2-25>, <그림 2-26>과 같다. Prophet과 ARIMA는 데이터가 비균일성을 보이는 경우 적합이 불가하다. 때문에 총수명의 고장함수 추정에는 Layer1의 데이터만 적용 가능하다. G-prophet은 Prophet을 전역 최적화 가능하도록 개선한 형태이다. 따라서 모든 함정의 고장함수가 추정되었다. 공통적으로 비교모델들은 육조형태를 보이지 않고 선형 주기성과 변동성 적합에 초점이 맞춰져있다. Prophet과 ARIMA는 추세와 주기 특성 추출에 많은 양의 데이터를 필요로 하기 때문이다. ARIMA는 특히 주기성을 탐색하지 못하고 이동평균 기능만이 활용되었다.

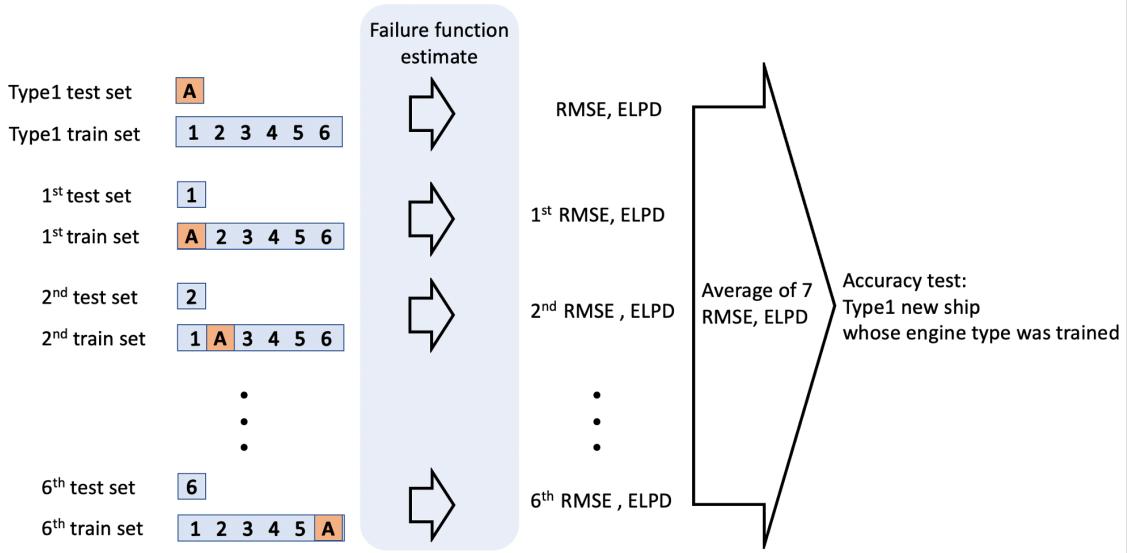
4. 일반고장함수 비교 분석

Layer1의 정확도 측정결과는 <표 2-3>과 같다. 계층모델은 총수명간의 고장량 변화와 각 계층간의 정보 공유로 정확도가 가장 좋았다(RMSE가 낮을수록, ELPD가 높을수록 정확한 모델이다). G-prophet은 전역 최적화를 통한 계층간의 정보공유가 가능하여 Prophet보다 성능이 좋았다. 계층모델, G-prophet, Prophet이 추정결과의 분산을 가지는 반면 ARIMA는 상수값의 결과 추정으로 분산이 0이다. ARIMA는 주변공간(Marginal space)을 측정할 수 없으므로 ELPD 산출이 불가능하다.

<표 2-3> 일반고장함수(Layer1) 정확도 비교

	Hierarchical Bayesian model	G-prophet	Prophet	ARIMA
RMSE	0.9475	1.0068	1.0395	0.9553
ELPD	-0.6307	-1.2185	-1.2506	-

고장함수는 다양하게 활용 가능하다. 함정 개별 고장함수는 해당 함정의 잔여 수명간 고장 예측에 활용될 수 있다. 수리부속의 필요량이나 정비량을 미리 산출할 수 있다. 함정 타입별 고장함수는 해당 타입 함정들의 평균적인 고장량을 의미한다. 동시에 신규함정 도입시 활용 가능하다. type1의 함정이 신규 건조된다고 가정하자. type1의 고장함수는 도출되어있다. 신규함정의 건조과정에 이루어지는 ILS(종합군수지원, Integrated logistics support)에서 총수명간 소요되는 정비량과 예상 수리부속 예산을 가늠할 수 있다. 함정 엔진 전체의 고장함수도 유사하게 활용가능하다. 전체 고장함수는 실적함이 없는 신규 함정의 도입시 정비량과 수리부속 예산 책정 등에 활용 가능하다. 해군은 신규함정 도입시 실적함이 있는 경우 기존 함정들의 고장 기록이나



<그림 2-27> 신규함정 도입 상황을 고려한 Cross-validation

정비기록을 참고한다. 실적함이 없는 경우에는 유사 목적의 기준 실적함 기록을 참고하여 ILS 계획을 세운다. 그런데 본 절의 마지막에는 실적함이 없는 경우 유사 목적 함정의 기록을 참고하면 안된다는 분석 결과를 도출한다.

신규함정이 도입되는 경우의 분석을 위해서 Cross-validation 기법을 <그림 2-27>과 같이 적용하였다. <그림 2-27>은 type1의 고장함수를 이용하여 type1에 신규함정이 도입된다는 상황을 가정한 Cross-validation이다. 성능 테스트용 함정을 한척 정하고 전체 데이터에서 제거한다. 예를 들어 99척의 함정 중 1번함을 테스트 데이터로 활용한다면 나머지 98척의 데이터로 모델을 훈련하고 1번함의 고장 데이터로 정확도를 측정한다. 같은 방법으로 1 ~ 99번 함정을 하나씩 제외하고 정확도를 측정할 수 있다. Cross-validation 실험 상황은 두 가지로 구분된다. 첫 번째는 실적함이 있는 경우의 신규함정 정확도 예측이다. type1 1번함이 신규함이라고 가정할 때 1번함을 제외한 98척의 함정으로 모델을 구축하여 도출된 type1 고장함수와 1번함의 정확도를 비교한다. 두 번째는 실적함이 없는 경우의 신규함정 정확도 예측이다. 99척의 함정으로 구축된 모델의 전체함정 고장함수와 데이터 셋에 없는 함정의 고장 데이터의 정확도를 비교한다. 비교모델들도 같은 상황을 가정하여 성능을 비교하였다. 첫 번째 상황의 결과는 <표 2-4>이고, 두 번째 상황의 실험 결과는 <표 2-5>와 같다.

type5를 제외하면 모두 계층형 모델의 성능이 가장 좋았다. type5는 전체 탑입들 중 데이터의 수가 가장 적다. 따라서 한척의 데이터가 테스트 데이터로 제거되었을 때 학습은 다른 탑입 함정들의 영향을 많이 받았다고 할 수 있다. 따라서 더 많은 데이

<표 2-4> 실적함이 있는 상황(Layer2 고장함수 활용 Layer3 예측)의 정확도 비교

Engine type	RMSE(ELPD)			
	Hierarchical Bayesian model	G-prophet	Prophet	ARIMA
Type 1	0.9374 (-0.8431)	0.9959 (-2.5303)	0.9622 (-2.4390)	1.1886 -
Type 2	0.9884 (-0.8054)	1.0073 (-3.1071)	0.9887 (-2.4391)	1.1151 -
Type 3	0.9731 (-1.0025)	0.9988 (-2.4545)	0.9996 (-2.5149)	1.0471 -
Type 4	0.9658 (-1.0218)	1.0133 (-3.5159)	1.0594 (-3.0400)	1.0342 -
Type 5	1.0131 (-0.8532)	0.9984 (-1.7807)	1.2092 (-2.8526)	1.0962 -

<표 2-5> 실적함이 없는 상황(Layer1 고장함수 활용 Layer3 예측)의 정확도 비교

Engine type	RMSE(ELPD)			
	Hierarchical Bayesian model	G-prophet	Prophet	ARIMA
New type 1	0.9620 (-2.9535)	1.0155 (-4.8511)	1.0155 (-4.8511)	1.1078 -
New type 2	0.7782 (-2.3136)	1.0629 (-5.1454)	1.0629 (-5.1454)	0.7961 -
New type 3	1.1069 (-3.1876)	1.0563 (-5.1652)	1.0563 (-5.1652)	1.0263 -
New type 4	0.8546 (-2.5311)	1.0352 (-5.0259)	1.0352 (-5.0259)	1.0031 -
New type 5	0.9128 (-2.2613)	1.0064 (-4.8539)	1.0064 (-4.8539)	0.9991 -

터를 통한 확인이 필요하다. 전체적으로 계층형 모델은 실적함이 있는 경우의 예측에 유용하게 활용될 수 있다고 판단된다. 해군은 장기적으로 동일한 함정을 배치형식으로 여러척 도입한다. 이 경우 해당 타입의 고장함수를 활용하여 ILS 의사결정에 도움

을 받을 수 있다.

<표 2-5>는 훈련 데이터 셋에 없는 5척의 테스트 데이터를 활용하여 정확도를 측정한 것이다. New type 3을 제외한 모든 경우에 계층형 모델가 가장 정확했다. G-prophet은 Prophet과 결과가 같다. G-prophet은 실적함정의 분산을 활용하여 전역 최적화된 형태이므로 실적함정이 없는 경우 Prophet과 같은 결과를 산출한다. 해군은 실적함이 없는 신규함정 도입시에도 계층모델을 활용하면 정확도 높은 예측이 가능하다.

해군은 노후된 함정을 신규 함정으로 지속적으로 교체한다. 목적에 맞는 함정을 도입하기 때문에 최신화 되었으나 함정의 제원이나 사이즈 등은 유사하다. 이 경우 해군은 과거에 유사한 목적으로 활용하던 함정의 데이터를 활용하여 신규 도입함정의 ILS 의사결정을 한다. 일반고장함수 추정에 포함된 5개의 함정 엔진 type에는 노후 함정과 그 함정을 대체하는 함정의 type이 포함되어 있다. 함정 타입별 고장함수의 유사도 측정을 위해 함수간 유클리디안 거리(Euclidean distance)를 측정하였다.

유클리디안 거리가 가까울수록 고장함수가 유사하다고 할 수 있다. 함정 타입별 고장함수를 도입시기 기준으로 신형(Young), 중간(Middle), 구형(Old)로 구분하였다. 총

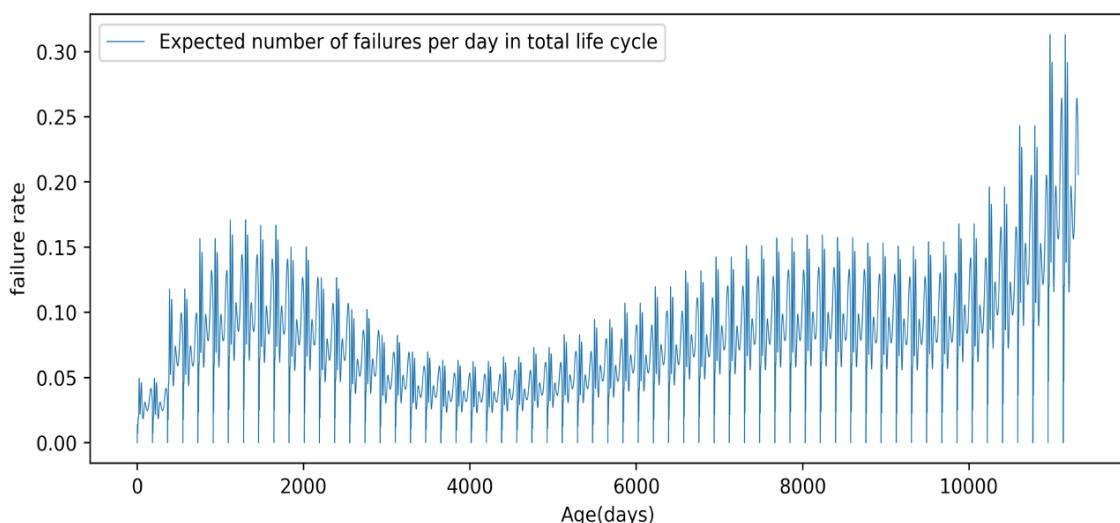
<표 2-6> 함정 타입별 고장함수간 거리(Euclidean distance)

Engine type		Euclidean distance
Young vs Middle	5 vs 1	0.0425
Young vs Young	5 vs 4	0.0461
Young vs Middle	4 vs 1	0.0466
Middle vs Old	1 vs 3	0.1057
Young vs Old	5 vs 2	0.1076
Middle vs Old	1 vs 2	0.1090
Young vs Old	5 vs 3	0.1237
Young vs Old	4 vs 2	0.1244
Young vs Old	4 vs 3	0.1278
Old vs Old	2 vs 3	0.1836

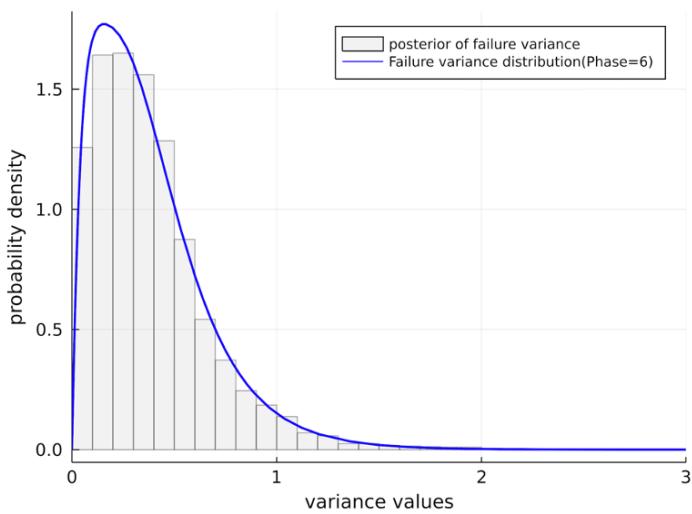
5개의 타입이므로 10가지 경우의 수를 <표 2-6>과 같이 비교하였다. type 4, 5는 비교적 신형 함정이고, type 2, 3은 구형함정이다. type 1은 총수명 기준 중간 나이에 해당한다. 고장함수간 거리가 짧은 순으로 정렬하였다. 대체로 도입시기가 유사할수록 고장함수간의 거리가 짧았다. type4는 type2를 대체하기 위한 신규함정이다. 해군의 ILS 검토방식에 따르면 type4의 신규 건조시 type2의 데이터를 참고하였을 것이다. 그러나, 실제로 type4와 유사한 데이터는 type5, 1에서 얻을 수 있다. 즉 해군은 신규함정 건조시 유사 실적함이 아닌 유사 도입함정의 데이터를 참고해야한다. AHP(Analytic hierarchy process)를 활용한 분석에서 도입년도가 유사한 함정의 정비경향이 유사하다는 연구가 있었다(Yoo et al., 2019).

5. 일단위 일반고장함수 도출

계층모델로 추정된 일반고장함수는 연단위의 이산형 추정결과이다. 긴급고장함수는 일단위의 연속형 함수이다. 본 연구의 목적은 시스템 다이나믹스를 활용한 해군 시스템의 정비분야 구현이다. 시뮬레이션의 시간단위(time step) 통일을 위해 연단위의 일반고장함수를 일단위로 변환해야한다. 긴급고장함수 추정시 반년 단위의 고장확률은 함정의 임무기간과 정박기간이 반영되어 적합되었다. 일반고장도 긴급고장과 같이 임무와 정박의 패턴을 반영하여 내삽(interpolation)할 수 있다. 긴급고장함수에서 도출한 <그림 2-10>의 연단위 확률을 일반고장함수에 <그림 2-28>과 같이 내삽하였다. 내삽방법은 긴급고장함수와 동일하다.



<그림 2-28> 일단위 일반고장함수



<그림 2-29> 일반고장함수의 표준편차 분포 적합

식(1)에서 일반고장함수는 정규분포로 가정되어 표준편차를 가진다. 표준편차는 HMC 샘플링을 통해 사후분포로 추정되어 있다. <그림 2-23>의 일반고장함수는 정규분포의 평균값만을 활용하여 도식한 결과이다. 일반고장함수의 분산을 적용하기 위해서는 표준편차 사후분포를 활용해야한다. <그림 2-29>는 전체 엔진 고장함수 표준편차 (σ_y)의 사후분포이다. 식(1)에서 σ_y 는 모수 1의 지수분포로 가정

되었으나 데이터의 적합과 계층간 정보 공유를 통해 감마분포와 유사한 형태로 적합되었다. 보다 정확한 분포 도출을 위해서는 감마분포 가정의 적합보다 단계형 분포를 활용하는 것이 적합하다. <그림 2-29>는 감마형태의 표준편차 사후분포를 단계형 분포로 적합한 것이다. 단계형 분포를 활용한 모델 구축은 향후 데이터 축적으로 베이지안 모델의 모수가 변경되어도 phase의 큰 변화 없이 활용 가능하다는 장점이 있다.

제 3장 약전정비 정책

해군의 주기적인 함정 운용은 작전 상황에 따라 변동되지만 4.5개월 운용과 1.5개월 정비를 크게 벗어나지 않는다. 추진용 디젤엔진의 매뉴얼에는 최소 300시간 장비를 운용 후 정비를 수행하는 것을 최소한의 정비로 추천한다. 해군은 과거에 300시간 장비 운용에 걸리는 시간이 평균적으로 4.5개월이라는 경험을 바탕으로 4.5개월 운용 후 1.5개월 정비를 수행하여 반년의 운용주기를 구축했다.

2장에서 추정한 일반고장함수의 형태는 초반 5년을 제외하면 육조모양을 맑았다. 수명 초반과 후반에는 고장이 많이 발생하고 수명 중반에는 고장이 상대적으로 적게 발생한다. 일반고장은 함정에 축적되고 계획정비 시 해소된다. 일정한 간격으로 정비를 수행한다면 수명 초반과 후반에는 일반고장이 많이 축적된 상태로 정비부대에 입고된다. 반면 수명 중반에는 일반고장이 적게 축적된 상태이다. 함정의 입장에서 일반고장이 많이 축적된 상태로 작전을 수행하면 장비의 최대성능 발휘에 문제가 발생할 수 있으므로 위험을 감수해야한다. 정비부대 입장에서 수명 초반이나 후반의 함정이 동시에 입고된다면 정비업무량이 급격하게 증가할 수 있다. 계획정비 기간이 1.5개월로 고정되어 있기 때문에 특히 수명후반의 함정이 동시 입고되는 경우 많은 업무부하를 감당해야한다. <그림 2-14>의 데이터에서 확인할 수 있듯이 해군은 과거에 일시적으로 많은 함정을 건조하였고 현재 그 함정들은 노후함정이 되었다. 실제 상황에서 노후 함정들이 동시에 입고되는 상황이 많다. 결국 일정 주기로 수행하는 계획정비는 비효율적이다. 고장함수를 기반으로 적정수준의 일반고장이 축적되었을 때 정비를 수행한다면 함정에 누적되는 일반고장량을 줄이고, 정비부대도 과도한 업무를 피할 수 있다.

3장에서는 일반고장함수를 적용한 약전정비정책 2가지를 제안한다. 첫 번째는 주기적으로 정비를 수행하면서 일반고장함수를 적용할 수 있는 방법이다. 두 번째는 일반고장함수에 따라 일정수준 일반고장이 함정에 누적되었을 때 정비를 수행하는 방법이다. 스마트 네이비의 최종 목표인 상태기반정비는 함정 상태가 일정 수준 악화되었을 때 늦기 전에 정비를 수행하는 개념으로 두 번째 제안 정비정책과 유사하다. 정비정책들의 현실성을 증명하기 위해 시스템 다이나믹스를 활용한 여러 척의 함정과 한 개소의 정비부대가 설치된 함대 구조를 구축하여 시뮬레이션한다. 정비부대에는 2대의 상가대가 마련되어 있다. 함정들은 상가대를 공유하며 정비를 수행하는 과정에서 먼저 정비중인 함정으로 인해 입고되지 못하고 대기해야하는 상황이 발생하기도 한다. 대기중인 함정은 추가적인 작전임무를 수행하며 그동안 일반고장은 계속 축적된다.

제 1절 고장함수의 약점정비 적용 효과

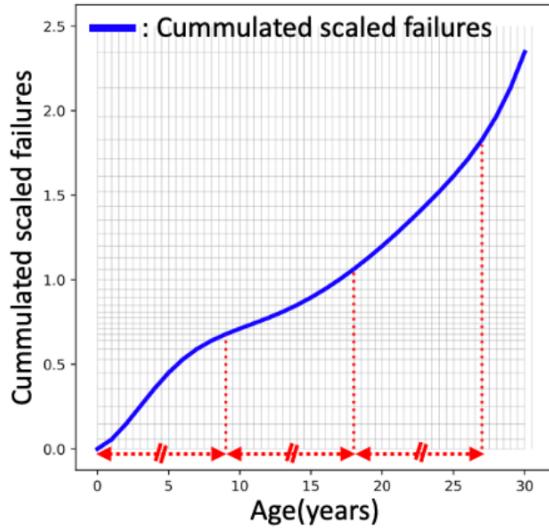
본 연구에서는 일정한 주기로 수행하는 현 해군의 정비정책을 주기 고정형 정비(PFM, Period fixed maintenance) 라고 명명한다. PFM은 0.5년 주기로 일정하게 정비로 수행되기 때문에 일정이나 예산관리 측면에서 편리하다. 일반고장함수는 육조 형태와 유사하므로 PFM의 매번 정비시 수행하는 정비량은 달라진다. 노후 함정의 경우 작전중에 일반고장에 노출되는 정도가 심해져 장비 최대성능발휘에 문제가 발생할 수 있다. 일반고장과 긴급고장의 상관성에 대해 본 연구에서는 심도있게 분석하지 않는다. 다만, <그림 2-12>와 <그림 2-13>에서 총수명 1 ~ 5년에 해당하는 부분을 제외하면 일반고장함수와 긴급고장함수의 패턴이 유사하다는 점은 주목할 만하다. 일반고장이 많이 발생할 때 긴급고장도 많이 발생하기 때문이다. 축적된 일반고장이 긴급고장으로 이어지는지에 대해서는 추후 심도있는 분석이 필요하다. 본 연구에서는 일반고장과 긴급고장의 선형적 관계는 확인하지만, 수학적 관계정립은 하지 않는다(6장에서 자세히 다룬다). 본 장에서는 고장함수가 전시하는 고장량에만 주목한다. 정비기간과 운용기간이 일정할 때 수명 후반의 함정은 고장에 많이 노출된다. 수명 후반 함정의 정비횟수를 늘여 운용기간을 줄여 고장에 노출되는 정도를 줄일 수 있다. 작전을 수행하지 않는 기간이 길수록 고장은 줄어든다. 총수명동안 계획정비 수행 시점을 유동적으로 변화시켜 고장에 노출되는 정도를 줄일 수 있다.

계획정비 간격을 변화시키는 방법으로 본 장에서는 두 가지 정비정책을 다룬다. 첫 번째는 총분해정비 시점을 유동적으로 변경하는 정책이다. 해군은 약 9년 주기로 총수명간 3회의 총분해정비를 수행한다. 총분해정비 시점을 고장함수 기준으로 분할하고 분할된 각 구간에서 최적화된 PFM을 수행하는 방법이다. 계획정비 간격을 최적화 한다는 점에서 간격 최적화 정비(IOM, Interval optimization maintenance) 정책이라고 명명한다. 두 번째는 총분해정비를 고려하지 않고 총수명 전체구간에 걸쳐 일반고장 누적값을 평준화하는 정책이다. 일정 수준의 고장량을 기준으로 정비를 수행한다는 점에서 고장량 고정형 정비(FFM, Failure rate fixed maintenance) 정책이라고 명명한다.

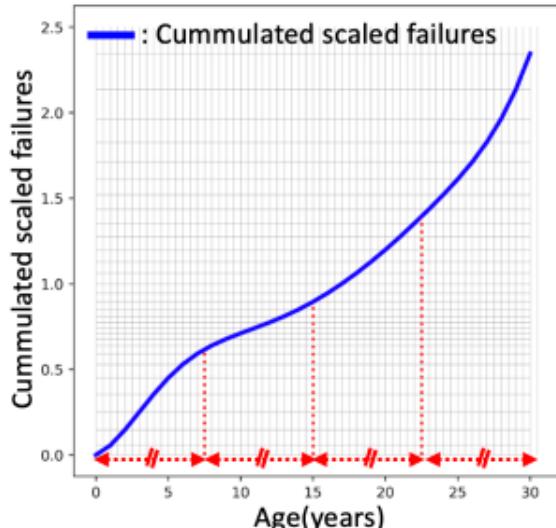
간격 최적화 정비(IOM)에 대한 보다 자세한 내용은 Choi. et al.(2020)을 참고할 수 있고, 고장량 고정형 정비(FFM)에 대한 내용은 Choi. et al.(2021)을 참고할 수 있다. 본 장에서는 긴급고장함수는 고려하지 않는다. 신규 정비정책을 결정함에 있어 긴급고장을 고려하지 않기 때문이다. 긴급고장함수를 고려한 실제 해군 시스템의 구현과 효과 분석은 5장부터 다룬다.

1. 간격 최적화 정비(IOM) 모델 구축

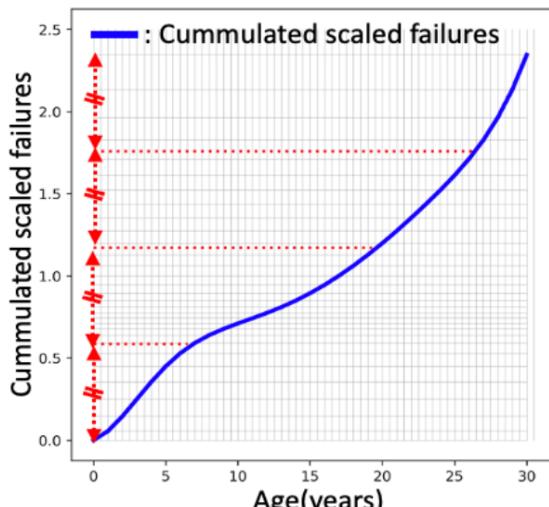
IOM(Interval optimization maintenance)은 총분해정비 시점을 결정하고 총분해정비와 총분해정비 사이의 구간에서 주기 고정형 정비(PFM)을 수행하는 정비 정책이다. 본 장에서는 총분해시점을 기준으로 3가지 정책을 비교하였다.



<그림 3-1> NP(Naval policy) 모델



<그림 3-2> DP(Divided by period) 모델



<그림 3-3> DF(Divided by failure) 모델

<그림 3-1>에서 <그림 3-3>은 총분해정비 구분 시점을 달리한 3가지 간격최적화 모델이다. 파랑색 선은 비율조정된 일반고장함수의 전체엔진 고장함수의 연차별 누적값이다. 전체엔진 고장함수는 함정이나 함정 탑재과 무관하게 해군 전투함 추진용 디젤엔진 전체를 대표하므로 3장 이하 본 연구의 분석 대상으로 활용된다. <그림 3-1>은 현재 해군의 총분해정비 정책이다. 3번의 총분해정비 시점은 9년 간격이다. 9, 18, 27년차에 총분해정비를 수행한다. <그림 3-2>는 총수명기간을 동일하게 4등분하여 각 분할 지점에서 총분해정비를 수행하는 모델이다. 총분해정비 시점은 7.5, 15, 22.5년이다. <그림 3-3>은 총수명간 누적된 일반고장량을 동일하게 4등분한 모델이다. 총분해정비 시점은 6.9, 19.6, 26.4년이다. 3개 모델은 모두 총분해정비 사이 구간에서 일반고장량에 따라 PFM의 주기를 최적화한다. 각 정비정

간을 동일하게 4등분하여 각 분할 지점에서 총분해정비를 수행하는 모델이다. 총분해정비 시점은 7.5, 15, 22.5년이다. <그림 3-3>은 총수명간 누적된 일반고장량을 동일하게 4등분한 모델이다. 총분해정비 시점은 6.9, 19.6, 26.4년이다. 3개 모델은 모두 총분해정비 사이 구간에서 일반고장량에 따라 PFM의 주기를 최적화한다. 각 정비정

<표 3-1> 간격 최적화 정비(IOM) 모델 구분 기준

Interval optimization maintenance model	OVHL division criterion	4-divided intervals(year)			
		1st	2nd	3rd	4th
NP (Naval policy)	Manufacturer's manual	9	9	9	3
DP (Divided by period)	Equal 4 division of life cycle periods	7.5	7.5	7.5	7.5
DF (Divided by failure)	Equal 4 division of total failure rate	6.9	12.7	6.8	3.6

책의 총분해정비 구분 기준과 각 구간의 길이는 <표 3-1>과 같다.

<그림 3-1>에서 <그림 3-3>의 누적 고장량은 내삽되지 않은 <그림 2-23>의 파랑색 일반고장함수를 연차별로 누적한 것이다. 일반고장함수는 이산형 함수이다. 연중 정비 최적화 지점을 탐색을 위해 연도별 고장 기댓값 사이를 선형회귀(Piecewise linear regression)로 연결하였다. 일반고장함수를 누적한 함수를 $F(x)$ 라고 정의하였다. $F(x) - F(x - 1)$ 는 지점 $x - 1$ 에서 x 사이 기간의 고장량이 된다(x 는 실수이다). 총분해정비 3회를 기준으로 총수명은 4개 구간으로 분할된다. 분할된 구간의 집합을 $I = \{1, 2, 3, 4\}$ 라고 하자. 각 구간의 시작과 끝 지점은 총분해정비 수행지점이다. 총분해정비 시작지점을 a_i ($\forall i \in I$), $a_0 = 0$ 라 하면 $a_i - a_{(i-1)}$ 은 분할된 구간의 길이가 된다. x_i ($\forall i \in I$)가 구간 i 에서 수행한 계획정비 횟수일 때, $(a_i - a_{(i-1)}) / x_i$ 는 i 구간에서 수행하는 PFM의 정비 간격이 된다.

간격 최적화 정비는 i 구간에서의 고장량을 평준화하는 문제이다. 이는 구간들의 고장량들의 분산을 최소화하는 문제와 같다. 동시에 계획정비 횟수는 정수라는 제약 조건을 가진다. 문제와 제약조건을 고려하여 MINLP(Mixed integer non linear problem)을 활용 할 수 있다. MINLP는 비선형 함수에서 이산 변수들의 최적 조합 탐색 문제에 활용된다(Belotti et al., 2009; 2013). MINLP는 조각 선형회귀(Geißler et al., 2012)나 선형과 비선형의 혼합형태 등의 최적화(Bragalli et al., 2006; Floudas et al., 1989)에 활용된다. Choi. et al., (2019)는 팀의 인원수 균등화에 있어 인원수를 고려한 비선형 분산을 최소화하는데 MINLP를 활용하였다. IOM의 문제는 이와 유사한 상황이라고 할 수 있다. IOM 최적화 문제는 식(2)와 같다.

식(2)의 목적함수는 분할된 구간 i 들에서의 고장량 분산을 최소화하는 것이다. 총수명간 계획정비 횟수는 62회(31년 x 연2회 계획정비)이다. 총수명간 총 고장량은

2.3457이며 일반고장함수의 누적으로 산출할 수 있다. 62회의 계획정비시 수행하는 평균 정비량 $M = 0.0378$ ($2.3457/62$) 이다. 총수명간 계획정비 횟수는 62회이며, i 구간의 계획정비 횟수 x_i 는 음수가 될 수 없다는 비음조건이 제약조건으로 설정된다.

$$\begin{aligned} obj. MinZ &= \sum_i \sum_{j=1}^{x_i} (M - (F(a_{(i-1)} + (\frac{a_i - a_{(i-1)}}{x_i}) * j) \\ &\quad - F(a_{(i-1)} + (\frac{a_i - a_{(i-1)}}{x_i}) * (j-1)))^2 \\ s.t. \quad \sum_i x_i &= 62 \quad \forall i \in I \\ x_i &\geq 0 \quad \forall i \in I \end{aligned} \tag{식(2)}$$

I : 분할된 각 구간의 집합

M : 계획정비시의 평균 정비량

$F(x)$: 고장함수

a_i : 충분해정비 시작 시점

x_i : i -구간에서 실시한 계획정비 횟수

식(2)를 Python 프로그래밍으로 구현하여 3가지 모델의 구간별 최적 계획정비 횟수를 산출하였다.

2. 고장량 고정형 정비(IOM) 정책 효과 분석

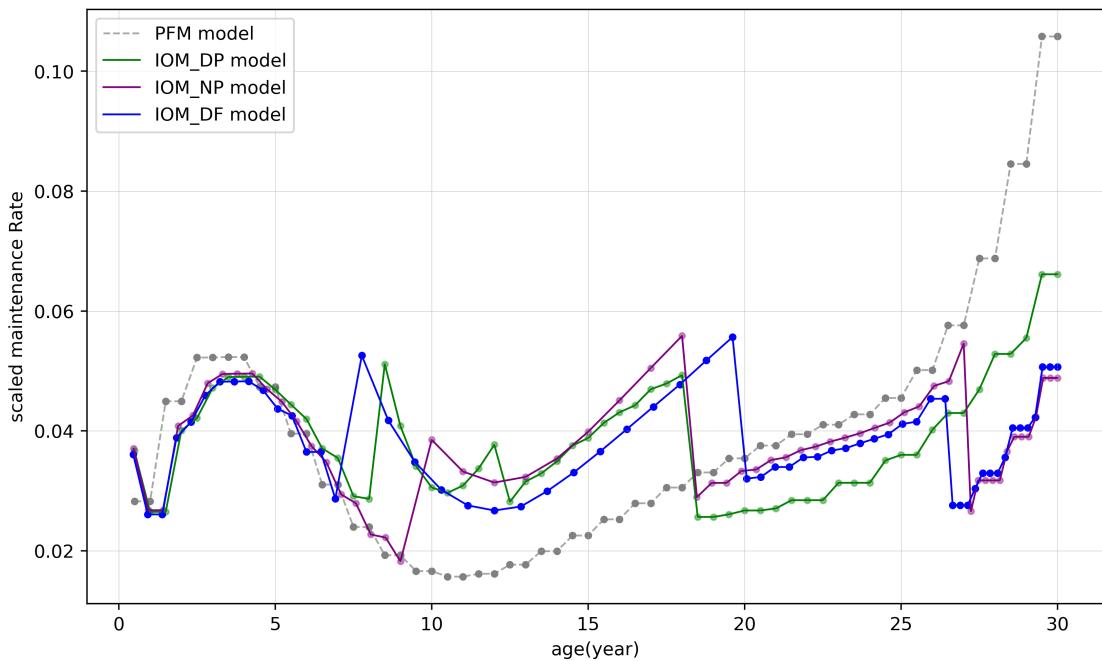
최적화 결과 모델들의 계획정비 간격은 <표 3-2>와 같았다. NP 모델의 첫 번째 9년에는 19회의 계획정비를 수행하는 것이 적절했고, 구간내에서의 PFM 간격은 0.4737년(약 5.7개월) 이었다. 두 번째 9년의 기간 동안은 1년에 1회 계획정비를 하는 반면 마지막 3년의 구간 동안은 0.2308년(약 2.8개월)마다 정비하는 것이 적절했다. NP 모델은 현재 해군의 OVHL 간격을 유지하면서 구간별 계획정비 간격을 최적화 한 것이다. 일반고장함수는 총수명간 비선형적 고장발생을 보인다. 따라서 고장이 많이 발생하는 노후기간(마지막 3년)에는 약 2.8개월 간격의 정비를 수행하는 것이 적절하였다. 최적화 구간에는 계획정비 기간 1.5개월이 포함되어 있다. NP 모델의 마지막 2.8개월 기간 중 1.5개월은 계획정비 수행기간이 된다. 1.3개월간 작전 운용 후 1.5개월의 정비를 수행한다는 의미이다. 1.3개월의 운용기간은 현행 4.5개월 운용의 약 0.3배 수준이다. 해군은 노후함정에 대해 과소정비를 수행하고 있다. 한편 두 번째 구간의 고

<표 3-2> IOM 모델들의 계획정비 간격 최적화 결과

Interval optimization maintenance model	Intervals(year) / Frequency (Maintenance interval(year))			
	1st	2nd	3rd	4th
NP (Naval policy)	9 / 19 (0.4737)	9 / 9 (1)	9 / 19 (0.4737)	3 / 13 (0.2308)
DP (Divided by period)	7.5 / 16 (0.4688)	7.5 / 8 (0.9375)	7.5 / 12 (0.625)	7.5 / 24 (0.3125)
DF (Divided by failure)	6.9 / 15 (0.46)	12.7 / 15 (0.8467)	6.8 / 15 (0.4533)	3.6 / 15 (0.24)

장은 적으므로 연 1회 계획정비 하는 것으로 충분하다. 해군은 두 번째 구간에서 필요 수준의 2배의 과대 정비를 수행한다는 의미가 된다. DP와 DF 모델도 같은 방법으로 이해할 수 있다.

<그림 3-4>는 모델간 계획정비량을 비교한 것이다. 그래프의 각 점은 계획정비 수행 시점이다. 예를들어 마지막 계획정비시 PFM 모델(회색)은 약 0.105의 일반고장을 함



<그림 3-4> 모델간 계획정비량 비교

정에 축적하여 계획정비를 수행한다. DF 모델(파랑색)은 약 0.05의 일반고장을 축적하여 계획정비에 들어간다. 총수명간 계획정비 횟수는 모두 62회로 동일하다. IOM 모델들은 OVHL 시점마다 정비량이 크게 증가하거나 감소한다. 수명 중반 부분에서 PFM은 과대정비를 수행하지만 수명 후반 부분에서는 과소정비를 수행한다. PFM 모델의 수명 후반 부분의 일반고장 축적량은 IOM 모델들의 약 2배 이상에 달한다.

PFM 모델과 IOM 모델의 총수명간 평균 계획정비량($M = 0.0378$)은 동일하다. 계획정비 주기에 변화를 주는 것으로 안정적인 함정 운용이 가능하다. <표 3-3>은 함정에 축적되는 일반고장의 최대값과 계획정비시의 정비량(<그림 3-4> 그래프들의 각 점)의 편차를 비교한 것이다. PFM에 비해 IOM 모델들의 일반고장 최대 누적값이 작다. 이는 항해중 노출되는 일반고장의 정도가 상대적으로 작음을 의미한다. 작전 운용 안정성과 연관된다. 일반고장함수와 긴급고장함수의 패턴은 유사하였다. 긴급고장은 작전 수행일수가 많을수록 많이 노출된다. 일반고장에 노출되는 정도가 크다면 긴급고장에 노출되는 정도도 크다(6장에서 자세히 기술한다). PFM은 IOM에 비해 고장에 노출될 위험성도 높다. DF 모델은 일반고장의 최대값이 가장 작은 동시에 정비 편차도 가장 작다. 이는 모델들의 고장함수의 적용 정도와 연관이 있다. PFM은 고장함수가 전혀 적용되지 않은 정비정책이다. NP와 DP 모델은 총수명기간을 4분할하는 과정에 고장 함수가 개입되지 않았다. DF 모델은 4분할 기준부터 고장함수가 적용되어 있다. 총수명의 고장량을 기준으로 4분할하고 분할된 구간 내에서 PFM 주기를 최적화한다. 4개의 모델 중 가장 고장함수가 많이 적용된 모델이다.

모든 모델들의 총수명간 정비횟수는 동일하므로 계획정비 예산과 운용가용도가 동일하다. 계획정비 기간을 제외한 구간이 작전 운용 기간이기 때문이다. 동일한 조건에서 정비주기를 변경하는 것만으로 얻어지는 효과는 크다. <표 3-3>의 최대값과 편차를

<표 3-3> 모델의 성과 비교

Maintenance model	Max. Normal failures	Std. Maintenance rate
PFM	0.1058	0.0202
IOM	NP (Naval policy)	0.0661
	DP (Divided by period)	0.0559
	DF (Divided by failure)	0.0557
		0.0082

각각 작전 운용 안정성, 정비업무 안정성으로 볼 때, DF 모델은 PFM에 비해 최대 47% 안정적인 작전 운용이 가능하다. 정비업무는 약 62% 안정적으로 수행 가능하다.

본 절의 IOM에서는 총수명간 정비횟수가 동일하여 운용가용도가 모두 동일하다고 평가하였다. 긴급고장이 포함되면 결과가 달라진다. 긴급고장은 정박중에는 발생하지 않으므로 작전운용 일수가 많을수록 긴급고장에 많이 노출된다. PFM은 수명말기에도 동일하게 6개월 주기의 정비를 수행한다. DF모델은 수명말기 3.6년간 15회의 계획정비를 수행한다. 수명말기 기간의 작전운용 기간은 20.7개월((3.6*12)-(1.5*15))이다. PFM의 3.6년간 작전운용 기간은 32.7개월((3.6*12)-(1.5*7))이다. 수명말기에 PFM은 DF모델에 비해 1.58배 작전을 많이 수행한다. 수명말기의 높은 긴급고장 확률에 노출되는 일수가 많다. 긴급고장의 발생은 운용가용도와 정비예산에 영향을 미친다.

IOM은 고장함수를 활용하여 PFM의 주기를 재도출한 것이다. 일정한 주기로 계획정비를 수행하면 일정계획이나 예산편성이 편리하다는 장점이 있다. IOM은 주기적인 계획정비의 편의를 최대한 반영하면서 고장함수를 도입하는 정비정책이라고 할 수 있다.

상태기반정비는 정비계획이나 예산활용에 있어 IOM보다 더 큰 유연성을 요구한다. IOM의 총수명간 정비주기 변경은 3회(OVHL 시점)이나, 상태기반정비는 필요시 입고 이므로 정비간격이 유동적으로 변할 수 있다. 고장함수를 활용하여 상태기반정비의 효과를 시뮬레이션 할 수 있다. 고장함수는 총수명간 장비의 상태변화를 나타내는 것 이기 때문이다. 다음절에서는 고장함수가 나타내는 상태를 기반으로 정비 수행하는 모델을 구축하고 효과를 확인한다.

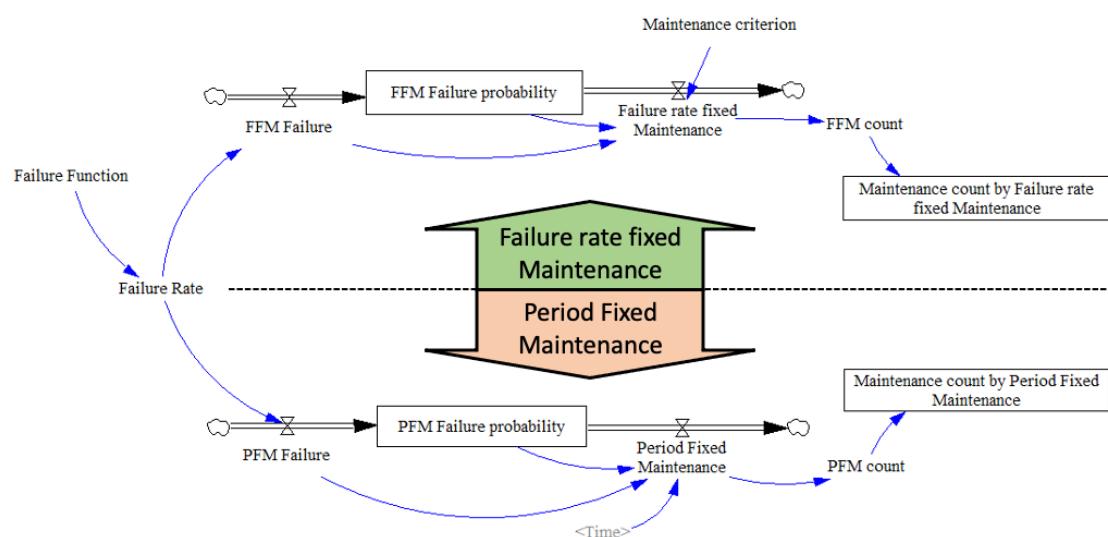
3. 고장량 고정형 정비(FFM) 모델 구축

정비일정 계획이나 정비예산 활용의 편의성은 주기 고정형 정비(PFM)의 장점인 반면, 상태기반정비에서는 제한된다. 상태기반정비에서는 장비의 상태에 따라 정비를 수행하므로 일정계획이 자주 변할 수 있기 때문이다. 일반고장함수는 총수명주기의 장비상태를 나타낸다. 일반고장함수에 따라 정비 수행시기를 설정하면 상태기반정비를 시뮬레이션할 수 있다. 본 절의 모델은 일반고장함수를 활용하여 정비 입고시기만을 고려하므로 고장량 고정형 정비(FFM, Failure rate fixed maintenance)라고 명명한다. FFM 모델의 정비기간은 45일로 고정되어 있다. 정비기간을 장비상태에 따라 유동적으로 설정할 수 있고(5장에서 자세히 다룬다) 실시간 센서 데이터를 모니터링 할 수 있다면 상태기반정비 시뮬레이션이 가능하다.

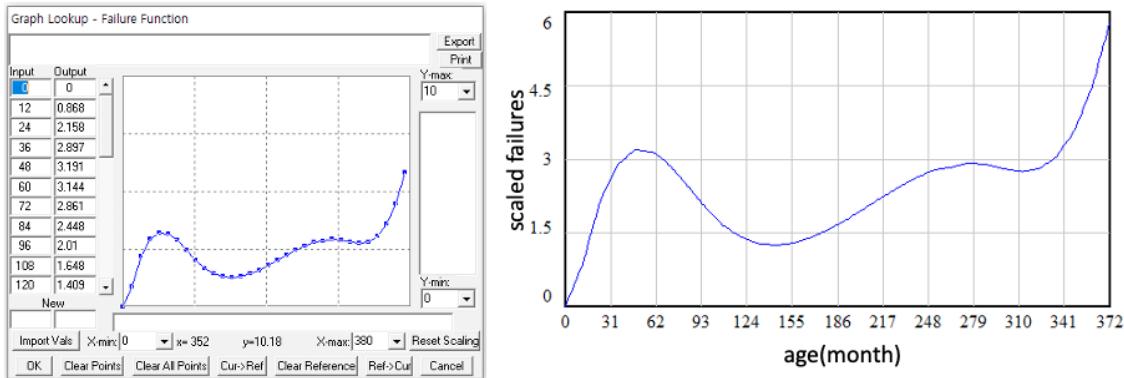
FFM은 시스템 다이나믹스를 활용하여 구현한다. IOM과 같이 프로그래밍을 통한 구현도 가능하나, 확장성을 고려해야하기 때문이다. FFM 모델의 발전은 고장함수 바탕

의 상태기반정비를 구현하는 것이다. 상태기반정비를 해군에 실제 적용하였을 경우의 효과를 분석하기 위해서는 시스템 다이나믹스로 구현하고 필요한 모듈을 추가하는 방식으로 모델을 발전시켜야 한다. 해군 함대에는 여러 척의 함정들이 배치되어 있다. 함정들간의 작전 임무 교대, 정비 등을 고려하면 복잡도가 급격히 상승한다. 따라서 프로그래밍 구현은 난이도가 굉장히 높다. 상대적으로 시스템 다이나믹스는 인과관계를 통한 피드백 루프로 작동되기 때문에 복잡한 모델 구현에 유리하다(Azar, 2012; Karnopp, 2012). 과거의 연구들에서는 인과관계와 시스템의 복잡성, 변수들간의 균형점 최적화(trade off optimization) 등을 위해 시스템 다이나믹스가 활용되었다(Fang and Zhaodon, 2015; Mcdevitt et al., 2005; Linnéusson et al., 2018; Coyle and Gardiner, 1991). 또 모듈 형식의 모델 보완이 가능하므로 확장 가능성 있는 모델 구축에 적합하다. 본 연구의 FFM 모델은 3장 2절, 4장의 내용을 보완하여 5장에서 복잡도 높은 시스템으로 확장된다. 시스템 다이나믹스 소프트웨어는 Vensim 을 활용하였다. Vensim은 시스템 다이나믹스 기반의 소프트웨어이나 모델의 구성에 따라 객체기반(Agent-based) 시뮬레이션도 가능하다는 장점이 있다(Jones, 2014; Eberlein and Peterson, 1992). 5장 이후 다루는 모델은 시스템 다이나믹스를 활용 한 객체기반 시뮬레이션이다.

<그림 3-5>와 같이 시스템 다이나믹스 모델을 구축하였다. 가운데 점선을 기준으로 상단은 FFM, 하단은 PFM 모델이다. 가장 좌측에 있는 Failure function은 일반고장 함수를 구현하는 변수이다. Lookup 함수 형태로 입력 가능하다. Lookup 함수는 사용자가 직접 x, y축의 값을 입력하여 함수를 설정하는 방법으로 <그림 3-6>과 같이



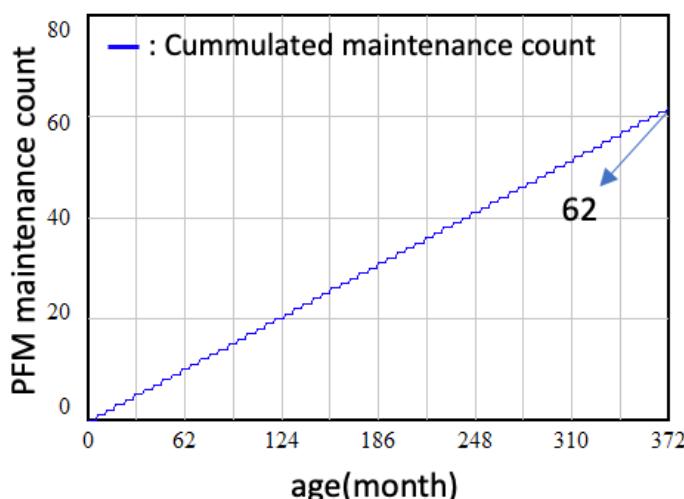
<그림 3-5> FFM(상단), PFM(하단) 모델 구축



<그림 3-6> 일반고장함수의 시스템 다이나믹스 적용

구현한다. <그림 3-6>의 좌측은 사용자가 입력하는 창이다. 일반고장함수는 연단위의 이산형 데이터이다. FFM 모델은 월 단위 time step을 기준으로 설정되어 있다. 따라서 12개월에는 1년차의 일반고장함수의 비율 조정된 값인 0.868을 입력하였다. 같은 방법으로 31년차까지의 일반고장함수값을 모두 입력하면 <그림 3-6>의 우측과 같이 일반고장함수를 시스템 다이나믹스에서 구현할 수 있다. <그림 3-5>의 Failure Rate는 Failure Function에서 고장을 발생시키는 변수이고 FFM Failure와 PFM Failure에 동일하게 적용된다. 발생된 일반고장은 함정에 누적된다. 모델에서 FFM Failure probability와 PFM Failure probability가 함정에 해당한다. 누적된 고장은 각 정비정책에 따라 해소된다. FFM은 정비 시작 기준이 필요하다. 장비가 어느 정도 상태가 되면 정비 입고할 것인지에 대한 기준이다. Maintenance criterion은 FFM의 정비 시작기준이다. Maintenance criterion은 14.22로 설정하였다. 본 절에서 비율 조절된 일반고장함수의 총수명간 누적값은 882이다(본 연구의 각 장애에 적용되는 고장함수들의 비율조정 모수는 군의 보안정책상 모두 다르게 설정하였다).

PFM을 적용하고 있는 해군은 882의 고장량을 62회의 계획정비를 통해 수리한다. 평균적으로 14.22(882/62)의 정비를 수행한다고 할 수 있다. FFM의 정비 입고 기준을 14.22로 설정하면 총수명간 FFM과 PFM의



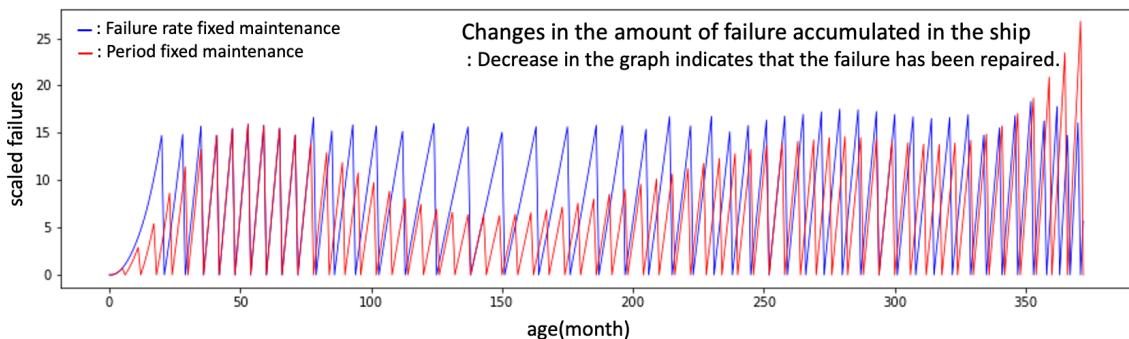
<그림 3-7> PFM의 총수명간 정비횟수

평균 정비량이 같아진다. Maintenance count by Failure rate fixed maintenance 와 Maintenance count by Period fixed maintenance는 두 정비정책에서 정비를 한번 수행할 때마다 1씩 증가한다. PFM의 누적 정비횟수가 62로 산출된다면 모델이 정상적으로 작동한다고 할 수 있다. <그림 3-7>은 PFM의 시뮬레이션 결과 산출된 누적 정비횟수이다. 본 연구에서는 편의상 월단위의 time step으로 시뮬레이션 하였다. 5개월의 운용과 1개월의 계획정비주기가 반복된다. 372개월은 총수명 31년이고 반년에 1회 계획정비를 수행하므로 모델은 정확히 62회의 계획정비 횟수를 시뮬레이션하였다.

4. 고장량 고정형 정비(FFM) 정책 효과 분석

<그림 3-5> 모델은 완전히 동일한 함정 2척을 대상으로 FFM과 PFM을 적용한 것으로 이해할 수 있다. 일반고장량이 누적되는 저량변수(FFM Failure probability, PFM Failure probability)를 함정이라고 가정하자. <그림 3-8>은 함정에 누적된 고장량의 변화이다. 일반고장함수를 통해 발생한 고장은 함정에 축적된다. 본 절의 시뮬레이션은 완전정비를 가정하였다. 정비부대는 정기기간 중 함정에 누적된 일반고장을 100% 정비한다. FFM은 정비 기준점이 되면 고장량이 모두 해소되고, PFM은 5개월 운용후 1개월간 고장량이 모두 해소된다. 그래프에서 상승부분은 작전중 일반고장이 함정에 누적되는 부분이고, 하락부분은 정비를 수행한 지점이다. 고장이 적게 발생하는 수명 중반에 FFM은 PFM에 비해 정비간격이 길다. 반면 수명 후반에는 일반고장이 빠르게 누적되므로 FFM의 정비간격이 PFM보다 짧다. 총수명간 함정에 누적된 고장량의 평균은 FFM은 7.56, PFM은 5.91 이었다.

<표 3-4>는 FFM, PFM이 적용된 두 함정이 정비부대에 입고될 때의 고장량에 대한 통계값이다. 각 통계지표는 IOM의 경우와 같다. 최대값은 작전운용 중 위험에 노출되



<그림 3-8> 함정에 누적된 고장량의 변화

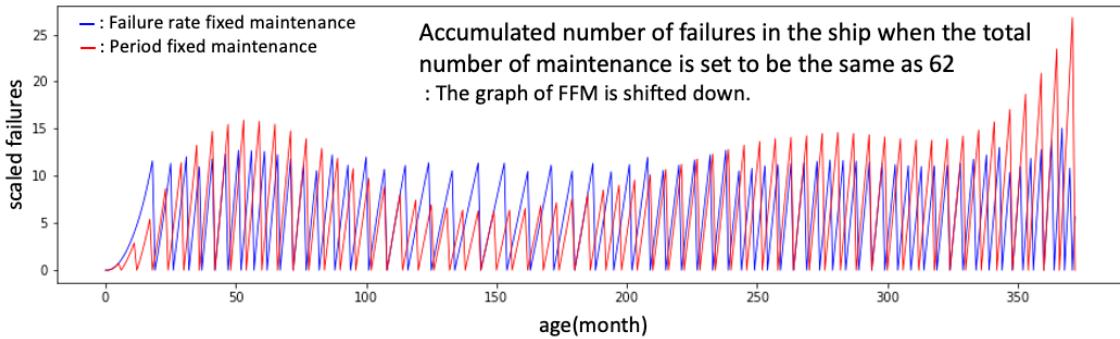
<표 3-4> 정비부대 입고시 고장량의 통계값

Maintenance model	Maintenance counts	Max	Min	Mean	Std.	Period between maintenance(year)		
						Max	Min	Std.
FFM	48	18.5	14.7	16.14	0.90	1.25	0.1667	0.2579
PFM	62	31.8	0.72	14.22	5.50	0.5	0.5	0

는 정도로 이해할 수 있다. FFM의 최대값은 18.5, PFM은 31.8로 PFM은 FFM에 비해 최대 위험도가 1.72배 높다. 함정에 누적된 일반고장의 편차는 PFM이 FFM에 비해 6.11배 크다. 편차는 정비부대 정비부하와 관련이 있다. FFM의 경우 최소 14.7에서 최대 18.5까지의 일반고장을 축적하여 입고되므로 편차가 크지 않다. PFM은 최소 0.72에서 최대 31.8까지로 비교적 편차가 크다. 시뮬레이션에서 1회 정비에 소모되는 시간은 1개월로 동일하다. 편차가 크다는 것은 정비부대 입장에서 업무가 거의 없는 경우가 있는 반면 과한 업무를 수행해야하는 경우도 발생한다는 것이다. 정비인력의 능력에는 한계가 있으므로 과한 업무가 발생하면 완전한 수리를 못하고 정비기간이 끝날 수 있다. 불완전 정비된 일반고장은 함정에 잔류하기 때문에 다음 정비시 더 많은 정비 수행으로 이어질 수 있다(5장 이후 자세히 다룬다). 한편 FFM의 정비간격은 일정하지 않다. 정비간격의 편차는 총수명간 계속 변하며 최소 0.1667년(2개월)에서 최대 1.25년(15개월)간격으로 정비를 수행한다. 상태기반정비 수행을 위해서는 시뮬레이션 결과로 도출된 정비간격의 유동성을 감당할 수 있어야 한다.

두 정비정책의 입고 정비량 평균은 PFM이 작다. FFM의 정비 입고 기준은 14.22로 PFM의 평균값이다. FFM은 일반고장이 14.22 이상 누적되어야 정비를 수행하므로 14.22보다 평균이 높다. 평균값이 높은만큼 총 정비횟수가 줄어든다. PFM은 <그림 3-7>과 같이 총수명간 62회의 정비를 수행한다. FFM은 총수명간 48회의 정비로 동일한 정비량을 모두 해소한다. 정비횟수의 감소는 총 정비예산과 관련된다. 1회 정비 예산을 동일하다고 가정할 때 FFM은 PFM에 비해 약 22%(1-48/62) 정비예산을 절약할 수 있다.

총 정비예산을 고정한 채로 FFM 정책의 효과를 확인하는 것은 총 정비횟수를 62회로 동일하게 맞춘다는 의미가 된다. FFM의 정비 입고기준을 하향시켜 정비를 자주 실시하도록 조절할 수 있다. Maintenance criterion 변수를 10.2로 설정하면 FFM의 총 정비횟수는 62회가 된다. <그림 3-9>와 같이 FFM은 입고 기준이 낮아져 그래프



<그림 3-9> 총 정비횟수 통일시 함정에 누적된 고장량의 변화

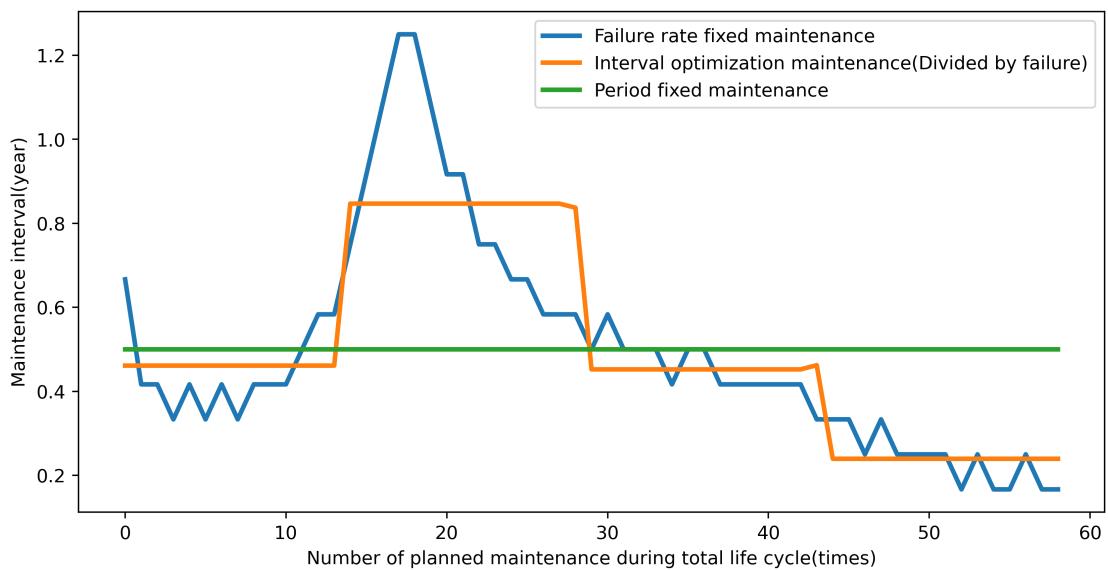
가 전체적으로 하향 이동했다. 이 경우 총수명간 함정에 축적된 일반고장량의 평균은 FFM은 5.61이고 PFM은 5.91로 동일했다. 동일한 정비예산으로 함정을 운용한다면 FFM의 경우 일반고장이 함정에 누적되는 정도를 줄일 수 있다. 수명후반에 정비를 자주 수행하여 긴급고장의 발생 가능성을 낮추는 효과는 동일하다.

<표 3-5>는 총 정비횟수를 같은 경우의 계획정비 입고시의 고장량을 비교한 것이다. 모델을 비교한 것이다. FFM 함정에 축적된 평균 고장량이 11.46으로 줄어들었다. 편차는 0.9에서 0.86으로 감소했다. 최대 고장량 또한 18.5에서 15.07로 감소했다. 총 정비횟수를 동일하게 설정하면 <표 3-4>에 비해 더 안정적인 작전운용과 정비부대 운용이 가능할 것으로 판단된다.

<표 3-5> 총 정비횟수 통일후 정비부대 입고시 고장량의 통계값

Maintenance model	Maintenance counts	Max	Min	Mean	Std.
FFM	62	15.07	10.21	11.46	0.86
PFM	62	31.8	0.72	14.22	5.50

한편 FFM은 정비간격이 계속 변한다. 앞서 기술한바와 같이 상태기반정비에서는 잦은 정비간격 변화를 수용할 수 있어야한다. <그림 3-10>은 PFM, IOM(DF 모델), FFM모델들의 총수명간 정비주기 변화를 나타낸 것이다. PFM은 일정주기를 유지하므로 주기변화가 없다(초록색). IOM은 OVHL을 기준으로 정비주기가 변하므로 총수명간 3번 주기가 변경된다(주황색). FFM은 거의 모든 정비시 주기가 다르다(파랑색). 수명 중반구간에는 고장이 적어 주기가 길고, 수명 말기에는 고장이 많으므로 정비 주기가 짧다. 상태기반정비 구현을 위해서는 이와 같이 일정계획에 유연성을 갖추어야 한다.



<그림 3-10> PFM, IOM, FFM의 총수명간 정비주기 변화

3.1절에서 기술한 3가지 정비정책(PFM, IOM, FFM)은 모두 함정 한척을 대상으로 한다. 해군 함대에는 여러 척의 함정이 정비부대 1개소를 공유한다. 수리중인 함정의 정비가 지연되면 다음 순번의 함정은 대기를 해야한다. 대기기간이 길어질 경우 대기 하던 함정은 추가적으로 작전임무를 수행한다(자세한 내용은 2.1절을 참조하라). FFM을 함대에 적용한다고 가정했을 때 수명 후반에 위치한 함정이 많다면 대기가 반드시 발생한다. FFM의 수명 말기에는 잦은 간격으로 정비를 수행해야하기 때문이다.

제 2절 대기현상을 고려한 정비정책 효과 분석

FFM 모델은 함정 한척을 기반으로 시뮬레이션 되었으므로 정비부대 한 개소에서 여러 척을 수리하는 실제 해군의 시스템과는 거리가 있다. 함대에는 정비부대가 1개소 존재한다. 일반적으로 상가대는 2개소 존재한다. 최대 2대를 동시에 정비할 수 있다는 의미이다. 수명주기가 비슷한 함정이 동시에 입고되면 대기현상이 발생할 수 있고, 수명 말기의 함정들이 동시에 입고되면 정비부대의 정비업무량도 크게 증가하게 된다.

대기행렬은 정비분야의 분석에 다양하게 활용되었다. Ok et al.(2014)는 효율적인 상가대 규모를 도출함에 있어 함정들의 정비 입고 대기현상을 고려하였다. 함정의 정비부대 입고 간격을 포아송(Poisson)으로 가정하고 함정의 입고와 출고 현상을 분석한 연구들이 많았다(Go et al., 2013; Kim and Yoon., 2015; Jo and Yoon.,

2019). 단, 본 절의 연구와 같이 고장함수의 설정에 따라 도착 간격이 변하는 시뮬레이션에 관한 연구는 찾아보기 힘들다.

본 절에서는 실제 상황과 유사한 시뮬레이션 환경을 구축하여 PFM과 FFM의 성능을 비교한다. 해군의 OO부대의 상황을 재현한다. 6척의 함정이 상가대 2개소를 공유하는 시스템을 구성한다. PFM 모델의 주기에 따라 함정들은 4.5개월 작전 운용 후 정비부대 입고한다. 정비부대에 여분의 상가대가 없는 경우 추가 작전임무를 수행하며 대기한다(계획정비는 일반고장 해소를 위하 정비이고, 작전임무가 가능하다).

대기행렬의 성과지표는 일반적으로 평균 대기시간(mean waiting time)을 많이 사용한다(Boxma et al., 1979; Chae and Lee, 1995; Zhang et al., 2009; Gorunescu et al., 2002). 긴급고장은 장비가 작동되지 못하는 상태로 대기를 해야 하기 때문에 함정가동률에 영향을 미치지 않는다. 반대로 일반고장은 작전수행이 가능하며, 함정은 계획정비 대기 발생시 추가적인 작전임무를 수행한다. 일반고장에 대해서는 평균 대기기간이 큰 의미를 가지지 않는다. 단, 대기기간이 길어지면 긴급고장에 노출되는 시간이 길어지는 것과 같다. 일반고장의 대기와 같이 대기기간에 추가적인 임무를 수행하는 대기행렬은 평균 대기기간이 다른 사건으로 이어질 수 있다. 이는 시스템의 신뢰도와 직결된다. 신뢰도는 장비가 고장 없이 일정 기간 동안 성능을 발휘할 확률을 의미한다. 함정 정비 시스템에서 대기의 발생은 신뢰도 저하와 연결될 수 있다.

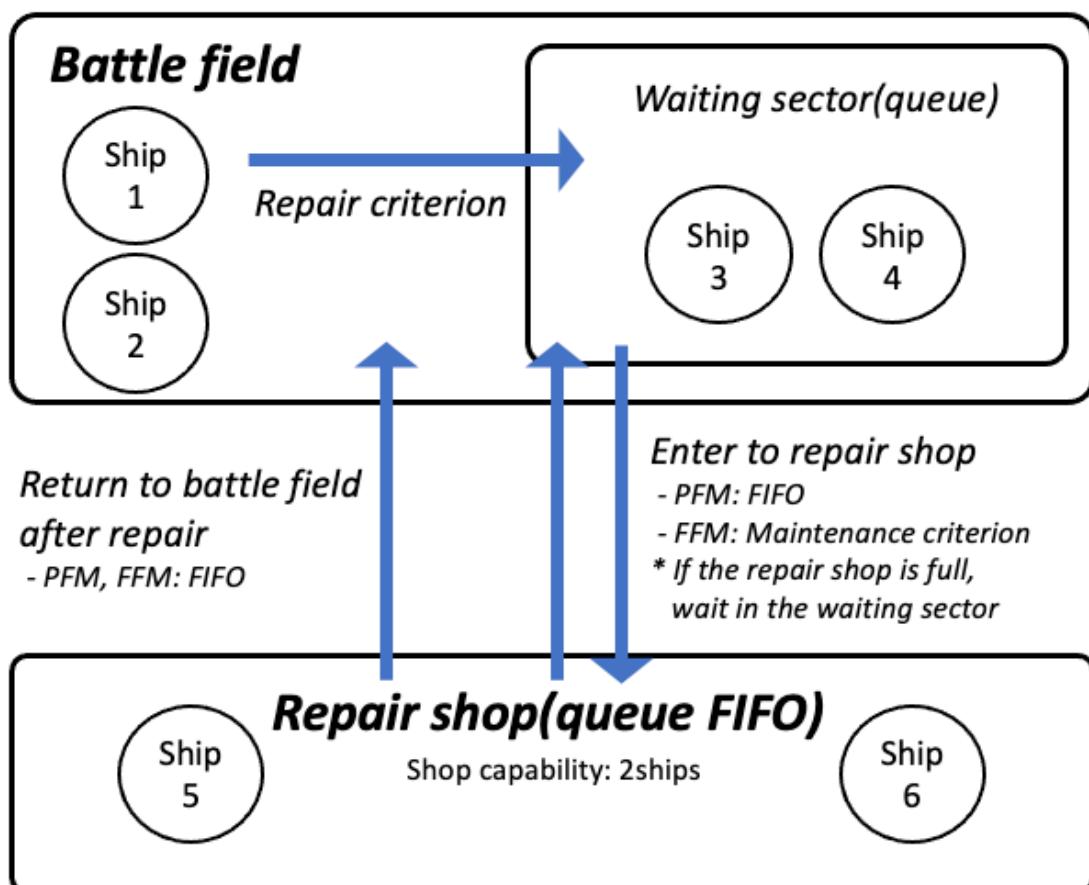
본 절에서 다루는 두 정비정책의 주요 성과지표는 함정 가동률과 정비부대 가동률이다(평균 대기기간에 대한 분석은 6장에서 다룬다). 함정 가동률은 높을수록 좋다고 판단된다. 연중 언제든 작전임무에 투입될 수 있기 때문이다. 반면 정비부대 가동률이 높으면 긴급고장이나 장기화되는 정비에 대한 대응능력이 떨어진다고 판단된다. 정비 기간은 함정 가동률을 떨어뜨린다. 작전에 투입될 수 없는 구간이기 때문이다. 총수명 주기 동안 정비횟수가 많다는 것은 함정 가동률이 떨어진다는 것과 같다. 정비횟수가 적어지면 함정 가동률은 올라가는 반면 작전 운용중 함정에 축적되는 고장은 많다. 3.1절에서 Maintenance criterion을 14.22에서 10.2로 감소시켰을 때 총수명주기간 정비횟수는 48에서 62회로 증가하였다. 31년은 11,315일이다. 48회 정비 일수는 2160일이고, 62회 정비일수는 2790일이다. 62회 정비의 경우 함정가동률은 75.34%이고, 48회 정비의 경우는 80.91%이다. 상태기반정비에서 정비 입고 기준은 중요하다. 본 절의 마지막에는 정비입고 기준을 변화시킬 때의 함정 가동률과 정비부대 가동률 변화를 확인한다.

본 연구에 대한 보다 자세한 내용은 Park et al.(2021)에서 확인할 수 있다.

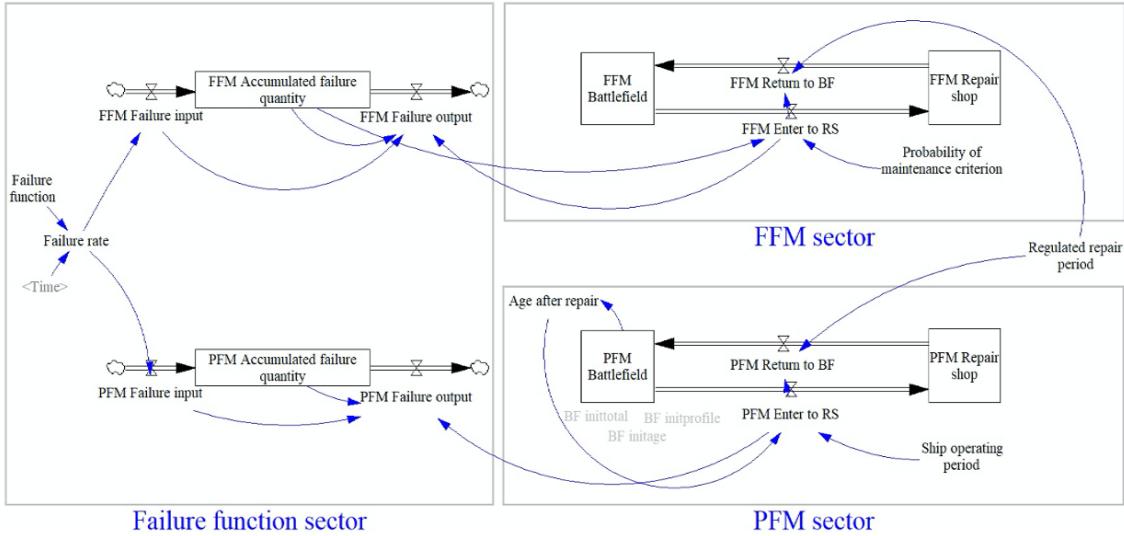
1. 대기행렬을 적용한 시스템 다이나믹스 정비모델 구축

함정 6척과 상가대 2개를 운용하는 시스템을 구현할 때 작전구역(Battle field)과 정비부대(Repair shop)은 대기행렬이다. 정비입고 기준을 만족하는 함정은 대기구역(Waiting sector)으로 이동한다. 대기중인 함정은 상가대에 자리가 있는 경우 정비부대(Repair shop)에 입고된다. 정비부대에 입고된 함정은 정해진 정비기간(1.5개월) 후 다시 작전구역에 복귀한다. 이를 도식화하면 <그림 3-11>과 같다.

PFM의 경우 대기구역에서 정비부대의 이동, 정비부대에서 작전구역으로 이동은 모두 FIFO(First in first out)에 따라 움직인다. PFM은 정비 종료 후 일정 기간이 지나면 대기구역으로 이동한다. 정비가 먼저 종료된 함정이 먼저 정비를 수행하게 된다. FFM은 작전 중 정비 입고기준에 도달하는 일반고장이 축적되었을 때 대기구역으로 이동한다. 수명에 따라 일반고장 누적 속도가 다르므로 먼저 정비가 끝난 함정이 먼저 다음 정비를 시작하지 않는다. 정비부대에 입고된 함정은 일정기간동안 정비를 받



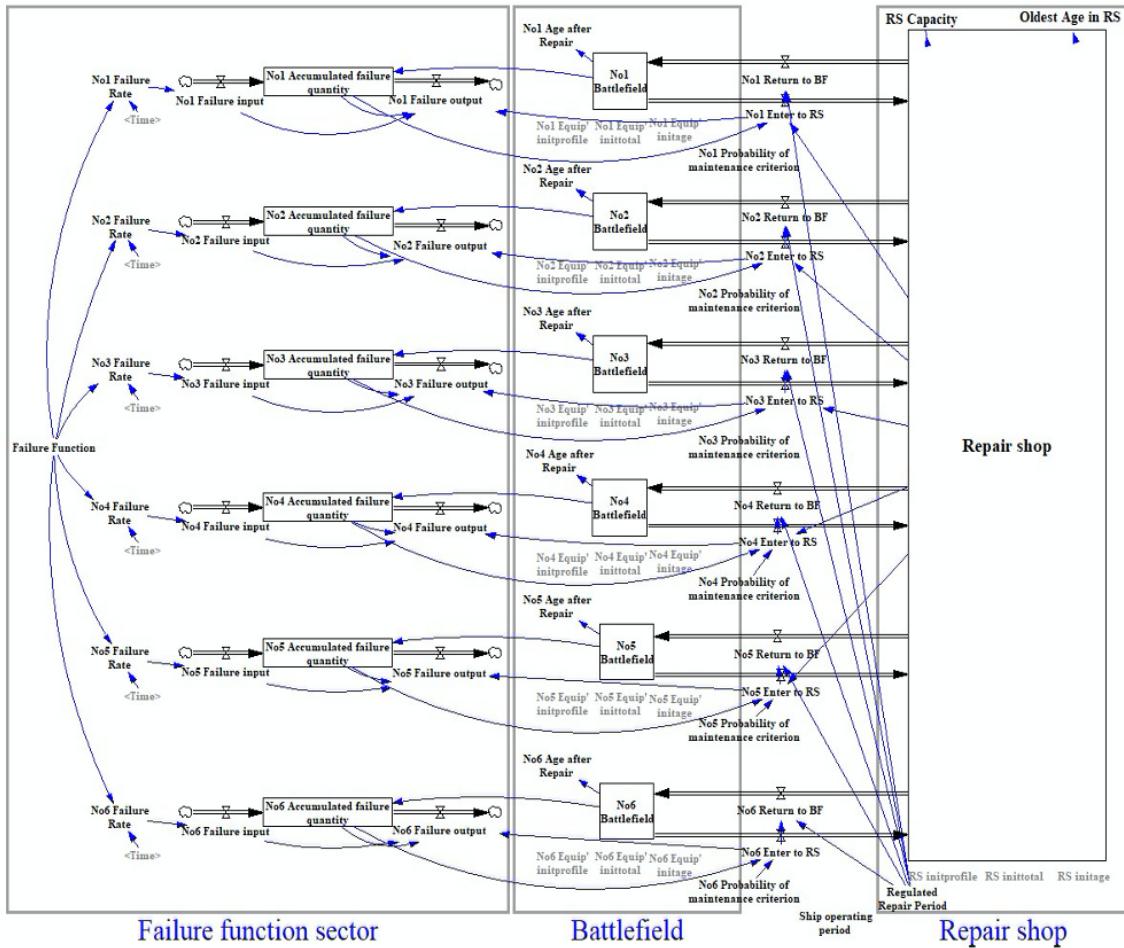
<그림 3-11> 대기행렬을 고려한 정비 시스템



<그림 3-12> 대기행렬이 반영된 시스템 다이나믹스 정비모델

고 FIFO에 따라 작전구역으로 복귀한다. Repair shop은 queue FIFO로 표현된 것에 비해 Waiting sector는 queue로 표현된다. 이는 긴급고장함수를 고려한 모델링이다. 긴급고장 발생시에는 FIFO 기준보다 긴급고장 정비가 우선되어야하기 때문이다(5장에서 다룬다).

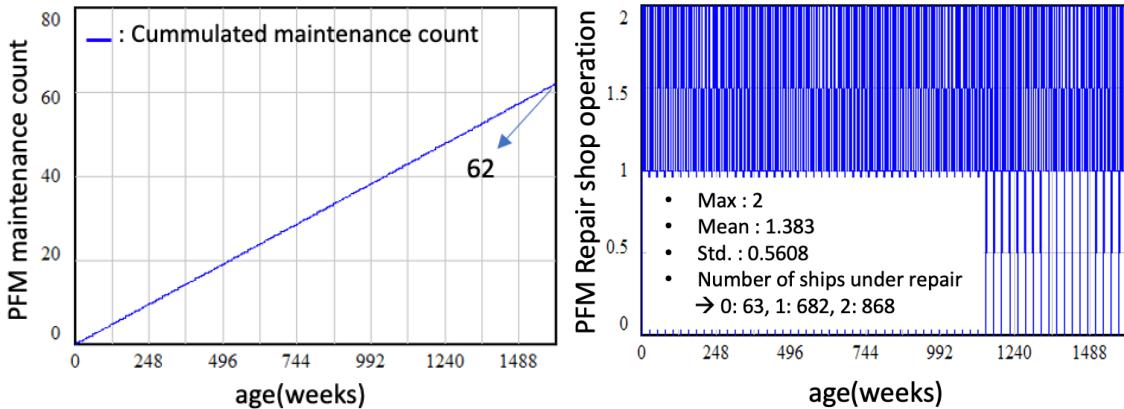
<그림 3-11>의 시스템을 시스템 다이나믹스로 구현하면 <그림 3-12>과 같다. <그림 3-5>에서 대기현상 구현을 위해 FFM sector, PFM sector가 추가되었다. Failure function sector에서는 일반고장이 발생하여 함정에 해당하는 stock 변수(FFM Accumulated failure quantity, PFM Accumulated failure quantity)에 축적된다. FFM 함정의 일반고장량이 정비 기준(Probability of maintenance criterion) 이상으로 누적되면 FFM Enter to RS를 통해 정비부대에 입고된다. 정비 기준은 비율조정된 일반고장함수의 총 누적 고장량 2,954을 총수명 정비횟수 62로 나눈 47.65를 설정하였다. 정비 기준 설정시 OVHL은 고려하지 않는다. OVHL의 정비효과는 일반고장함수를 통한 확인이 어렵다. 일반고장함수의 9, 18, 27년차는 OVHL을 수행한 구간인데 OVHL 이후 고장량이 줄었다고 판단하기 힘들다. 데이터 원본(<그림 2-16>의 파랑색 선)에서도 OVHL의 효과는 부각되지 않는다. IOM 모델 또한 OVHL은 구간분류를 위한 기준으로 활용되었고 OVHL 정비효과에 따라 구분된 것은 아니다. PFM은 Ship operating period의 설정(4.5개월)에 따라 작전구역에서 정비구역으로 이동한다. FFM Battlefield와 FFM Repair shop은 함정 한척에 대한 대기행렬이다. 두 queueing stock은 상수 1을 주고받는다. 1은 함정의 대수를 의미한다. 입고기준을 넘는 경우 인과관계에 따라 작전구역의 함정 1척을 정비부대로 이동시킨다. 함정 한



<그림 3-13> OO부대 정비 시스템 구현

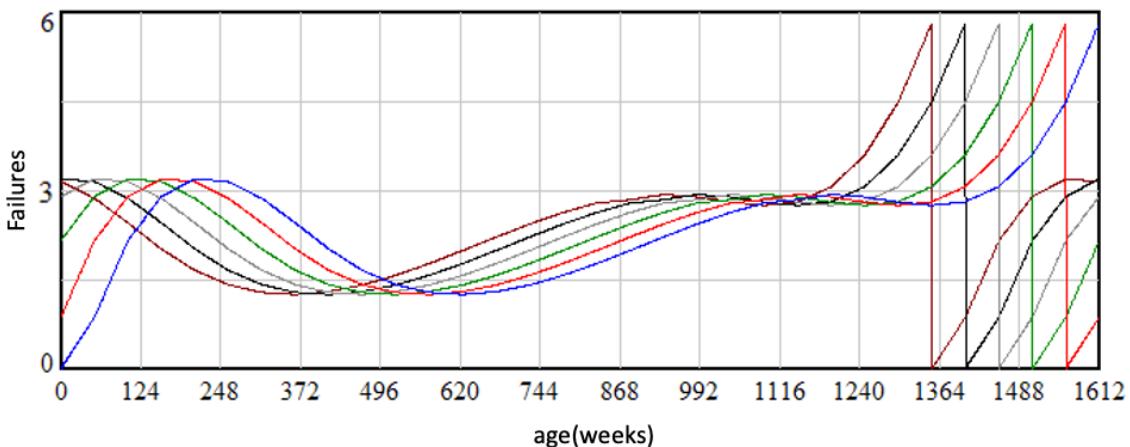
척 단위의 대기행렬 변수를 설정함으로서 시스템 다이나믹스를 활용한 객체 기반 시뮬레이션이 가능하다. 정비부대에 들어간 함정은 Regulated repair period에 설정된 1.5개월이 지난 후 작전구역으로 복귀된다. 3장과 동일하게 모든 정비는 완전정비로 가정하였다. 정비가 완료되면 두 정비모델의 Failure output을 통해 모든 누적 고장량이 해소된다.

3장의 정비모델 연구들은 공통적으로 함정 한척을 기준으로 하였다. <그림 3-12>는 한척에 대한 대기행렬 적용 모델이므로 6척에 대한 모델로 확장하여 <그림 3-13>과 같이 OO부대의 정비시스템을 구현하였다. OO부대의 함정 배치 상황을 고려하여 6척 함정들간의 수명 차이는 1년으로 설정하였다. OO부대는 모두 같은 함정 타입으로 구성되어 있다. 함정들은 해군의 함정 건조계획에 따라 1년에 1척씩 전력화되었으므로 수명 차이는 1년이다. 6척의 함정은 정비정책에 따라 정비부대에 입고된다. 정비부대 입고 우선순위가 같은 경우에는 누적된 고장량이 많은 함정이 우선 정비수행토록 설



<그림 3-14> PFM의 평균 정비횟수

<그림 3-15> PFM Repair shop 작동현황



<그림 3-16> 6척 함정들의 총수명간 고장 발생

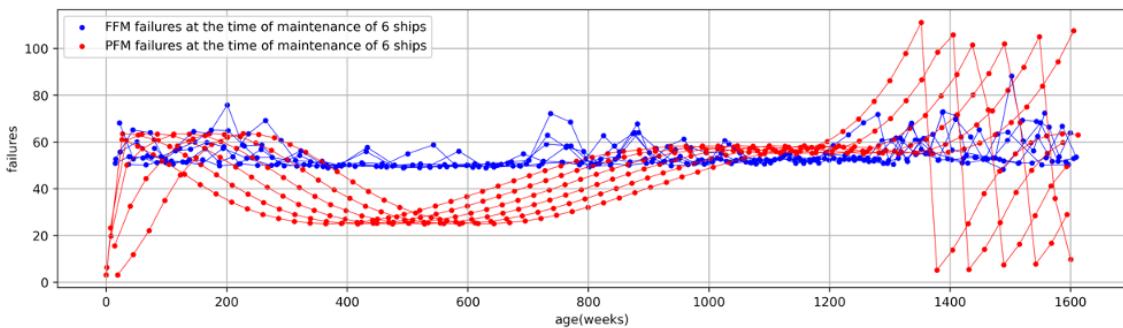
정하였다.

<그림 3-14>는 PFM 함정들의 총수명간 누적된 평균 정비횟수이다. 최고값은 62이다. 해군 정비정책에 따라 함정들은 31년간 0.5년 주기로 총 62회의 정비를 수행하였다. <그림 3-15>는 정비부대의 작동현황이다. 정비부대는 최대 2척의 함정을 동시에 정비하였다. 한척도 정비하지 않는 일수는 63일, 1척 정비중인 일수는 682일, 2척인 일수는 868일이다. 최대 허용 능력 2척 대비 평균 1.383척 정비중이므로 정비부대 운영률은 0.6915이다. <그림 3-17>은 함정 6척의 총수명간 고장 발생량이다. 6척의 함정에 모두 일반고장함수가 적용되었고 수명 1년 차이로 고장이 발생한다. 약 1,364 일 이후의 패턴 변화부분은 31년의 총수명이 도래하여 기존의 함정이 폐선되고 신규 함정이 도입된 부분이다. 폐선 즉시 신규함정이 도입되며 수명은 1년차부터 시작된다 고 가정하였다. 해군은 도태함정을 대신하기 위한 신규함정을 건조하여 교대시킨다. 모델은 현실의 정비횟수, 정비창 최대 정비대수를 잘 반영하고 있으며, 일반고장함수

가 반영되었다.

2. 정비모델 시뮬레이션 결과 분석

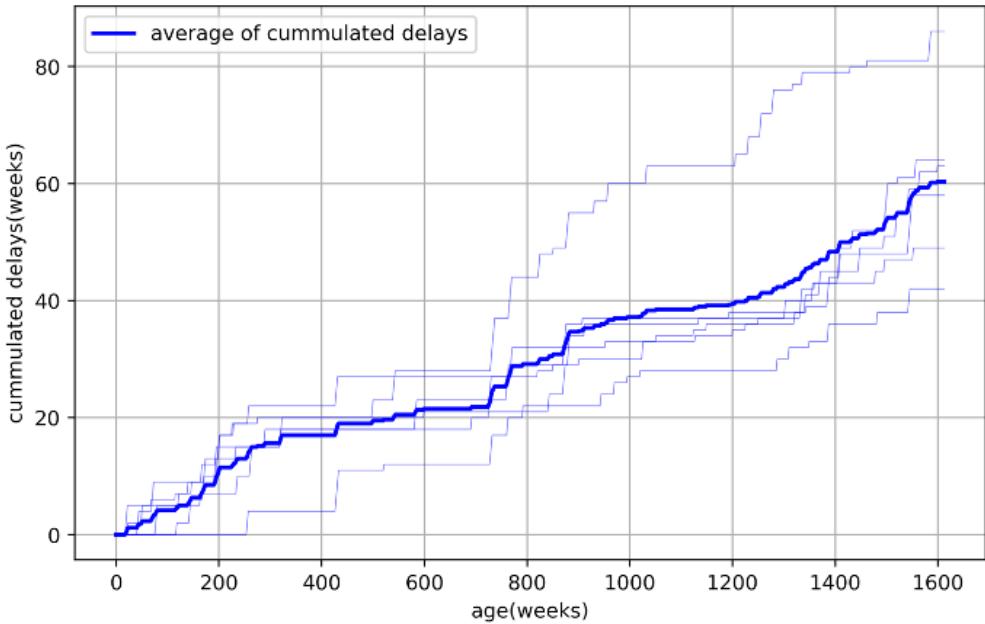
함정 6척의 정비부대 입고시 고장량은 <그림 3-17>과 같다. 각 점이 입고시의 고장량이다. 변화 추이 확인을 위해 선으로 연결하였다. PFM은 일반고장함수의 형태를 따라 정비입고시 고장량의 편차가 크다. FFM은 입고시 고장량의 편차는 상대적으로 작으나, 정비 입고 기준에 따라 입고 간격이 계속 달라진다. 이는 1척 기준의 FFM에서도 확인되었다. <표 3-4>의 1척 기준 모델에서 PFM의 편차가 FFM보다 6.11배 컸다. 6척 모델에서 편차는 PFM이 3.16배 크다. 6척의 총수명간 정비횟수 평균은 PFM 62회 대비 FFM 54.33이었다. 함정 1척 대상의 FFM이 48회였던 것에 비해 54.33로 증가하였다. 항해중 고장에 노출되는 위험의 최대값은 PFM이 1.26배 컸다. 한편 정비부대 운용률은 FFM이 0.6070으로 PFM 대비 0.0845 작다. 정비부대 운용률의 감소정도는 정비횟수의 감소정도(54.33/62)와 유사하다. 시뮬레이션 결과는 <표 3-6>과 같다.



<그림 3-17> 함정들의 정비 입고시 고장량

<표 3-6> 정비부대 입고시 고장량의 통계값(6척 기준)

Maintenance model	Maintenance counts	Failures of 6 ships				Repair shop		
		Max	Min	Mean	Std.	Max capacity	Mean availability	
FFM	54.33	88.2	48.3	54.72	5.80	2	1.214	0.6070
PFM	62	111.11	3.14	47.50	18.32	2	1.383	0.6915



<그림 3-18> FFM 모델의 지연 현상

PFM은 순차적으로 정비를 수행하기 때문에 대기가 발생하지 않는다. 정비 시기가 도래하였을 때 적절한 정비를 받을 수 있다. 반면 FFM은 정비주기가 유동적으로 변하기 때문에 대기가 발생한다. <그림 3-18>에서 얇은 선은 6척 개별 함정들의 대기 일수이고 굵은 선은 평균선이다. 6척의 함정들은 평균 60.3주의 대기가 발생하였다. 대기로 인해 FFM 함정들은 정비 입고 기준을 초과하여 추가적인 임무를 수행한다. <그림 3-17>에서 47.65를 넘는 점들은 대기로 인해 늦게 시작된 정비이다. 대기가 발생한다면 총수명간 정비횟수는 줄어들어야 한다. 1척 기준의 FFM에는 대기없이 입고 기준 초과시 즉시 정비가 시작된다. 반면 본 절의 연구에서는 대기가 발생함에도 불구하고 총 정비횟수가 1척 기준 대비 크다. 이는 시뮬레이션 모델의 시간단위가 다르기 때문이다. 1척 기준 모델의 시뮬레이션 목적은 개략적인 고장함수의 효과를 확인하기 위한 것으로 5개월 운용 1개월 정비를 가정으로 하였다. 해군은 4.5개월 운용, 1.5개월 정비 수행중이므로 실제와의 차이가 있다. 본 절의 모델은 여러 함정으로 인한 대기현상 발생시 고장함수 적용 모델의 효과를 확인하기 위한 목적으로 시뮬레이션 되었다. 20주 운용, 6주 정비를 기준으로 설정하여 현실성을 보다 강화하였다. 본 모델은 대기현상 발생시 1주일 단위로 대기를 수행한다. 보다 현실성 있는 모델 구축을 위해서는 시뮬레이션 모델의 time step을 일단위로 수정해야한다. 이는 5장 이후의 모델에 적용된다.

함정의 운용가용도는 <표 3-7>과 같다. 평균적으로 FFM은 PFM에 비해 운용가용도가 0.0283 높다. 정비횟수가 적은만큼 FFM은 작동 불가기간(downtime)이 적기 때문

<표 3-7> 함정 운용가용도(6척 기준)

	FFM	PFM
Ship1	0.7991	0.7693
Ship2	0.7991	0.7693
Ship3	0.7954	0.7693
Ship4	0.7954	0.7693
Ship5	0.7954	0.7693
Ship6	0.8009	0.7693
Average	0.7976	0.7693

이다. 5장 이후 모델에는 긴급고장으로 인한 대기현상이 반영된다. 일반고장은 대기가 발생하여도 작전 수행이 가능하므로 대기와 운용가용도가 무관하다. 긴급고장 발생시에는 작전이 불가하다. 긴급고장 발생시 대기가 발생하면 대기기간만큼의 작동 불가기간이 발생하여 운용가용도가 감소한다.

함정 운용가용도는 높을수록 작전 수행에 유리하고, 정비부대 운용률은 낮을수록 긴급고장과 같은 추가적인 정비에 대처할 수 있다. 해군은 해군 함정 외에도 해경, 육경 등의 함정 정비를 지원한다. 이와 같은 측면에서 정비 여유 능력은 항상 갖추어져야 한다. FFM 모델은 입고기준을 조절하여 운용가용도, 정비부대 운용률을 조절할 수 있다. <표 3-8>은 FFM 모델의 정비 입고 기준에 따른 운용가용도, 운용률의 변화와 작전 중 함정에 누적되는 고장의 정도를 나타낸 것이다.

함정의 운용가용도가 높아질 때 정비부대의 운용률은 떨어진다. 정비 입고 기준 약 38.5일 때 정비횟수는 62회가 된다. 함정과 정비부대의 가용도는 유사하다. 작전중 고장에 노출되는 정도는 FFM이 더 적다. 정비횟수는 예산과 연관된다. 같은 예산을 활용할 때 FFM 정비 정책을 적용시 함정을 더 안정적으로 운용할 수 있다. 정비 입고 기준이 약 65보다 커지면 상가대 2대의 운용률이 0.5보다 작아진다. 정비부대의 상가대는 1대로 충분하다는 의미가 된다. 운용가용도가 높다는 것은 작전 운용 일수가 많다는 것이다. 이는 고장에 노출되는 시간이 길어짐을 의미한다.

본 절의 연구에서는 6척의 함정을 시스템 다이나믹스 모델에 적용하여 1척 기준 대비 현실성을 높였다. 다만 몇 가지 한계가 존재한다. 첫 번째, 분석의 편의를 위해 시간 단위를 일주일로 설정하여 대기현상을 1주일 단위로 계산하였다. 두 번째, 긴급고

<표 3-8> FFM 함정 운용가용도와 정비부대 운용률

Maintenance criterion	Operational availability	Repair shop availability	Maintenance count	Accumulated failure statistics on the ship		
				Max	Mean	Std.
30	0.7436	0.769	68.83	26.33	13.64	3.017
35	0.7581	0.7255	65	30.03	15.10	3.674
38.5 (PFM)	0.7686 (0.7693)	0.694 (0.6915)	62	33.05 (45.41)	16.43 (17.44)	4.000 (6.327)
40	0.7751	0.6745	60.33	30.98	17.05	4.538
45	0.7901	0.6295	56.33	39.06	19.12	4.901
47.65	0.7976	0.607	54.33	40.60	20.41	5.453
50	0.8030	0.5905	52.83	39.93	21.33	5.594
55	0.8165	0.55	49.16	44.76	23.65	6.686
60	0.8256	0.5225	46.83	51.37	25.90	7.464
65	0.8364	0.4907	43.83	51.44	28.18	7.917
70	0.8459	0.4622	41.16	66.07	30.64	8.667

장함수의 미적용으로 PFM의 대기 현상이 관찰되지 않았다. 세 번째, OO부대의 함정 배치 상황을 고려하였기 때문에 수명이 다른 여러 함정들이 배치된 경우에 대해서는 시뮬레이션 하지 않아 일반화된 해군 정비시스템 시뮬레이션 모델이라고 할 수 없다. 네 번째, 정비부대의 정비능력을 완전정비로 가정하였다.

FFM은 함정의 입고 기준을 유동적으로 조절한다. FFM에서 고장이 많은 기간에는 정비 간격이 짧고, 고장이 적은 기간에는 간격이 넓다. 대기가 발생하면서 정비 기준보다 많은 정비량이 들어오는 경우도 있다. PFM에서는 계획정비마다 정비해야 할 업무량이 다르다. 그럼에도 불구하고 계획정비 기간은 6주로 고정되어 있다. 정비원이 하루에 할 수 있는 업무량은 한계가 있다. 정비량이 많은 기간에는 많은 정비 일수가 필요하다. 6주의 정비기간이 부족할 수 있다. 반대로 정비량이 적은 수명 중반 구간에서는 정비 일수가 과하게 설정되었을 가능성도 있다.

FFM 모델은 정비 입고기준만 유동적이다. 상태기반정비가 되기 위해서는 정비기간의 유동성을 반영해야 한다. 정비기간은 입고된 함정의 고장량과 정비부대의 정비능력에 따라 결정되어야 한다. 실제 정비에 필요한 시간에 대해 연구하고 적정 정비시

간을 설정 모듈을 추가하여 모델을 발전시켜야 한다.

4장에서는 정비부대의 정비능력에 대해 연구한다. 정비부대 정비능력은 2가지로 구분할 수 있다. 하나는 정비를 수행했을 때 100% 완전정비 대비 몇 %의 정비를 수행하였는가에 대한 능력이다. 본 연구에서는 이를 완전 정비율이라고 한다. 다른 하나는 정비원의 업무 능력이다. 과거의 연구에서는 사람의 업무속도가 유동적이라고 하였다. 정비원이 빠르게 일을 한다면 하루에 처리할 수 있는 업무량이 많아지고 함정 정비기간이 짧아진다. 4장에서 정비부대 정비능력을 추정한다.

제 4장 정비부대 정비능력

긴급고장은 발생 즉시 모항에 입항하여 수리된다. 긴급고장 발생 시에는 즉시 수리 부속을 교체하거나 고장원인을 제거하기 때문에 완전정비에 속한다. 완전정비란 고장 부분을 새것과 유사한 수준으로 장비상태를 향상시키는 정비를 의미한다. 긴급고장이 완전정비에 준하게 수리되는 반면 일반고장은 그렇지 않다. 계획정비에 포함되는 수많은 정비항목 중에 상태저하 개소를 정확히 찾는 것은 어렵기 때문이다.

주기적으로 수행하는 계획정비 항목은 표준 정비항목과 비표준 정비항목으로 구분된다. 표준 정비항목은 매번 계획정비시 반드시 확인하는 정비항목이다. 확인의 정도는 정비항목마다 다르다. 어떤 정비항목은 윤활유 보충 등 장비 상태 유지를 목적으로 한 보충적 성격을 가진다. 어떤 정비항목은 이상유무를 확인하라와 같이 시각적인 이상 유무를 확인한다. 비표준 정비항목은 표준 정비항목에 없는 수리건이다. 장비의 상태 저하를 인지한 승조원이 신청하거나, 표준 정비중 확인된 상태 저하 개소를 추가적으로 정비하는 경우에 해당한다. 일반적으로 정비의 단계는 진단 → 정비 → 시운전으로 구성된다. 정비요원이 장비를 직접 운영하며 고장개소를 진단하고 문제 개소를 식별하여 정비를 수행한다. 정비 후에는 정상 작동 여부를 시운전을 통해 확인한다. 모든 절차를 정비요원이 직접 수행한다. 그러나, 해군 정비부대는 일반적으로 정비 기능만을 수행한다. 고장 상황이 특별히 중요한 사안이거나 승조원이 요청한 사항이 아니면 진단과 시운전은 승조원이 수행한다.

장비의 상태를 가장 정확히 아는 사람은 승조원이다. 작전 중 장비를 지속 운영하면서 상태저하를 확인할 수 있기 때문이다. 계획정비 입고시 정비항목 신청은 승조원이 직접 입력한다. 30년 이상 근무한 숙련된 승조원의 경우 디젤엔진의 작동 소음만 듣고도 어떤 부품의 성능이 저하되었다는 것을 인지할 정도로 장비상태 인지능력은 우수하다. 승조원들은 위험을 감수하고 작전임무를 수행하기 때문에 장비상태에 민감하다. 작은 상태이상이라도 계획정비 항목으로 제출한다. 승조원이 제출하는 정비 항목에는 장비의 모든 고장상태가 포함되어 있다고 할 수 있다. 장비상태는 작전의 성패와 승조원의 안전과 직결되므로 빠짐없이 작성하고 완전정비 되길 바란다.

정비부대 정비원의 입장은 다르다. PFM 정비정책에서 정비일수는 한정(45일)되어 있고 정비항목은 많게는 수백 건에 달한다. 수많은 정비항목에 대해 승조원과 일일이 인터뷰할 수 없다. 정비원은 작전환경에서 실제 운용중인 장비의 상태를 확인하지 못한다. 때문에 신청된 정비항목에 대해서 매뉴얼대로 정비를 수행한다. 정비항목 중 표준정비항목에 포함이 되어있으면 매뉴얼대로 시각검사를 수행하거나, 윤활유를 보충하는 것으로 해당 정비를 마무리한다.

정비가 종료된 후 승조원들이 느끼는 장비의 상태는 작전수행이 가능한 수준을 유지 할 뿐 말끔하게 정비되었다는 느낌을 받지 못하는 경우가 대부분이다. 완전정비가 수행되지 못한 것이다. 해군은 계획정비가 종료되면 모든 항목이 완전정비 되었다고 가정한다. 그러나 실제로는 함정에 축적된 일반고장이 완전히 해소되지 못한 상태이다. 해군의 PFM 계획정비 기간은 45일로 고정되어 있다. 함정의 크기나 용도를 고려하지 않는다. 최전방에서 작전을 수행하는 함정이나, 최후방에서 작전 지원을 수행하는 함정이나 모두 45일로 고정되어 있다. 심지어 이지스급이나 독도함같은 대형함정과 참수리급 같은 소형함정의 계획정비 기간이 동일하다. 정비인원이 다르게 할당되지도 않는다. 정비원 수와 정비기간이 같은데 정비량의 차이가 난다면 정비속도가 다르다고 이해할 수 있다.

완전정비되지 못한 일반고장은 함정에 축적된 상태로 남게 된다. 잔여 고장은 다음 계획정비에 성능이 더욱 저하되어 정비가 되거나, 다음정비에도 발견되지 못하여 계속 남게 된다. 완전정비의 효과를 100%라고 본다면 실제 정비 효과는 100%에 미치지 못한다.

2장에서 추정한 일반고장함수는 불완전한 정비효과가 포함되어 있다. 일반고장함수 추정에 활용된 데이터는 승조원이 신청한 정비항목의 수를 기준으로 하기 때문이다. 3년차 함정이 10건을 정비 신청했다면 그중 몇 건은 3년차 이전에 발생한 고장에 해당한다. 신청된 정비항목에는 이전 계획정비 시 불완전 정비된 고장들이 포함되어 있다. 고장함수를 활용한 새로운 정비정책의 효과 분석이나 예산 검증 등을 위해서는 일반고장함수에서 PFM 정비효과를 제거해야한다. 2년차 계획정비 후 불완전 정비건 수가 몇 건 발생했는지 알아야 순수하게 3년차에 발생한 고장량을 알 수 있다. 2장의 일반고장함수를 활용하여 새로운 정비효과를 검증한다면 현재의 정비효과와 신규 정책의 정비효과가 중첩된다.

4장에서는 정비부대의 정비능력을 추정한다. 장비 상태를 가장 정확히 인지하는 승조원을 대상으로 설문을 수행한다. 승조원들은 두 가지 질문에 대한 답변을 수행한다. 첫 번째 질문은 계획정비 후 장비의 상태는 완전정비 100%를 기준으로 어느 정도인가이다. 두 번째 질문은 정비지침에 표기된 표준 정비 공시(정비에 필요한 시간)에 비해 실제로 필요한 시간은 몇 % 수준인가이다. 첫 번째 설문 결과를 바탕으로 해군 정비부대의 정비능력은 완전정비 대비 몇 % 수준인지 추정한다. 추정된 정비능력을 바탕으로 정비효과가 제거된 일반고장함수를 다시 추정한다. 두 번째 설문 결과를 통해 정비에 필요한 공시가 표준 공시 대비 몇 % 수준인지 파악한다. 두 가지 추정은 모두 베이지안 추정을 활용한다. 설문결과는 승조원의 의견이므로 베이지안 사전분포로 활용가능하다. 사전분포는 데이터를 접하여 사후분포로 축소되기 이전의 예상 범

위이다. 설문 결과는 데이터 확인 전에 실제 승조원들이 생각하는 범위가 되므로 사전분포로 구성하기 적절하다.

제 1절 정비부대의 완전 정비율 추정

Shin et al.(1996)은 GAN(Good as new)와 BAO(Bad as old)로 완전정비와 불완전정비를 구분하였다. Malik(1979)의 PAR(Proportional age reduction)모델과 유사하게 정비를 수행할수록 정비효과에 따라 장비가 노후된다는 주장이다. GAN과 BAO의 파라미터는 수리적으로 도출되어 특정상황에 국한된다. 시뮬레이션을 통한 여러 가지 상황에 적용하지 못했다는 한계가 있었다. Xu et al.(2021)은 상태기반정비의 최적화에 마코프 의사결정 프로세스(Markov decision process)를 활용하였다. 최적화 목적식은 경제적 최대 이익점을 찾는 것으로 정비효과의 도출에는 크게 집중하지 못했다. 군과 같이 경제적인 요소보다 정비효과가 중시되는 경우에 대한 연구는 드물다. 민간 기업이나 산업체의 장비들은 최대한 경제적으로 활용되어야 할 대상인 반면, 군의 장비는 반드시 작동해야하는 장비이기 때문이다.

계획정비가 종료된 후 승조원들은 장비의 상태가 얼마나 좋아졌는지 시운전을 통해 확인한다. 시운전을 통해 완전정비되지 못했다는 느낌을 받는다. 정상 운용 기준치에 미충족하는 경우 하자정비를 요청하지만 별도의 기록을 남기지는 않는다. 하자정비는 정비기간의 연장에 포함되어 불완전정비로 분류되지 않는다. 대부분의 하자정비는 6 주의 계획정비기간에 모두 해결된다. 불완전정비는 대부분 장비의 정상 운용 기준치는 충족하지만 승조원이 원하는 수준으로 수리되지 않은 정비이다. 승조원들은 장비가 정상 기준치를 충족하기 때문에 추가적인 정비요청이나 기록 없이 다음 계획정비 시 재요청하여 장비 상태를 호전시킨다. 축 회전수 1,800rpm으로 1시간 이상 유지하는 것을 정격성능 기준으로 삼는 디젤엔진을 예를 들어보자. 신품은 1,800rpm으로 2 시간을 유지한다. 정격성능 충족 엔진은 1,800rpm으로 1시간 15분이나 1시간 5분을 유지할 수도 있다. Shin et al.(1996)의 BAO 모델과 같이 정비되어 정격성능은 충족 하나 이전보다는 상태가 떨어진 것이다. 승조원들은 성능저하를 느끼고 정비를 요청 하지만, 정비종료 후 시운전시에 이전 같은 성능은 아니라고 느낄 뿐 기록을 남기지 않는다. 정비기간은 종료되었고 정격성능은 만족하기 때문에 다음 계획정비시 재요청 한다.

불완전 정비 수준에 대한 기록이 정확히 남아있지 않으므로 완전 정비율 추정을 위해서는 승조원의 느낌을 수치화 해야한다. 사전지식을 바탕으로 추정해야하므로 베이

지안 추정을 활용한다. 사전분포에는 사전지식을 포함할 수 있고 데이터와 결합하여 적절한 사후분포를 도출하게 된다. 정비율에 대한 사전분포는 승조원을 대상으로 한 설문조사를 바탕으로 한다. 설문 결과를 분석하여 사전분포를 선정한다(정비율 사전분포). 또 <그림 2-14> 데이터의 연차별 평균 고장량을 바탕으로 고장발생의 범위를 사전분포로 선정한다(고장확률 사전분포). 고장량과 정비율의 두 사전분포와 고장 데이터가 결합되어 고장확률 사후분포와 완전 정비율 사후분포가 도출된다.

베이지안 모델은 장비의 고장과 정비의 순서를 바탕으로 구성한다. 고장 사전분포에서 추출된 임의수량의 고장이 발생하면 정비율 사전분포에서 추출된 임의의 정비 확률만큼 수리된다. 수리되지 못한 불완전 정비건은 함정에 남은채 다음 계획정비시 포함되어 다시 요청된다. 고장과 정비의 순환 구조를 베이지안 통계언어 Stan을 활용하여 모델링하고 HMC 샘플링을 수행한다. 샘플링을 통해 추정된 사후분포는 2가지이다. 하나는 승조원의 설문을 통한 사전지식과 데이터가 결합되어 추정된 완전 정비율 분포이다. 다른 하나는 수명 연차별 고장확률이다(일반고장함수). Piecewise 형태의 일반고장함수가 도출되며, 이는 관측 데이터와 비교하여 사후분포가 적절한 범위에서 추정되는가에 대한 검증의 용도로 활용된다.

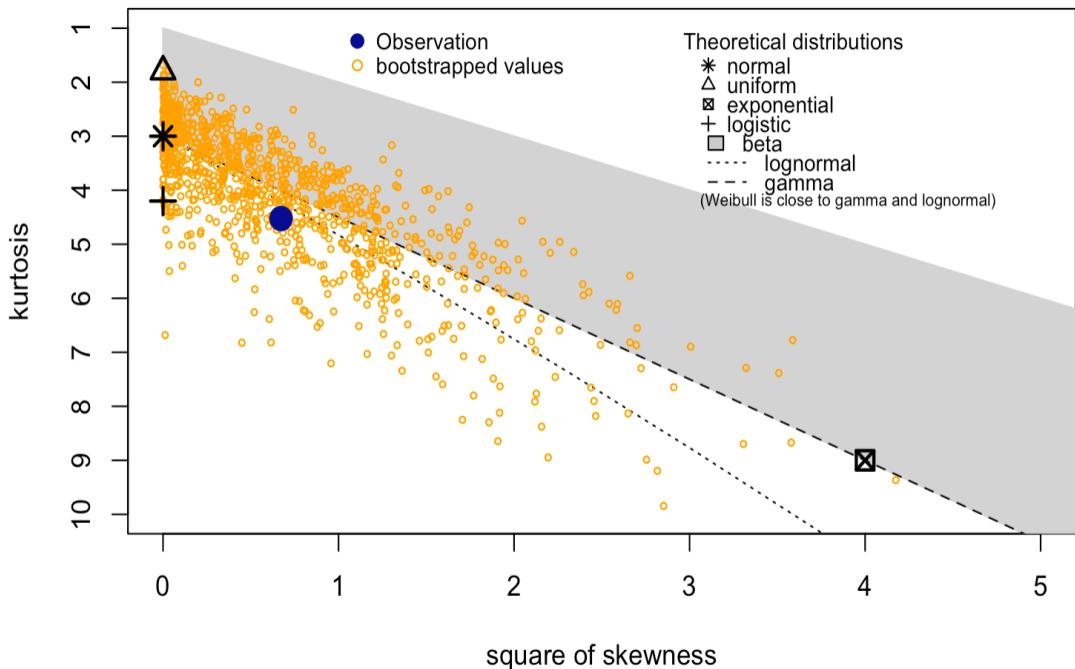
일반적으로 내연기관은 6,000여개의 부품으로 구성된다. 해군 전투함 추진용 디젤엔진의 부품이 6,000개라고 가정한다. 6,000개의 부품중 10년차에 100개가 고장난 후 80개가 완전 정비되었을 때 불완전 정비된 부품수는 20개이다. 11년차에 50개가 고장나면 승조원들은 이전년도에 불완전 정비된 20개와 새로 고장난 50개를 합쳐 70개를 정비요청한다. 11년차에 20개중 10개가 불완전 정비되고 50개중 5개가 불완전 정비되었을 때 12년차에 새로 발생한 고장 150개와 10개, 5개를 합쳐 165개를 정비요청하게 된다. 이와 같은 방법으로 총수명동안 불완전 정비된 부품은 계속 정비요청된다.

본 절의 연구에 대한 보다 자세한 내용은 Choi and Moon(2021)을 통해 확인할 수 있다.

1. 고장확률 사전분포 추정

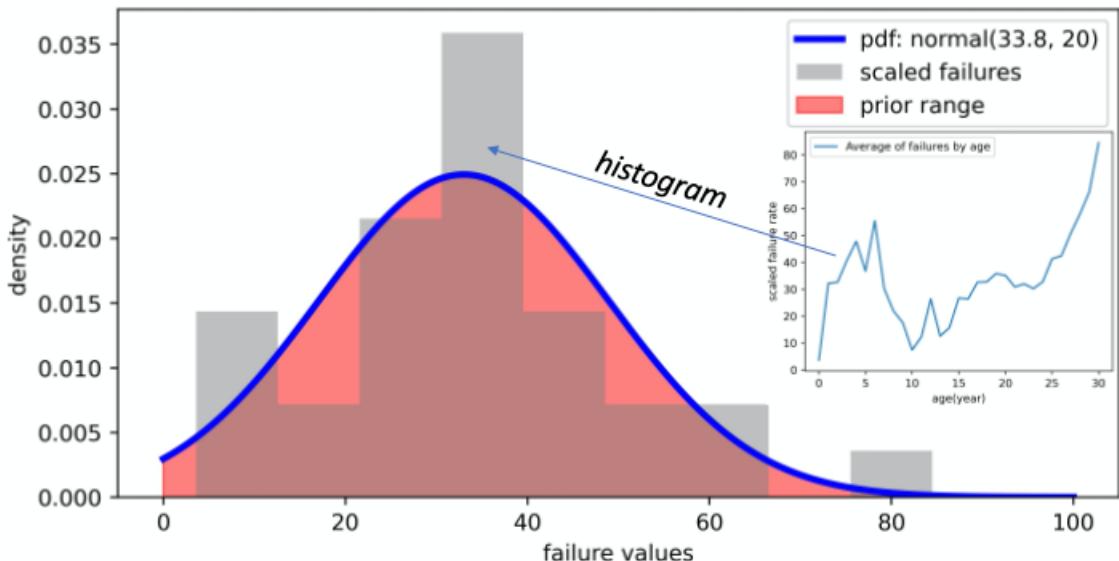
실증적 베이지안(Empirical bayesian inference)에서 사전분포 결정 과정을 사전분포 도출(prior elicitation)이라고 한다. 데이터는 모집단이 아니므로 특정 분포를 결정하는 과정은 복잡하다. 예를들어 특히 전문가의 의견이 좌편향 감마분포인데 데이터가 정규분포의 형태를 띠는 경우에는 더욱 어렵다. 사전분포 형태 결정을 위해 프로그래밍 언어 R에서 제공하는 Cullen and Frey 그래프를 활용하였다. Cullen and Frey 그래프는 입력된 데이터의 왜도(skewness)와 첨도(kurtosis)를 분석하여 유사한

Cullen and Frey graph



<그림 4-1> 고장 데이터의 Cullen and Frey 그래프

분포들의 후보를 시각적으로 제공해준다(Cullen and Frey, 1999). <그림 4-1>은 연차별 평균 고장량 데이터를 Cullen and Frey 그래프로 분석한 것이다. 관측 데이터(Obsevation)은 파랑색으로 한곳에 몰려있다. Cullen and Frey 그래프는 데이터의 형태를 고려한 븗스트랩(Bootstrap) 결과를 동시에 추정한다. 븗스트랩된 데이터(주황색)는 넓게 펴져있다. 사용자는 그래프에 표시된 데이터의 위치에 따라 적절한 분포를 선택할 수 있다. 븗스트랩된 데이터는 정규(normal), 감마(Gamma), 와이블(weibull), 로그정규(lognormal)의 주변에 고밀도로 분포된다. 베타분포 범위에는 븗스트랩 데이터가 가장 많이 포함된다. 사전분포는 특정 모수를 필요로 한다. 베타분포와 같이 광범위한 표현이 가능한 분포는 특정 모수를 결정하기 힘들다는 문제가 있다. 사전분포 후보에서 제외하였다. 후보모델의 비교는 AIC(Akaike information criterion)를 활용하였다. AIC는 모델의 예측 에러를 평가하는 방법으로 모델 선정(model selection)에 많이 사용된다(Kuha, 2004; Vrieze, 2012). 4개의 후보 분포를 MLE(Maximum likelihood estimate) 적합 후 AIC 비교 결과 정규분포의 AIC값은 264.81로 다른 후보 분포(와이블: 266.29, 감마: 267.16, 로그정규: 272.1)보다 작았다. 정규분포의 모수는 $\mu = 33.8$, $\sigma = 16.9$ 였다. 적합된 모수는 데이터에 최적합된 분포이므로 강정보 사전분포(Strongly informative prior)이다. 강정보 사전분포를 활용하면 베이지안 추정과정에서 새로운 정보의 반영이 어렵다(Gajewski et al., 2008; Zhang and



<그림 4-2> 고장확률 사전분포

Long, 2010; Jiang et al., 2015). 상대적으로 약정보 사전분포(Weakly informative prior)는 데이터에 포함되지 않은 새로운 정보의 가능성을 염두해둔다. 고장확률 사전 분포의 편차를 상향조정하여 약정보 사전분포의 효과를 반영하였다. <그림 4-2>는 고장확률 사전분포 적합 결과이다. 붉은색 음영부분이 사전분포 범위이다. 베이지안 모델을 구축하고 HMC 샘플링을 수행하면 붉은 범위에서 샘플들이 추출된다. 데이터는 2 ~ 4장에서 다룬 해군 전투함 추진용 디젤엔진의 연차별 평균 고장량을 히스토그램으로 표현한 것이다. 평균값이므로 데이터는 총 31개(1 ~ 31년)이다. 데이터가 적은 만큼 사전분포의 선정이 중요하고 약정보 사전분포로 변환하는 것이 중요하다. 고장 확률은 0보다 작을 수 없다. 사전분포의 범위에서 0이하의 부분을 제거해야한다. 0이하의 부분을 제거하면 사전 확률분포의 합은 1보다 작다. Stan에서는 분포 범위의 일부를 사전확률 샘플링 구간으로 선정 가능하다.

2. 정비율 사전분포 추정

함정 디젤엔진을 관리하는 승조원들은 해군에 입대함과 동시에 엔진 정비와 관리에 대해 교육받는다. 디젤엔진의 교육은 실제 장비를 육상에 비치하여 직접 분해, 조립, 작동하는 식으로 이루어진다. 최소 6개월 이상의 전문 교육을 마친 승조원은 함정에 승조하게 된다. 해군의 디젤엔진은 출력에 따라 기통수와 사이즈가 다를 뿐 구조는 대동소이하다. 승조원들은 계획정비 기간을 제외하면 매일 엔진을 정비한다. PMS(Planned maintenance system)는 함정에 근무중인 승조원이 직접 정비를 수행

하여 장비상태를 점검 유지하기 위해 수행된다. 이 과정에 승조원들은 디젤엔진에 대한 전문성이 크게 향상된다. 통상적으로 2년 이상 함정 승조경험이 있는 중사 이상급의 부사관 계층의 엔진 운영관리 경력은 교육기간을 포함하여 3년 이상이 된다. 이들은 엔진을 직접 분리하여 정비를 수행하고 다시 조립할 정도의 전문적인 수준을 갖추고 있다.

정비율 사전분포는 함정 승조원의 설문을 통해 추정한다. 설문은 2021년 2월 15일 ~ 2월 24일 기간중 해군의 000급 000함 등 3척과 육상에 근무중인 내연기관 담당장 19명을 대상으로 수행하였다. 19명의 승조원들은 최소 2년 이상 디젤엔진 운영관리 경력이 있는 전문가들이다. 설문 대상자 현황은 <표 4-1>과 같다.

<표 4-1> 설문 대상자 현황

military class	Experience on board(year)						Total
	0 ~ 3	3 ~ 5	5 ~ 10	10 ~ 15	15 ~ 20	20 ~	
Officer				1			1
Chief petty officer					3	1	4
Petty officer	2	5	5	2			14
total	2	5	5	3	3	1	19

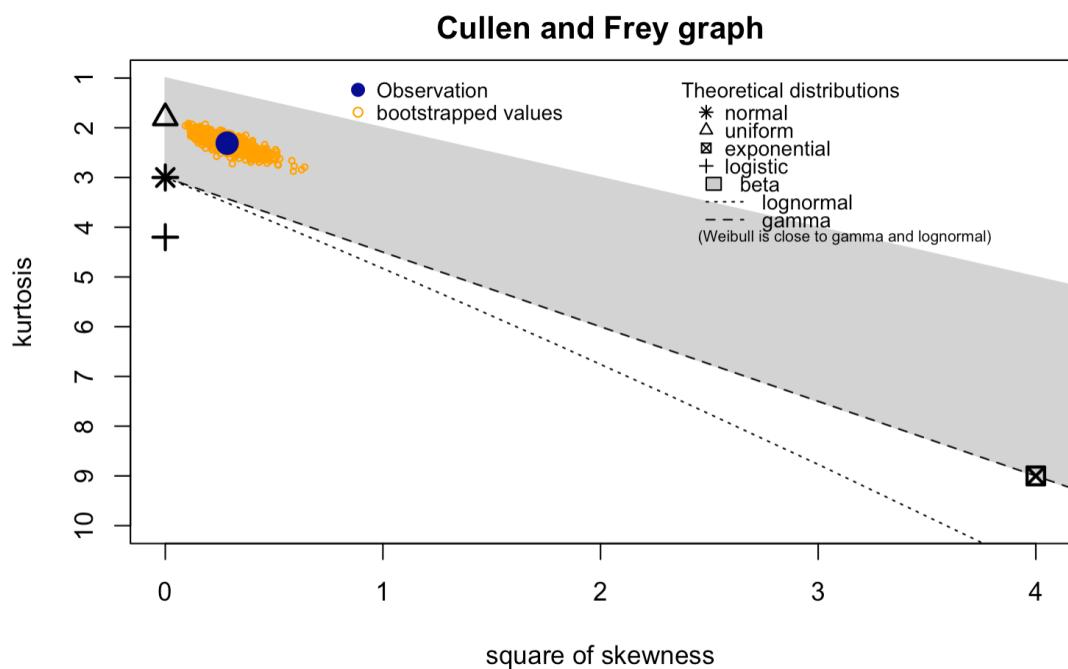
승조원들은 정격성능을 발휘하고 있지만 성능이 일부 저하된 부분까지 모두 정비요청한다. 승조원들이 요청한 정비목록은 장비의 상태저하 개소 전체를 식별한 것으로 가정한다. 이 가정을 바탕으로 승조원들은 2가지 설문에 응답하였다.

- Q.1. What percentage of the total degraded parts are identified by mechanics.
- Q.2. What percentage of the identified total degraded parts are completely repaired?

설문항목 Q.1과 Q.2는 정비효과에 동시에 영향을 미친다. Q.1은 정비 범위에 영향을 미친다. 승조원이 100건의 정비요청을 했다고 가정하자. Q.1의 식별능력이 90%라면, 정비부대에서 수리하는 정비건은 90건이 된다. Q.2는 90건의 정비목록 중 몇 건이 완전정비 되는가에 대한 질문이다. Q.2가 90%라면 최종적으로 승조원이 요청한 100건의 정비 중 81건($100 \times 0.9 \times 0.9$)은 완전정비되고, 19건은 불완전정비되어 다음 계

<표 4-2> 설문 응답결과

Survey number	Response range(%)			
	60 ~ 70	70 ~ 80	80 ~ 90	90 ~ 100
Q.1	-	10	3	6
Q.2	5	5	6	3

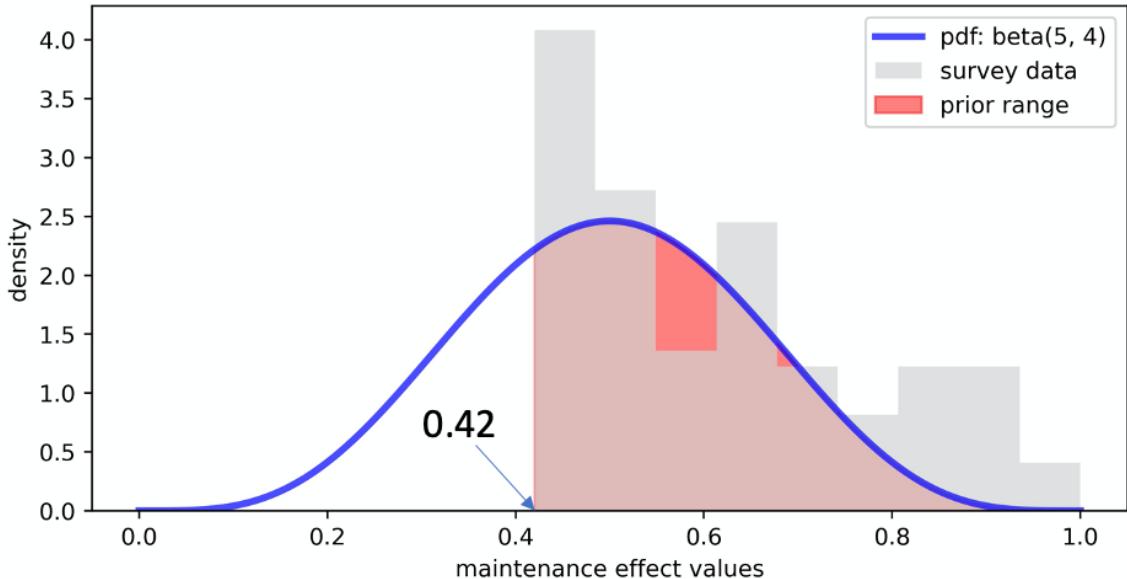


<그림 4-3> 정비율 데이터의 Cullen and Frey 그래프

회정비시 다시 요청된다. 최종적으로 정비율은 81%가 된다. 피설문자 19명은 전원 2 가지 질문에 응답하였다. 응답결과는 <표 4-2>와 같다.

설문항목 2가지는 각각의 경우의 수(Q.1: 19, Q.2: 19)를 고려하여 조합하였다. 정비율 데이터는 총 361개(19×19)가 된다. 361개의 데이터를 활용하여 고장확률 사전분포와 동일하게 Cullen and Frey 그래프를 통해 분포를 선택하고, MLE 추정으로 적정 모수를 선택하였다.

<그림 4-3>은 정비율 데이터 361개에 대한 Cullen and Frey 그래프이다. 븋스트랩 데이터들이 고장확률 데이터와 달리 수렴되어 있다. 정규, 일양, 감마분포와 가깝지만 단정짓기에는 모호하다. 데이터의 수렴정도와 모든 데이터가 베타분포의 범위에 포함되어 있다는 점을 고려하여 정비율 사전분포의 형태는 베타분포로 선정하였다. MLE



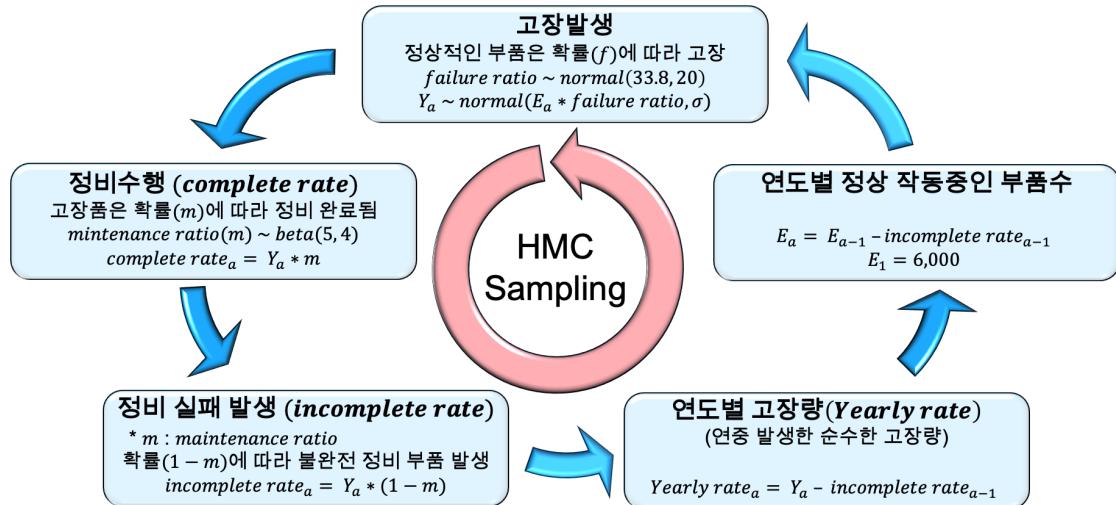
<그림 4-4> 정비율 사전분포

과정을 통해 적정 모수는 $\alpha = 4.61$, $\beta = 2.90$ 이 추정되었다. 약정보 사전분포 효과를 위해 모수 범위를 수정하여 <그림 4-4>와 같이 최종적으로 $beta(5, 4)$ 를 정비율 사전분포로 추정하였다.

설문조사 데이터를 통한 정비율 데이터의 최소값은 0.42이었다. 사전분포의 범위는 베이지안 통계언어 Stan을 활용하여 제한하였다.

3. 완전 정비율 추정 모델 구축

베이지안 모델은 고장으로 인한 승조원의 정비요청, 정비, 불완전 정비로 인한 재요청 순서로 구성된다. <그림 4-5>는 모델 구축과정을 표현한 것이다. 고장확률(Failure ratio)에 따라 고장난 엔진 부품은 계획정비 기간동안 수리된다. 완전 정비율(Maintenance ratio)에 따라 부품은 정비 완료되거나 불완전 정비된다. a년도의 고장 부품수에서 a-1년도에 불완전 정비된 부품수를 제외하면 a년도에 발생한 새로운 고장 부품의 수가 된다. a년도에 발생한 새로운 고장 부품의 수를 본 연구에서는 순수한 고장량(Pure failures)이라고 지칭한다. 일반적으로 내연기관은 사이즈의 차이가 있을뿐 구성 부품의 수는 6,000여개로 대동소이하다. 최초 디젤엔진의 부품수를 6,000개라고 할 때 a년도에 고장나지 않은 부품의 수는 a-1년도의 정상작동중인 부품수에서 a-1년도에 불완전 정비된 부품의 수가 된다.

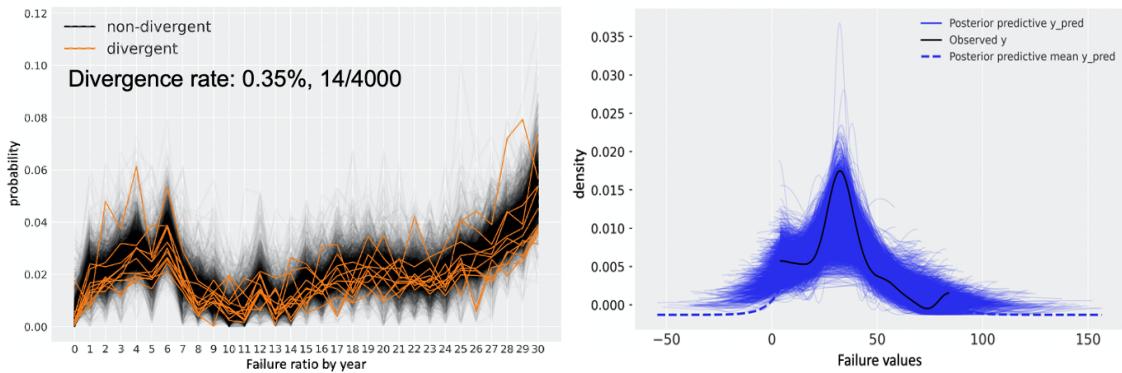


<그림 4-5> 고장과 정비 프로세스

$$\begin{aligned}
 & maintenance ratio \sim Beta(5, 4) \\
 & failure ratio \sim Normal(33.8, 20) \\
 & complete rate_a = Y_a * maintenance ratio \\
 & Incomplete rate_a = Y_a * (1 - maintenance ratio) \\
 & yearly rate_a = Y_a - Incomplete rate_{a-1} \\
 & E_1 = 6,000 \\
 & E_a = E_{a-1} - Incomplete rate_{a-1} \\
 & Y_a \sim Normal(E_a * failure ratio, \sigma)
 \end{aligned} \tag{2}$$

위 과정을 식(2)와 같이 표현할 수 있다. *maintenance ratio*와 *failure ratio*는 정비율과 고장확률의 사전분포이다. Y_a 는 해군 전투함 추진용 디젤엔진의 연차별 평균 고장량이다. Y_a 는 동시에 승조원이 요청한 정비건수(데이터)이며, 성능저하된 전체 부품수이다. 성능저하 부품들은 *maintenance ratio*에 따라 완전정비되거나 불완전 정비된다. Y_a 는 정규분포를 따른다고 가정하였다. Y_a 의 평균은 a년도의 고장부품수가 되고, 표준편차는 별도로 지정하지 않았다. Stan에서는 모수의 분포를 별도로 지정하지 않는 경우 무정보 사전분포로 간주되고, HMC 샘플링 과정에서 충분히 넓은 모수 공간을 탐색하도록 설계되어 있다(Carpenter et al., 2017; Hoffman and Gelman, 2014).

Stan의 진단기능을 통해 HMC 수렴 여부를 확인하였다. <그림 4-6>은 HMC 체인의 발산정도를 진단한다. 0.35%의 샘플들이 수렴하지 않았다. <그림 4-6>에서 주황색으로 표시된 선들은 수렴하지 않은 샘플들에 해당한다. <그림 4-7>의 사후예측분포에서는 샘플 발생 범위 내에 관측 데이터가 존재하여 적절하게 샘플링 된 것으로 판단된



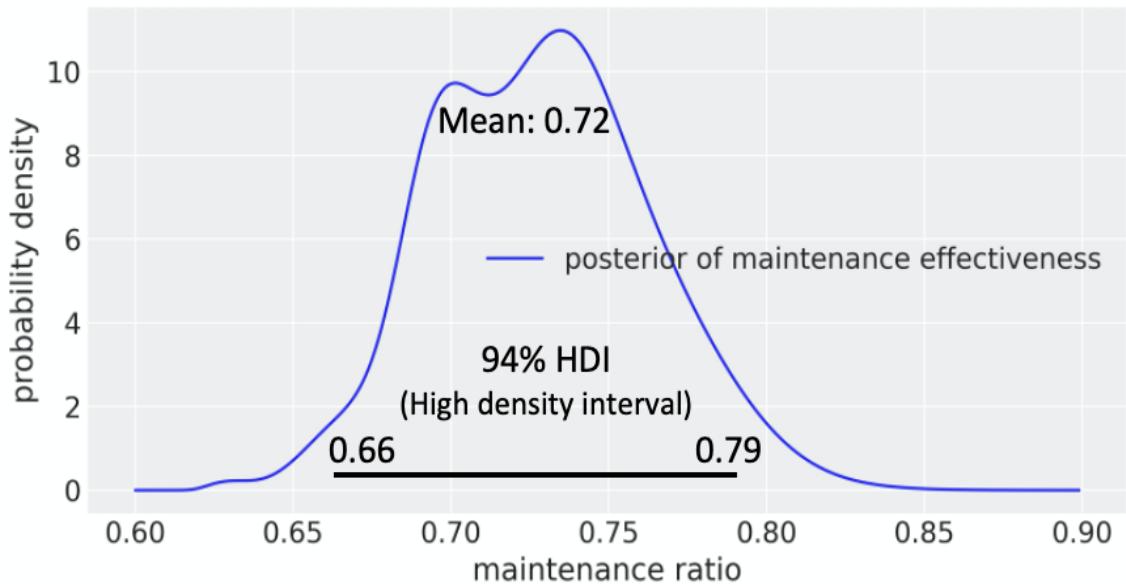
<그림 4-6> 고장확률 샘플링의 발산 진단

<그림 4-7> 고장확률 사후 예측 분포

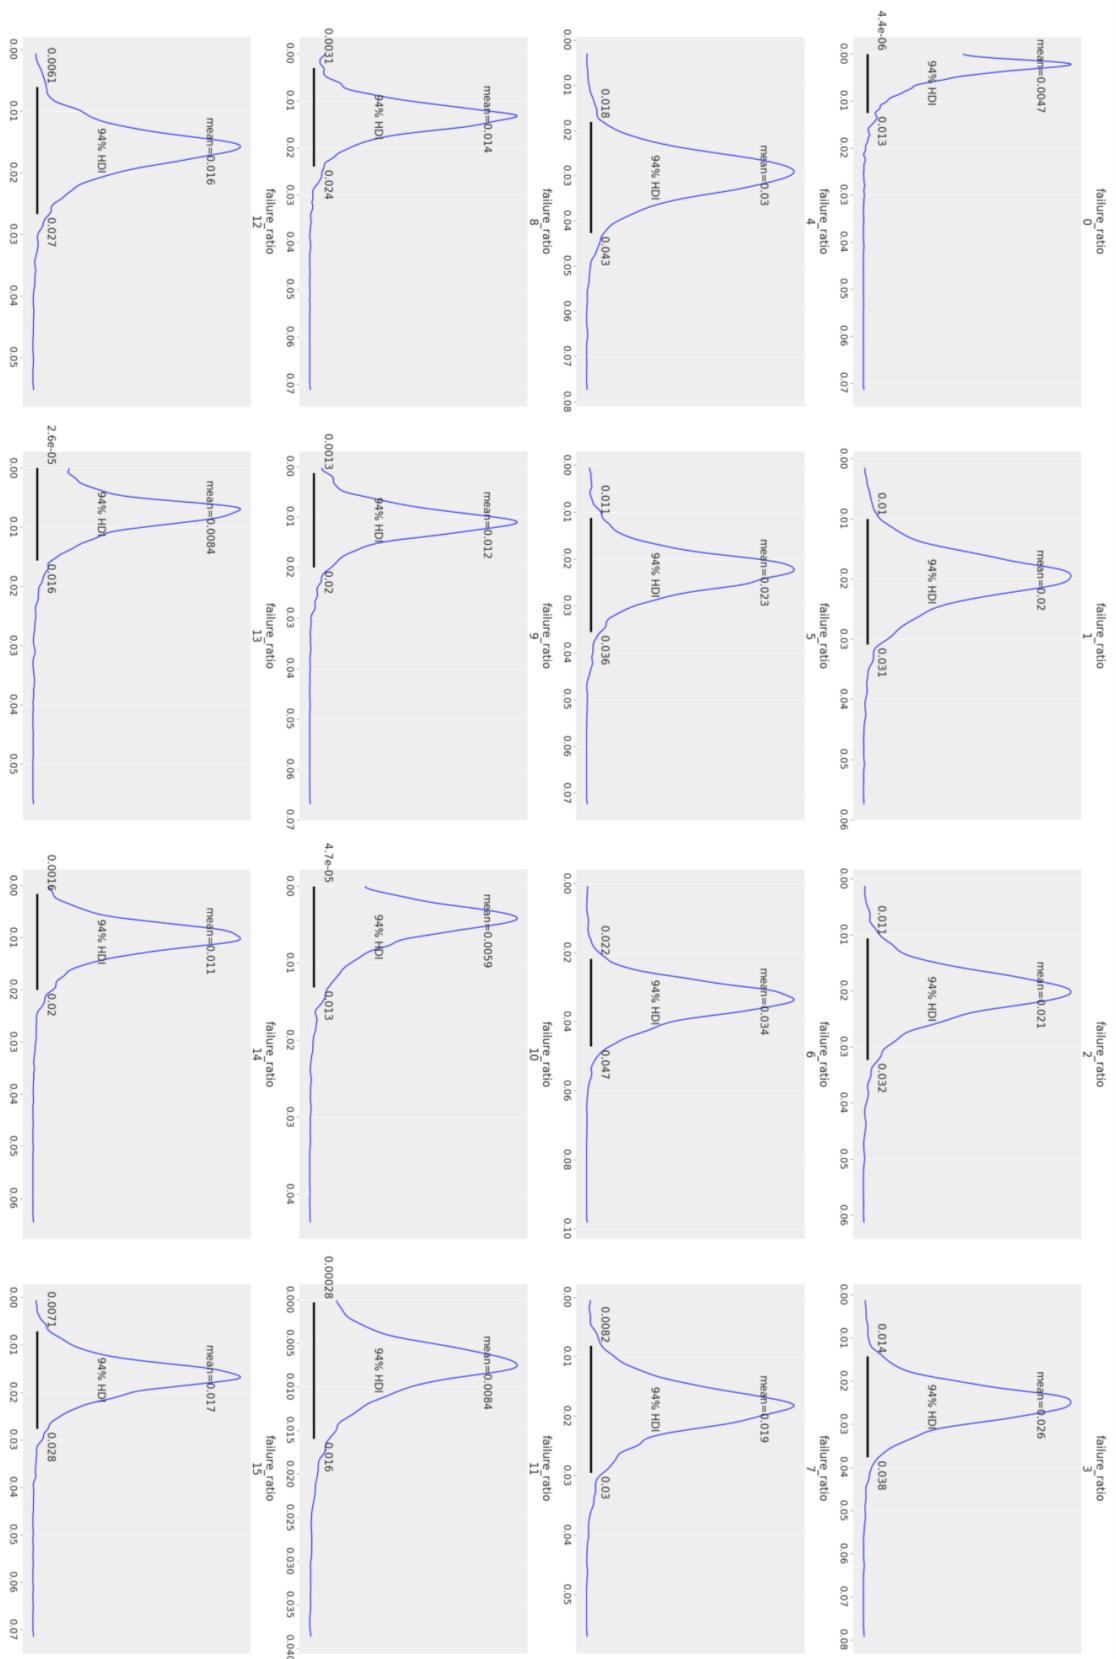
다. R-hat과 BFMI 진단 결과는 문제없었다. Carpenter et al.(2017)은 모든 샘플들이 수렴할 때까지 모두 수정과정을 거치길 추천한다. 0.35%의 발산이 있으나 데이터의 수가 매우 적고(연차별 평균 고장량 31개 데이터), 기타 진단 항목들이 모두 이상 없다는 점을 고려하여 사후분포 추정에 큰 영향 없다고 판단하였다.

4. 완전 정비율 추정 결과 분석

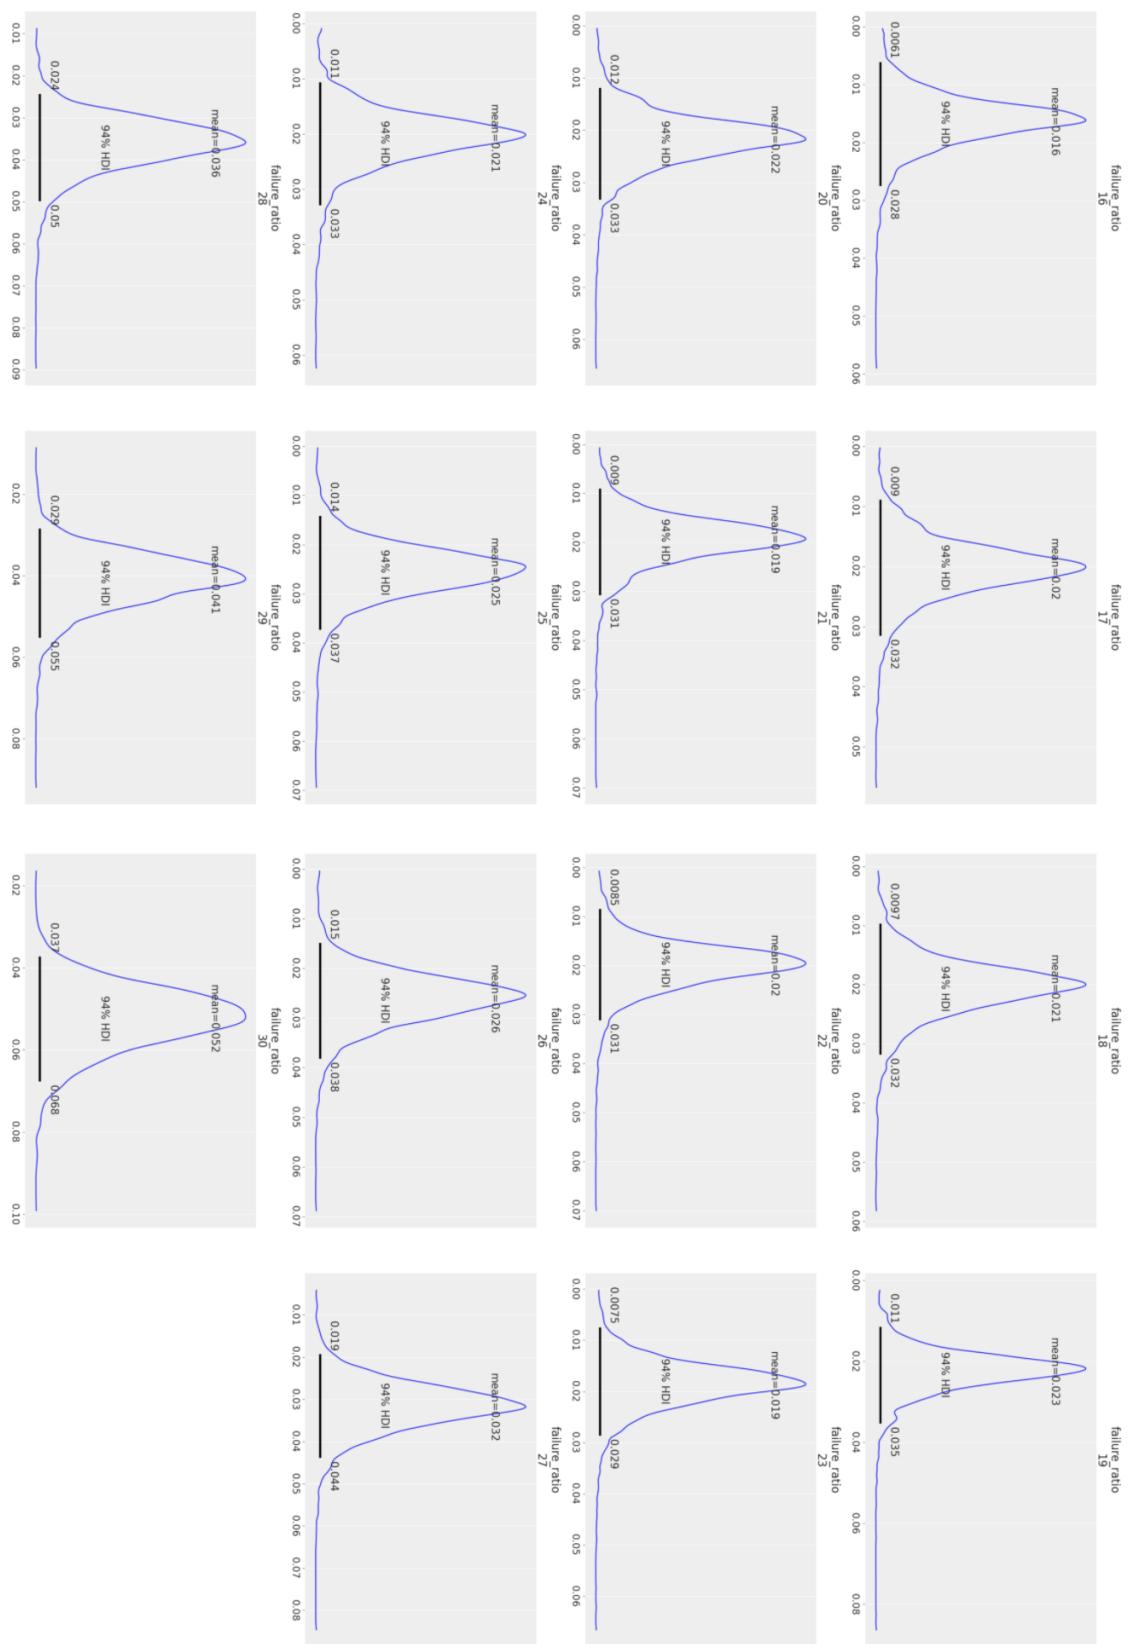
HMC 샘플링을 통해 식(2)의 모수들이 추정되었다. <그림 4-8>은 정비율의 사후분포이다. 정비율의 사전분포는 $\text{beta}(5, 4)$ 였다. 0.42이상의 범위에서 설정된 베타분포였으나, 사후분포 추정결과 평균은 약 0.72였다. 해군의 완전정비 가정과 달리 72% 수



<그림 4-8> 정비율 사후분포 추정결과

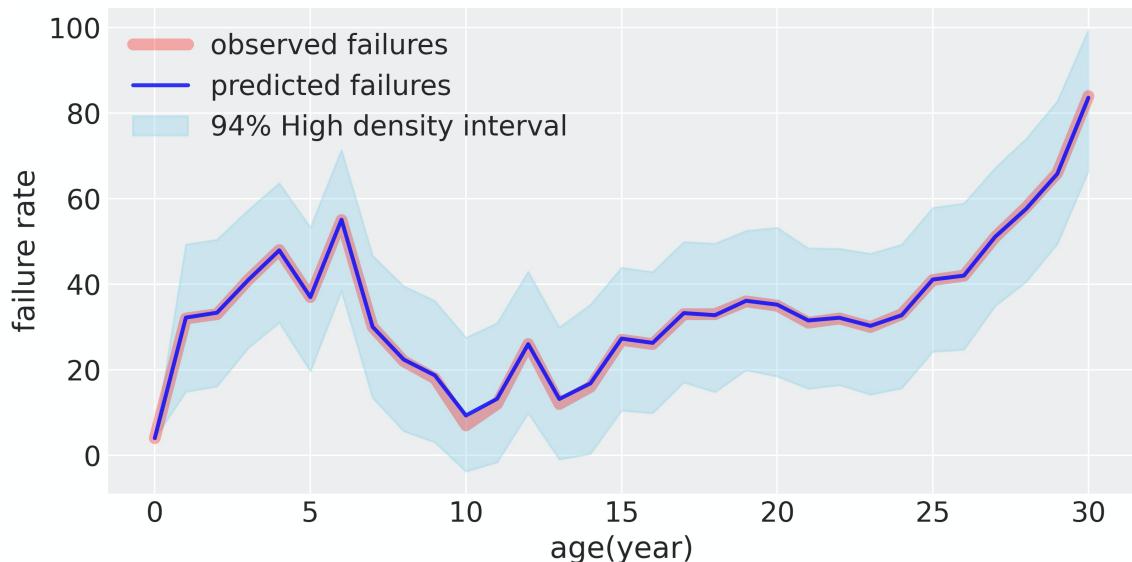


<그림 4-9> 고장률 사후분포 추정결과(0 ~ 15년)



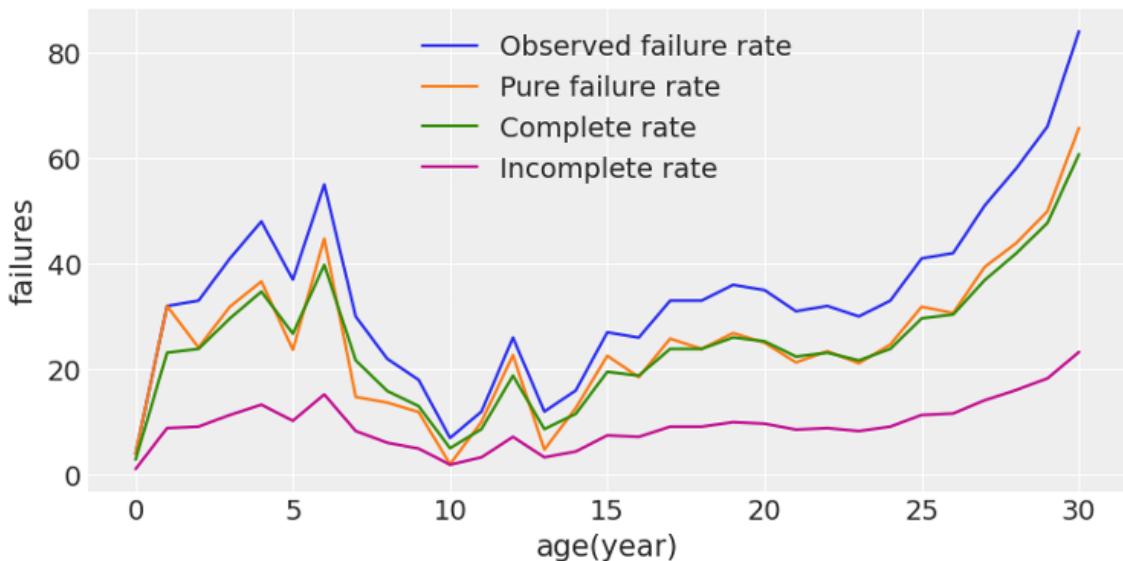
<그림 4-10> 고장확률 사후분포 추정결과(16 ~ 30년)

준의 정비효과가 있는 것으로 분석되었다. 94% HDI(High density interval)가 0.66 ~ 0.79로 추정되었다는 것은 전체 정비의 94%는 66 ~ 79%의 정비효과가 발생한다는 의미가 된다. 100%를 가정하는 완전정비에 비하면 굉장히 낮은 수준이다. <그림 4-9>와 <그림 4-10>은 고장률 사후분포 추정결과이다. 고장률 사후분포는 설문 조사 결과를 포함하여 재도출한 연차별 고장량의 일반고장 확률분포이다. <그림 4-9>와 <그림 4-10>의 일반고장함수는 연차별 평균 고장량과 설문 데이터만으로 추정된 일반고장함수이므로 정확도 측면에서 2장의 일반고장함수보다는 신뢰성이 낮다. 단, 연차별 고장 발생의 범위를 추정하였다는 점에서 의미가 있다. 고장률 사후분포의 평균값들은 최소 0.0059에서 최대 0.052까지 분포되어 있다. 6,000개의 엔진 부품 중 최소 36개($6,000 * 0.0059$)에서 최대 312개($6,000 * 0.052$)의 부품이 연중 상태가 저하되거나 고장날 수 있다. <그림 4-11>은 고장률 사후분포를 활용하여 연차별 고장량을 예측한 것이다. 예측결과의 평균값이 파랑색 진한 선으로 표시되었고, 94% 고밀도 구간(HDI)가 주변에 하늘색으로 음영처리 되었다. 붉은색 선은 관측 데이터의이다. 관측 데이터와 예측 결과가 거의 일치한다. HMC 샘플링 결과 소량의 발산(0.35%)이 있었으나 모델은 잘 추정되었다고 할 수 있다.



<그림 4-11> 연차별 고장량 예측결과

<그림 4-12>는 추정된 사후분포들을 활용하여 각 변수들을 사후예측한 결과이다. 고장 데이터인 파랑색 선은 연중 발생한 순수한 고장량(주황색, pure failure rate)와 이전년도에 발생한 불완전 정비량(자주색, Incomplete rate)의 합이된다. 예를들어 1년차의 관측 고장량은 1년차에 발생한 순수한 고장량과 0년차의 불완전 정비량의 합이다. 완전 정비량(Complete rate)과 순수한 고장량은 유사하다. 완전 정비량과 순수



<그림 4-12> 고장 관련 변수들의 사후 예측 결과

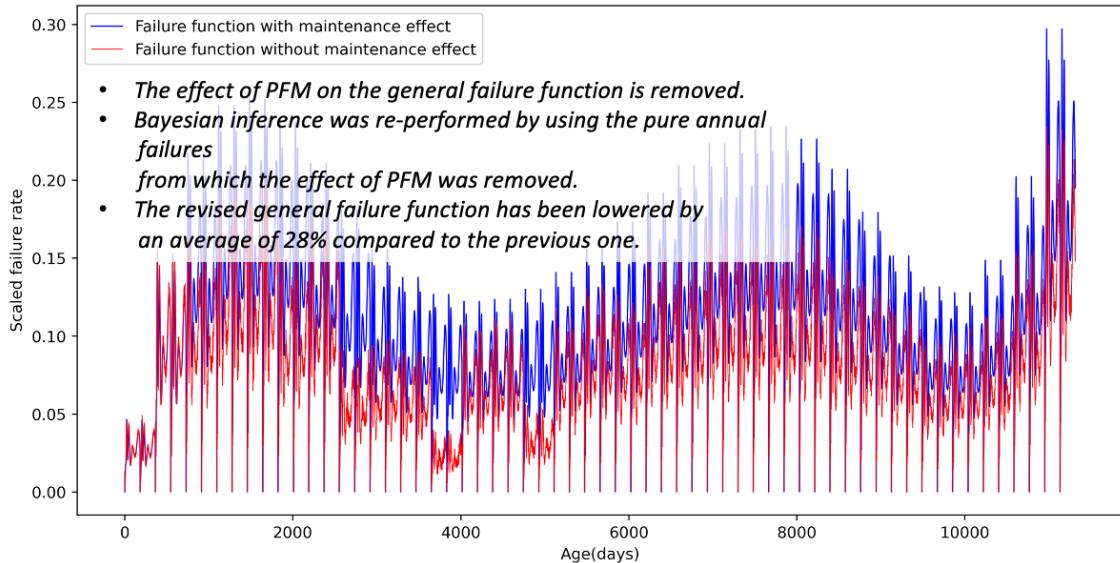
한 고장량의 유사하다는 것은 순수한 고장량이 정격성능 이하로 떨어진 고장량이라고 해석할 수 있다. 정비부대는 승조원이 요청한 정비건 중 정격성능 이하로 떨어진 개소에 대해서만 정비를 수행한다고 할 수 있다. 즉, 정비부대는 예방정비(Preventive maintenance)보다 고장정비(Corrective maintenance)의 기능을 수행한다.

5. 완전 정비율을 활용한 일반고장함수 재도출

2 ~ 3장에서 예서 추정한 일반고장함수는 승조원이 요청한 정비데이터를 기반으로 추정되었다. 일반고장함수에는 정비부대 정비능력에 따라 약 28% 정도의 불완전 정비가 누적되어 포함되어 있다. 즉, 주기 고정형 정비(PFM)의 정비효과가 반영되어 있다고 할 수 있다. 간격 최적화 정비(IOM)와 고장량 고정형 정비(FFM) 시뮬레이션 과정에는 PFM의 정비효과 반영된 일반고장함수가 사용되었다. IOM과 FFM의 효과를 비교하기 위해서는 일반고장함수에서 PFM 정비효과를 제거해야 한다.

일반고장함수의 추정에 적용된 데이터를 <그림 4-12>에서 추정된 순수 고장량으로 교체하였다. 2장의 과정에 따라 계층형 베이지안 모델을 활용하여 연단위의 일반고장함수를 도출하였다. 연단위의 일반고장함수를 다시 일단위로 내삽(interpolation)하였다. 최종적으로 PFM 정비효과가 제거된 일반고장함수를 <그림 4-13>과 같이 도출하였다.

본 절에서는 정비부대 정비능력 2가지 중 정비부대의 완전 정비율을 추정하였다. 해군의 완전 정비 가정과 달리 베이지안 추정결과 평균 72% 수준의 정비효과가 있었



<그림 4-13> PFM 정비효과가 제거된 일반고장함수

다. 정비효과의 사후분포를 활용하여 연간 발생하는 순수한 고장량을 도출하였다. 순수한 고장량은 데이터에 포함된 기존의 정비 정책(PFM)의 효과를 제거한 것이다. 순수한 고장량을 활용하여 일반고장함수를 다시 도출하였다.

제 2절 정비원의 유동적 정비능력 추정

해군의 정비기간은 엔진의 크기나 용도와 무관하게 모두 1.5개월로 고정되어 있었다. FFM을 도입하면 정비원의 업무량은 평준화되기 때문에 1.5개월간 일정한 수준의 정비를 수행하게된다. PFM은 정비시마다 정비량이 다르다. 수명말기 함정의 정비가 시작되면 정비량이 많고, 수명중반 함정의 경우는 정비량이 상대적으로 적다. 사람이 하루에 할 수 있는 업무량은 정해져 있음에도 불구하고 함정의 사이즈나 연차와 무관하게 정비기간이 고정되어 있다. 정비량이 많은 경우 모든 수리를 수행하기 위해서는 정비원의 수가 많아져야 한다. 정비원이 부족하면 불완전 정비로 이어질 수 있기 때문이다.

1절에서 언급한바와 같이 함정 승조원도 정비를 수행한다. 승조원은 매일 같은 장비를 운영하고 정비하기 때문에 정비능력도 상당한 수준이다. 본 연구에서 다루고 있는 디젤엔진의 정비능력은 특히 우수하다. 전투체계나 무기체계 장비들과 달리 해군의 창설과 동시에 디젤엔진이 활용되었고 누적된 정비 기능과 노하우가 대대로 전수되기 때문이다. 과거로부터 축적된 정보들은 교육부대에 보존되어 초임 간부와 병사를 교

육하는데 활용된다. 디젤엔진의 경우 실물 장비를 교육부대에서 갖추어 직접 실습할 수 있는 시스템이 갖춰진지 오래다. 정비부대 정비원들은 군무원으로 구성되고 있으나 정비의 최종 검수는 승조경력이 많은 부사관이 수행한다. 그만큼 승조원의 정비능력이 우수하다는 의미이다.

승조원들은 매일 장비를 운용하고 정비한다. 정비지침페이지라는 문서에 의거하여 소요 인원과 공시를 계획한다. 예를들어 정비지침페이지에는 A정비의 필요인원을 상사 1명의 2시간, 중사 2명의 2시간과 같은 형식으로 규정한다. A정비는 3명이 2시간씩 정비할 것을 요구한다. 인원수와 소요시간은 계급별로 구분되며 계급별로 정비능력이 비슷한 수준이라고 가정된다. 정비능력은 개인의 성향이나 능력에 따라 다를 수 있다. 디젤엔진과 같이 해군에서 운용된지 오래되어 관리 노하우가 많은 장비는 특히나 개인별 정비능력의 차이가 많이 날 수 있다. 정비능력은 정비 소요시간에 직접적인 영향을 미친다.

개인의 정비능력이 우수하면 빠른 시간에 정비를 마칠 수 있다. 그러나 정비가 일찍 끝났다고 다른 정비를 수행하진 않는다. 하루 표준 일과는 8시간으로 규정되어 있다. 계획정비제도(PMS: Planned maintenance system)는 정비지침페이지에 규정된 소요 공시를 합쳐 하루에 8시간인 경우 정비를 수행하지 못하게 되어있다. 즉 개인의 능력이 우수하여 정비를 빨리 끝내도 하루에 최대 8시간치의 정비만을 수행해야 한다. 8시간치 이상의 업무를 수행하면 오히려 징계의 대상이 된다.

계획정비제도는 해군 정비관리규정(2018)에 명시되어 있다. 정비관리규정은 1985년부터 시행되었다. 계획정비제도가 정확히 언제 규정에 포함되었는지 확인 불가하나, 정비지침페이지의 소요공시가 전체적으로 검토된 실적은 전무하다. 매년 검토를 수행하고 있으나 신규나 삭제 대상의 정비목록을 갱신하는 수준이다. 교육부대의 정비교육 시스템이 발전하고 우리나라의 기초교육 수준이 높아짐에 따라 현 시대 승조원들의 정비능력은 과거보다 우수할 가능성이 있다. 즉 정비지침페이지에 규정된 공시는 실제 필요 공시보다 많이 책정되어 있을 수 있다.

한편 과거에 비해 승조원들은 많은 정비부담을 느끼게 된다. 과거에 비해 작전구역이 넓어졌고, 훈련 등의 소요도 많아졌다. 승조원들이 계획정비제도에 투자할 수 있는 시간적 여유가 적어졌다는 의미이다. 승조원들은 함정이 모항에 입항해있는 기간에 8시간치의 정비를 계획한다. 계획된 일정 중 다른 업무로 소요되는 시간을 고려하면 실제 정비에 투자할 수 있는 시간은 8시간보다 적다. 그럼에도 불구하고 모든 정비가 수행된다. 실제 정비에 걸리는 시간은 규정보다 짧다는 의미이다.

사람의 업무속도는 업무량보다 남은 잔여 업무시간의 영향을 받는다는 과거의 연구가 있었다. 업무시간에 비해 해야할 업무량이 많으면 업무속도가 증가한다는 연구였

다. 승조원이 정비 수행에 걸리는 시간은 정비지침페이지보다 짧을 것이다. 그 이유는 과거에 비해 승조원의 교육수준이 높기 때문일 수 있고, 과거에 비해 승조원의 일정이 바빠져 정비를 빠르게 수행해야하는 상황이 되었을 수 있다.

본 절에서는 승조원을 대상으로 설문을 수행하여 정비지침페이지에 규정된 소요공시 대비 실제 정비에 걸리는 시간을 베이지안 추정하였다. 추정된 정비소요시간에 대한 사후분포와 과거의 연구들을 비교하여 적절성을 판단한다. 과거의 연구와 추정된 사후분포를 적용하여 시스템 다이나믹스 모델을 구축한다.

정비소요시간의 베이지안 추정에 대한 세부내용은 Choi et al.(2021)에서 확인 가능하다.

1. 정비소요시간 추정 모델 구축과 결과

설문 대상과 기간은 <표 4-1>과 동일하다. 설문 문항은 5가지이나 질문은 모두 동일하다.

- *Q. Please answer based on your current class. Assume that you perform the maintenance of Examples 1-5. How long does it take for the mechanic to actually perform the maintenance on the example?*

설문 문항의 1~5번 예시는 정비수행주기에 따라 5가지 항목을 한 개씩 제시하였다. 정비지침페이지는 수행 주기에 따라 크게 7가지(Daily, Weekly, Monthly, Quarterly, Semi-annually, Annually, Requirement) 종류로 구분 가능하다. 이중 Daily와 Annually를 제외한 5가지에 해당하는 정비지침페이지를 한 개씩 예시로 제공하였다. Weekly(W) 항목은 매주 1회 이상 실시해야하는 정비이다. 수행 빈도가 잦은만큼 승조원의 정비 숙련도가 매우 높다. Semi-annually(S) 항목은 반년에 1회 이상 수행하는 항목이고 수행빈도가 낮아 승조경력에 따라 숙련도의 차이가 날 수 있는 항목이다. Monthly(M)과 Quarterly(Q)는 각각 월, 분기주기로 수행하는 정비항목으로 W건과 S건의 중간정도 빈도로 수행된다. Requirement(R) 항목은 장비 작동상황에 따라 정비를 수행한다. 설문에 제시된 R건의 정비주기는 약 4개월이다.

피실험자는 정비지침페이지를 보고 본인이 수행하는데 걸리는 실제 시간을 작성한다. 피실험자의 계급이 정비지침페이지의 규정 계급보다 상급일 경우, 본인이 지켜본 해당 계급 승조원들이 정비를 수행하는데 걸리는 실제 시간을 작성한다. 하사계급 1명 4시간 소요로 규정된 정비항목의 경우를 예로 들어보자. 하사계급인 피설문자는 본인이 해당 정비를 하는데 소모되는 실제 시간인 3시간을 작성하면 된다. 중사계급

인 피설문자는 본인이 지켜본 하사 계급자들이 해당 정비에 소모하는 실제 시간인 2.5시간을 작성하면 된다. 이와 같은 방법으로 19명의 피실험자들은 5건의 설문에 모두 응답하였다.

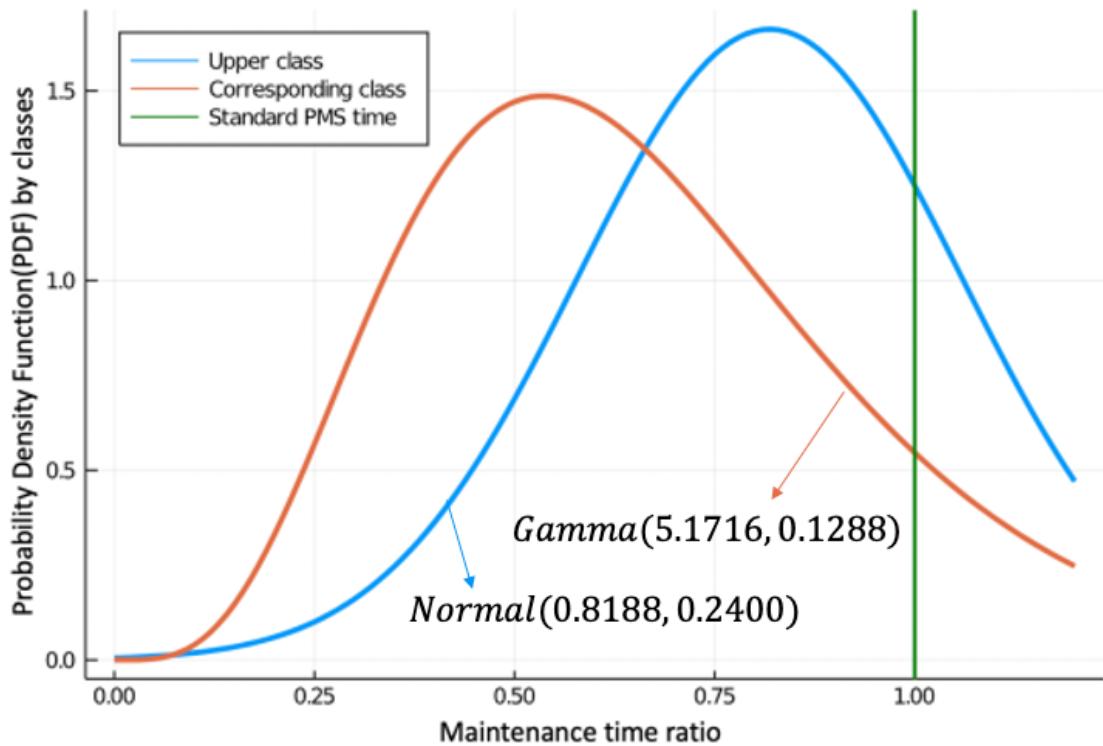
정비지침페이지의 종류는 매우 다양하다. 같은 장비의 정비건이라도 정비 난이도에 따라 정비 인원이 다르고, 시간도 다르고 규정되어 있다. 본 절의 연구에서는 정비 시간만을 고려한다. 설문 대상으로 제시한 5건의 정비 항목은 기준 계급과 시간이 다르다. 따라서 기준공시 대 응답결과의 비율로 설문 데이터를 정리하였다. 비율 수정된 설문결과는 설문 항목과 무관하게 같은 기준으로 비교할 수 있다. 설문 응답 내용을 비율 수정한 결과는 <표 4-3>과 같다.

<표 4-3> 설문 응답 내용의 비율 수정 결과

Maintenance interval	Ratio of standard consumption time			
	Corresponding class		Upper class	
	Mean	Std.	Mean	Std.
Weekly	0.5333	0.2422	0.8154	0.2882
Monthly	0.3778	0.3692	0.8500	0.2901
Quarterly	0.6095	0.4271	0.4998	0.1926
Semi-annually	0.7857	0.3231	0.8333	0.2887
Requirement	0.6220	0.3233	1.1666	0.2357
Total	0.6665	0.2933	0.8188	0.2400

1보다 큰 값은 규정 공시보다 실제 정비시간이 짧다고 대답한 것이고, 1보다 작은 값은 실제 정비시간이 규정공시보다 짧다는 것이다. R건을 제외한 모든 정비 항목에 대한 응답 결과가 실제 정비시간이 규정 공시보다 짧다고 응답하였다. 전반적으로 해당 계급들은 상위 계급들이 생각한 것보다 빠르게 정비를 수행할 수 있다고 답하였다. M건의 경우 해당계급의 평균은 0.3778, 상위 계급의 평균은 0.85이다. 상위 계급이 생각하는 절반수준의 시간에 정비를 수행할 수 있다는 의미가 된다. 상위 계급과 해당 계급의 차이는 교육이나 시간적 여건에서 기인할 수 있으나 세부적인 원인 분석은 시행하지 않는다.

해당 계급과 상위 계급의 응답결과는 베이지안 추정의 사전분포로 추정된다. 해당

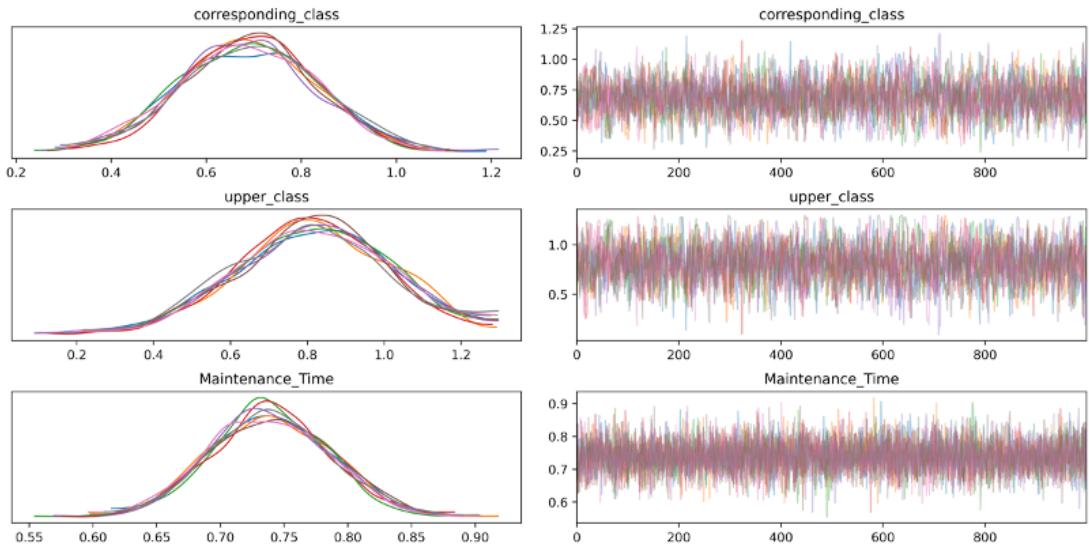


<그림 4-14> 상위계급과 해당계급의 사전분포 추정결과

계급 사전분포와 상위 계급 사전분포를 추정하고 데이터를 통한 HMC 샘플링을 통해 실제 정비소요시간에 대한 사후분포를 도출한다. 사전분포 추정방법 중 분포의 형태는 Cullen and Frey 그래프를 활용하였고, 해당 분포의 모수는 MLE 추정하였다. 4.1절과 같은 절차이나 본 절의 연구에서는 약정보 사전분포를 적용하지 않는다. 추가 데이터로 통한 베이지안 업데이트를 염두하는 것보다 두 사전분포의 정확한 결합이 중요하기 때문이다. 정비지침페이지의 기준시간(Standard PMS time)은 비율조정되어 1이다. 두 사전분포는 Stan에서 0보다 작아지지 않는 범위로 축소된다.

$$\begin{aligned}
 &\text{Corresponding} \sim \text{Gamma}(5.1716, 0.1288) \\
 &\text{Upper} \sim \text{Normal}(0.8188, 0.2400) \\
 &\text{Maintenance Time} = 0.6047 * \text{Corresponding} + 0.3953 * \text{Upper} \\
 &Y \sim \text{Normal}(\text{Maintenance Time}, \text{std})
 \end{aligned} \tag{3}$$

식(3)은 베이지안 모델이다. 해당계급(Corresponding)과 상위계급(Upper)의 사전분포가 포함된다. 정비소요시간(Maintenance Time)은 두 사전분포의 가중합으로 구성된다. 가중치는 설문의 응답수이다. 상위 계급의 응답수는 총 34개이고, 해당 계급의 응답수는 총 52개이다. 설문수에 따라 해당계급 사전분포에 0.6047(52/86), 상위계급 사전분포에 0.3953(34/86)을 부여하였다. 우도함수(Likelihood) Y는 정규분포를 가정

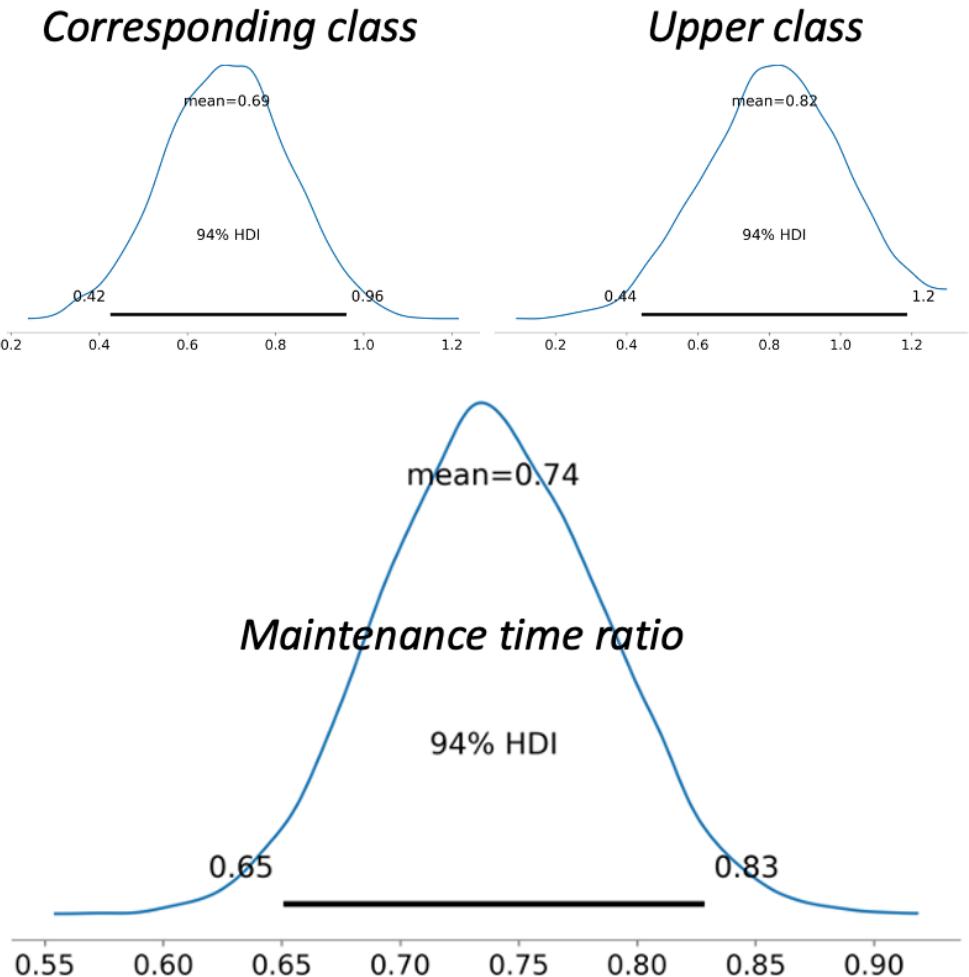


<그림 4-15> 해당계급, 상위계급, 정비 소요시간의 HMC 샘플링 결과

하였다.

<그림 4-15>는 해당계급, 상위계급, 정비소요시간에 대한 HMC 샘플링 결과이다. 상단의 3개 그림은 각 모수의 trace plot을 나타낸 것이다. 좌측은 체인별 KDE(Kernel density estimation) 결과이고 우측은 각 체인의 수렴성을 나타낸 것이다. 시각적으로 모든 체인의 수렴여부에 이상없음을 판단할 수 있다. 기타 Stan에서 제공하는 진단요소인 R-hat, BFMI, Marginal energy 등 모두 이상 없었다. <그림 4-16>은 모수들의 사후분포 추정결과이다. 위 두 개의 그래프는 해당계급과 상위계급의 사후분포이다. 해당계급은 규정시간 대비 평균 69%의 시간으로 정비를 수행할 수 있고, 상위계급은 해당계급이 평균 82%의 시간으로 정비가 가능할 것으로 본다고 할 수 있다. 해당과 상위계급들을 가중합한 결과 평균 74%의 시간으로 정비를 수행할 수 있다고 추정되었다. 고밀도 구간은 65 ~ 83%로 대부분의 정비를 규정대비 약 17% 빠르게 정비를 수행할 수 있다는 의미가 된다.

평균적으로 74% 빠르게 정비를 수행할 수 있다는 것은 하루 표준 일과시간인 8시간 중 5.92시간에 정비를 마칠 수 있음을 의미한다. 나머지 2.08 시간은 하루 최대공시의 제약 때문에 정비를 수행하지 못하는 시간이 된다. 약 26%의 정비시간이 절약되는 이유는 교육여건 개선을 통한 승조원들의 정비능력 향상, 함정 일정의 과다로 인한 실제 정비시간의 축소 등이다. 단 26%의 정비시간 단축 원인을 승조원의 정비능력 향상 한가지로 단정 짓기는 어렵다. 사람의 업무속도는 시간 대비 업무량에 따라 유동적으로 변할 수 있기 때문이다.



<그림 4-16> 해당계급, 상위계급, 정비 소요시간의 사후분포

2. 업무속도의 변화에 관한 문헌 연구

26%의 단축된 정비시간은 승조원의 정비능력 향상 외에도 업무속도 향상의 이유를 들 수 있다. 과거 해군은 작전 임무와 모항 대기를 반복하며 계획적으로 함정을 운용하였다. 현재 해군은 평상시 작전 임무 외에 다른 임무들이 많아졌다. 한국 해군이 강군이 되면서 주변국들과의 연합작전이 생기고, 개발도상국의 해군 발전을 위한 지원 등 과거에는 없던 부가적인 임무들이 많이 생겼다. 기존의 작전 일수가 축소되거나 개선되지는 않았다. 천안함 피격이나 연평도 포격 도발 사건과 같은 북의 무력 도발은 기존의 경비 작전 구역을 넓히고, 작전일수를 증가시키거나 새로운 경비 구역을 추가하게 하였다. 과거와 비교하여 현재 해군의 임무는 많아진 상태이다.

임무가 다양하다보니 임무 준비를 위한 추가적인 일정들이 하루일과에 포함되었다. 하루 표준 일과시간인 8시간 중 최소 2시간 이상은 승조원이 공통적으로 참여해야하

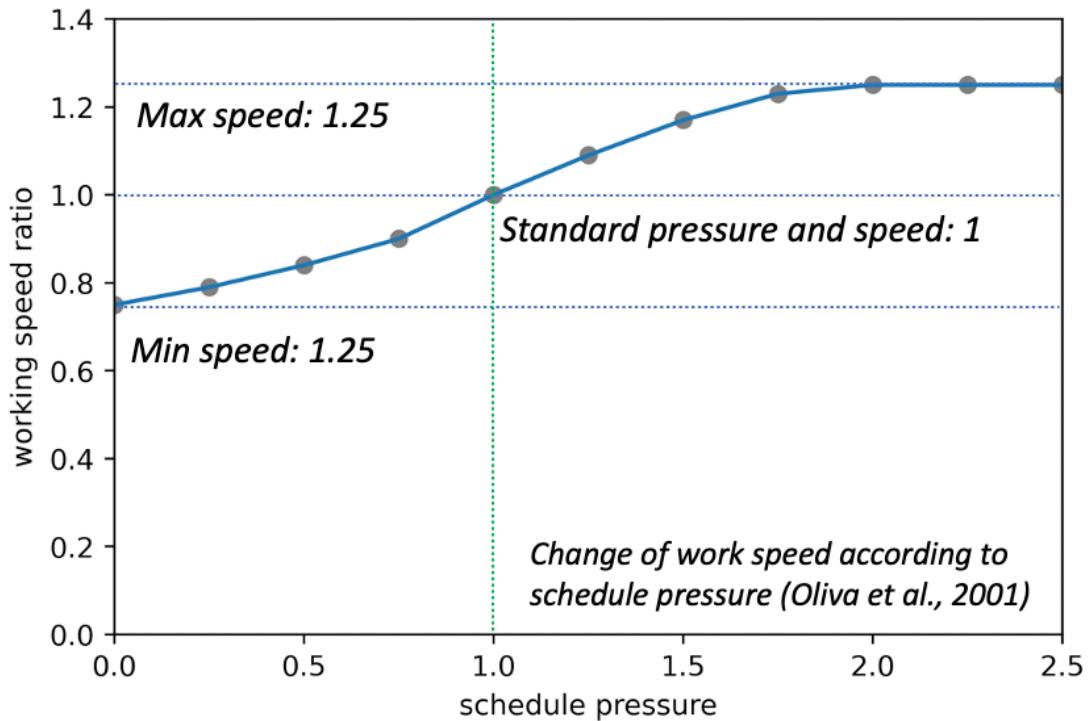
는 일과가 차지한다. 정비 일정이 시급한 경우 승조원 공통 일과에 불참할 수 있으나 군의 조직 문화상 쉽지 않다. 함정의 작전 임무는 늘어나고, 승조원의 정비 업무 시간은 줄어들었다. 시간적 측면에서 정비에 투자할 수 있는 시간이 감소하였다.

한편 함정 승조원의 수는 줄어들고 있다. 장비와 무기체계가 과학화되어 과거와 같은 수동식 장비운용을 자동화 운용체계로 대체하고 있기 때문이다. 함정 장비는 기본적으로 자동 - 반자동 - 수동작동이 가능하다. 자동화 불가시에는 수동으로 장비를 작동할 수 있어야 한다. 장비가 자동화되었다고 해도 장비 운용과 상태 점검을 위해서는 수동작동도 지속적으로 운용해야 한다. 결국 장비의 자동화가 업무의 축소로 이어졌다고 할 수는 없다.

군의 인력감축 정책도 승조원의 수를 줄이는데 영향을 주고 있다. 과거에는 예비개념의 승조원들이 편성되어 있었다. 정규 승조원에게 개인적인 문제가 생겼을 때 작전 수행을 대체할 예비 승조원을 운용할 수 있었다. 현재는 정책적으로 정규 편성 승조원의 수를 감축하고 있다. 승조원의 수가 줄어들면서 개인이 해야 할 업무량은 늘어났다. 초임 간부 전역의 주요 사유 중 하나는 과도한 업무량이다. 작전구역의 변화나 승조원 공통 일과 참여 등은 승조원들이 정비할 수 있는 시간을 축소시킨다. 인원 감축은 승조원 개개인의 업무 할당량을 증가시킨다.

시간과 업무량의 관계에 대한 과거의 연구들이 있었다. 파킨슨의 법칙(Parkinson's law)은 업무시간에 따라 업무속도가 달라진다는 법칙이다. 파킨슨은 2차 대전 중 해군 사무원의 수와 업무 처리량의 관계를 수학적으로 모델링하였다(Parkinson and Osborn, 1957). 사무원의 수가 많으면 개인별 업무 할당량은 줄어든다. 업무량이 적음에도 불구하고 업무시간은 줄어들지 않았다. 파킨슨은 업무속도가 업무량보다 일과 시간의 영향을 받는다고 주장하였다. Oliva and Sterman(2001)은 은행원들의 업무량과 그에 따른 속도 변화를 측정하였다. 측정결과를 <그림 4-17>과 같이 함수화 하였다. 일정압력(Schedule pressure)은 시간과 업무량의 관계를 의미하는 함수이다 (Sterman, 2000). 해군의 일과는 하루에 8시간이다. 8시간 공시의 업무를 수행한다면 일정압력은 1이다. 반면 하루에 12시간 공시의 일을 처리해야한다면 일정압력은 1.5(12/8)이 된다. 즉 일정압력이란 표준 업무량 대비 수행해야할 업무량이 된다. 하루에 8시간 공시의 업무를 부여하면 모두 처리할 수 있다. 이때의 업무속도는 1이다. 12시간 공시의 업무를 부여하면 업무속도는 일정압력 함수에 따라 1.17이 된다. 이때 실제 수행하는 업무량은 9.36시간(8×1.17) 공시가 된다. Oliva and Sterman(2001)은 일정압력 함수에 따라 업무속도가 최대 125%까지 증가하거나 최소 75%까지 감소한다고 하였다.

일정압력과 관련된 연구는 특정 업무분야에 국한되지 않고 다양하게 적용되었다. 건



<그림 4-17> 일정압력과 업무속도의 관계

설공사 현장 노동자(Nepal et al., 2006), 컴퓨터 프로그램 개발 업무(Rai and Mahanty, 2002)나 병원 응급실의 대기인원 수에 따른 진료속도(Kim et al., 2006) 등에서 일정압력으로 인해 업무속도가 변한다는 것이 확인되었다. 일정압력으로 업무 속도가 증가하면 피로도(Fatigue)가 발생할 수 있다. 피로도는 일정압력의 부산물 (Demerouti et al., 2001)로 업무능력을 떨어뜨려(Moon et al., 2004; Homer, 1999) 업무 오류를 증가시킨다(Olson, 1980)는 연구들이 있었다. 따라서 일정압력은 피로도로 인해 업무효율을 증가시키지 못하고(Abdel, 1989; Abdel and Madnick., 1986; Putman, 1978), 오히려 감소시키는 방향으로도 작용할 수 있다 (Thibodeau and Dodson, 1979). Choi et al.(2000)은 시간의 흐름에 따른 휴대전화의 타이핑 속도 변화와 오타율 측정 실험을 하였다. 실험에서 시간의 흐름은 피로의 누적이 된다. 이를 통해 일정압력과 피로도의 관계를 정량적으로 측정하였다. 단 실험의 내용이 매우 단순하여 일반화된 효과라고 할 수 없었다. 따라서 본 연구에서 피로도는 고려하지 않는다.

해군 승조원들은 이론적인 하루 최대 공시인 8시간치의 정비를 수행할 것으로 계획한다. 정비지침페이지의 공시를 확인하여 정비계획을 정보체계에 입력한다. 정비가 계획된 당일에 승조원 공통 업무가 많아 정비에 실제 투자할 수 있는 시간이 4시간이었

다고 가정해보자. 통상적으로 승조원 공통 업무는 오전, 또는 오후로 구분되고 4시간을 넘기지 않는다. 현실적으로 정비가 불가능할 정도의 승조원 공통 업무가 계획되면 정비계획을 지연시키거나 야간 근무를 통해 해결한다. 4시간 동안 8시간 공시의 업무를 수행해야한다. 이때 일정압력은 2가 되고, 업무속도는 1.25배가 된다. 총 8시간 공시의 정비 중 5시간치($4 * 1.25$)의 정비를 수행할 수 있다.

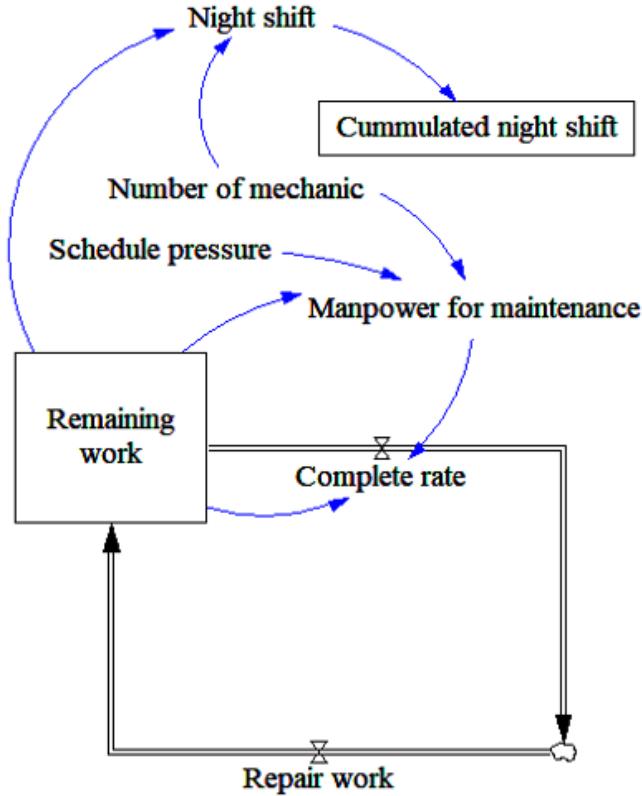
예시의 상황은 함정 정박중 빈번하게 발생한다. 작전임무의 증가로 모항 대기일수가 줄어들었기 때문이다. 탄약 탑재나 부식 적재 등 승조원들의 공통된 일과를 처리해야 하는 정도는 과거와 유사하나 모항 대기 일수가 적으로 승조원들이 정박 중 정비에 투자할 수 있는 시간이 짧다. 그럼에도 불구하고 승조원들은 8시간치의 정비를 모두 수행하고 정보체계에 정비완료 기록을 남긴다.

일정압력에 따라 최대 수행 가능한 공시는 5시간치 업무이나, 실제로는 8시간치 공시를 모두 완료한다. 3시간 공시는 정비능력의 향상에서 원인을 찾을 수 있을 것으로 판단된다. 정비소요시간 사후분포의 평균은 0.74이고 94% HDI는 0.65 ~ 0.83였다. 정비소요시간이 0.74일 때 8시간 공시 업무 수행에 걸리는 실제 시간은 5.92시간 ($8 * 0.74$)이다. 일정압력에 따라 5시간 공시 업무를 수행했다면 0.92 공시 업무가 남는다. 잔여 공시 업무는 점심시간을 활용하거나 소량의 초과 근무를 통해 해소 가능하다. 단, 정비소요시간 사후분포 추정은 승조원 설문을 바탕으로 수행했기 때문에 응답 결과에 일정압력이 포함되어 있을 가능성이 높다. 설문 응답 결과와 일정압력의 상관성에 대해서는 향후 심도있는 연구가 필요하다.

3. 실 정비소요시간을 고려한 시스템 다이나믹스 모델 구축

본 연구에서는 승조원의 설문결과에 일정압력의 효과가 포함되어 있다고 가정하였다. 정비 가능 시간의 축소로 승조원들은 항상 일정압력을 높게 느끼는 편이라고 가정하였다. 정비소요시간 사후분포 74%는 높은 일정압력을 느끼는 상황이라고 볼 수 있으며 이는 Oliva and Sterman(2001)의 최대 업무 속도 1.25배와 유사하다.

정비부대 정비원들의 상황도 승조원들과 유사하다. 해군의 전력증강 계획에 따라 정비 대상 함정은 계속 증가해왔으나 정비부대의 규모는 크게 변하지 않기 때문이다. 정비원도 승조원과 같이 정비지침페이지를 가지고 있다. 정비원의 정비지침페이지에는 정비항목별 정비원 계급, 공시가 부여되어 있다. 정비원들도 정비부대 공통 업무가 있어 실제 정비시간은 표준 시간보다 적다. 정비원의 교육체계도 승조원 동급 이상으로 구축되어 있다. 승조원과 정비원의 정비환경은 유사하다. 그러므로 본 연구에서는 승조원과 정비원의 업무속도 변화가 <그림 4-17>의 일정압력 함수를 따른다고 가정하였다.



<그림 4-18> 일정압력을 반영한 정비부대 모델

<그림 4-18>은 일정압력을 반영한 정비부대 정비원의 업무 프로세스를 시스템 다이나믹스 모델로 구축한 것이다. Repair work을 통해 입장함정의 누적된 일반고장이 투입된다. Remaining work에 축적된 입고 함정들의 일반고장은 수행한 정비만큼 줄어든다. 정비원의 수는 OO함대 디젤엔진 담당의 수를 반영하여 9명으로 설정하였다. 9명의 정비원들은 일정압력(Schedule pressure)을 고려하여 하루에 할 수 있는 정비량(Manpower for maintenance)이 결정된다. 누적 정비량이 일정수준 이상으로 많은 경우 정비원들은 야간 근무(Nightshift)를 통해 정비량을 해소한다. 정비원들의 일정압력은 식(4)와 같다.

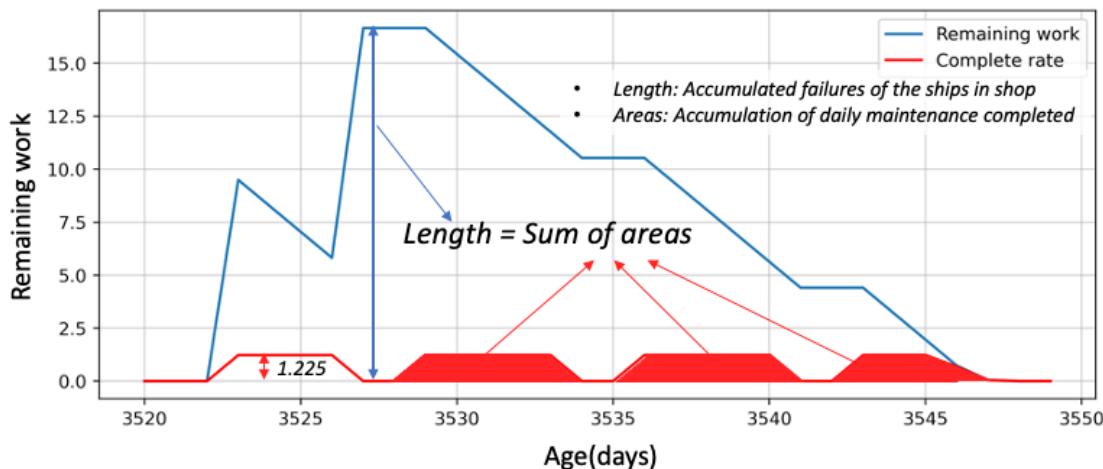
$$\text{Schedule pressure of mechanic} = \frac{\text{Remaining work}}{\text{Number of mechanic} * \text{Standard workload}} \quad (4)$$

식(4)에서 Standard workload는 하루 표준 공시 8시간치 업무량이다. 잔여 업무량을 표준공시 업무량과 정비원의 수의 곱으로 나누면 정비원들의 일정압력이 된다. 정비원들의 일정압력은 같은 부서의 업무이므로 개인적인 차이가 없이 모두 동일하다고 가정한다.

3장에서 언급한바와 같이 정비부대의 가동률은 낮게 유지되는 것이 좋다. 함정의 긴급정비 소요가 생기거나 육경, 해경과 같은 지원업무가 발생할 수 있기 때문이다. 긴급한 소요에 대비하기 위해 정비원들은 업무가 들어오면 최단시간 내 정비를 마치려고 노력한다. 실제로도 함정이 정비부대에 입고되면 정비원들은 야간근무를 하며 빠른 정비를 수행한다. <그림 4-17>에서 일정압력은 2이상일 때 업무속도는 1.25로 유지된다. 본 연구에서는 일정압력이 2를 넘으면 야간근무를 수행한다고 가정하였다.

승조원의 경우와 마찬가지로 일정압력이 2를 넘으면 업무속도 향상을 고려해도 표준 일과 시간 중에 정비를 마칠 수 없기 때문이다.

비율 조정된(scaled) 일반고장함수에서 PFM의 평균 정비량은 14.71이었다. 정비부 대에서는 최대 2척의 정비를 수행한다. PFM은 1.5개월간 수행되므로 정비일 하루의 평균 정비능력은 $(14.71*2)/45 = 0.65$ 이다. 야간근무는 하루 최대 4시간까지만 허용되면 이때 하루 최대 공시는 12가 된다. 야근 수행시 정비능력은 $0.98(0.65*1.5)$ 이다. 정비원은 9명이므로 개인의 정비능력은 0.07(야근시 0.11)이다. 일정압력이 최대가 될 때 개인의 정비능력은 0.09(야근시 0.13)이 된다. 개인의 정비능력을 시스템 다이나믹스 모델의 Manpower for maintenance 변수에 반영하고 일정압력과 정비원의 수에 따라 변하도록 모델을 구성하였다.



<그림 4-19> 잔여 고장량과 정비 완료량

<그림 4-19>는 모델의 Remaining work와 Complete rate의 그래프 중 3,520 ~ 3,550일 부분을 발췌한 것이다. 세로축의 길이는 함정이 입고되어 축적된 잔여 정비량(Remaining work)이자 완료한 정비량(Complete rate)이다. 축적된 정비량은 하루 최대 정비량을 고려하여 빠져나간다. 정비수행은 평일에만 이루어지기 때문에 7일 중 2일의 정비량은 0이다. 하루에 정비할 수 있는 최대 정비량의 최대값은 야간근무를 포함하여 $1.225(14.71*2/45*1.5*1.25)$ 이다. 함정이 입고되면 정비창의 업무량(Remaining work)은 크게 증가한다. <그림 4-19>에서는 2대의 함정이 연이어 입고되었기 때문에 파랑색 그래프가 두 번 상승하였다. 3,523일, 3,527일에 각각 한척씩 입고되었다. 축적되어 있는 정비량이 많기 때문에 정비원들은 계속 야간근무를 수행한다. 24일간(3,523 ~ 3,547일) 함정 2척의 고장량이 모두 해소되었다. 고장량이 해소된 뒤에는 승조원들과 함께 장비 시운전을 수행하기 때문에 퇴창은 최소 7일 이후

에 가능하다. 시운전 기간을 고려해도 2척의 정비는 31일로 충분하나, 해군은 45일을 계획정비 기간으로 규정한다.

상태기반정비는 장비 상태에 따라 정비시기를 유동적으로 조절할 뿐만 아니라 수리에 필요한 시간을 고려하여 정비기간을 결정한다. 3장의 PFM과 FFM 모델은 45일로 고정된 정비기간이 적용되어 있으나 실제 정비소요시간의 반영을 통해 빠른 퇴장이 가능해진다. 정비일수가 짧아지는 만큼 함정 운용가용도가 높아지고 동시에 정비부대의 여유 상가대 운용을 통해 긴급상황에 대처할 수 있는 능력이 높아질 것이다. 한편 정비일수가 짧아지면 총수명간 정비횟수가 늘어날 수 있어 총수명비용이 증가할 수 있다. 해군 정비 시스템은 여러 가지 변수들이 적용되는 복잡계이므로 시스템적 관점에서 이를 확인해야 한다.

제 5장 해군 야전정비 시스템 모델 설계

5장에서는 2 ~ 4장의 연구결과들을 종합하여 시스템 다이나믹스 모델에 반영한다. 모델의 기본 형태는 3장의 모델과 유사하다. 6척의 함정과 상가대 2개소를 운용하는 정비부대를 구현한다. 2장에서 도출한 긴급고장함수와 4장에서 수정된 일반고장함수를 6척의 함정에 적용하여 고장을 발생시킨다. 정비를 수행한 함정은 다시 작전임무를 수행한다. 대기가 발생한 함정은 추가 임무를 수행하고, 이때 일반고장은 계속 함정에 축적된다. 임무 수행기간 중에는 긴급고장이 발생할 수 있다. 긴급고장은 작전운용 중에만 발생한다. 긴급고장이 발생한 함정은 즉시 입고된다. 상가대가 모두 운용중이라면 지연이 발생한다. 긴급고장 입고 지연의 경우에는 추가적인 작전임무를 수행하지 못하고 정비 대기행렬의 최우선순위가 된다.

정비부대는 주말에는 정비를 수행하지 않는다. 일주일에 5일 정비업무를 수행한다. 정비원의 수와 잔여 정비량에 따라 일정압력을 느끼며 수리업무를 진행한다. 잔여 정비량이 하루표준 정비량의 2배가 넘을 경우 정비원들은 야간 근무를 수행한다. 정비 기간이 정해진 경우에는 정비가 빨리 종료되어도 작전임무에 투입되지 못한다. 긴급 고장 함정이 입고되는 경우 모든 정비원은 계획정비를 멈추고 긴급고장 정비에 투입된다. 긴급고장 정비를 위한 수리부속은 보유중이라고 가정한다. 2장의 긴급고장정비 데이터 191건에서 수리부속의 부재 등으로 인해 장기 지연된 경우를 제외하면 평균 긴급고장 정비기간은 1.99일 이었다. 따라서 긴급고장 정비기간은 2일로 가정한다.

긴급고장의 고장량은 완전정비인 반면 일반고장은 완전 정비되지 않는다. 4장의 정비율에 따라 평균 72%의 정비를 수행한다.

<표 5-1>는 3장의 모델과 5장의 모델을 비교한 것이다. 3장의 모델은 주단위로 시뮬레이션되었다. 일반고장함수는 연단위 고장함수이며 주단위 연산을 위해 연중의 고장함수는 선형 내삽(Linear interpolation)되었다. 반년단위의 작전운용주기가 내삽되고 PFM 정비효과가 제거된 수정된 일반고장함수를 적용하였다. 일반고장함수는 베이지안 통계로 추정되어 분산이 존재한다. 이전의 모델들은 고장함수의 연단위 평균값만을 활용하였다. 긴급고장함수는 별도의 분산이 없으므로 일반고장함수의 분산분포를 몬테카를로 시뮬레이션의 사건 발생 기준(Threshold)으로 활용하였다. 2장의 몬테카를로 시뮬레이션은 일양분포(Uniform distribution)을 적용하였으나, 일반고장함수의 분산분포를 적용하여 고장 발생의 주기적 특성을 반영하였다. 또 긴급고장 발생 후 정비일수(평균 2일)와 정비들의 대기일수를 일단위로 산출하기 위해 시뮬레이션의 시간단위를 일일 단위로 설정한다. 6척 함정과 2대의 상가대에 대해 총수명 11,315일

<표 5-1> 이전모델(3장)과의 비교

	Chapter 3	Chapter 5
Normal failure function	<ul style="list-style-type: none"> • PFM effect included • Linear interpolation 	<ul style="list-style-type: none"> • PFM effect removed (Modified normal failure function) • Operating cycle interpolation
Critical failure function	<ul style="list-style-type: none"> • Unapplied 	<ul style="list-style-type: none"> • Monte-Carlo simulation applied • Maintenance period: 2 days
Variance of failures	<ul style="list-style-type: none"> • Unapplied 	<ul style="list-style-type: none"> • Variance of normal failure function (for normal and critical failures)
Maintenance queue	<ul style="list-style-type: none"> • FIFO for normal failures 	<ul style="list-style-type: none"> • FIFO for normal failures • Critical failures are prioritized
Maintenance effect	<ul style="list-style-type: none"> • Unapplied 	<ul style="list-style-type: none"> • Average 72% for normal failures • Full repair for critical failures
Change in work speed	<ul style="list-style-type: none"> • Unapplied 	<ul style="list-style-type: none"> • Schedule pressure: up to 1.25x
Mechanic working day	<ul style="list-style-type: none"> • 7 days a week 	<ul style="list-style-type: none"> • 5 days a week
Simulation target	<ul style="list-style-type: none"> • OO Fleet (Differences in the age of ships: 1 year) 	<ul style="list-style-type: none"> • Apply to various situations (¹)NOLH applied)
Time step	<ul style="list-style-type: none"> • Weekly 	<ul style="list-style-type: none"> • Daily

간의 동태적 인과관계를 시뮬레이션한다.

3장의 모델은 OO 함대의 상황을 적용하여 함정들의 수명차이가 각 1년이었다. 때문에 <그림 3-17>과 같이 수명후반 구간의 함정들이 동시에 몰리는 현상이 있었다. 함정의 총수명은 31년이고 시뮬레이션 대상 함정은 6척이다. 수명 배치에 의한 차이를 확인하기 위해서는 $31^6 = 8.875\text{억 회의 시뮬레이션이 필요하다.}$ 또 함정 수명 외에도 정비 입고기준(PFM: 45일, FFM: 14.71)과 정비원 수(9명)를 고려하면 약 28조 4000 억 회의 시뮬레이션이 필요하다(충분한 범위의 시뮬레이션을 위해 FFM 정비기준 범

1) NOLH: Nearly orthogonal latin hypercube

<표 5-2> NOLH 샘플링된 33개 시뮬레이션 시나리오

Simulation number	Age of ships						Number of mechanics	Repair period (days)	Maintenance			
									criterions failures (number of failures)	Operating period (days)		
	No.1	No.2	No.3	No.4	No.5	No.6						
1	31	3	14	6	27	19	12	90	21.63	327		
2	28	31	4	12	15	6	9	83	28.63	223		
3	27	14	28	5	1	18	5	42	15.5	443		
4	17	27	31	13	29	5	5	51	11.13	81		
5	29	1	15	7	21	22	13	24	24.25	94		
6	30	29	10	9	14	7	18	22	26	262		
7	21	15	30	8	0	20	19	81	12.88	42		
8	16	21	29	11	28	8	20	57	10.25	430		
9	20	8	7	16	22	10	7	62	6.75	288		
10	23	20	9	21	7	16	10	79	5.88	120		
11	22	7	23	30	11	2	7	46	23.38	301		
12	24	22	20	29	23	30	11	35	20.75	107		
13	18	5	6	17	18	4	17	44	5	158		
14	26	18	12	27	5	17	16	38	8.5	365		
15	19	6	26	28	12	0	16	70	30.38	184		
16	25	19	18	31	25	28	15	77	19.88	353		
17	16	16	16	16	16	16	12	55	19	249		
18	0	28	17	25	4	12	13	20	16.38	171		
19	3	0	27	19	16	25	15	27	9.38	275		
20	4	17	3	26	30	13	20	68	22.5	55		
21	14	4	0	18	2	26	19	59	26.88	417		
22	2	30	16	24	10	9	11	86	13.75	404		
23	1	2	21	22	17	24	6	88	12	236		
24	10	16	1	23	31	11	6	29	25.13	456		
25	15	10	2	20	3	23	4	53	27.75	68		
26	11	23	24	15	9	21	17	48	31.25	210		
27	8	11	22	10	24	15	14	31	32.13	378		
28	9	24	8	1	20	29	18	64	14.63	197		
29	7	9	11	2	8	1	14	75	17.25	391		
30	13	26	25	14	13	27	8	66	33	340		
31	5	13	19	4	26	14	9	73	29.5	133		
32	12	25	5	3	19	31	8	40	7.63	314		
33	6	12	13	0	6	3	10	33	18.13	146		

위는 5.00 ~ 33.00, 정비원의 수는 4 ~ 20으로 설정하였다). 본 연구에서는 시간의 제약으로 NOLH 샘플링을 통해 33회로 단축 시뮬레이션하였다. NOLH는 독립적인 변수들의 발생범위를 고려하여 유의미한 시뮬레이션만을 직교 샘플링(Orthogonal sampling)하는 방법이다(Iman et al., 1980). 본 연구의 모델에는 10개의 독립적인 변수(함정 6척의 수명, 정비원수, 정비기간, 입고기준 정비주기 및 고장량)가 있다. Latin hypercube 샘플링결과 33회의 시뮬레이션이 필요하며, 시뮬레이션별 변수값들이 <표 5-2>와 같이 직교 샘플링되었다.

해군의 00년도 예산소모 실적 데이터를 통해 대략적인 예산규모를 추정하였다. 계획 정비와 긴급정비에는 인건비와 수리부속비 등이 포함된다. 정비에 소모된 연간 총 예산과 고장 및 정비 발생 건수 데이터를 바탕으로 계획정비와 긴급정비 금액을 산출하였다. 작전중인 함정은 승조원 인건비, 유류소모액 등의 작전운영비가 소모된다. 총 작전운영비를 척수로 나누어 평균 일당 운영비를 반영하였다. 연간 물가 상승률이나 유류단가의 변동은 반영하지 않으며, 보안의 문제로 구체적인 단가는 기재하지 않는다. 시뮬레이션을 통해 총수명간 함정들이 수행한 계획정비와 긴급정비 횟수, 총 작전 일수와 정비일수를 산출할 수 있다. 예산 소모량을 반영하면 총수명간 운영유지비를 구할 수 있다.

제 1절 해군 야전정비 시스템 다이나믹스 모델 구축

본 연구에서는 <표 5-1>을 반영하여 4가지의 시뮬레이션 모델을 비교한다. 시뮬레

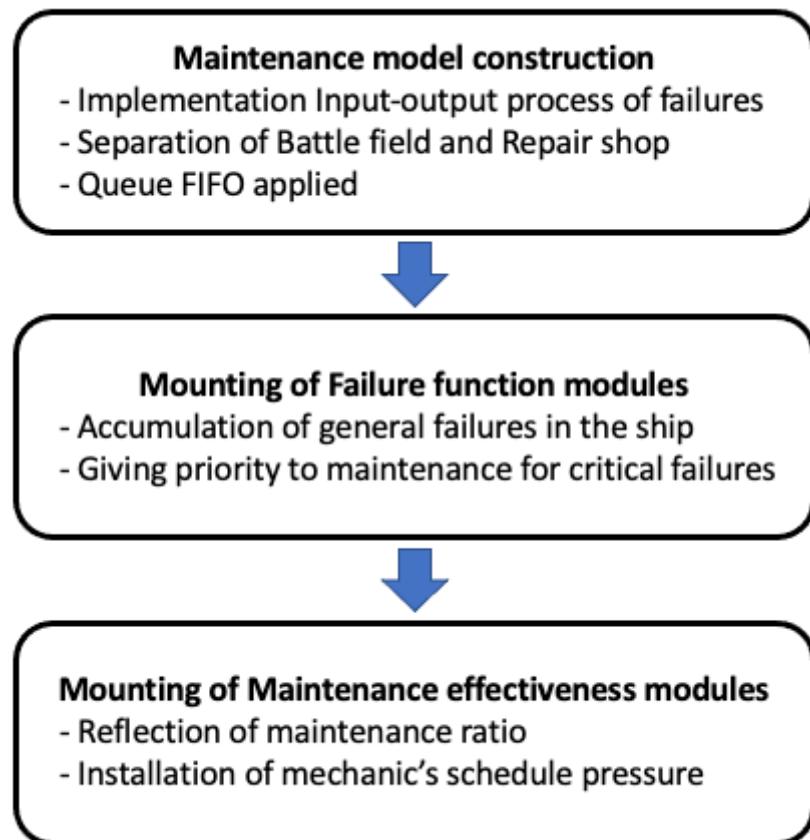
<표 5-3> 모델 구성

Models	Maintenance criterion	Repair period criterion
<i>Model 1 (PFM_FRP)</i>	• PFM : Period fixed maintenance	• FRP : Fixed repair period
<i>Model 2 (PFM_NRP)</i>	• PFM : Period fixed maintenance	• NRP : Non-fixed repair period
<i>Model 3 (FFM_FRP)</i>	• FFM : Failure rate fixed maintenance	• FRP : Fixed repair period
<i>Model 4 (FFM_NRP)</i>	• FFM : Failure rate fixed maintenance	• NRP : Non-fixed repair period

이션을 구분하는 기준은 정비입고(Maintenance criterion)과 정비기간기준(Repair period criterion)이다. 4개의 모델을 <표 5-3>과 같이 구성하였다. FFM_NRP 모델은 장비의 상태에 따라 정비 입고되고, 정비부대의 상황에 따라 정비가 완료 되는대로 퇴창한다. 시뮬레이션에 반영되는 모듈들의 현실성을 고려할 때 FFM_NRP 모델은 상태기반 예측정비이다.

시스템 다이나믹스는 모델의 모듈식 탑재가 가능하다는 장점이 있다. 5장의 모델에는 2장의 일반/고장함수, 3장의 PFM/FFM 모듈, 4장의 정비부대 정비율과 정비원 정비능력 모듈이 순차적으로 탑재된다. 모듈 탑재 순서는 <그림 5-1>과 같다.

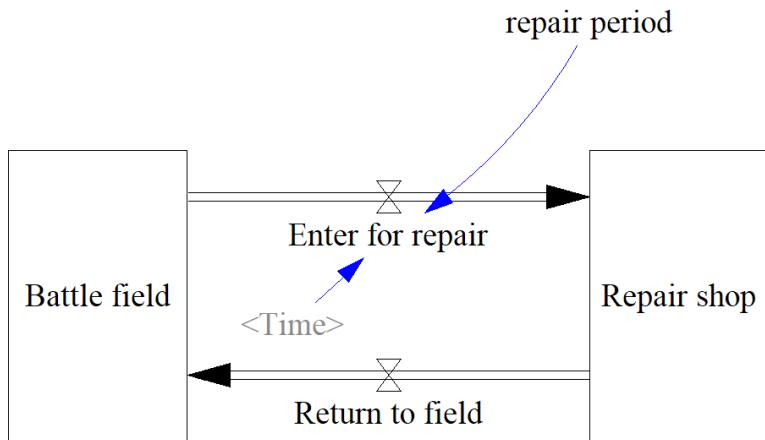
본 장의 1절은 <그림 5-1>의 순서에 따라 모델을 구축한다. 2절에서는 4가지 모델에 반영된 변수들의 정상 작동 여부를 검증한다.



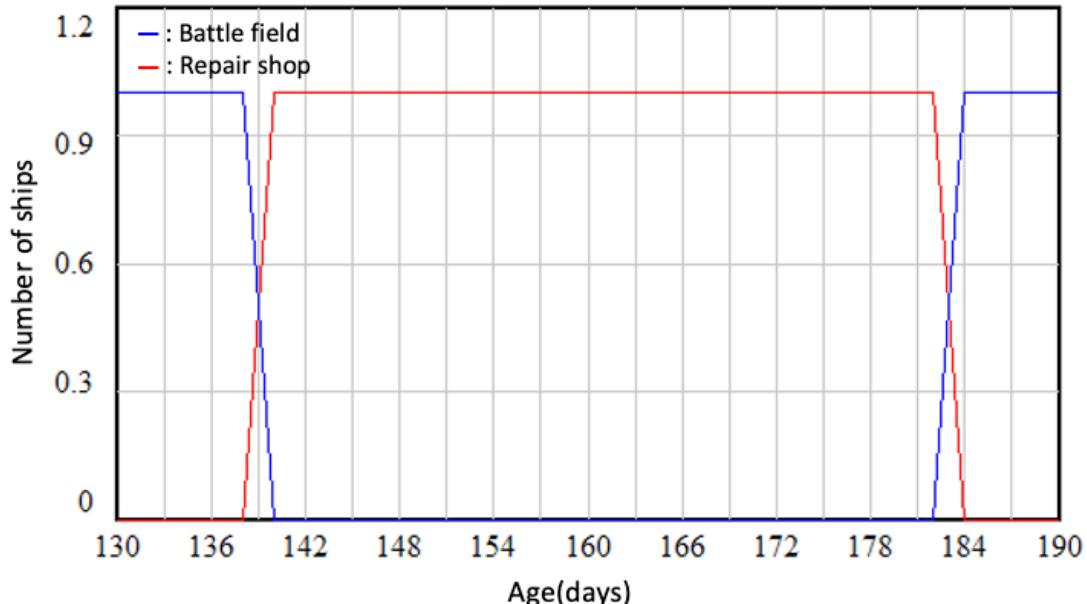
<그림 5-1> 시스템 다이나믹스 모듈 탑재 순서

1. 야전정비 모델 구축

해군의 야전정비는 정비기간이 도래한 함정의 입고, 정비기간이 종료된 함정의 퇴창이 반복되는 시스템이다. 함정은 반년주기로 작전과 정비를 반복한다. 이는 <그림



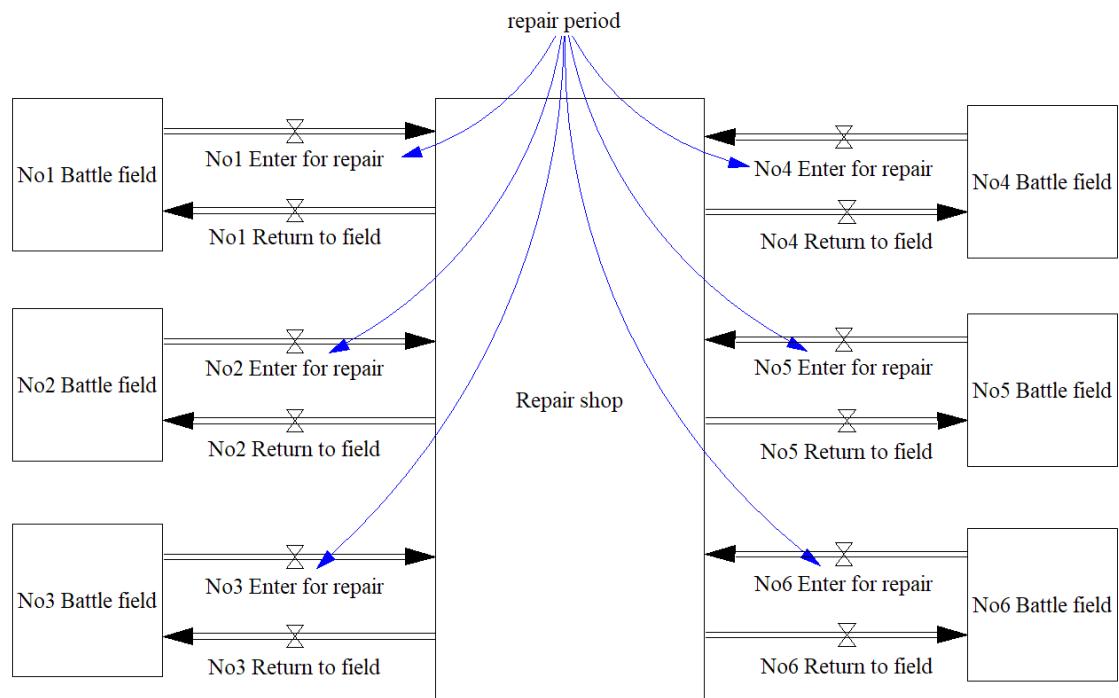
<그림 5-2> 야전정비 모델



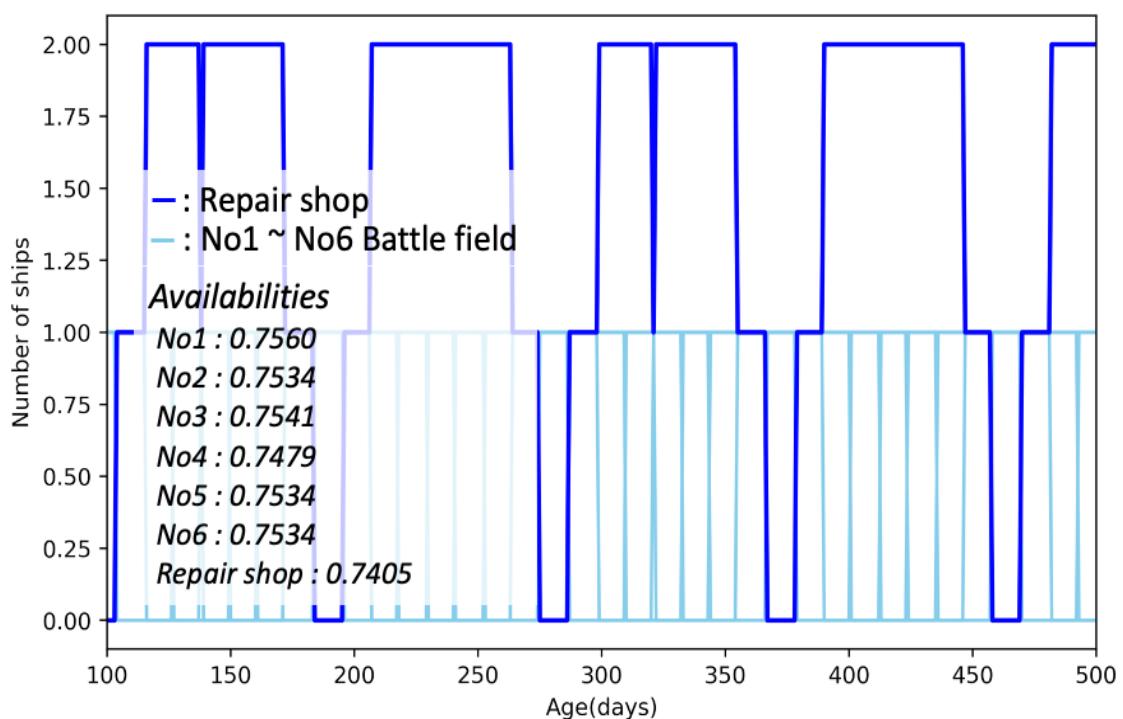
<그림 5-3> 야전과 정비부대간 이동

5-2>와 같다. 야전(Battle field)의 함정 1척은 137일 또는 138일째 정비부대(Repair shop)에 입고된다. 45일 정비를 수행하고 다시 야전으로 복귀한다. <그림 5-3>과 같이 138일째에 함정이 정비부대로 입고되므로 야전의 함정 척수는 1에서 0으로 줄어든다. 동시에 정비부대는 0에서 1로 늘어난다. 이 모델은 함정의 이동만을 고려한다. 1척을 기준으로 설계되어 대기 없이 야전과 정비부대를 시간에 따라 이동할 뿐이다.

매우 단순한 모델이지만 현재 해군의 정비시스템과 동일하다. 주기적으로 2개의 저량변수(Stock variables) 사이를 왕복한다. 함정수 대 상가대 수의 비율은 3장과 동일하게 6척과 2대이다. <그림 5-4>는 함정 6척과 상가대 2대의 상황이다. <그림



<그림 5-4> 함정 6척을 반영한 야전정비 모델



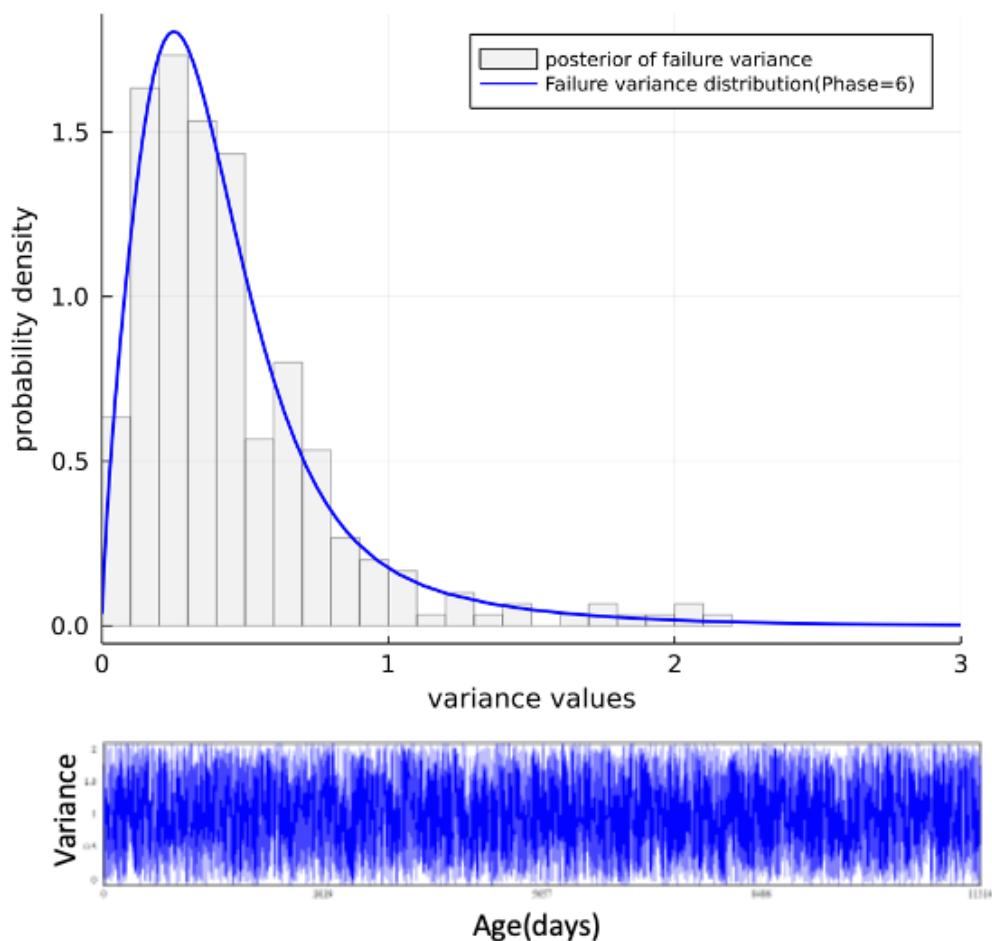
<그림 5-5> 함정들과 정비부대의 저량변수 변화

5-5>와 같이 6척의 함정들은 개별적으로 작전운용 후 정비부대에 입고하여 45일의 정비를 받는다. 상가대 2대는 6척의 함정 정비를 수용하기에 충분하기 때문에 모델에서 대기는 발생하지 않았다.

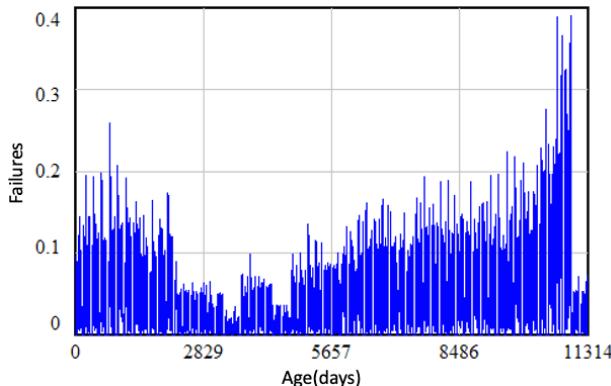
정비부대 운용률은 0.7405였다. 정비부대 운용률은 상가대에 함정이 입고해 있으면 운용중인 것으로 계산된다. 정비원들이 실제 정비를 수행하는가와는 무관하다. 해군은 함정 운용가용도 75% 이상을 목표로 한다. 함정들의 총수명간 평균 운용가용도는 0.7530였다. 긴급고장이 발생하여 상가대의 추가적인 정비소요가 발생한다면 계획정비 함정의 입고가 늦어지고 함정 운용가용도는 낮아질 수 있다.

2. 고장함수 모듈 탑재

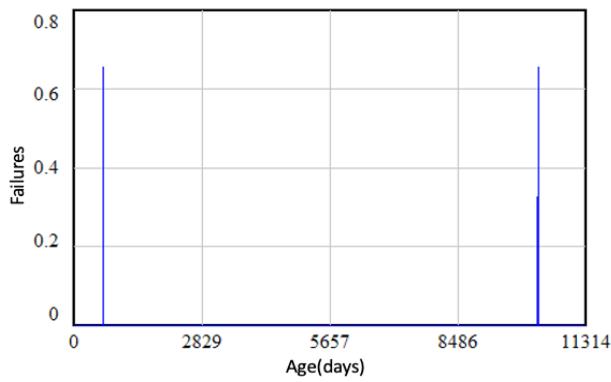
<그림 5-4>는 개별 함정들의 저량변수들로 구성되어 각 변수는 0 또는 1의 값을 가



<그림 5-6> 적합된 분산과 시뮬레이션 결과

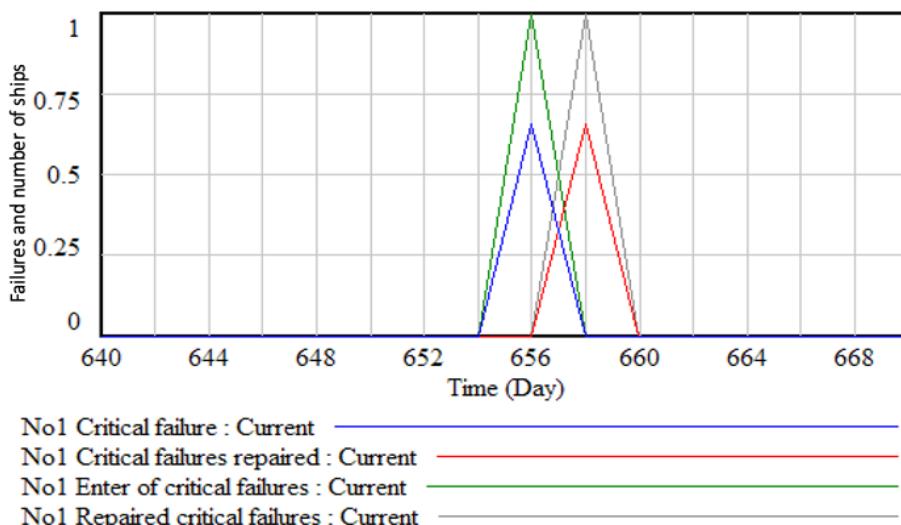


<그림 5-7> 분산 적용된 일반고장함수

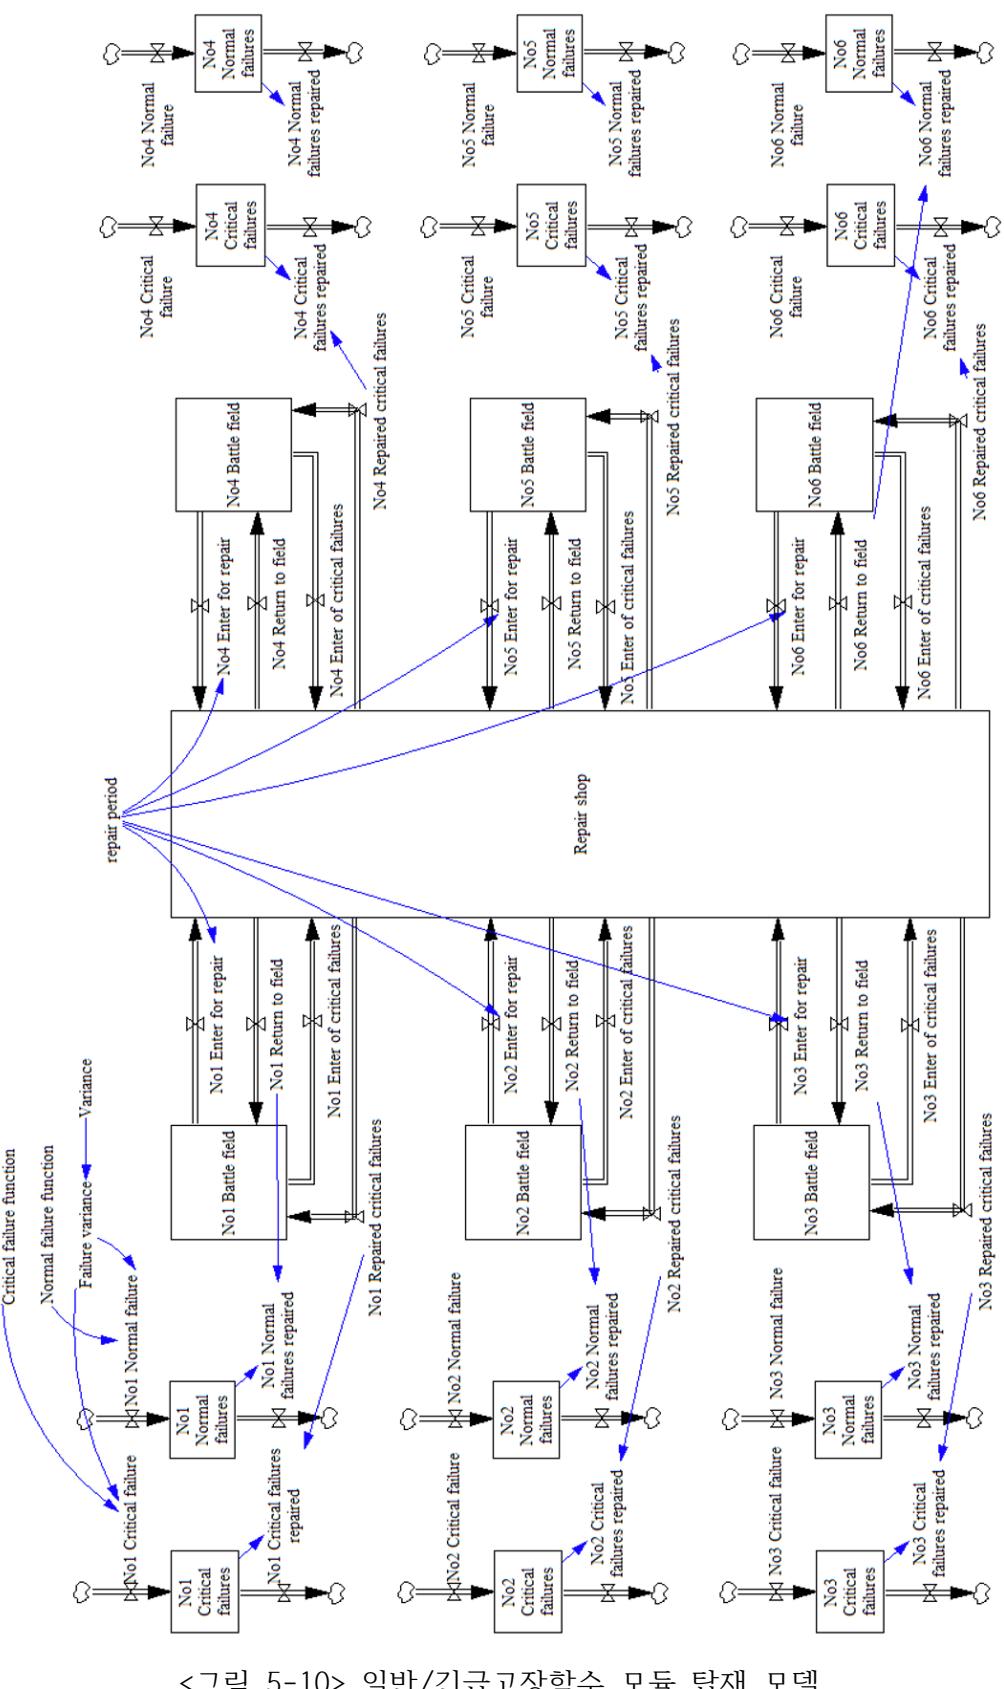


<그림 5-8> 긴급고장 시뮬레이션 결과

진다. 정비부대는 최대 2척까지 동시 정비하므로 0, 1, 2 값을 가진다. <그림 5-4>는 함정의 움직임을 반영한 모델이므로 고장량의 변화를 측정하기 모듈이 추가되어야한다. 일반/긴급고장함수는 Lookup 함수 기능으로 구현하였다. <그림 5-6>의 위의 그림은 일반고장함수의 분산은 베이지안 추정된 분산이며 아래 그림은 Lookup 함수로 적용되어 시뮬레이션한 결과이다. 고장량은 모두 정규분포로 가정되었으나, HMC 샘플링 과정에서 데이터에 따라 형태가 왜곡되었다. 단계형 분포(phase 6)로 적합하고 Lookup 함수를 활용하여 시스템 다이나믹스 모델에 적용하였다. <그림 5-6>은 동시에 고장이 발생하는 범위에 대한 분포가 된다. 이를 긴급고장함수의 몬테카를로 시뮬레이션 발생함수로 적용하였다. 분산을 적용한 일반고장함수는 <그림 5-7>과 같다.



<그림 5-9> 긴급고장 발생 시 함정 입고 및 퇴창

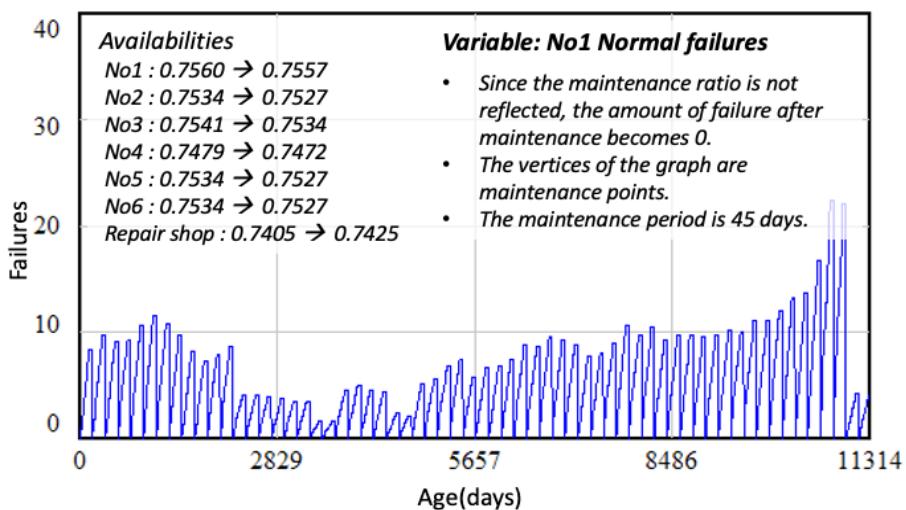


<그림 5-10> 일반/긴급고장함수 모듈 탑재 모델

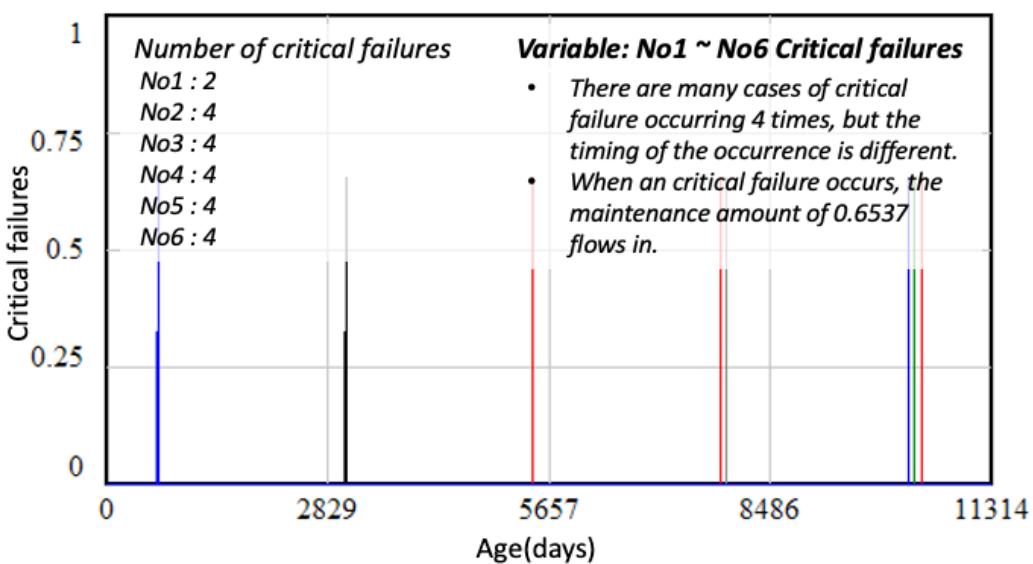
전체적인 형태는 일반고장함수의 형태가 유지되면서 변동 폭이 존재하는 것을 확인할 수 있다. <그림 5-8>은 분산분포를 기준으로 몬테카를로 시뮬레이션을 수행하였을 때 발생한 긴급고장이다. 총수명간 2회의 긴급고장이 발생하였다.

<그림 5-9>는 첫 번째 발생한 긴급고장을 확대한 것이다. 656일차에 긴급고장 발생으로 입고된 함정은 658일차에 정비완료 후 퇴창하였다. 긴급고장의 고장량은 0.6537이다. 긴급고장은 2일 동안 입고, 정비, 퇴창 3가지 업무가 이루어진다. 함정의 입고와 퇴창, 정비 준비에 1일 소모를 가정할 때 1일치의 정비량이 들어오면 2일의 기간이 소모된다. 따라서 정비원 9명의 하루치 정비량인 $14.71 \times 2 / 45 = 0.6537$ 이 정비부대에 투입된 후 수리되었다. 긴급정비의 정비량은 <표 5-2>의 시뮬레이션 시나리오에 따라 정비원의 수가 변동되는 경우 정비원의 수에 맞는 하루치 정비량이 발생하게 된다.

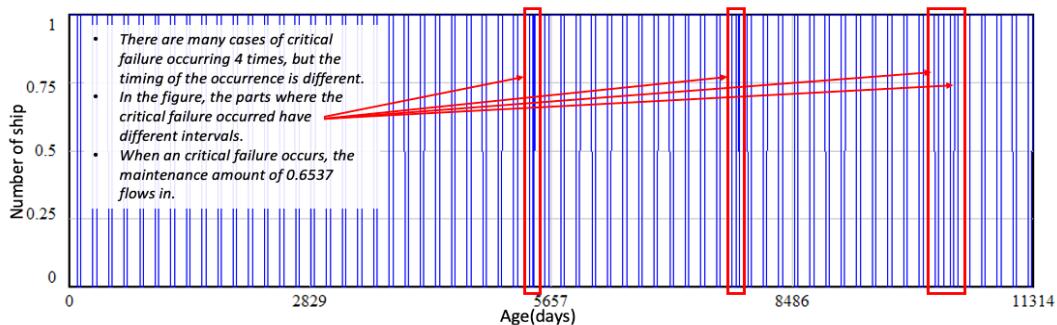
<그림 5-10>은 일반고장함수와 긴급고장함수 모듈이 탑재된 모델이다. 각 함정에 해당하는 No.1 ~ 6 Battle field 변수에서 일반고장과 긴급고장이 구분되어 정비부대에 입력된다. 두 경우 모두 동일하게 함정 1척이 이동하므로 1 또는 0 값을 가진다. 1번함의 일반고장량은 <그림 5-11>과 같다. 그래프의 꼭지부분은 정비 수행지점이다. PFM의 정비기간은 45일로 일정하다. 정비기간 중에는 더 이상의 일반고장이 축적되지 않으므로 입고시의 값이 유지된다. 정비부대 정비율이 반영되지 않았으므로 정비 후의 일반고장량은 0(완전정비)이다. 긴급고장은 <그림 5-12>와 같이 총수명간 2 ~ 4회 발생하였다. 2번 함정은 긴급고장이 4회 발생하였다. <그림 5-13>에서 일반고장의 누적에 의한 계획정비 간격은 일정하다. 긴급고장은 작전 중에만 발생하므로 간격이 다른 부분이 긴급고장 발생부분이 된다.



<그림 5-11> 1번함의 일반고장량 변화



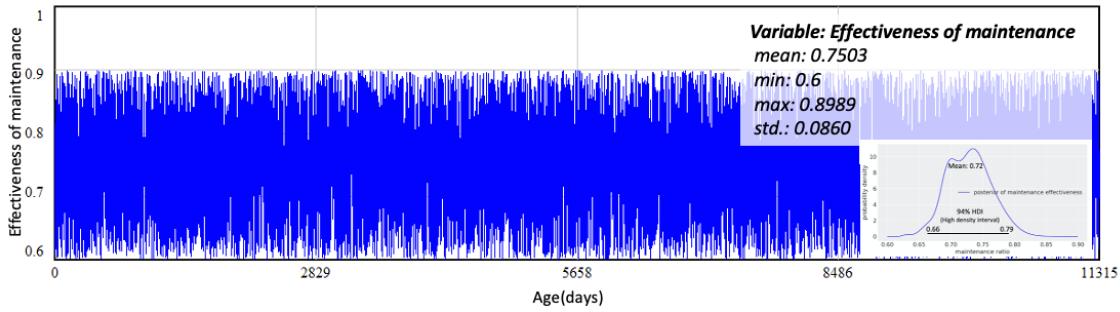
<그림 5-12> 1 ~ 6번함의 긴급고장 발생



<그림 5-13> 2번함의 일반정비와 긴급정비 시점

3. 정비부대 정비율과 정비원 정비능력 모듈 탑재

<그림 4-8>의 평균 0.72(94% HDI: 0.66 ~ 0.79)인 정비부대 정비율 사후분포는 특정 분포로 적합이 어렵다. 단계형 분포로 적합하여 모델에 적용하였다. 0.6이하 범위와 0.9이상의 범위는 확률은 0이다. Lookup 함수를 활용하여 모델에 적용하고 시뮬레이션하여 <그림 5-14>와 같은 결과를 도출하였다. 시뮬레이션 결과는 최소 0.6, 최대 0.8989, 평균 0.7503이었다. 사후분포 추정결과와 평균 약 3%의 차이가 발생하였다. PFM 모델의 최대 고장량은 25.69였으며, 3%는 0.7707이다. 정비부대의 하루치 업무량(0.65)과 유사한 수준이므로 총수명 기간의 시뮬레이션에는 큰 문제없다고 판단하였다.

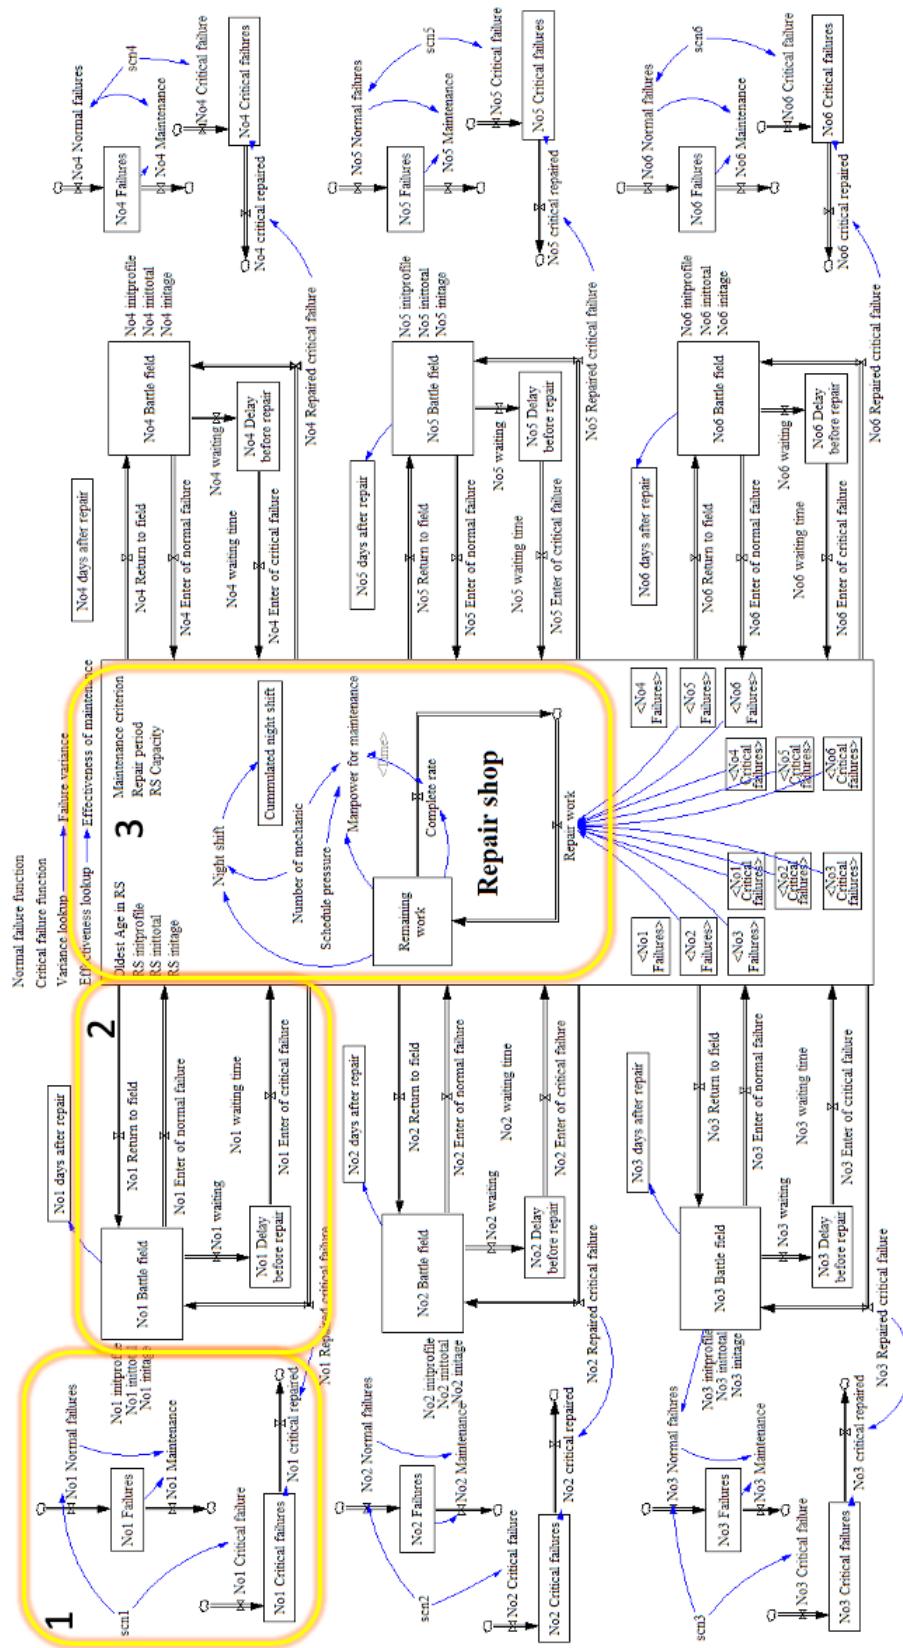


<그림 5-14> 정비부대 정비율 시뮬레이션 결과

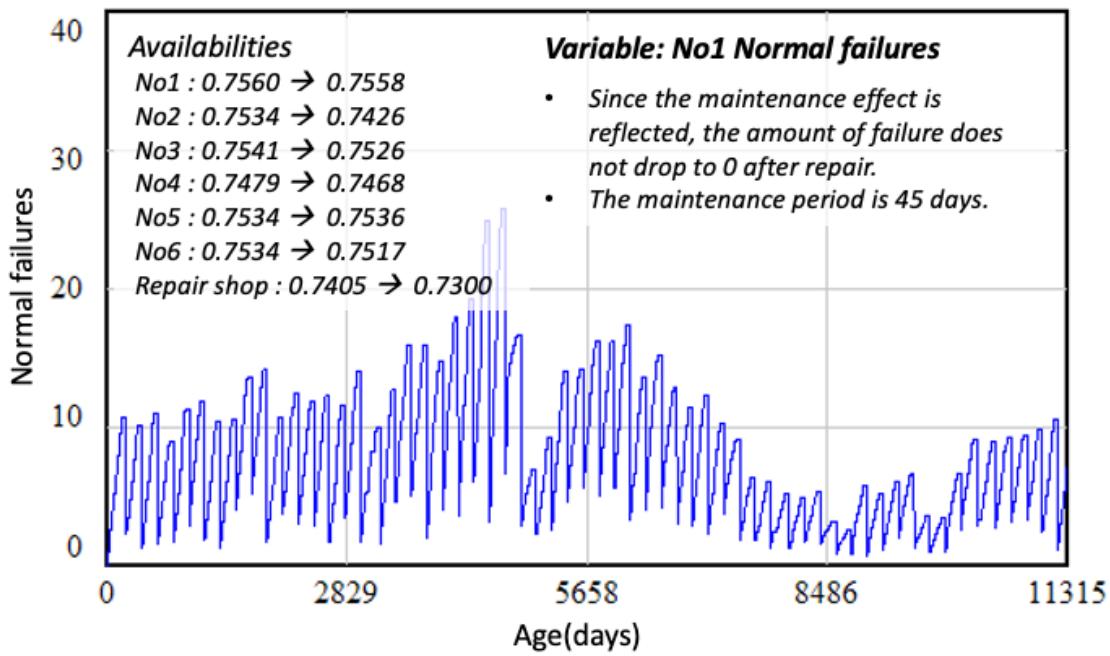
<그림 4-18>의 정비원 정비능력 모듈을 탑재하여 정비량에 따라 업무속도가 변하도록 하였다. 최종적으로 <그림 5-15>는 본 연구의 최종 모델이다. 최종모델은 크게 3개의 모듈로 구성된다. 1번 섹터는 고장함수 모듈이다. 고장함수모듈에서는 일반고장과 긴급고장의 발생과 고장량을 생성한다. 일반고장은 함정에 누적되어 계획정비시 해소되는 반면 긴급고장은 발생 즉시 대기행렬 최우선 순위에 대기하였다가 정비된다. 함정이 대기하거나 정비부대로 이동하는 과정은 2번 섹터에서 이루어진다. 작전 구역 대기행렬과 정비부대 대기행렬 사이로 함정 1척이 이동한다. 긴급고장 입고에는 저량변수가 별도로 구성된다. 여기에는 긴급고장이 발생하였으나 즉각 정비부대에 입고되지 못하는 함정들이 대기한다. 긴급고장 대기중에는 추가적인 작전이 불가하므로 별도의 저량변수로 이동하여 함정 운용을 막는다. 정비부대의 용량은 최대 2대이며 2대가 계획정비를 수행하고 있으면 긴급고장이 발생해도 정비를 수행하지 못하고 상가대에 여분이 생길 때까지 대기해야한다. 3번 섹터는 정비부대 정비율과 정비원의 정비능력 섹터이다. 함정의 고장량은 <그림 5-14>의 정비율에 따라 수리되며 미완료 정비건은 함정에 축적된 상태로 유지된다. 정비원들은 Remaining work의 잔여 정비량에 따라 일정압력을 느끼며 일일 단위의 정비량을 수행하고 필요시 야간 근무를 수행한다.

정비율이 0.6 ~ 0.8989의 범위에서 추출되므로 일반고장은 0으로 떨어지지 않는다. 계획정비와 긴급고장 정비에 대기가 발생하기도 한다. 이러한 사유로 <그림 5-16>과 같이 함정 운용가용도는 대부분 저하되었다. 정비부대 가동률은 낮아졌다.

정비부대의 가동현황은 <그림 5-17>과 같다. 상단의 그림은 잔여 정비량의 변화이고, 하단의 그림은 정비원들의 업무량의 변화이다. 함정이 입고되면 정비부대의 정비량이 일시적으로 증가한다. 함대에 유사 수명의 함정들이 모여있는 경우 수명 후반에는 정비량이 급격히 증가한다. 정비원들은 함정이 입고되면 긴급고장이나 기타 정비 업무 지원을 위해 최단시간 내 정비량을 해소한다. 하단의 그림에서 함정의 입고는



<그림 5-15> 초기 요구모델

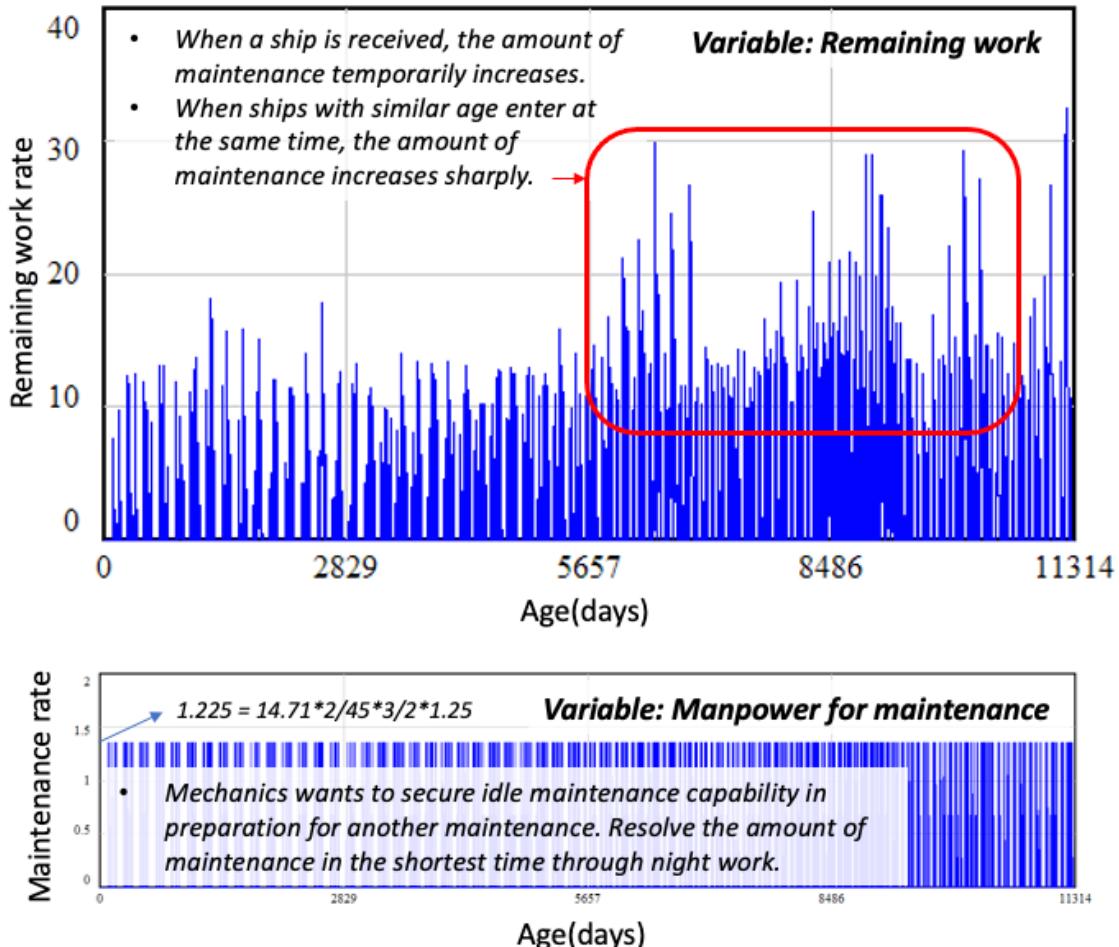


<그림 5-16> 최종 모델의 일반고장량 변화

정비량의 급격한 증가와 같으므로 정비원들은 야간 근무를 수행하게 된다. 해군 정비 부대의 실제 상황도 동일하다. 함정이 입고되고 잔여 업무량이 많으면 야간 근무를 지속적으로 수행한다. 정비원들의 하루 최대 업무량은 식(5)와 같다.

$$\text{Maximum work rate} = 14.71 * 2 / 45 * 1.5 * 1.25 = 1.225 \quad (5)$$

식(5)의 14.71은 평균 계획정비량이다. PFM을 수행중인 해군 함정이 평균적으로 수행하는 계획정비시 정비량이다. 2는 동시에 정비하는 함정의 수이다. 정비부대는 동시에 2척의 함정을 수리할 정비능력을 가지고 있다. 45는 계획정비 기간이다. 1.5는 야간근무로 인해 표준일과 8시간 대비 12시간을 근무하는 경우이다. 1.25는 일정압력에 따라 최대 증가하는 정비량의 비율이다. 계산 결과는 1.225이다. 즉, 1.225는 최대 일정압력을 느끼는 정비원 9명이 야간 근무를 포함하여 수행할 수 있는 하루 업무량이다. NOLH 샘플링된 시뮬레이션 시나리오의 정비원 수에 따라 일일 최대 업무량은 변하게 된다. <그림 5-17>에서 정비원들은 대부분의 근무일에 야간근무를 수행하면서 정비 업무가 없는 일수를 최대한 확보하고 있다. 총 야간 근무일수는 총수명 11,315일중 3,936일로 평일 근무중 48.83%를 야간근무하고 있다.



<그림 5-17> 잔여 정비량과 정비원 업무량 변화

제 2절 모델의 타당성 평가

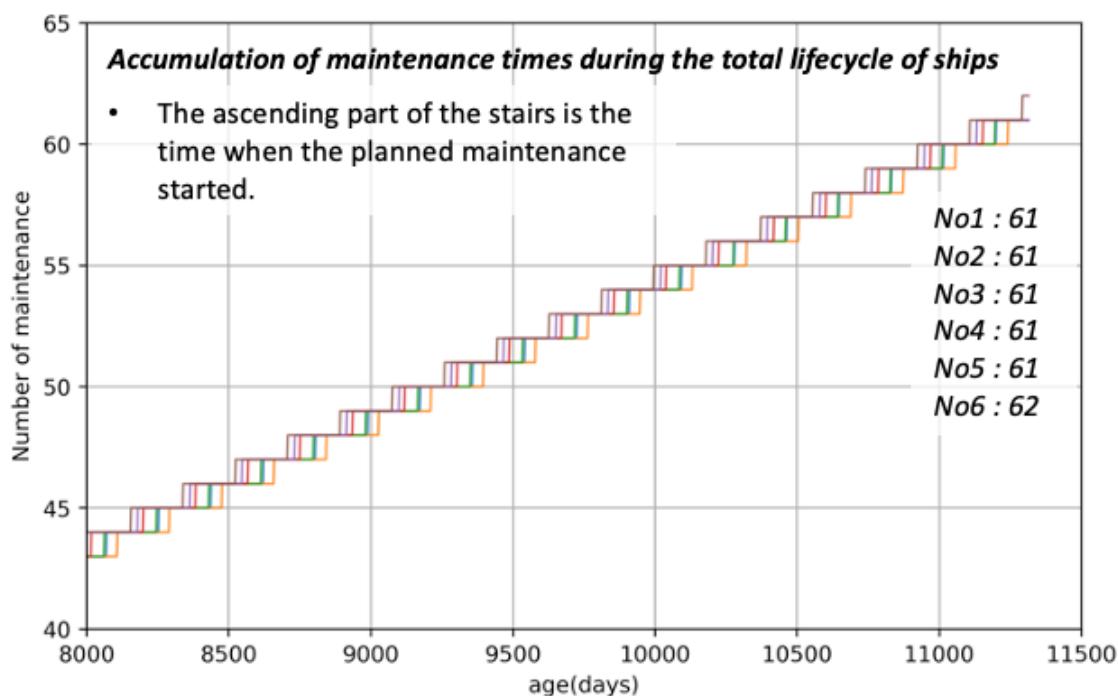
시스템 다이나믹스 모델의 검증방법으로 Sterman(2000)은 4가지 방법을 제시한다. 첫 번째는 모델의 구조가 적절히 반영되었는지 확인한다. 연구모델은 5.1절과 같이 기본 정비모델을 바탕으로 모듈을 추가하는 방식으로 구축되었다. 모듈들은 2 ~ 4장에서 검증을 마친 후 모델에 탑재되었으므로 모델의 구조는 적절하다고 할 수 있다. 두 번째는 모델에 대한 사전지식과 시뮬레이션 결과의 일치성을 판단한다. 세 번째는 각 변수 단위의 통일성을 확인한다. 변수들은 일일 단위의 시간축에 따른 고장량의 변화를 측정하였다. 함정에서 발생된 고장량은 정비부대 입장에서는 정비량과 같다. 고장량과 정비량은 같은 단위이다. 네 번째는 불확실성에 대한 강건성을 확인한다. 본

절에서는 모델 구축 과정에서 검증된 두 가지 요소를 제외하고 시뮬레이션 결과의 사전지식과의 일치성, 불확실성에 대한 강건성을 확인한다.

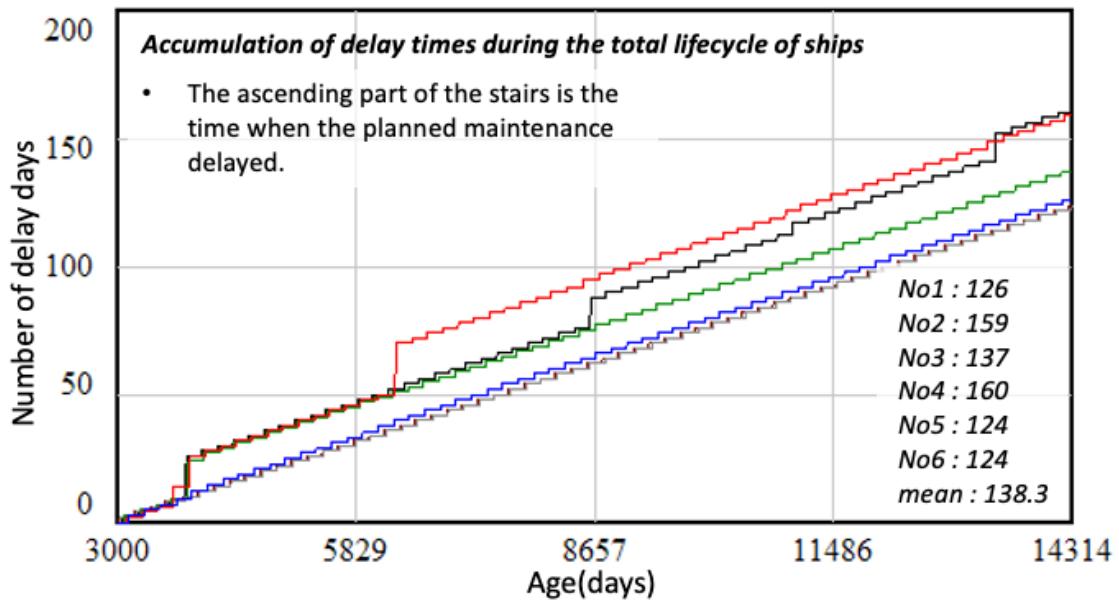
타당성 평가 대상은 본 연구의 기본 모델인 PFM_FRP이다. PFM_FRP는 해군의 현재 정비정책이다. 동시에 고정된 주기로 함 운용되므로 시뮬레이션 결과를 직관적으로 해석하기 편리하다. 현실성과 강건성 평가에 있어 시뮬레이션 결과가 실제 상황과 유사한지의 판단 가능하다.

1. 현실성 평가

현실성 테스트는 총 정비횟수를 통해 확인할 수 있다. 간격의 차이가 발생할 수 있으나 작전과 정비는 총수명간 계속 반복되기 때문이다. 해군의 정비 정책에서 이론적인 총수명주기간 계획정비 횟수는 62회이다. 시뮬레이션을 통해 62회의 계획정비를 수행했는지 확인할 수 있다. <그림 5-18>은 6척 함정의 총수명간 계획정비횟수이다. 6번함을 제외한 5척의 함정이 모두 61회의 계획정비를 수행하였다. 이론적인 총수명간 계획정비 횟수인 62회보다 1회 적게 수행하였다. 이는 대기행렬의 영향이다. <그림 5-19>는 총수명간 함정들의 총 대기일수이다. 평균 138.3일의 대기가 발생하였다. 함정들은 138일 작전, 45일 정비를 반복한다. 138.3일의 지연은 평균적으로 한 주기 만큼의 작전을 더 수행했다는 의미가 된다. 총수명은 11,315이므로 대기의 발생은 함



<그림 5-18> 총수명간 총 계획정비 횟수



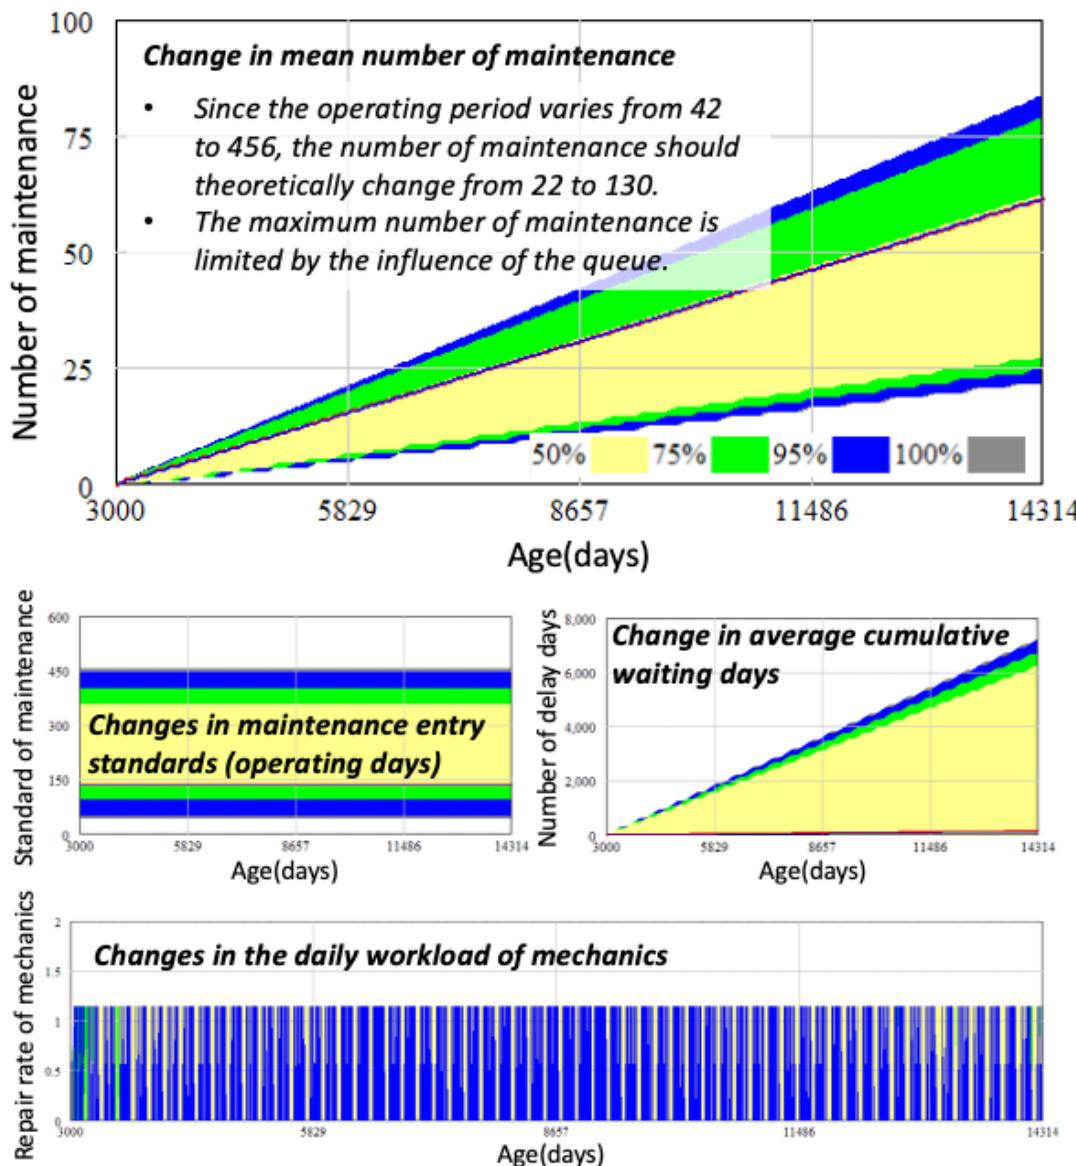
<그림 5-19> 총수명간 누적 대기일수

정의 계획정비 횟수를 감소시킨다. 따라서 PFM_FRP 모델은 현실성이 반영되었다고 할 수 있다.

2. 강건성 평가

불확실성에 대한 강건성은 입고기준의 변화에 따라 총수명간 정비횟수가 어떻게 변하는지를 통해 확인한다. 3장의 FFM 모델에서 최대 입고 간격은 456일이었다. PFM 모델의 기준인 138일 대비 약 3.3배에 해당한다. 모델의 정비 입고주기를 42 ~ 456 일로 변화시켰다. 기본모델은 총수명간 주기적인 작전운용일수와 정비기간을 반복한다. 작전일수가 42일인 경우 작전 42일 + 정비 45일 = 87일의 주기를 가진다. 456일인 경우에는 501일 주기를 가진다. 총수명간 계획정비횟수는 약 22 ~ 130회의 범위가 될 것이다. 기본모델을 200회 시뮬레이션한다. 변동이 큰 입고기준에도 현실적인 결과가 도출되는지 확인하여 강건성을 평가한다.

<그림 5-20>은 정비횟수의 강건성 평가 결과이다. 시뮬레이션의 50%는 노란색 범위에서 결과가 도출된다고 해석한다. 좌측 하단과 같이 정비기준인 작전 운용일수가 42 ~ 456일로 변하였다. 총 정비횟수는 약 22 ~ 80회까지 변하였다. 이론적인 최대 정비횟수는 130회였다. 입고기준이 42일 정비로 줄어드는 경우 함정들의 대기는 길어진다. 평균 대기일수는 총수명간 최대 7,000일까지 증가하였다. 대기행렬이 정상적으로 기능하여 과다한 계획정비 현상을 통제하였다. 정비원들은 업무량에 따라 야간 근



<그림 5-20> 정비효과의 강건성 평가 결과

무를 수행한다. 계획정비를 자주 수행하면 정비원의 야간근무가 잦아진다. 드물게 들어오는 경우에도 정비량이 많으므로 야간근무가 많아진다. 따라서 정비원들의 95% 업무부하 부분이 총수명의 많은 부분을 차지하고 있다.

정비입고 기준의 변화는 모델에 탑재된 모듈들에 영향을 미치고 상호보완적인 모습을 보인다. 축적된 일반고장량이 정비원들의 업무량을 통제하고, 대기행렬을 통해 정비횟수가 일정수준 이상 증가하지 못하게 통제한다. 즉 입고기준의 다양한 변화에 대해 모델은 모듈들의 인과관계에 의해 강건성이 유지된다.

제 6장 해군 야전정비 모델 시뮬레이션 결과분석

시뮬레이션을 통해 함정들의 운용가용도, 총수명간 긴급고장 횟수, 계획정비와 긴급 정비시의 대기일수, 정비부대 가동률, 정비원의 야근일수, 함정들의 항해중 위험 노출도, 총수명비용 등을 확인할 수 있다. 시뮬레이션을 통해 확인 도출되는 변수들은 <표 6-1>과 같다.

<표 6-1> 시뮬레이션 도출 변수

Field	Details	Abbreviation
Ship	Total cost of repair parts consumed	Cost_spare_part
	Average of cumulative delay days	M_cumulative_delays
	Average of number of maintenance	M_N_maintenance
	Total labor cost	Cost_mechanics
	Total cost of ship operating	Cost_ship_operating
	Operational availability	Ao
	Life cycle cost	Life_cycle_cost
Normal failures	Maximum/average/Std. of normal failures accumulated in the ship	Max_accumulated_NF M_accumulated_NF SD_accumulated_NF
	Average number of critical failures	M_N_CF
	Maximum/average number of delays by critical failure	Max_delays_CF M_delays_CF
Repair shop	Probability of critical failures	Probability_CF
	Night work days	Nightwork_days
	Max/Average/Std./Utilization of manpower for maintenance	Max_manpower M_manpower SD_manpower Manpower_utilization
	Maximum/average/Std. work load of mechanics	Max_workload M_workload SD_workload
	Repair shop utilization	Repair_shop_utilization

연구모델은 해군 정비 현상을 설명할 수 있는 대부분의 변수들을 포함하고 있다. 따라서 <표 6-1>의 종속변수 외에도 정비 정책으로 인한 여러 가지 현상들을 시뮬레이션 할 수 있다. 서론에서 기술한 바와 같이 시스템 다이나믹스 시뮬레이션은 모델에 포함되는 변수의 수가 현실과 유사한 수준으로 증가함에 따라 디지털 트윈스의 수준으로 발전할 수 있다. 본 연구에서는 스마트 네이비가 상태기반정비로 나아가는 과정에 검토해볼 수 있는 모델들을 비교한다. 독립변수들의 설정에 따른 종속변수의 변화 관계를 선형관계로 설명한다. 선형회귀를 통한 분석은 비선형회귀 분석보다 정확도가 다소 떨어진다. 단 선형회귀는 직관적으로 변수간의 관계를 파악할 수 있고 복잡한 회귀 모델로 발전하기 위한 기초가 될 수 있다는 장점이 있다. 용도에 따라 회귀 모델을 재구성함에 따라 해군 정비 시스템을 수식으로 표현하는 것이 가능하다.

1절에서는 NOLH 샘플링된 33가지 시뮬레이션을 결과를 분석한다. 시스템 다이나믹스의 복잡계에 포함된 변수들은 인과관계로 묶여 있다. 변수들간의 관계를 직관적으로 해석하기 어려울 수 있다. 예를들어 $A \rightarrow B \rightarrow C \rightarrow D \rightarrow B$ 의 인과관계가 있을 때 $A \rightarrow B$ 는 직관적 해석이 가능하지만 $B \rightarrow C$ 는 쉽지 않다. 루프가 생기기 때문이다. 1절에서는 직관적 해석이 불가한 관계를 확인하기 위해 변수들간의 상관계수를 확인하고 분석한다. 2절에서는 1절에서 확인한 변수들간의 관계를 선형회귀를 통해 분석한다. 최적화를 통해 모델들의 적절한 독립변수 설정 상태를 확인한다. 함정 운용 가용도나 총 수명비용 외에도 긴급고장으로 인한 임무 실패율은 정비정책 결정에 중요한 의사결정 참고자료가 될 수 있다. 함정 운용가용도는 높을수록 좋고, 총수명 비용과 임무 실패율은 낮을수록 좋다. 3개 변수의 최적화를 통해 모델들을 비교한다.

제 1절 시뮬레이션 결과 분석

일반적으로 정비정책 결정에는 장비 운용가용도와 비용을 고려한다. 본 절에서는 모델들의 NOLH 시뮬레이션 결과를 확인한다. NOLH 시뮬레이션의 세부결과는 부록 1 ~ 4에 첨부하였다. 33개의 시나리오에서 시뮬레이션된 함정 운용가용도와 총수명 비용의 결과를 확인한다. 두 종속변수의 최대값, 중간값, 최소값에 해당하는 시나리오에서 모델 변수들의 동적 행태를 확인하고 비교한다. 최종적으로 모델들의 결과와 OO 함대의 상황을 비교하여 정비정책 변화에 따른 차이를 확인한다.

시뮬레이션 전체 변수들의 상관관계를 분석하였다. 모델의 독립변수는 5종류이다. 모델에 따라 독립변수는 최소 2가지에서 3가지가 된다. PFM_FRP 모델의 경우 독립 변수는 작전운용기간, 정비일수, 정비월수 3가지이다. FFM_NRP 모델의 경우에는 정

비 입고기준 고장량과 정비원수 2가지이다. PFM 모델들은 정비 입고기준 고장량은 독립변수에서 제외된다. FFM 모델은 반대로 작전운용기간이 독립변수에서 제외된다. NRP 모델들의 정비기간은 정비원의 수와 정비량에 따라 유동적으로 변하기 때문에 독립변수가 아니다. 공통적으로 정비원수는 모든 모델의 독립변수에 해당된다. 독립변수들을 정리하면 다음과 같다.

- *Independent Variables*

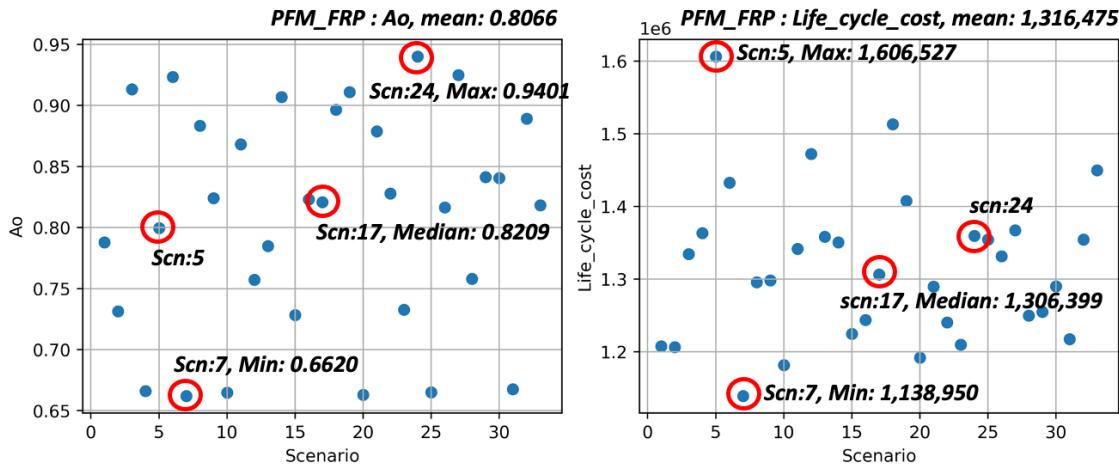
1. Operation period of the PFM models
2. Standard failure rate for maintenance of the FFM models
3. Repair period of the FRP models
4. Number of mechanics
5. Age of 1 ~ 6 ships

시스템 다이나믹스 시뮬레이션 결과변수들의 상관관계는 계수를 통한 직관적인 해석이 어렵다. 수많은 변수들의 인과관계에 의해 결정되기 때문이다. PFM_FRP 모델은 4개의 모델들 중 가장 복잡도가 떨어진다. 시간의 흐름에 따라 고정적으로 움직이기 때문이다. PFM_FRP 모델의 피드백 루프 개수는 약 21만개이다. 가장 복잡한 FFM_NRP 모델의 피드백 루프수는 약 23만개이다. 이와 같이 복잡한 관계를 직관적으로 해석하는 것은 어렵다. 따라서 변수들의 상관관계 분석을 통해 시스템의 인과관계를 이해하는 과정이 필요하다. 새로운 정비정책의 시뮬레이션에 있어 발생할 수 있는 현상들의 인과적 관계를 파악하는 과정은 중요하다. 문제의 발생 소지를 인지하여 현실성 있는 정비정책으로 개선해야하기 때문이다. 인과적 설명 가능여부를 판단하여 종속변수 값들이 현실적으로 가능한지 판단할 수 있다.

1. PFM_FRP 모델 시뮬레이션 결과

PFM_FRP 모델의 시뮬레이션 세부결과는 부록 1에 첨부하였다. <그림 6-1>은 함정 운용가용도와 총수명비용의 결과이다. 시나리오들의 함정 운용가용도의 평균은 80.66%, 총수명비용 평균은 약 1.3조원이었다. 운용가용도는 약 66 ~ 94%, 총수명비용은 1.1 ~ 1.6조원까지 분포되어있다. 총수명비용의 최대값은 다른 시나리오 결과들에 비해 상대적으로 거리가 멀다. 두 변수의 최대, 중간, 최소값의 시나리오에 해당하는 5, 7, 17, 24번 시나리오의 결과를 확인하였다.

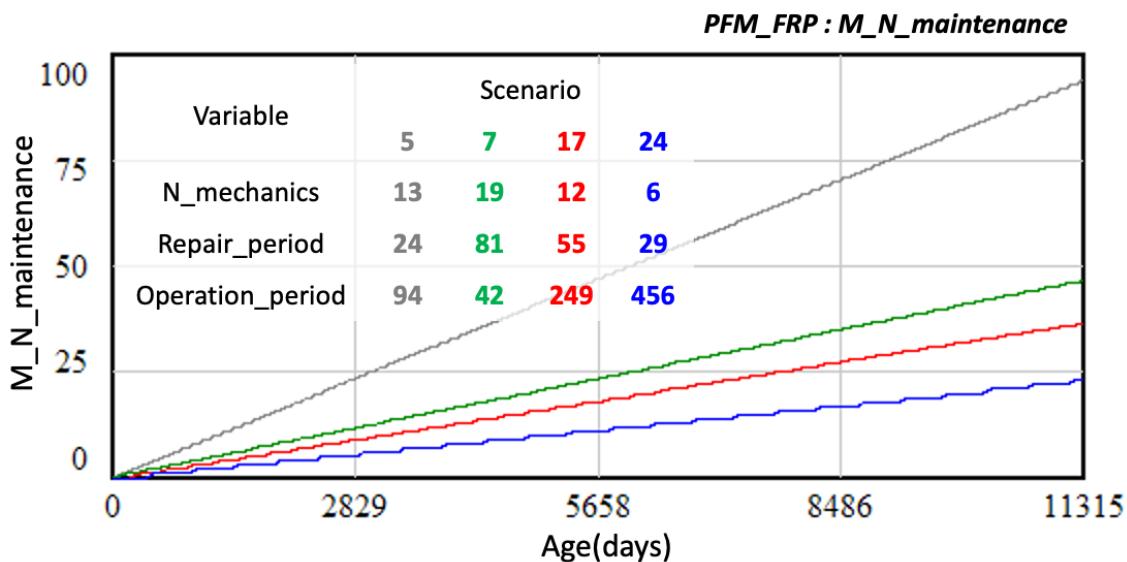
<그림 6-2>는 함정들의 평균 정비횟수이다. PFM_FRP 모델은 운용기간과 정비기간 두 가지 변수에 의해 정비횟수가 결정된다. 5, 7, 17, 24번 시나리오의 운용과 정비



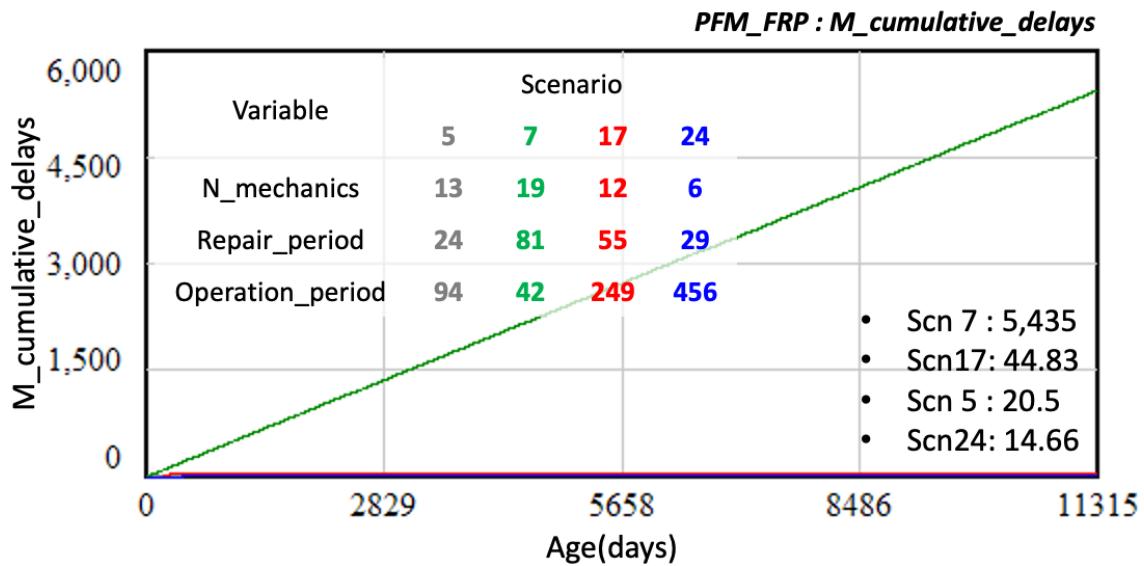
<그림 6-1> 함정 운용가용도와 총수명 비용(PFM_FRP 모델)

를 합친 한주기는 각각 118, 123, 304, 485일이다. 주기가 짧을수록 총 정비횟수가 많다. 자연이 발생할 경우 운용기간은 독립변수 설정보다 길어지는 반면 정비기간에는 자연이 없으므로 일정하다. 정비기간이 짧은 순으로 시나리오를 나열하면 5 - 24 - 17 - 7 순서이다. 총수명 비용이 많은 순서와 동일하다. 정비기간이 짧으면 운용기간이 길고 그만큼 총수명 비용이 많다. 운용기간이 짧은 순서는 7 - 5 - 17 - 24이며 함정 운용가용도가 낮은 순서와 같다. 운용기간이 길수록 함정 운용가용도는 높고 총수명 비용도 크다.

7번 시나리오의 경우 운용기간이 정비기간보다 짧다. PFM_FRP에서 대기가 없기 위

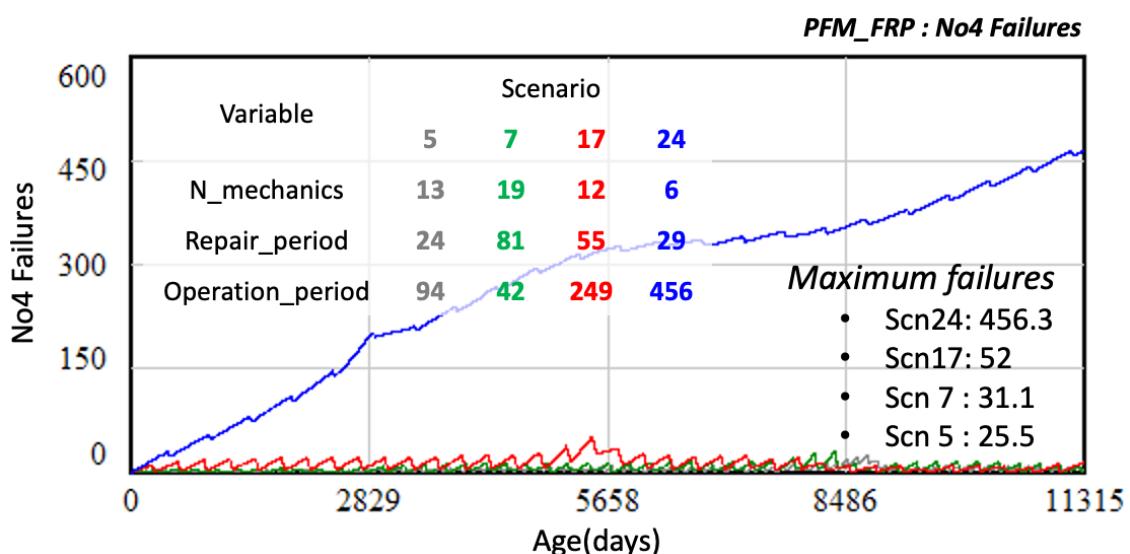


<그림 6-2> 함정들의 평균 정비횟수(PFM_FRP 모델)



<그림 6-3> 평균 누적 대기기간(PFM_FRP 모델)

해서는 운용기간이 정비기간에 비해 최소 3배 이상 커야한다. 함정 6척에 상가대 2대를 운용하기 때문이다. 다른 시나리오들의 차이는 모두 3배 이상이나 7번 시나리오는 0.52배이다. <그림 6-3>과 같이 다른 시나리오에 비해 7번 시나리오의 누적 대기기간이 월등하게 길다. 상가대에 여분이 생기면 즉시 다음 함정이 입고된다. 상가대 가동률은 시나리오 순으로 각각 0.5985, 0.9990, 0.5310, 0.1785이다. 7번 시나리오의 경우 상가대가 쉬지 않고 돌아간다. 상가대 가동률이 높으면 함정이 작전에 투입될 수 있는 일수가 적다. 따라서 상가대 가동률이 높을수록 함정 운용가용도는 낮다.



<그림 6-4> 4번 함정의 누적 고장량 변화(PFM_FRP 모델)

반대로 상가대 가동률이 낮은 경우는 24번 시나리오와 같이 정비기간에 비해 운용기간이 긴 경우이다. 일반고장함수의 고장량이 456일간 누적된 후 29일 동안 정비해야 하는 시스템이다. 24번 시나리오의 정비원 수는 6명이다. 많은 정비량을 단시간에 정비해야 하므로 과도한 일정압력을 받으며 업무하게 된다. 일정압력을 강하게 받음에도 불구하고 6명이 할 수 있는 업무량에는 한계가 있다. <그림 6-4>는 총수명간 함정에 누적된 고장량의 변화이다. 4번함의 예를 들었다. 24번 시나리오 함정들은 운용기간이 길어 많은 고장량을 가지고 있고 한다. 정비기간이 짧고 정비원의 수가 적어 고장 개소를 모두 수리하지 못한다. 함정의 일반고장 누적은 심하지만 정비부대는 입고 함정이 없어 가동률이 낮다. 17번 시나리오도 운용기간에 비해 정비기간이 짧다. 단 이 경우에는 12명의 정비원이 누적 일반고장을 해소할 수 있다.

<그림 6-5>는 변수들간의 상관계수이다. 독립변수들의 상관계수는 낮다. 종속변수 값은 독립변수와 다른 종속변수들의 연계적 상호 인과관계에 따라 결정된다. 정비원 수(N_mechanics)와 총 야간근무 일수(Nightwork_days)간의 상관계수는 -0.72이다. 정비원수가 많을수록 정비량을 빠르게 해소할 수 있으므로 음의 상관관계를 가진다. 이와 같이 직관적인 해석이 가능한 경우 외에 종속변수간의 인과관계에 따라 해석이 어려운 경우도 있다.

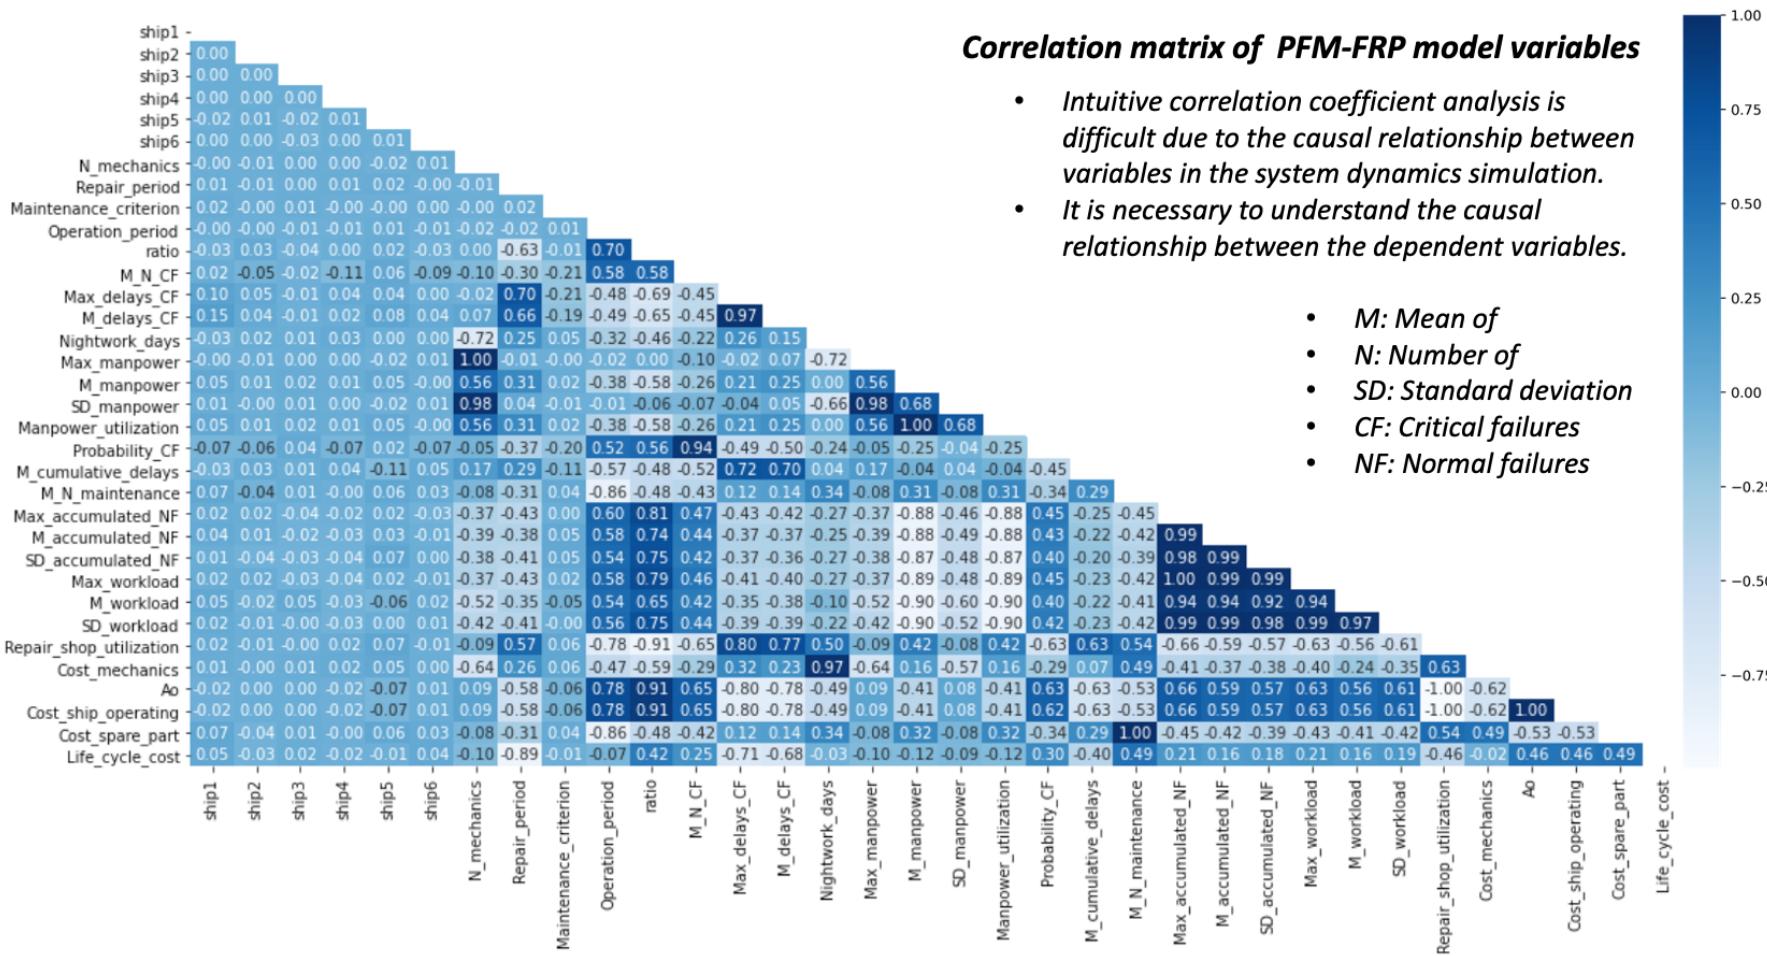
함정들의 평균 정비지연일수(M_cumulative_delays)와 함정 가동률(Ao)의 상관계수는 -0.63이다. 작전 일수(Operation_period)만큼 운용된 함정이 정비입고 되지 못하면 지연이 발생한다. 지연기간에는 추가적인 임무를 수행한다. 지연이 길어질수록 함정의 작전수행 기회를 많아진다. 따라서 함정 가동률과 양의 상관관계라고 생각할 수 있다. 분석결과는 음의 상관관계를 가진다. 정비지연 일수와 함정 가동률은 직접적인 관계가 아니기 때문이다. 함정 가동률이 높다는 것은 함정의 작전 운용 기간이 길다는 것이다. 총 작전일수가 길어지면 상대적으로 총 정비일수는 줄어든다. 함정이 작전 수행하는 동안 정비중인 함정은 수리가 종료된다. 작전 중인 함정이 정비 입고시기가 되었을 때는 이미 기존의 함정들은 수리가 종료된 뒤이다. 작전일수가 길어질수록 정비 입고가 지연될 가능성이 적어지는 것이다. 따라서 지연일수와 함정 가동률은 음의 상관관계이다. 시뮬레이션 결과변수들은 인과적 특성에 따라 직관적 해석이 어려울 수 있다. 직관적 해석이 어려운 상관관계들의 해석을 <표 6-2>와 같이 정리하였다. 일반적으로 상관계수 절대값이 0.3 이상인 경우 뚜렷한 상관관계, 0.7 이상인 경우는 강한 상관관계라고 해석한다.

긴급고장 발생횟수(M_N_CF)와 작전일수(Operation_period)의 상관계수는 0.58이다. 일반고장함수와 긴급고장함수는 수명주기 초반을 제외하면 형태가 유사하였다. 두 고장함수의 관계를 수리적으로 분석하기 위해서는 모든 일반고장과 긴급고장의 발생

부품과 원인을 분석해야 한다. 부품의 상태가 긴급고장으로 이어지는 현상을 파악해야하기 때문이다. 현실적으로 해군 고장 데이터의 양질 측면에서 분석이 힘들다. 명확한 수리적 관계의 규명은 힘들지만 시뮬레이션 결과를 통해 일반고장과 긴급고장의 관계를 대략적으로 이해할 수 있다. 작전일수가 길면 함정에 축적되는 일반고장이 많고, 동시에 긴급고장의 발생횟수도 많다. 고장에 노출되는 일수가 길어지기 때문이다. 함정에 축적된 일반고장량(Max_accumulated_NF, M_accumulated_NF)과 긴급고장 발생횟수의 상관관계는 각각 0.47, 0.44로 양의 상관관계를 가진다. 일반고장과 긴급고장의 관계는 6.2절에서 회귀분석한다.

정비부대 가동률(Repair_shop_utilization)과 총수명비용(Life_cylce_cost)의 상관계수는 -0.46이다. 정비부대 가동률이 높다는 것은 함정 가동률이 낮다는 것이다(이들의 상관계수는 -99.99이다). 정비부대 가동률이 높으면 정비원 총 인건비(Cost_mechanics)와 총 수리부속비(Cost_spare_part) 비용이 커진다. 그럼에도 불구하고 정비부대 가동률과 총수명비용의 음의 상관관계라는 것은 함정 운용비(Cost_ship_operation)가 인건비와 수리부속비를 합한 것보다 크다는 의미이다.

총수명 비용은 총 함정 운용비와 총 수리부속비의 영향이 크고 인건비의 영향은 상대적으로 작다. 수리부속비용은 정비횟수와 연관이 크고 정비횟수는 함정 운용일수와 정비일수의 영향이 크다. 즉 총수명 비용은 함정의 운용과 정비의 비율을 통해 경제성을 확보할 수 있다.



<그림 6-5> PFM_FRP 모델의 변수간 상관관계

<표 6-2-1> PFM_FRP 모델의 상관관계 해석(1)

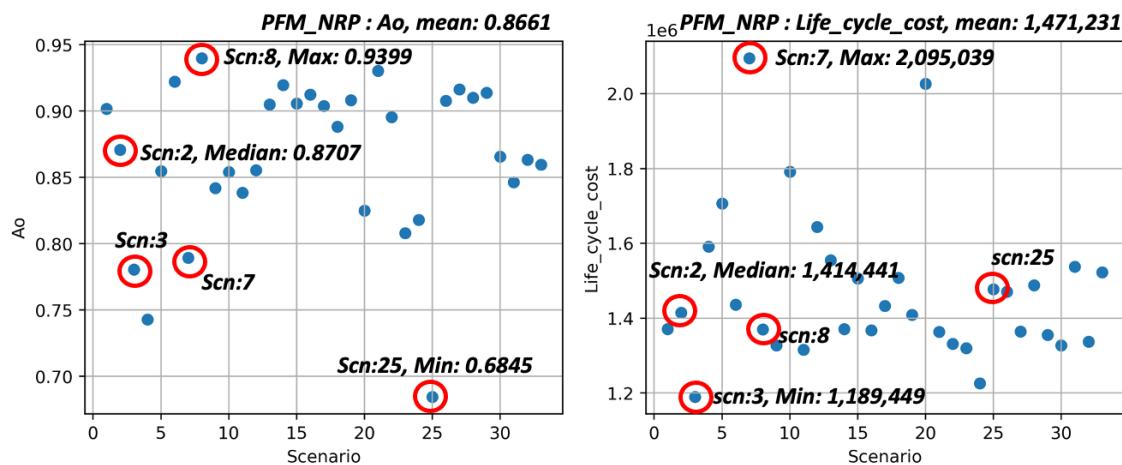
Variables		Correlation coef.	Details
Operation_period	M_N_CF	0.58	Since critical failures does not occur during the maintenance period, the longer the operation period, the more critical failure occurs.
Operation_period Ao	M_cumulative_delays	-0.57 -0.63	The long operation of the ship means that the number of days of operation is long. If the operation period is long, the maintenance period is relatively short. All maintenance has been completed during the operation period, so repairs are possible without delay.
Operation_period	Cost_spare_part	-0.86	The spare part consumes both normal failure maintenance and critical failure maintenance. If the operation_period is long, the number of maintenance is reduced and the cost of repair parts is reduced.
M_N_CF	M_cumulative_delays	-0.52	The longer operation period, the more critical failures occurs. The longer operation period, repairs are possible without delay.
Nightwork_days	SD_manpower	-0.66	The deviation of the maintenance rate increases as the number of mechanics increases. A large number of mechanics reduces the number of night shifts.
Max_manpower	Cost_mechanics	-0.64	If the maximum maintenance amount of maintenance personnel is large, it means that the number of maintenance personnel is large. A large number of mechanics allows repairs to be completed quickly, reducing night shifts. The cost of a night shift is 1.5 times the cost of a normal working day. The reduction in night shifts also reduces labor costs.

<표 6-2-2> PFM_FRP 모델의 상관관계 해석(2)

Variables		Correlation coef.	Details
M_manpower	Max_workload	-0.89	When the average amount of work of a mechanic is high, the amount of remaining work decreases rapidly. The maximum remaining workload is low.
Max_accumulated_NF	Repair_shop_utilization	-0.66	A high maintenance rate means a long operation period, so the number of
M_accumulated_NF		-0.59	maintenance days is relatively reduced. The operation rate of the repair shop
SD_accumulated_NF		-0.57	decreases.
Repair_shop_utilization	Cost_spare_part	0.54	A busy repair shop means frequent maintenance, so the cost of spare parts increases.
Repair_shop_utilization	Cost_ship_operating	-1.00	The availability of repair shops is equivalent to a decrease in the number of operating days. Reduces ship operating costs.
Repair_shop_utilization	Life_cycle_cost	-0.46	If the usage rate of the repair shop increases, the operation rate of ships decreases and the operating cost decreases. A decrease in total life cycle cost means that the operating cost of the ship is greater than the maintenance cost.
Life_cycle_cost	Cost_mechanics	-0.02	Total life cycle cost is not related to the number of mechanics. There is a similar
Cost_ship_operating		0.46	relationship between the cost of spare parts and the operating cost of a ship.
Cost_spare_part		0.49	

2. PFM_NRP 모델 시뮬레이션 결과

PFM_NRP 모델의 시뮬레이션 세부결과는 부록 2에 첨부하였다. <그림 6-6>은 함정 운용가용도와 총수명비용의 결과이다. 시나리오들의 함정 운용가용도의 평균은 86.26%, 총수명비용 평균은 약 1.45조원이었다. 운용가용도는 약 67 ~ 94%로 분포되어 PFM_FRP 모델과 유사한 범위였다. 총수명비용은 1.2 ~ 2.0조원까지 분포되어 PFM_FRP 모델보다 범위가 넓었다. 전체적으로 운용가용도가 높을 때 총수명 비용이 낮은 형태를 보인다. NRP 모델의 유동적 정비로 인한 영향으로 보인다. 운용가용도와 총수명비용의 관계에 대해 6.2절에서 회귀분석한다. 두 변수의 최대, 중간, 최소값의 시나리오에 해당하는 2, 3, 7, 8, 20번 시나리오의 결과를 확인하였다.

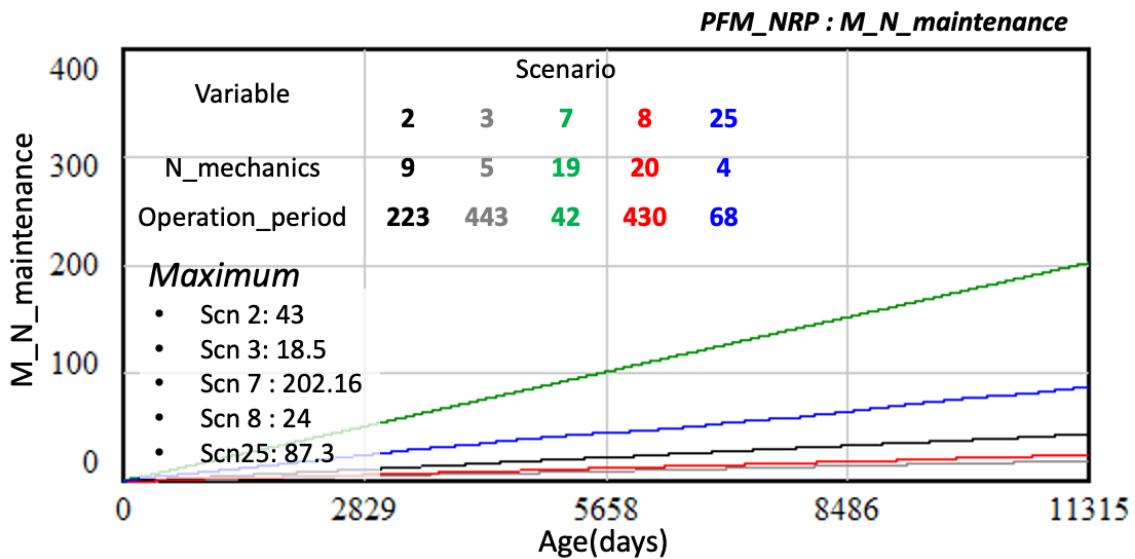


<그림 6-6> 함정 운용가용도와 총수명비용(PFM_NRP 모델)

<그림 6-7>는 함정들의 평균 정비횟수이다. 운용기간이 길수록 정비횟수가 적다. PFM_NRP 모델은 정비기간이 유동적이다. 시나리오들의 평균 정비기간은 각각 34.2, 134.5, 11.8, 28.6, 40.3 이었다. 평균 정비기간과 함 운용기간을 합친 대략적인 한 주기는 각각 257.2, 557.5, 53.8, 458.6, 108.3으로 3 - 8 - 2 - 25 - 7 시나리오 순으로 같다. 주기가 길수록 정비횟수가 적다. 주기가 길면 총수명간 정비를 수행할 기회가 적어지기 때문이다.

한편 이 순서는 총수명 비용이 적은 순과 동일하기 때문에 정비비용이 총수명 비용에 미치는 영향이 크다고 판단할 수 있다. 정비비용(인건비 + 수리부속비)가 적은 순서는 8 - 3 - 2 - 25 - 7 이다. 3번과 8번 시나리오 외의 순서가 동일하다. 정비비용이 클수록 총수명 비용이 크다는 경향이 있다. PFM_FRP 모델의 총수명 비용은 작전 운영비용의 영향이 컷으나 PFM_NRP 모델은 정비비용의 영향이 크다.

수리부속비는 총수명 정비비용과 순서가 동일하다. 즉 유동적인 정비기간에서 발생

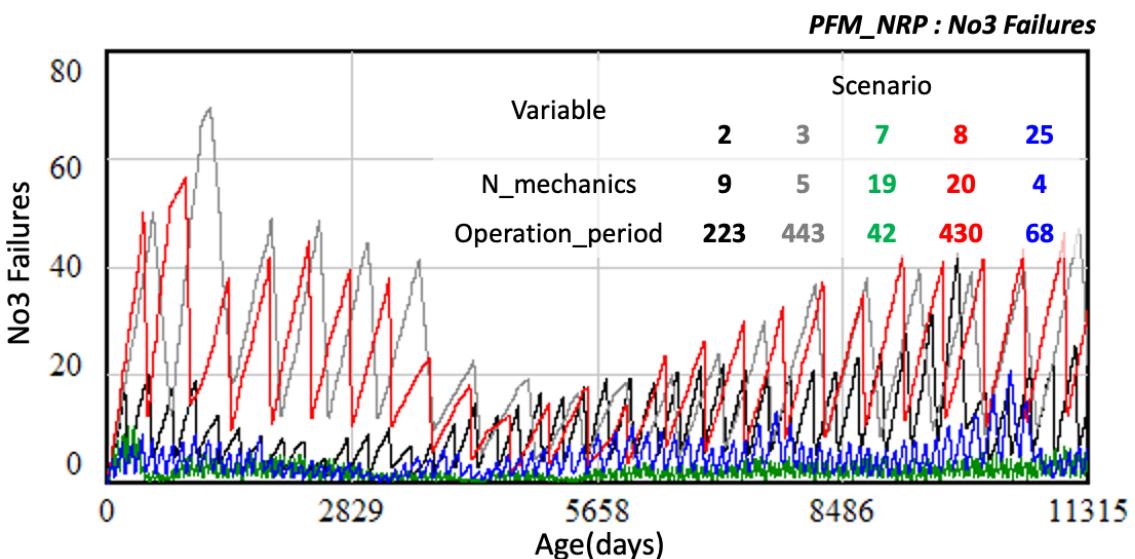


<그림 6-7> 함정들의 평균 정비횟수(PFM_NRP 모델)

하는 인건비의 차이가 3번과 8번 시나리오의 총 정비비용 차이를 유발한다고 할 수 있다. 3, 8번 시나리오는 작전운용기간은 유사하나 정비원 수의 차이가 크다.

총 정비일수는 정비횟수 * 평균 정비기간으로 가늠할 수 있다. 시나리오 순으로 1470.6, 2488.3, 2385.5, 686.4, 3518.2이다. 정비일수가 적을수록 작전일수가 많기 때문에 함정 운용가용도가 높다.

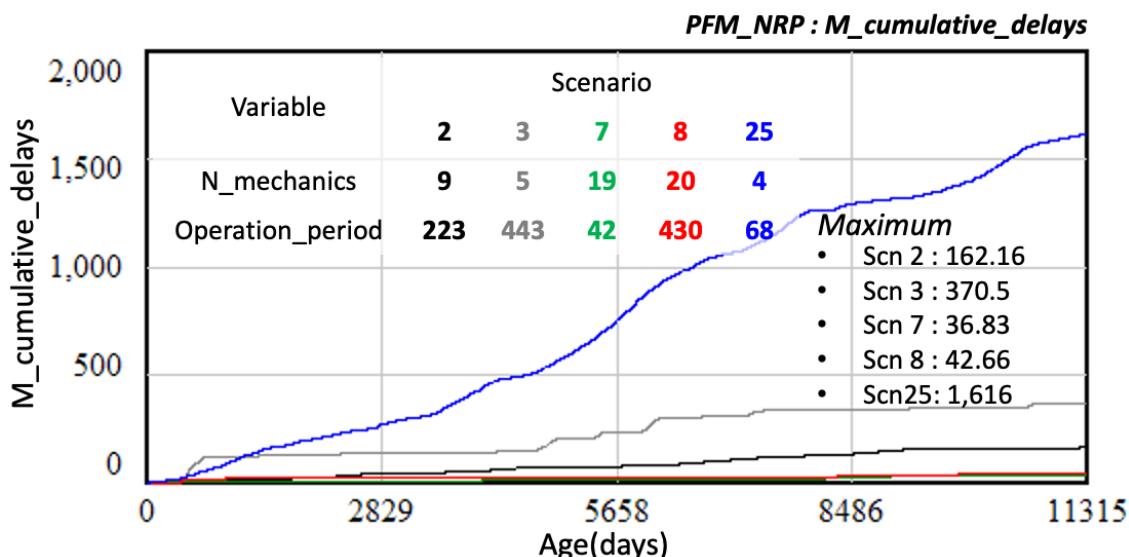
<그림 6-8>은 3번함의 시나리오별 누적 고장량의 변화를 나타낸다. PFM_NRP 모델



<그림 6-8> 3번 함정의 누적 고장량 변화(PFM_NRP 모델)

은 함정의 누적 고장량에 따라 정비기간이 변하기 때문에 <그림 6-4>와 같이 일반고장이 정비기간 내 해소되지 못해 쌓여가는 현상은 나타나지 않는다.

<그림 6-9>는 총수명간 누적된 함정들의 평균 대기기간이다. 25번 시나리오의 경우 총 대기일수가 1,616으로 다른 시나리오에 비해 많다. PFM_FRP 모델에서 작전기간이 정비기간의 3배 이상이 되어야 대기가 발생하지 않는다고 하였다. PFM_NRP 모델의 경우도 동일하다. 작전 운용기간이 평균 정비기간의 3배 이상 되어야 대기가 발생하지 않는다. 시나리오들의 작전 운용기간 / 평균 정비기간 값은 각각 6.5, 3.3, 3.6, 15.0, 1.7이다. 25번 시나리오의 경우는 3배를 넘지 않은 많은 대기가 발생하였다.



<그림 6-9> 평균 누적 대기기간(PFM_NRP 모델)

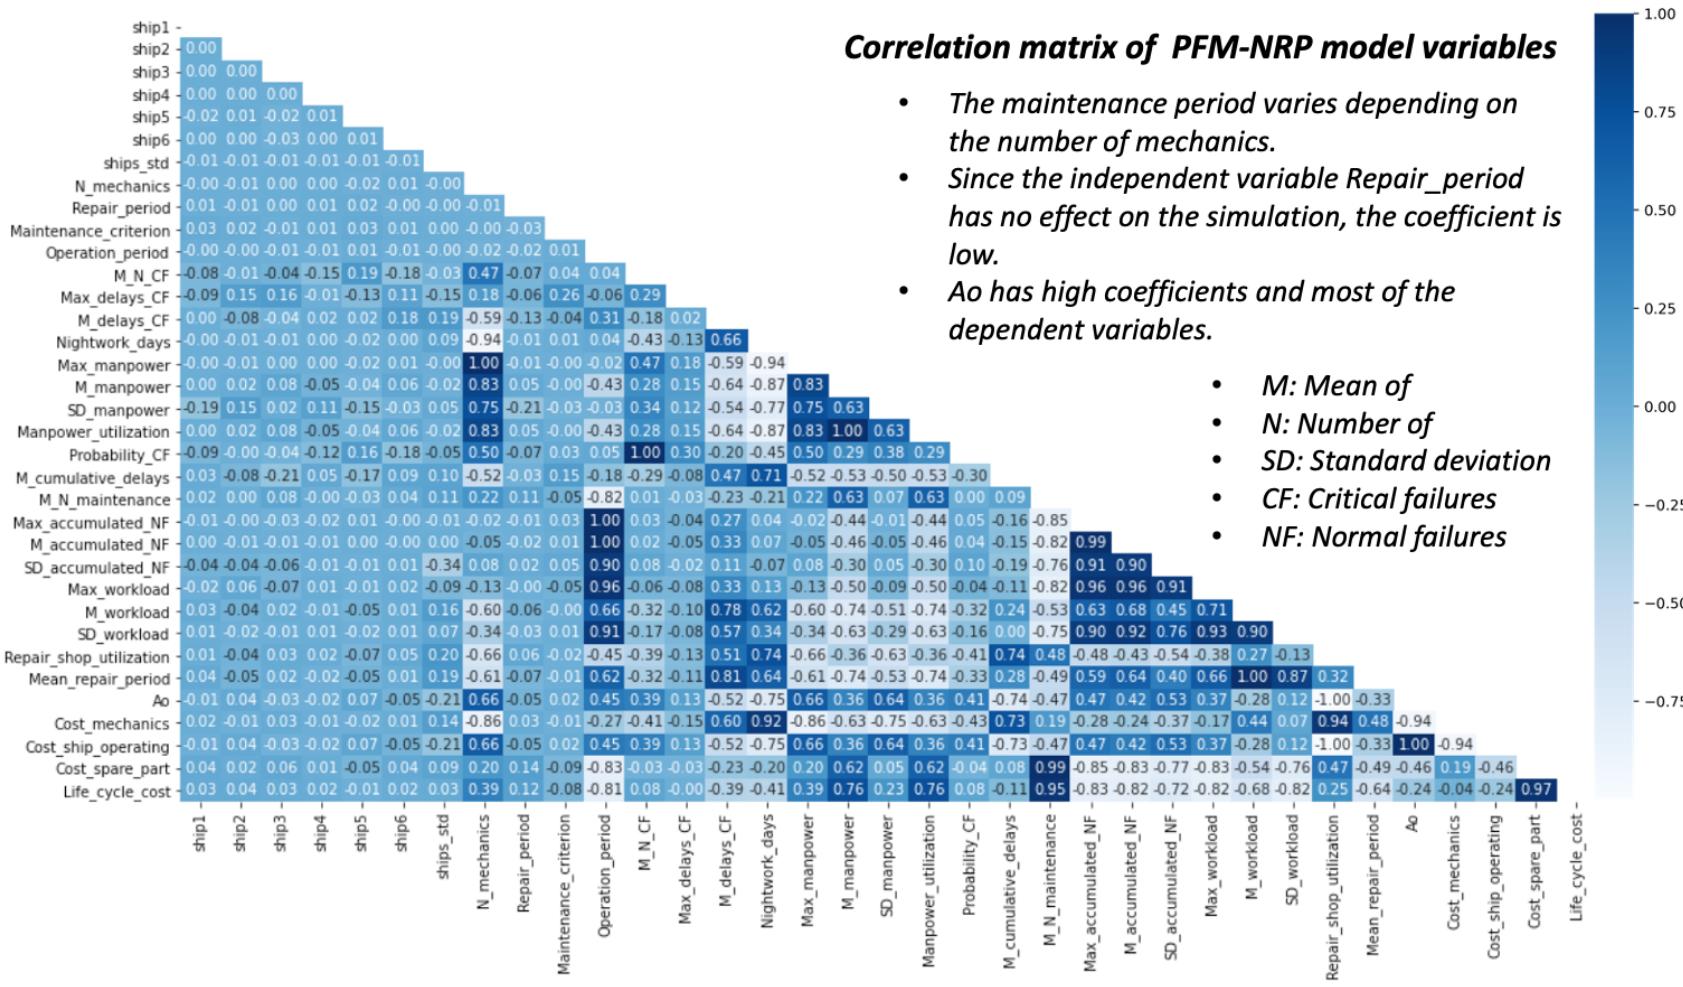
변수들의 상관관계와 분석을 <그림 6-10>, <표 6-3>과 같이 정리하였다. 정비원의 수(N_mechanics)와 총 인건비(Cost_mechanics)의 상관계수는 -0.86이다. 정비원이 많으면 인건비가 증가할 것으로 생각할 수 있다. 그러나, 총 인건비는 야간근무일수(Nightwork_days)의 영향을 더 크게 받는다고 할 수 있다. 이들의 상관계수는 0.92이다. 정비원이 많아지면 야간근무일수가 줄어들어 총 인건비가 감소한다. 해군은 인력 감축 정책을 통해 정비원의 수도 줄여나가고 있다. 함정 건조 계획에 따라 전력이 지속 증강될 때 정비원 수의 감축은 야간근무 증가로 이어진다.

함 운용기간(Operation_period)이 길면 일반고장을 많이 축적하여 정비부대에 입고된다. 정비원의 평균 업무량(M_manpower)가 증가할 것으로 판단할 수 있다. 그러나, 운용기간이 길면 정비횟수가 그만큼 줄어든다. 1회 정비시 정비원의 업무량은 커지는 반면 총수명간 정비원의 업무량은 감소한다.

긴급고장 정비 지연(M_delay_CF)이 많아질 때 정비 업무량이 많아지지는 않는다.

긴급고장 발생시에는 추가적인 작전임무를 수행하지 않으므로 고장량이 증가하지 않기 때문이다. 즉 긴급고장 정비 지연과 총 인건비(Cost_mechanics)는 직접적인 관련은 없다. 긴급고장 정비 지연은 정비부대가 일반고장 정비로 바쁜 상태임을 의미한다. 일반고장으로 인한 정비업무가 많을 때 야간근무가 증가하여 총 인건비가 증가한다. 따라서 긴급고장 정비 지연과 총 인건비는 양의 상관관계를 가진다.

총 정비횟수(M_N_maintenance)와 총수명 비용(Life_cycle_cost)의 상관계수는 0.96이고, 총수명 비용과 총 인건비의 관련성은 낮다. PFM_NRP 모델의 총수명 비용은 수리부속비의 영향을 많이 받는다. PFM_FRP 모델의 총수명 비용이 함정 운용비의 영향을 많이 받았던 것과는 반대된다.



<그림 6-10> PFM_NRP 모델의 변수간 상관관계

<표 6-3-1> PFM_NRP 모델의 상관관계 해석(1)

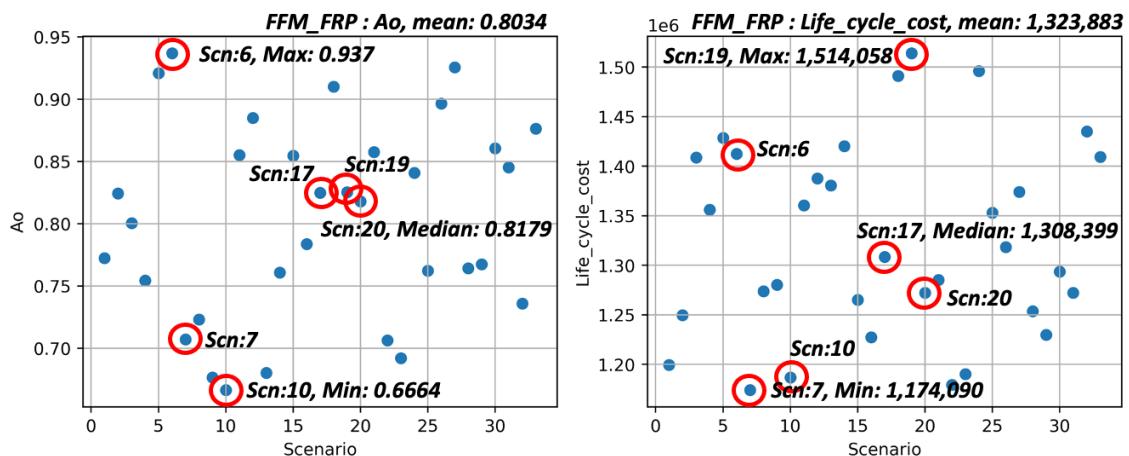
Variables		Correlation coef.	Details
N_mechanics	M_N_CF	0.47	If the number of mechanics is large, maintenance is completed quickly. As the number of operating days increases, the number of days exposed to critical failure increases.
Ao	0.66		If the number of mechanics is large, maintenance is completed quickly.
Repair_shop_utilization	-0.66		As the number of operating days increases, the operational availability of ships increases, and the operation rate of repair shops decreases.
Cost_mechanics	-0.86		A large number of mechanics reduces the number of night shifts. The number of night shifts is reduced and the total cost is reduced. It can be said that the total labor cost has a greater effect on the number of night shifts than the number of mechanics.
Nightwork_days	-0.94		
Operation_period	M_N_maintenance	-0.82	If the operating period is long, the total number of maintenance is reduced. The operation rate of the repair shop is reduced, and the average amount of maintenance that a mechanic must perform during the total life cycle is reduced.
Repair_shop utilization	-0.45		
M_manpower	-0.43		
M_workload	0.66		On the other hand, the amount of work to be performed during one maintenance increases.

<표 6-3-2> PFM_NRP 모델의 상관관계 해석(2)

Variables		Correlation coef.	Details
M_N_CF	Ao	0.39	The high availability of ships means that there are many days of exposure to critical failures.
M_delay_CF	Cost_mechanics	0.60	Delays in critical failures do not increase workload. It is not directly related to labor costs. Delays in critical failures occur when repair shops are busy. As repair shops are busy, labor costs increase. because mechanics perform night shift.
M_N_maintenance	Cost_ship_operating	-0.47	The more frequent the maintenance, the shorter the operating period. Reduced ship operating costs. The cost increases because the number of repair parts to be replaced during each maintenance increases, and the total life cost increases.
	Cost_spare_part	0.99	
	Life_cycle_cost	0.96	
Life_cycle_cost	Cost_mechanics	-0.04	The total cost of life is greatly affected by the cost of repair parts.
	Cost_ship_operating	-0.24	
	Cost_spare_part	0.97	

3. FFM_FRP 모델 시뮬레이션 결과

FFM_FRP 모델의 시뮬레이션 세부결과는 부록 3에 첨부하였다. <그림 6-11>은 함정 운용가용도와 총수명 비용의 결과이다. 함정 운용가용도의 평균은 80.34%, 총수명 비용 평균은 약 1.32조원이었다. 평균적으로 PFM_FRP 모델과 유사하다. 3장의 분석에서는 FFM 모델의 함정 운용가용도가 약 3% 높았으나, 긴급고장함수, 정비부대 정비능력 모듈이 추가되면서 유사한 수준이 되었다. 함정 운용가용도는 약 67 ~ 94%로 분포되었다, 총수명비용은 1.2 ~ 1.5조원까지 분포되었다. 전체적으로 함정 운용가용도와 총수명 비용의 산포도가 유사하다. 함정 운용가용도와 총수명 비용이 유사한 형태로 증감한다고 할 수 있다. 두 변수의 최대, 중간, 최소값의 시나리오에 해당하는 6, 7, 10, 17, 19, 20번 시나리오의 결과를 확인하였다.

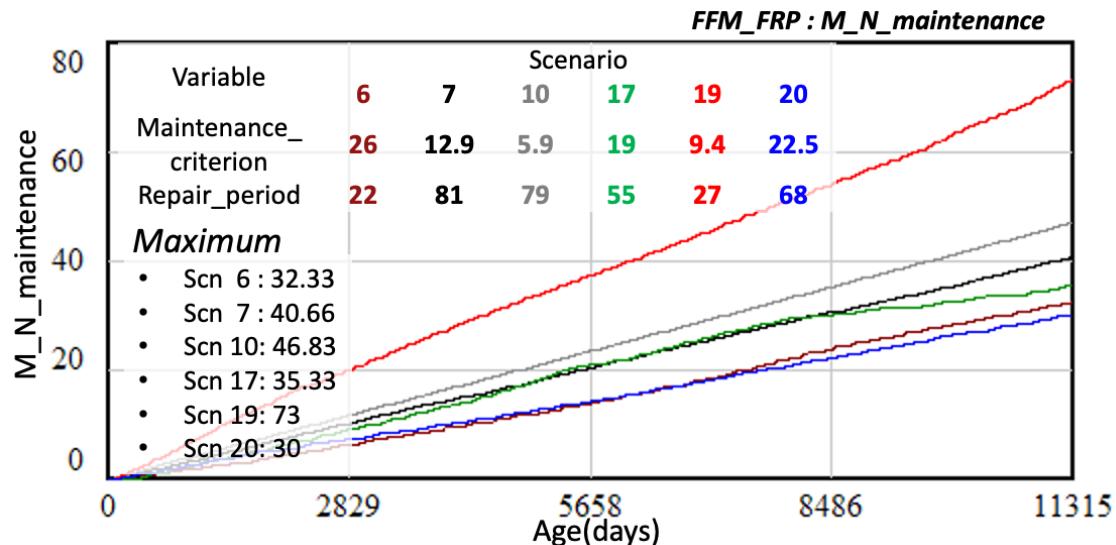


<그림 6-11> 함정 운용가용도와 총수명비용(FFM_FRP 모델)

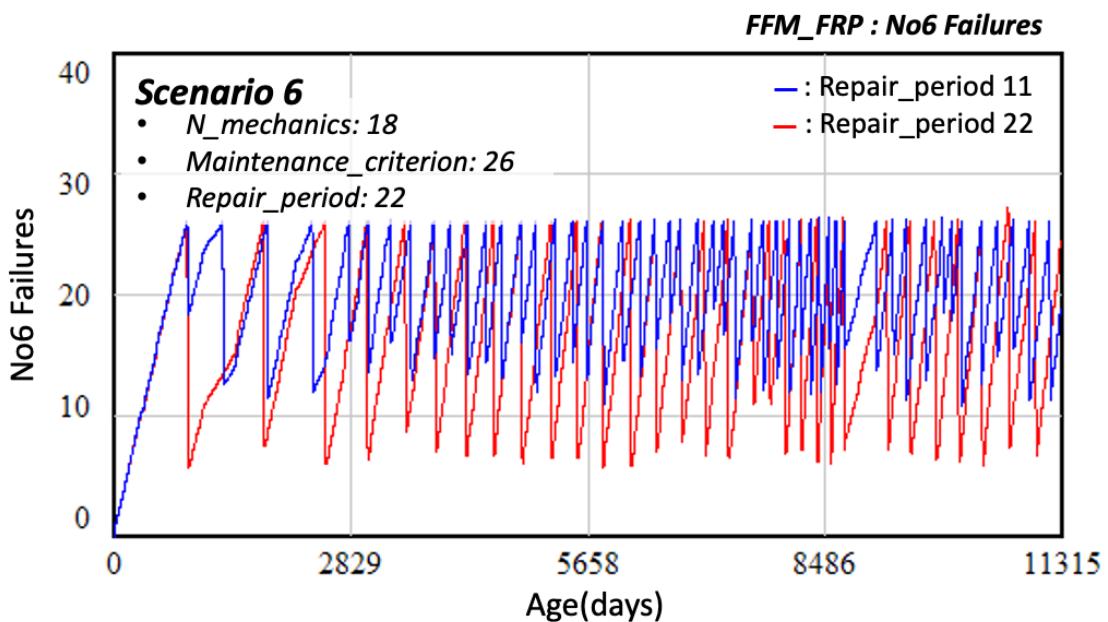
FFM 모델은 입고기준(Maintenance_criterion)에 따라 작전 운용기간이 다르다. 총 정비일수가 길수록 함정 운용 가용도는 낮다. 총 정비일수는 시나리오 순서대로 720, 3320.17, 3780, 1986.67, 1982.5, 2066.17이다.

<그림 6-12>는 총 정비횟수이다. 정비횟수는 함정의 한 주기와 관련이 있었다. FFM_FRP 모델의 한 주기(평균 작전 운용기간 + 정비일수)는 각각 353.59, 278.28, 239.07, 320.27, 155, 377.17이다. 주기가 가장 짧은 시나리오 19가 정비횟수가 가장 많다.

FFM_FRP 모델은 33개 시나리오 모두 일반고장이 함정에 과도하게 축적되는 현상은 보이지 않았다. PFM_FRP 모델의 경우 작전기간에 비해 정비기간이 짧은 경우 정비 업무량을 감당하지 못해 <그림 6-4>와 같이 일반고장이 축적되는 현상이 발생하였다. PFM_NRP 모델은 정비기간이 유동적이므로 정비량에 따라 정비기간이 변하면서 함정의 과도한 고장량 축적을 막았다. FFM_FRP 모델은 정비기간이 정해져 있기



<그림 6-12> 함정들의 평균 정비횟수(FFM_FRP 모델)



<그림 6-13> 정비기간 단축시 함정에 축적된 일반고장량의 변화

때문에 정비횟수의 변화를 통해 일반고장의 지속적인 누적을 방지한다. FFM_FRP 6 번 시나리오의 정비기간(Repair_period)를 반으로 감소시켜 <그림 6-13>와 같이 결과를 비교하였다. 빨강색이 원래의 6번 시나리오, 파랑색은 정비기간을 축소시킨 것이다. 입고 기준인 고장량 26이 되면 정비를 수행한다. 정비기간이 짧기 때문에 빨리 퇴장한다. 단 입고기준점에 도달하는 시기가 빠르기 때문에 정비횟수가 많다. 시나리

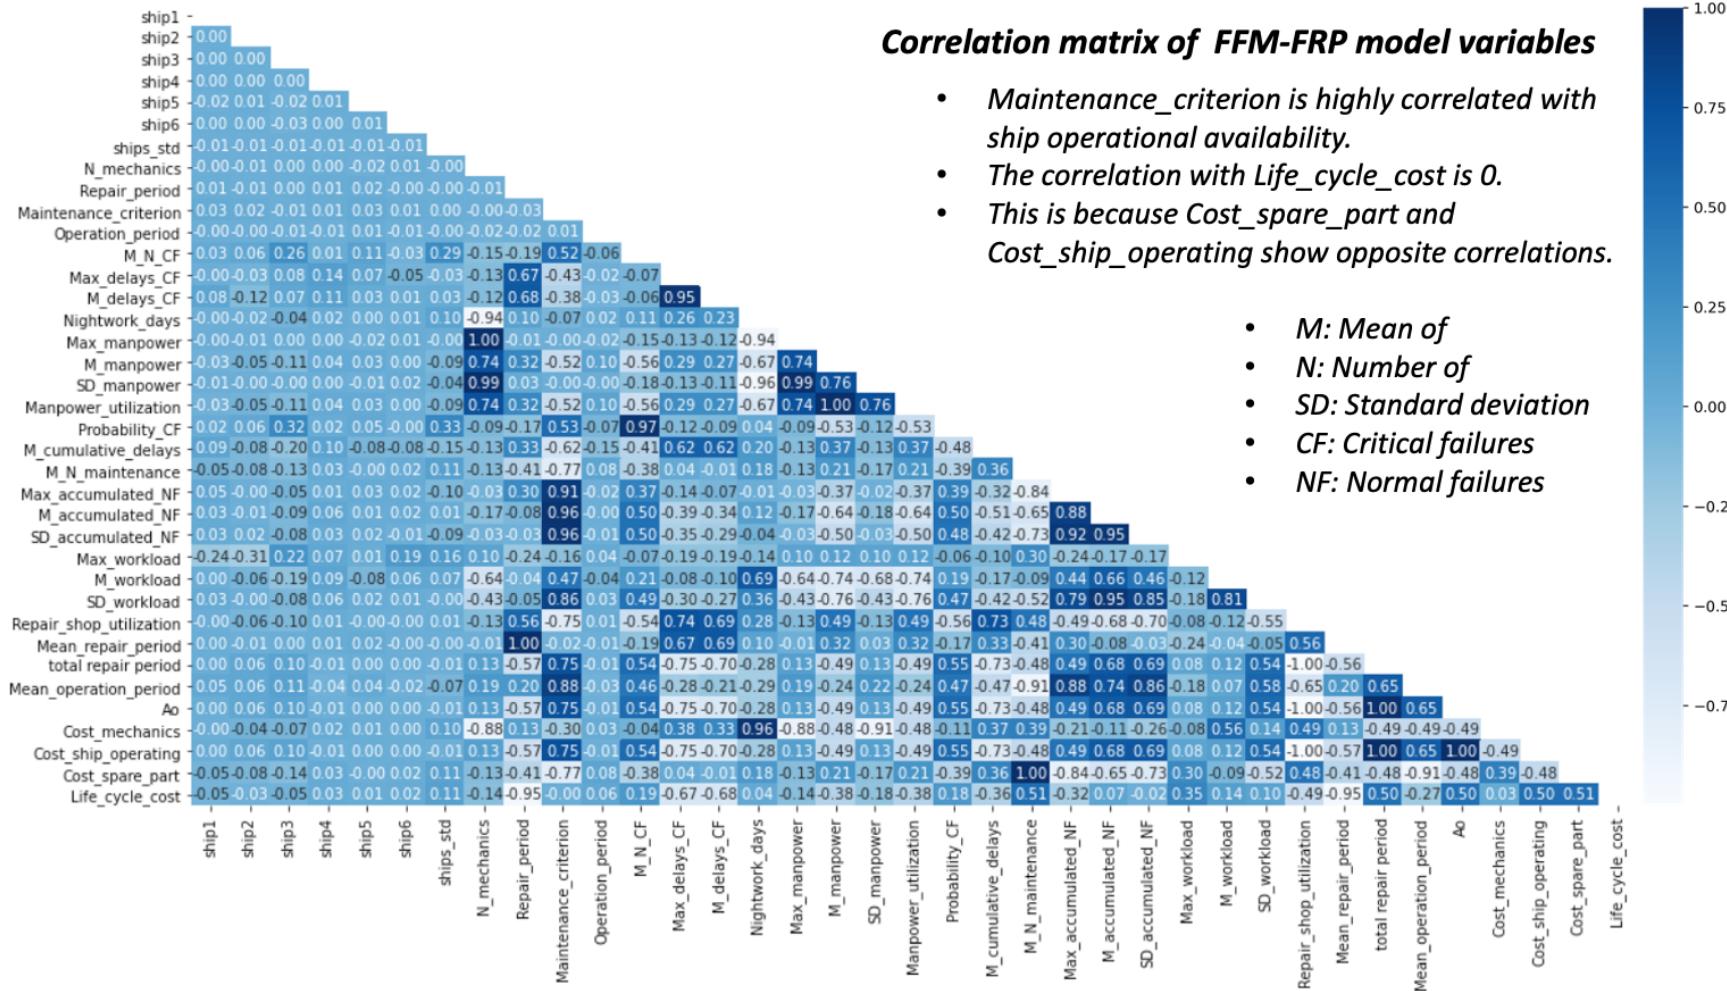
오 6의 총 정비횟수는 32.33회이나 정비기간을 단축시킨 경우의 총 정비횟수는 51회이다. FFM_FRP 모델은 입고기준에 따라 정비횟수를 조절하며 함정의 과도한 고장 축적을 막는다.

변수들의 상관관계는 <그림 6-14>와 같으며 직관적으로 해석하기 힘든 관계를 <표 6-4>와 같이 정리하였다.

총수명 비용은 수리부속비(0.50)와 함정 운용비(0.51)와의 상관계수가 유사하다. 인건비와 야간근무일수의 상관계수(0.96)는 이전 모델들과 동일하게 높으나 총수명 비용과의 상관계수는 0.03으로 낮다. 작전일수와 정비횟수가 총수명 비용에 유사한 수준의 영향을 미친다고 할 수 있다.

FFM_FRP의 함정 운용가용도는 정비 입고기준(Maintenance_criterion)의 영향을 많이 받는다. 입고기준과 함정 운용비는 양의 상관관계(0.75)를 가진다. 반면 수리부속 비용은 정비횟수(M_N_maintenance)와 관계가 크다. 함정 운용가용도가 높을 때 정비횟수는 상대적으로 줄어들게 되므로 수리부속 비용도 감소한다. 정비 입고기준과 수리부속비는 음의 상관관계(-0.77)를 가진다. 그럼에도 불구하고 정비 입고기준은 총수명 비용과의 상관계수가 0이다. 0.75와 -0.77은 정반대 방향의 유사한 크기의 상관성이라고 이해할 수 있다. 총 인건비는 정비 입고기준과 상관성이 낮다. 정비 입고기준은 함정 운용비, 수리부속비와 정반대의 상관관계를 가지기 때문에 효과가 상쇄되었다고 이해할 수 있다.

정비기간(Repair_period)이 길면 총수명간 작전 일수가 상대적으로 감소하기 때문에 함정 운용비가 감소한다. 작전 일수는 정비 입고 기준에 따라 결정되기 때문에 정비기간은 운용과 정비 한주기의 길이를 결정한다. 정비기간이 길면 한 주기의 길이가 길어진다. 총수명간 정비횟수는 감소하게 되므로 수리부속비가 감소한다. 즉 정비기간이 길면 함정 운용비와 수리부속비가 모두 감소하게 되므로 총수명 비용이 감소한다.



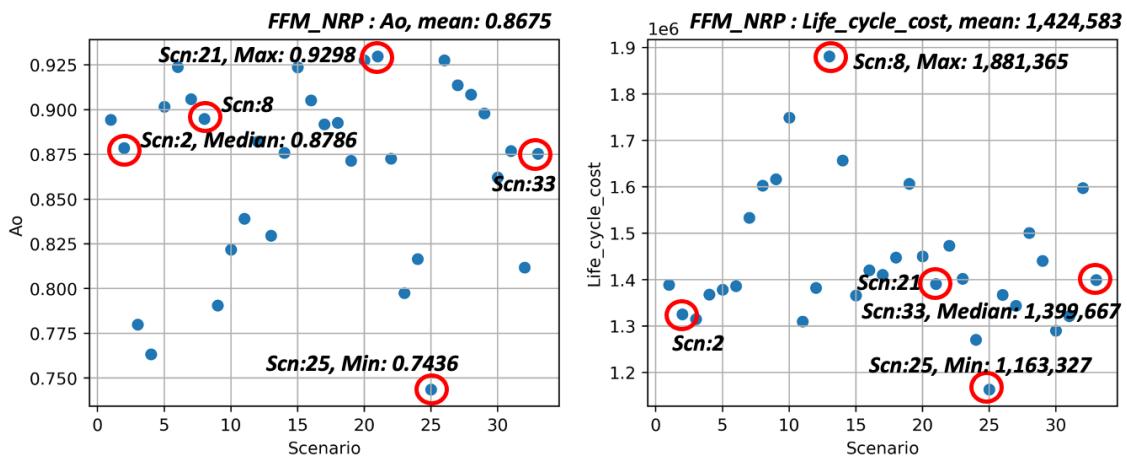
<그림 6-14> FFM_FRP 모델의 변수간 상관관계

<표 6-4-1> FFM_FRP 모델의 상관관계 해석

Variables		Correlation coef.	Details
Repair_period	Cost_mechanics	0.13	Repair_period has little to do with labor costs. There is a similar degree of correlation with the ship operation cost and the cost of repair parts. The total life cost was not linearly related to the ship operation cost and the cost of repair parts (see Fig. 6-11). It can be said that the correlation between repair period and total life cost increased due to the combined effect of these costs.
	Cost_ship_operating	-0.57	
	Cost_spare_part	-0.41	
	Life_cycle_cost	-0.95	
Maintenance_criterion	Ao	0.74	Since the maintenance period is fixed, the number of operating days of a ship is determined by maintenance_criterion. The coefficient with Ao is high. Since it is highly correlated with the number of days of operation, the correlation coefficient with the total ship operation cost is also high. On the other hand, the larger the criterion, the fewer maintenance times, so the total cost of repair parts is reduced.
	Cost_mechanics	-0.30	
	Cost_ship_operating	0.75	
	Cost_spare_part	-0.77	
	Life_cycle_cost	0.00	The low correlation with total life cost is unusual. It can be inferred that this is because the cost of operation and the cost of spare parts show the opposite correlation.

4. FFM_NRP 모델 시뮬레이션 결과

FFM_NRP 모델의 시뮬레이션 세부결과는 부록 4에 첨부하였다. <그림 6-15>은 함정 운용가용도와 총수명 비용의 결과이다. 함정 운용가용도의 평균은 86.75%로 PFM_NRP 모델과 평균적으로 유사하고 4개 모델중 가장 평균이 높다. 총수명비용 평균은 약 1.4조원으로 PFM_NRP 모델보다 약 500억원 적다. 함정 운용가용도는 약 74 ~ 93%로 분포되었다, 총수명비용은 1.2 ~ 1.9조원까지 분포되었다.



<그림 6-15> 함정 운용가용도와 총수명 비용(FFM_NRP 모델)

FFM_NRP 모델은 상태기반정비와 유사하다. 정비 필요 상황이 되면 입고되고, 정비가 완료 되는대로 다시 작전을 수행한다. 이전의 3개 모델과 달리 정비 입고 기준과 퇴장 기준을 상수로 규정할 수 없다. 독립변수도 2개(정비 입고기준 고장량, 정비원 수)로 가장 적다. 독립변수의 수가 적은만큼 종속변수간의 관계가 더 복잡하고 피드백 루프는 약 23만개로 4개 모델중 가장 많다. 변수간의 관계를 해석하기 더욱 어렵다. <그림 6-15>에서 함정 운용가용도와 총수명 비용의 형태는 운용가용도가 높아질 때 총수명 비용도 높아지지만 비교적 크게 증가하지 않는다.

25번 시나리오는 두 종속변수 모두 최하위 값을 가진다. 25번 시나리오의 입고기준 고장량은 27.75이고, 정비원 수는 4명이다. OO함대 기준의 입고기준 고장량이 14.71임을 고려할 때 약 2배 정도 운용기간이 길다. 정비원의 수는 9명 대비 4명으로 0.5 배 수준이다. 그럼에도 불구하고 운용가용도는 OO함대의 수준(약 0.75)과 유사하다. 상태기반정비를 적용할 때 운용가용도를 비슷한 수준으로 유지한다면 정비원은 현재의 절반 수준으로도 충분하다는 의미가 된다. 평균 정비기간은 53.36일로 현재보다 길다. 입고기준이 높기 때문에 정비기간도 늘어난다. 입고기준의 상향은 정비횟수의 감소와 연관된다. 시나리오 25의 총 정비횟수는 20회이다. OO함대 62회의 1/3수준으로 정비횟수가 감소한다. 정비횟수는 총수명 비용과 연관이 있다. OO함대의 약 1.4

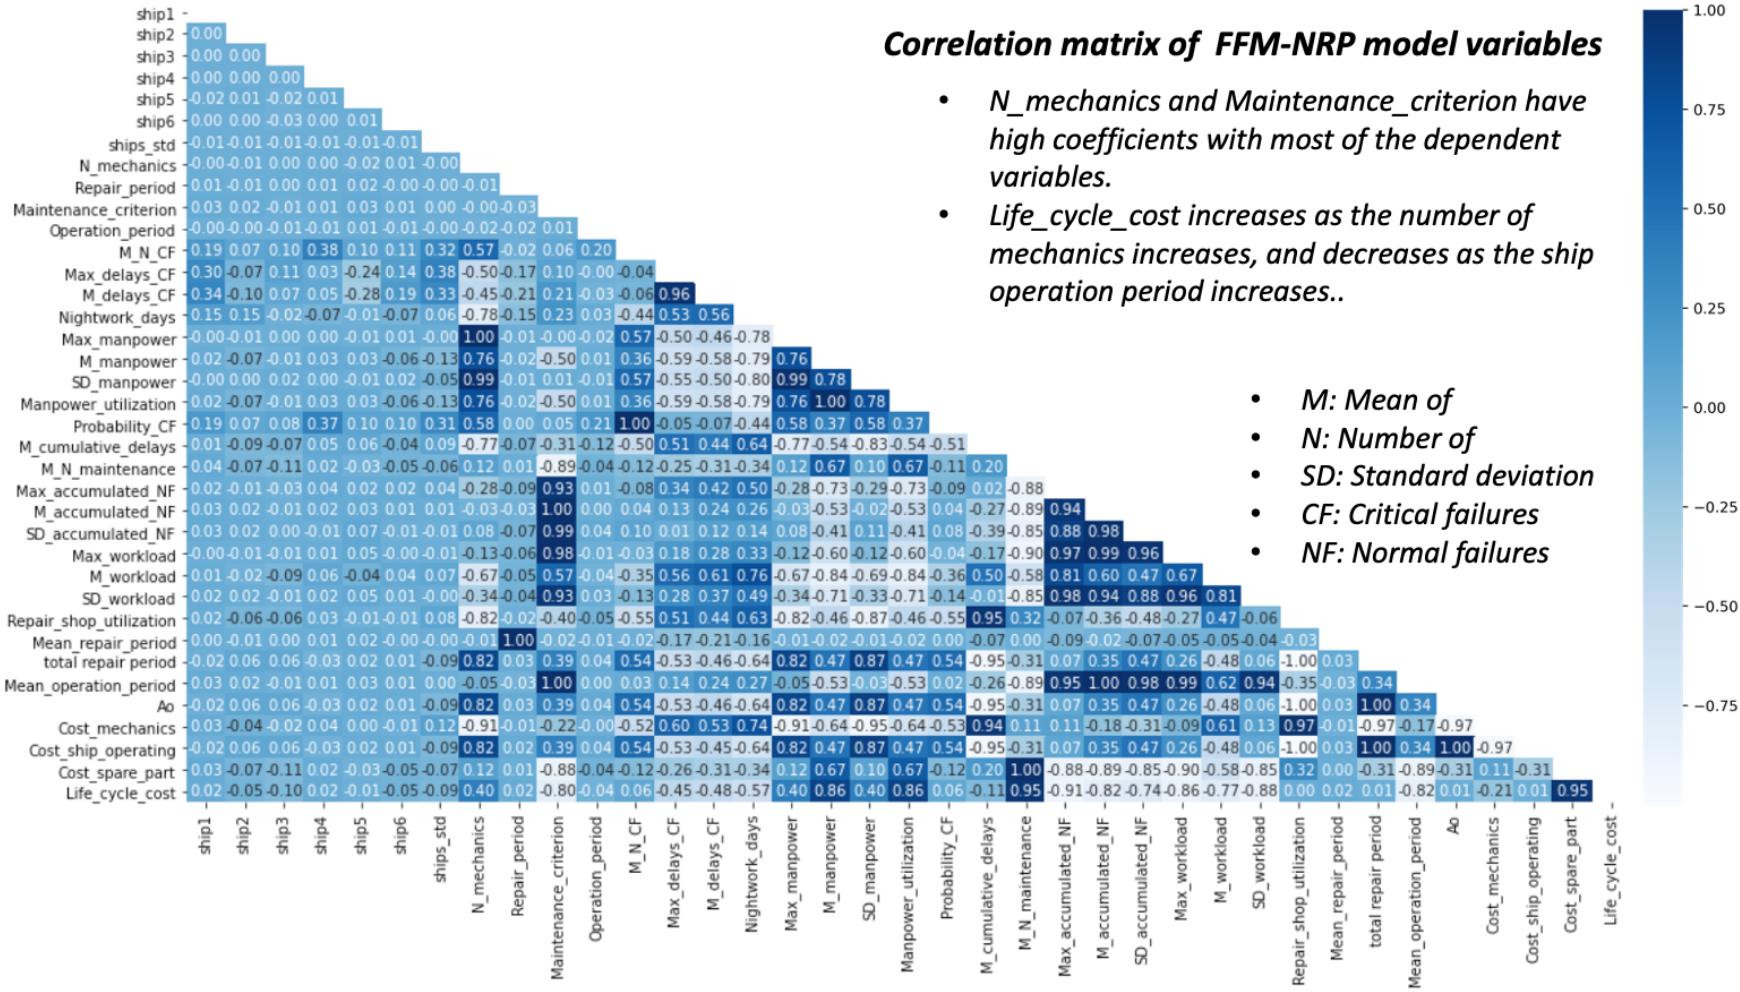
조원의 총수명 비용에 비해 25번 시나리오는 1.2조원이다.

이전 모델들은 독립변수의 설정에 따라 몇 천일 가량의 대기가 발생하거나, 함정 내 축적된 일반고장이 완전 해소되지 못하고 증가하는 현상 등 현실에서 발생하면 안되는 상황들이 있었다. FFM_NRP 모델은 정비 시기나 정비기간이 유동적으로 변경되기 때문에 이와 같은 상황들이 없었다.

<그림 6-16>과 <표 6-5>는 변수들의 상관관계와 분석이다. 정비원의 수와 인건비는 음의 상관관계를 가진다(-0.91). 정비원의 수가 증가하면 야근일수가 감소하기 때문이다. 정비원의 수와 야근일수와의 상관계수는 -0.77이었다. 정비원의 수가 많으면 정비가 빨리 종료되어 작전일수가 증가하고, 함정 운용비가 증가한다. FFM_NRP 모델에서 정비횟수는 정비원의 수와 정비 입고기준 고장량에 의해 결정된다. 수리부속 비용은 이 둘의 영향을 동시에 받는다. 정비원 수와 수리부속비용의 상관계수는 0.12였다. 정비입고 기준이 정비원의 수보다 수리부속비용에 미치는 영향이 크다는 의미이다.

정비 입고기준은 함정 운용가용도와의 상관계수가 FFM_FRP 모델에 비해 높지 않다(0.39). FFM_FRP 모델의 경우 이들의 상관계수는 0.74였다. 함정 운용가용도의 결정에 정비원의 수도 영향을 미치기 때문이다. 정비 입고기준과 정비부대 가동률의 상관계수는 -0.40이다. FFM_NRP 모델은 특정 독립변수가 종속변수와의 강한 상관관계를 가지지 않았다. 독립변수의 직접적인 영향력이 적고, 종속변수들간의 인과관계에 의해 다른 종속변수 값이 결정되는 경향이 크기 때문이다.

정비 입고기준은 작전운용일수를 결정하기 때문에 함정 운용비와 상관관계가 클 것이라고 생각할 수 있다. 정비원 수의 영향으로 함정 운용비보다 수리부속비용의 계수가 더 컸다. 이는 정비 입고기준이 작전운용일수보다 정비횟수의 결정에 더 큰 영향을 미친다는 의미이다.



Correlation matrix of FFM-NRP model variables

- *N_mechanics* and *Maintenance_criterion* have high coefficients with most of the dependent variables.
- *Life_cycle_cost* increases as the number of mechanics increases, and decreases as the ship operation period increases..

- *M*: Mean of
- *N*: Number of
- *SD*: Standard deviation
- *CF*: Critical failures
- *NF*: Normal failures

<그림 6-16> FFM_NRP 모델의 변수간 상관관계

<표 6-5-1> FFM_FRP 모델의 상관관계 해석(1)

Variables		Correlation coef.	Details
N_mechanics	Probability_CF	0.58	As the number of mechanics increases, maintenance is completed quickly. It has a positive correlation with Ao because the number of operational days increases. The probability of emergency failure increases as the number of operation days increases.
	Ao	0.82	
	Cost_mechanics	-0.91	The number of mechanics and the Cost_mechanics have a negative correlation. This is because when the number of mechanics increases, the number of night shift days decreases. The coefficient between the number of mechanics and the number of night shift days was -0.77. If the number of mechanics is large, maintenance will be completed quickly, increasing the number of operating days and increasing the operating cost of the ship. In the FFM_NRP model, the number of maintenance is determined by the number of mechanics and the maintenance criterion. The cost of spare parts is affected by both, and the coefficient with the number of mechanics is 0.12. In other words, it means that the maintenance criterion has a large effect on the cost of repair parts.
	Cost_ship_operating	0.82	
	Cost_spare_part	0.12	
	Life_cycle_cost	0.40	

<표 6-5-2> FFM_FRP 모델의 상관관계 해석(2)

Variables		Correlation coef.	Details
Maintenance_criterion	Ao	0.39	For Maintenance_criterion, the coefficient with Ao is not as high as that of the FFM_FRP model, 0.39. In the case of the FFM_FRP model, their coefficient was 0.74. This is because the number of mechanics also affects Ao's decision. The coefficient between Maintenance_criterion and Repair_shop_utilization is -0.40. In the FFM_NRP model, a specific independent variable did not have a strong correlation with the dependent variable. This is because the coefficient tends to be determined by the causal relationship between the dependent variables.
Cost_mechanics		-0.22	Since Maintenance_criterion determines the number of operating days, it can be thought that the correlation with Cost_ship_operating will be large. Due to the influence of N_mechanics, the coefficient with Cost_spare_part was larger than Cost_ship_operating. This means that Maintenance_criterion has a greater influence on the determination of the number of maintenance times than the number of operational days.
Cost_ship_operating		0.39	
Cost_spare_part		-0.88	
Life_cycle_cost		-0.80	

제 2절 변수들의 선형관계 분석 및 최적화

6.1절에서는 상관계수를 통해 변수간의 관계를 확인하였다. 상관계수를 변수간의 영향력이라는 수학적 지표로 활용해서는 안된다. 본 절에서는 선형회귀(Linear regression)를 통한 변수간의 수치적 관계를 확인한다. 시뮬레이션 모델들의 독립변수들과 종속변수들의 선형회귀 분석을 통해 변수들의 영향력을 분석한다.

선형회귀 모델의 독립변수에는 시뮬레이션 결과변수들을 모두 포함할 수 없다. 예를 들어 합정 운용가용도를 회귀 반응변수로 설정할 때 독립변수에는 작전 운용기간과 총 정비횟수를 동시에 포함할 수 없다. 시뮬레이션 결과변수들은 모두 독립변수들의 인과적 관계에 의한 결과물에 해당하며, 상관성에 따라 높은 다중공선성(Multi-collinearity)을 가지기 때문이다. 모든 선형회귀 모델에 대해 VIF(Variance inflation factor) 검사를 수행하고 회귀 모델을 적합한다. 또 선형회귀 모델의 잔차(Residual)는 독립성(Independent), 정규성(Normally distributed), 등분산성(Homoscedasticity)을 가져야한다(Faraway, 2016). 독립성 검정은 더빈-왓슨 검정(Durbin-Watson test), 정규성 검정은 샤피로 윌크 검정(Shapiro-Wilk test), 등분산성 검정은 레빈 검정(Levene test)를 수행하였다. 검정 방법들은 기준을 만족한다는 귀무가설을 기반으로 한다. 예를 들어 샤피로 윌크 검정에서는 p_value 가 0.05 이상일 때 잔차가 정규성을 가진다는 귀무가설을 채택한다.

분석 대상 변수(선형회귀 반응변수)를 제외한 모든 시뮬레이션 변수들을 독립변수로 설정 후 선형 적합 하였다. 적합 결과의 VIF, Durbin-Watson test 등을 통해 모델의 적합성을 판단하였다. 종속변수의 수(23개)에 따라 23개 선형회귀 모델이 적합되었다. 23개 모델들은 공통적으로 모든 VIF 검사 결과 다중공선성이 확인되었다. 회귀 모델의 독립변수들을 제거하는 방법으로 다중공선성을 낮출 수 있다(Faraway, 2016). 후진선택법(Backward stepwise)을 활용하여 적절한 독립변수가 구성될 때까지 변수들을 제거하였다. 결과적으로 시스템 다이나믹스 시뮬레이션의 독립변수만으로 구성하였을 때 다중공선성이 해결되었다. 선형회귀 잔차의 검증 중 독립성의 문제는 발생하지 않았다. 정규성의 문제가 발생하는 경우 Box-Cox transform(Sakia., 1992)을 활용하여 독립변수들을 정규화하였다. 등분산성의 문제는 독립변수 변환(제곱, 제곱근 등)을 통해 해결하였다.

회귀모델을 적합하면 종속변수와 무관하게 합정들의 수명이 유의하지 않은 변수가 되었다. <표 6-6> PFM_FRP 모델 독립변수들의 주요 종속변수 10가지에 대한 선형회귀 모델의 p 값이다. 합정의 수명(Ship1 ~ Ship6)은 공통적으로 p 값이 모두 0.05를 넘어 유의하지 않다. 6.1절에서 합정의 수명은 모든 변수와 상관계수가 낮았다. 3

<표 6-6> PFM_FRP 모델의 선형회귀 p_value

Independent variables	OLS linear regression p_value of dependent variables									
	M_delays_CF	Night_work_days	Manpower_utilization	Probability_CF	M_cumulative_delays	M_N_maintenance	M_accumulated_NF	Repair_shop_utilization	Ao	Life_cycle_cost
Ship1	0.224	0.789	0.723	0.678	0.821	0.391	0.866	0.795	0.770	0.558
Ship2	0.751	0.933	0.949	0.695	0.843	0.534	0.918	0.881	0.899	0.656
Ship3	0.871	0.976	0.908	0.777	0.984	0.982	0.820	0.815	0.814	0.843
Ship4	0.978	0.811	0.995	0.707	0.843	0.904	0.959	0.897	0.884	0.890
Ship5	0.525	0.928	0.675	0.875	0.499	0.305	0.914	0.168	0.167	0.905
Ship6	0.774	0.947	0.943	0.683	0.794	0.772	0.841	0.800	0.807	0.666
N_mechanics	0.556	0.000	0.001	0.804	0.329	0.197	0.008	0.054	0.055	0.210
Repair_period	0.000	0.058	0.043	0.035	0.082	0.000	0.002	0.000	0.000	0.000
Maintenance_criterion	0.966	0.861	0.710	0.848	0.762	0.656	0.872	0.596	0.604	0.865
Operation_period	0.001	0.009	0.021	0.004	0.002	0.000	0.000	0.000	0.000	0.335

장에서 수명이 유사한 함정이 몰려있을 때 대기 발생으로 인해 운용가용도가 낮아지는 등의 문제가 발생할 수 있다고 가정하였으나, 선형회귀 적합결과 유의하지 않았다. 4가지 모델들은 모델 구성 특징에 따라 유의한 독립변수가 확인되었다. <표 6-6>의 PFM_FRP 모델의 경우 정비 입고기준 고장량은 모든 종속변수들에 대해 유의하지 않았다. PFM_FRP 모델의 정비 입고기준은 작전운용 기간(Operation_period)이기 때문이다. 같은 이유로 다른 모델들의 유의한 독립변수들도 시뮬레이션 모델의 설정과 같았다. FFM 모델들은 공통적으로 작전운용 기간이 유의하지 않았고, NRP 모델들은 정비기간이 유의하지 않았다. 4개 모델들은 공통적으로 정비원 수가 유의하였다.

그러나 본 절의 회귀모델은 작전운용 기간, 정비 입고기준 고장량, 정비기간, 정비원 수 4가지 변수들을 모두 포함하였다. FFM_NRP 모델의 경우 작전운용 기간과 정비기간은 유의하지 않으나, 포함하여도 선형회귀 모델에 문제가 발생하지 않기 때문이다. <표 6-7>과 <표 6-8>은 FFM_NRP 모델을 독립변수 4개와 2개로 적합하였을 경우의 결과이다. 잔차검정 결과는 모두 이상 없었으며 설명력(R_squared), AIC, 독립변수들의 계수(Coefficient), t 통계량(t-statistic) 등은 모두 유사하였다. 절편(Intercept)의 t검정 통계량의 차이에 따라 모델의 F 통계량(F-statistic) 차이가 발생하였으나 회귀모델 활용에 문제가 없다고 판단하였다.

일반적으로 조직은 장비 가용도와 비용을 고려한 최적 운용을 원한다. 군은 비용대 성능과 더불어 임무의 성공률도 중요한 정책 결정 요소이다. 따라서 선형회귀의 종속

<표 6-7> FFM_NRP(독립변수 4종) 모델 적합결과

<표 6-7> FFM_NRP(독립변수 4종) 모델 적합결과				
FFM_NRP model(4 independent variable included)		Residual diagnostics		
Adj. R_squared: 0.807				
Method: Least squares				
F-statistic: 34.43				
AIC: -152				
<hr/>				
Independent variables	Coef.	Std. err.	t-statistic	p_value
Intercept	0.7029	0.020	35.984	0.000
N_mechanics	0.0087	0.001	10.597	0.000
Maintenance_criterion	0.0024	0.000	5.043	0.000
Operation_period	2.505e-05	3.19e-05	0.785	0.439
Repair_period	0.0001	0.000	0.609	0.547

<표 6-8> FFM_NRP(독립변수 2종) 모델 적합결과

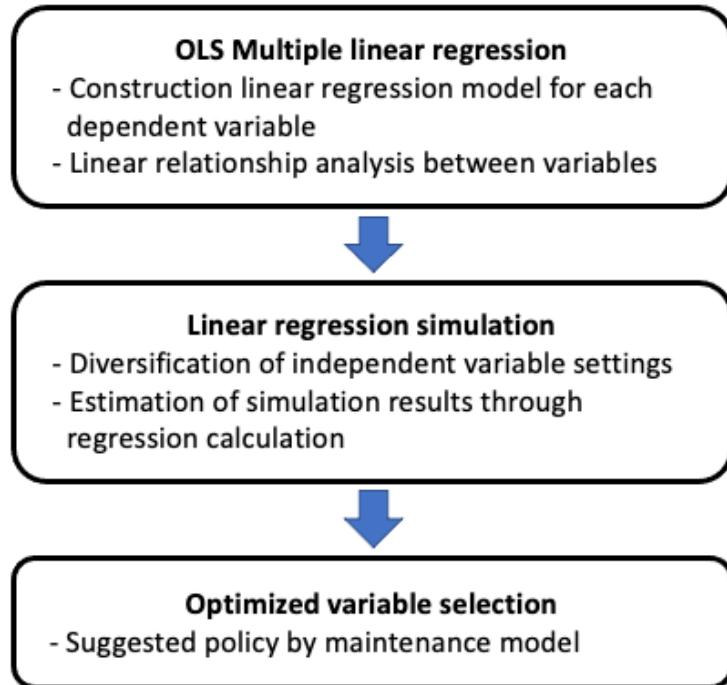
FFM_NRP model(2 independent variable included)				
Independent variables	Coef.	Std. err.	t	p_value
Intercept	0.7158	0.014	51.776	0.000
N_mechanics	0.0087	0.001	10.761	0.000
Maintenance_criterion	0.0024	0.000	5.124	0.000

변수들 중 함정 운용가용도(Ao), 임무 실패률(Probability_CF), 총수명비용(Life_cycle_cost)을 중심으로 분석한다.

시스템 다이나믹스 시뮬레이션은 NOLH 샘플링된 시나리오들을 활용하였다. 직교 샘플링을 통해 각 변수들의 넓은 범위의 구성을 적은 횟수의 시뮬레이션으로 확인하여 시간의 제약을 극복하였다. 단 NOLH 샘플링으로 모든 시뮬레이션을 대체할 수는 없다. 선형회귀식을 활용하면 가상의 시뮬레이션 결과들을 얻을 수 있다. NOLH에서 추출하지 못한 독립변수의 조합이 도출하는 종속변수 값을 선형회귀식 계산으로 산출 할 수 있다. 각 독립변수의 범위에서 임의의 값을 추출하여 12억회의 회귀 시뮬레이션을 수행한다.

회귀 시뮬레이션 결과 중 해군 적용에 적합한 최적 결과를 선정한다. 운용가용도가 최대, 임무 실패율과 총수명 비용이 최소가 되는 경우를 확인하고 최적 독립변수 구성을 탐색한다. 최적화를 통한 수치적 접근에는 한계가 있다. 현실적으로 불가능한 시나리오들을 제거해야하나, 이 경우에는 목적식에 변수들의 인과관계가 포함되어야 하므로 목적식이 복잡해진다. <그림 6-4>와 같이 일반고장이 지속적으로 누적되는 현상은 현실에서 발생하면 안된다. 그러나, 이 시나리오는 함정의 운용일수가 길고 정비기간이 짧다(NOLH 샘플링에서 운용기간과 정비기간의 양극단 값이 샘플링 되었다). 수치적 최적화 수행시 최적 시나리오로 선택될 가능성이 크다. 함정 운용가용도는 0.75 보다 커야하는 등 현실적 제약사항은 수치적 최적화 수행을 더욱 어렵게 한다. 선형회귀식의 계산은 컴퓨터 환경에서 굉장히 빠르다. 즉 무수히 많은 시나리오들을 구성하여 산출하고 최적의 결과를 탐색하는 것이 쉽다. 또 향후 모델의 활용중 목적에 다

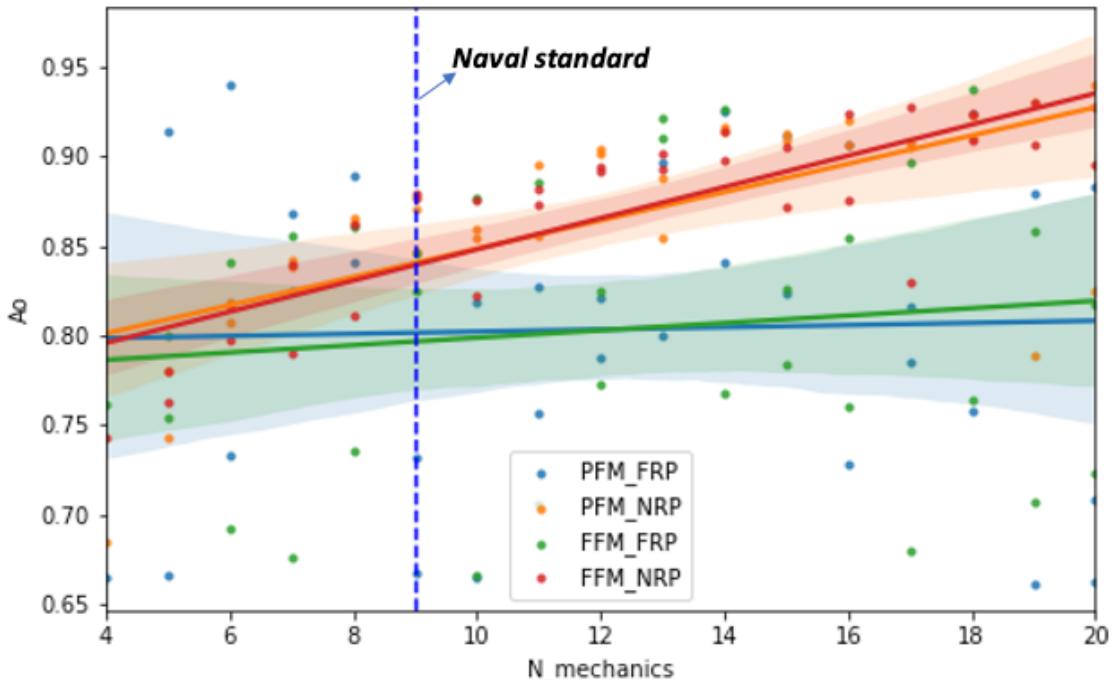
른 제약식을 추가하는 등의 상황에도 선형회귀식의 계산을 통한 산출이 더 간단한 방법이 된다. 모델별 최적화는 해군 정비시스템의 제안 정책이 된다. 위에서 설명한 시뮬레이션 결과 분석 절차는 <그림 6-17>과 같다.



<그림 6-17> 시뮬레이션 결과 분석 절차

1. 변수간 선형관계 분석

정비원수(N_mechanics)의 수와 함정 운용가용도의 관계는 <그림 6-18>과 같다. 모든 모델들은 정비원이 많을수록 함정 운용가용도가 높아진다. NRP 모델들의 기울기는 크고 FRP 모델들은 기울기가 작다. FRP 모델들은 정비기간이 고정되어 있기 때문이다. 해군의 기준은 9명이다. 9명을 운용하는 경우 PFM_NRP 모델의 운용가용도가 가장 크고 PFM_FRP 모델에 비해 약 3%가 크다. 해군의 현 정책에서 정비일수의 유연성을 확보하면 운용가용도를 향상시킬 수 있다. PFM_NRP 모델과 FFM_NRP 모델의 교차지점은 정비원 약 11명 구간이다. 해군 전력의 확대에 따라 정비인력이 추가 확보된다면 약 11명 이상이 될 때부터는 FFM_NRP 모델이 함정 운용가용도 향상에 좋다. 상태기반정비를 적용함에 있어 부대의 규모를 함께 고려해야한다는 의미로도 이해할 수 있다. FFM_NRP 모델 정비원 수의 회귀계수(coefficient)는 0.0087이었다. 정비원이 1명 증가할 때 함정 운용가용도가 0.0087 증가하는 경향이 있다. 선형

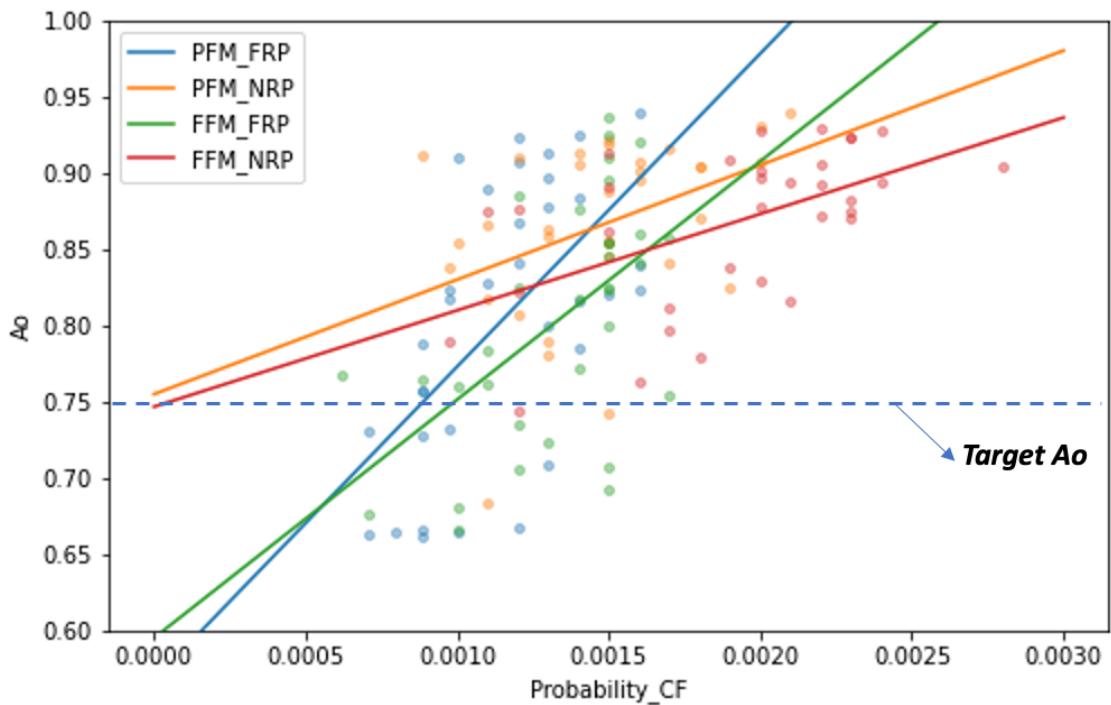


<그림 6-18> 정비원 수와 함정 운용가용도의 선형관계

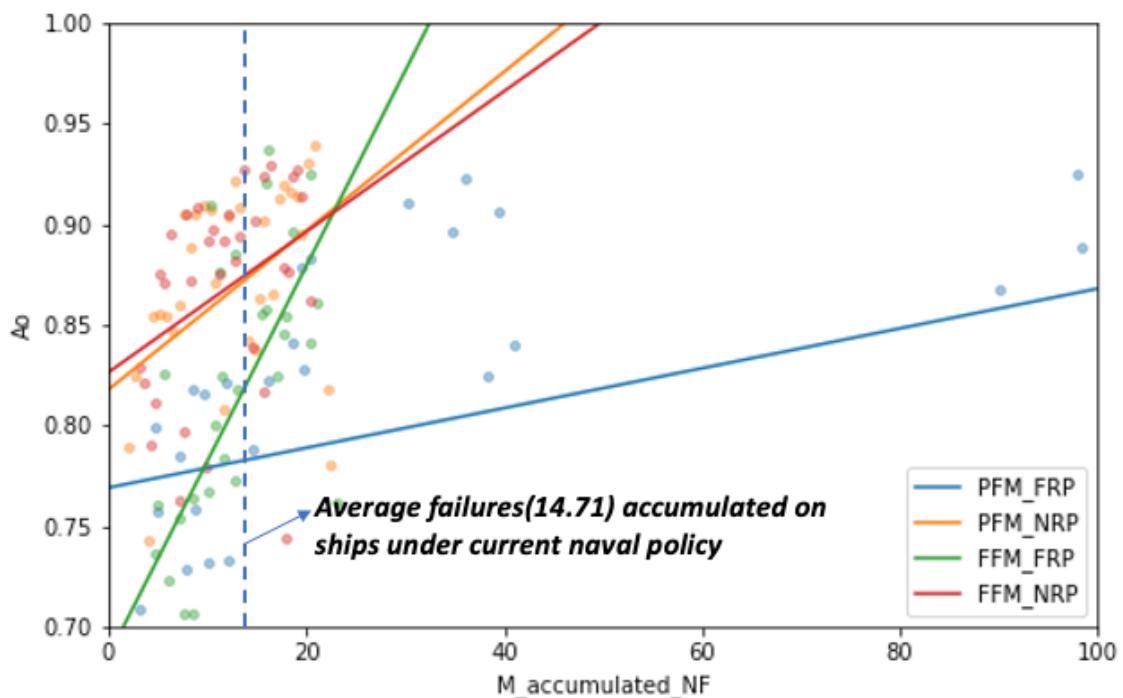
회귀는 비선형회귀와 비교하여 정확도 측면에서 한계가 있다. 정비원이 늘어남에 따라 함정 운용가용도가 무한히 증가하는 것은 불가능하기 때문이다. 따라서 본 연구의 회귀모델은 수치적인 경향성을 나타낸다고 이해해야한다. 기울기가 가장 작은 PFM_FRP 모델의 회귀계수는 0.0012였다. PFM_FRP 모델의 독립변수 중에는 정비 기간(Repair_period)의 회귀계수가 -0.0023으로 가장 영향력이 컸다.

상관관계 분석에서 함정 운용가용도는 작전일수와 양의 상관관계를 가졌다. 임무 실패율과 함정 운용가용도의 선형관계는 <그림 6-19>와 같다. 해군은 75% 함정 운용 가용도 이상 유지를 목표로 한다. 75%를 유지할 때 해군 정책의 임무 실패율은 약 0.009이다. NRP 모델들은 FRP 모델들에 비해 임무 실패율이 낮다. 함정 운용가용도를 약 87% 이상으로 향상시키면 PFM_FRP의 임무실패율이 가장 낮다. 임무 실패율을 줄이기 위해서는 목표 함정 운용가용도에 따라 정비정책을 선택하는 것이 좋다는 의미가 된다. 87%의 운용가용도를 기준으로 이하에서는 PFM_NRP 모델, 이상에서는 PFM_FRP 모델이 적절하다.

한편 함정 운용가용도가 87% 이상일 때 PFM_FRP 모델의 일반고장의 축적량은 크다. 함정의 일반고장을 정비기간 동안 모두 해소하지 못한다는 의미가 된다. <그림 6-20>은 함정에 축적되는 일반고장량의 평균값과 일반고장량과 운용가용도를 나타낸 것이다. 87% 이하에서 FFM_NRP 모델의 일반고장량 축적 정도가 가장 낮다. 일반고



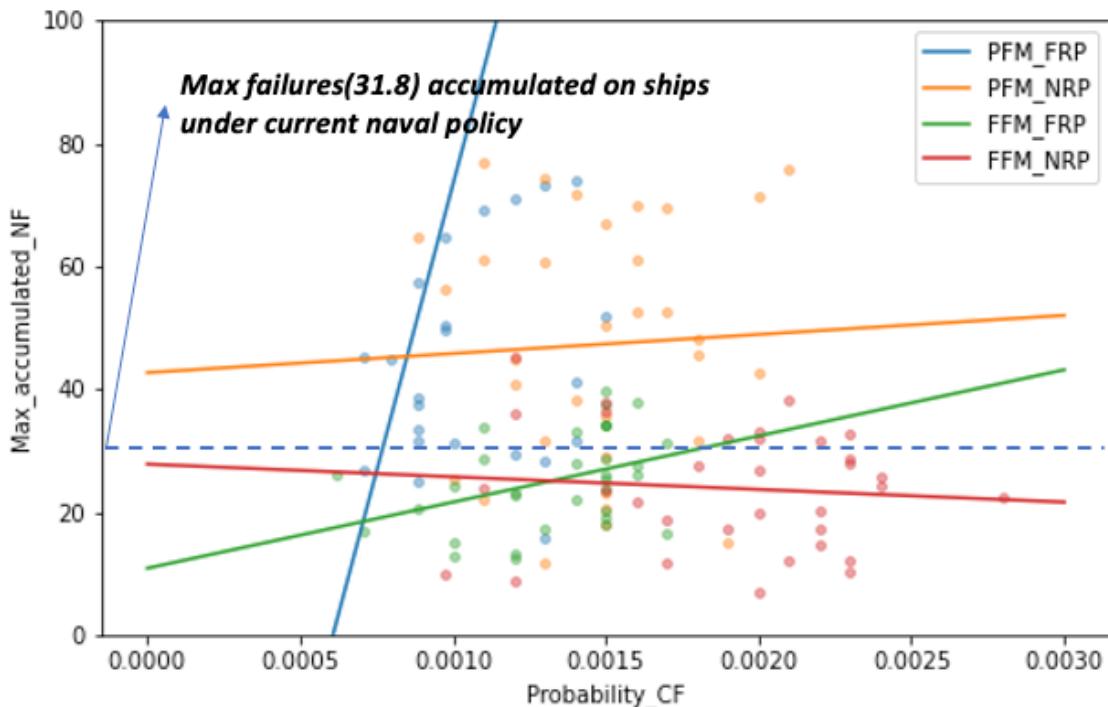
<그림 6-19> 임무 실패율과 함정 운용가용도의 선형관계



<그림 6-20> 함정 축적 일반고장량과 운용가용도의 선형관계

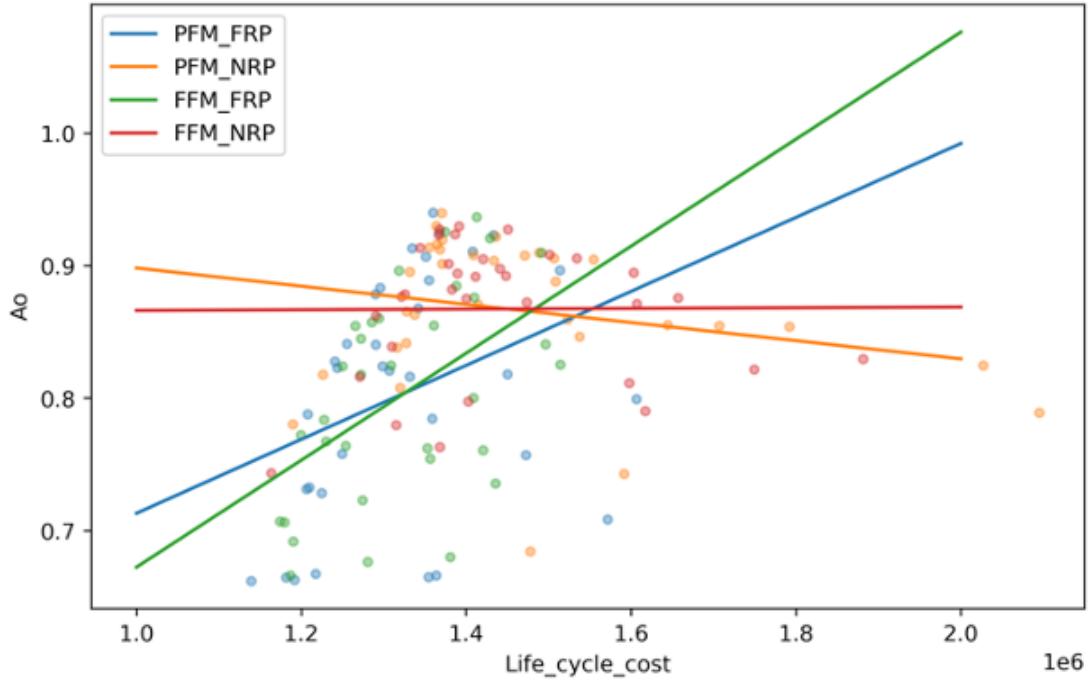
장은 작전임무를 수행할 수 있으나 제한된 성능을 내는 상태라고 가정하였다(4장). 현 해군의 PFM_FRP 정비정책에서 함정에 축적된 일반고장량은 14.71임을 고려할 때 PFM_FRP 정책으로 87%의 운용가용도 목표를 설정하는 것은 위험부담이 크다. 현재보다 10배에 가까운 일반고장량을 함정에 축적한 채로 운용하게 된다. 즉 FRP 모델을 활용한 함정 운용도의 향상에는 한계가 있을 수 있다.

일반고장의 축적이 많은 이유는 정비기간이 짧고 작전 운용기간이 길기 때문이다. <그림 6-21>에서 다른 3개 모델과 달리 FFM_NRP는 기울기가 음수이다. FFM_NRP 모델은 작전 운용과 정비의 회전이 빠르다. 고장확률이 높은 수명 말기에도 함정이 최대한 작전을 수행할 수 있도록 빠르게 정비한다. FFM_NRP 모델의 일반고장의 축적이 적다는 것은 정비 입고기준이 낮다는 것과 같다. 정비기간도 그만큼 빠르게 종료되어 작전에 투입되므로 긴급고장에 노출되는 정도가 커질 수 있다. 따라서 FFM_NRP 모델의 기울기는 음수가 되었다. PFM_NRP 모델은 긴급고장 확률이 높은 경우에 반면 다른 3개 모델들은 작전일수나 정비일수의 영향으로 비례적인 관계를 가진다.



<그림 6-21> 임무실패율과 함정 축적 일반고장량의 선형관계

해군의 현 상태인 75% 함정 운용가용도에서 총수명 비용은 약 1.12조원이다. <그림 6-22>에서 PFM_NRP 모델은 총수명 비용이 커질 때 오히려 운용가용도가 낮아진다. 해군 정비창에서는 해마다 정비기간 단축하고 있다. 예를들어 규정된 45일 대비해서



<그림 6-22> 총수명 비용과 함정 운용가용도의 선형관계

평균 2일을 줄였다고 성과를 평가한다. PFM_NRP는 현 해군 정책에서 정비기간만을 유동적으로 조절하는 정책이다. 총수명비용 1.12조원을 유지한다고 가정할 때 PFM_NRP 모델은 89%에 가까운 함정 운용가용도를 기대할 수 있다. 다만 현재 수준인 75%에서 13%를 올리기 위해서는 정비기간이 13% 줄어야한다. 그만큼 정비 기술에 투자되어야 가능할 것이다. FRP 모델들은 총수명 비용이 클수록 함정 운용가용도가 높아진다. 운용가용도 약 80%가 넘으면 FFM 모델을 활용하는 것이 효과적이다. FFM_NRP는 총수명 비용이 증가해도 비슷한 수준의 운용가용도가 유지된다.

2. 최적 독립변수 추정

NOLH를 활용한 시뮬레이션으로 독립변수와 종속변수들의 관계 확인하였다. 선형회귀를 통해 이들의 관계를 수식으로 정립하였다. 회귀식을 활용하여 NOLH에서 확인하지 못한 다양한 독립변수들의 조합 결과를 계산할 수 있다. 선형회귀를 통한 최적화의 장점은 빠른 속도이다. 독립변수가 4개로 감소하였음에도 변수범위 전체를 계산하기 위해서는 모델마다 약 12억회의 시뮬레이션이 필요하다. 5장에서 구축한 시스템 다이나믹스 모델의 1회 시뮬레이션 속도는 약 5초이다. 시스템 다이나믹스를 활용하여 12억회의 시뮬레이션을 수행하기 위해서는 약 277,000일이 필요하다. 반면 선형

회귀식 계산을 통한 시뮬레이션은 수 분 내로 가능하다. 본 연구에 활용된 컴퓨터의 성능은 Intel Core i7 2.6Ghz, 16GB DDR4 RAM이며 12억회의 선형 회귀식의 CPU 계산 소모시간은 16분 내외였다.

본 절에서는 모델별 최적의 독립변수를 도출한다. 약 12억개의 독립변수 조합을 선형 회귀식에 대입하여 계산한다. 12억개의 계산 결과 중 목적함수를 최대로 하는 독립변수 조합을 선정한다. 목적함수는 식(6)과 같이 3가지 종속변수로 구성된다. 함정의 운용가용도는 높아야한다. 긴급고장으로 인한 임무 실패율과 총수명 비용은 낮아야한다.

$$\frac{\text{Operational availability}}{\text{Probability of critical failure} * \text{Life cycle cost}} \quad \text{식(6)}$$

4개의 독립변수들은 모두 스케일이 다르다. 운용가용도는 최대 1을 넘기지 않지만 총수명 비용은 1조원이 넘는다. 시뮬레이션 결과에서 임무 실패율은 0.003을 넘지 않았다. 3가지 독립변수의 스케일을 통일시키기 위해 정규화(Normalization) 후 회귀연산을 수행하고 최종 결과를 언스케일(unscale)하였다.

PFM_FRP 모델에서 함정의 일반고장이 해소되지 않고 계속 누적된다. 이는 현실적으로 부적절한 결과이다. FFM_FRP 모델도 정비기간에 비해 과도한 정비입고 기준이 설정되면 해소되지 못한 일반고장이 함정에 계속 누적된다. LP(Linear programming)를 활용하면 연산속도가 선형회귀보다 더 빠를 수 있으나, 식(6)의 목적함수에 포함된 변수들 외의 제약식 구현이 어렵다. 예를 들어 <그림 6-4>와 같이 일반고장이 지속적으로 누적되는 경우나 <그림 6-20>과 같이 PFM_FRP 모델의 운용가용도가 87% 이상이 되는 등의 경우는 실무적으로 해군 적용은 곤란하다. LP 문제 해결시에는 이와 같은 제약식 반영을 위해서는 목적함수가 매우 복잡해진다. 또 향후 모델의 정책적 활용을 고려할 때 목적식이 변경되면 다시 LP문제를 구성해야하는 한계가 발생한다. 선형회귀식의 반복적 계산은 산출된 결과 중 비현실적인 결과를 제거하고 목적식에 부합하는 독립변수 구성을 확인하는 것으로 간단히 현실적인 최적값을 도출할 수 있다.

<표 6-9>는 모델들의 회귀계산 결과의 최적값이다. 공통적으로 최적값의 정비원수는 4명이었다. 정비원이 적은 경우가 최적인 이유는 여러 가지 경우가 있다. 예를 들어 정비량이 많은 경우이다. 많은 정비량의 빠른 해소를 위해서는 정비원이 많아야한다. 정비원이 많으면 정비 인건비가 상승한다. 정비량은 운용기간이 길수록 많다. 운용기간이 길면 긴급고장으로 인한 임무 실패 가능성도 높아진다. 반대로 정비량이 적은

경우는 많은 정비원이 불필요하므로 적은 방향으로 최적화된다. 따라서 정비원 수는 적어지는 방향으로 최적화된다. 한편 함정 운용가용도는 운용기간이 길거나 정비기간이 짧을수록 높아진다. 함정 운용비용과 정비비용의 적정 지점에 최적값이 도출되게 된다.

FFM_NRP 모델은 상태기반정비와 유사하다. 현재 해군의 독립변수 설정을 유지하면서 상태기반정비를 수행하면 운용가용도를 약 88.45%까지 향상된다. 총수명 비용은 약 1,000억원 증가한다. 최적값과 비교할 때 해군의 독립변수 설정을 유지하면서 상태기반정비를 수행하면 비효율적이다. 운용기간이 짧고 정비원의 수가 많아 정비기간도 짧아진다. 정비횟수가 불필요하게 많을 수 있고 총수명 비용도 비싸다.

해군은 상태기반정비를 도입하기에 앞서 정비기간을 단축하기 위해 노력중이다. 정비일수 감축을 통해 운용가용도를 높이려는 의도이다. 정비기간을 현재의 절반수준(23일)으로 단축했다고 가정해보자. 이때 임무실패율은 0.0012, 운용가용도는 0.8199, 총수명 비용은 약 1.5조이다. 운용가용도는 약 1% 상승할 때 총수명 비용이 약 220 억 상승한다고 할 수 있다. 다른 독립변수를 고정하고 정비기간만 단축하기 위해서는 정비부대의 시설을 개선하는 등 실무적인 개선이 필요하다. 여기서 소모되는 비용을 고려하면 총수명 비용 상승은 더욱 클 것으로 판단된다.

해군의 정비기간 단축 노력은 PFM_NRP 모델로 발전할 수 있다. PFM_NRP 모델은 6.2.1절의 선형관계 분석에서는 유리한 점들이 많이 확인되었다. 운용가용도가 높아질 때 오히려 총수명 비용이 감소하는 경향이 있으므로 목적함수 결과값의 향상에 유리하다. 그러나 최적화 결과 운용가용도는 76.48% 수준이었다. 이는 NOLH 샘플링 시나리오에서 포함되지 않은 독립변수 구성의 영향이라고 할 수 있다. 즉 정비부대 시설 개선 등 많은 투자를 통해 정비기간을 단축하여도 최적 운용가용도는 감소할 수 있다. 해군의 기대와는 반대된다.

FFM_NRP의 최적값은 운용가용도가 현재보다 약 5% 상승하고, 총수명 비용은 약 2,300억원 감소한다. 정비입고 기준이 현재보다 2배 이상 길기 때문에 임무실패율이 0.0002 상승하였다. 정비입고 기준이 2배 이상 크다는 것은 현재수준보다 일반고장량이 2배 이상 높을 수 있음을 의미한다. 또 정비원의 수는 현재보다 절반수준이 되었으므로 비현실적으로 보일 수 있다. 검증을 위해 최적 도출된 독립변수들을 시스템 다이나믹스 모델에서 확인하였으나 실무적으로 문제점이 될 만한 요소가 없었다.

목적함수에 반영된 종속변수들의 가중치는 모두 동일하다. 해군의 정책을 검토함에 있어 중요한 요소가 있다면 식(6)의 구성을 변경하거나, 가중치를 부여하는 등의 방법으로 결과를 도출할 수 있다. 회귀계산에 걸리는 시간이 짧기 때문에 목적함수 구성을 통한 다양한 방향의 검토가 가능하다.

<표 6-9> 모델들의 회귀계산 결과 최적값

variables	PFM_FRP		PFM_NRP		FFM_FRP		FFM_NRP	
	Navy setting	opt.						
Repair_period	45	22	-	-	45	21	-	-
Operation_period	138	214	138	104	-	-	-	-
Maintenance_criterion	-	-	-	-	14.71	5.14	14.71	32.54
N_mechanics	9	4	9	4	9	4	9	4
Probability_CF	0.0011	0.0013	0.0015	0.0011	0.0012	0.0012	0.0021	0.0013
Ao	0.7647	0.8614	0.9080	0.7648	0.7522	0.7660	0.8845	0.8187
Life_cycle_cost	1.3892	1.5317	1.3416	1.5919	1.2365	1.4976	1.4838	1.1577

제 7장 결 론

본 연구에서는 해군의 정비 시스템을 시스템 다이나믹스 모델로 구현하였다. 모델에 포함되는 주요 변수들을 적절한 통계기법들과 설문, 과거의 연구내용을 통해 도출하였다. 본 장에서는 연구 결과를 요약하고 한계점을 극복하기 위한 향후 연구방향을 제시한다.

제 1절 연구결과 요약과 의의

해군의 시스템은 핵심 전력인 함정을 중심으로 구성된다. 본 연구에서는 함정 6척이 상가대 2대를 공유하며 운용되는 시스템을 시스템 다이나믹스 모델로 구현하였다. 모델링 과정과 모델을 구성하는 변수들의 추정과정은 해군뿐만 아니라 민간 산업체에서도 필요에 따라 활용할 수 있도록 일반화 가능한 통계기법들을 활용하였다.

긴급고장함수는 추세와 확률의 분할과 통합으로 추정한다. 총수명간의 긴급고장 발생 추세는 B-spline을 활용하여 적합하였고, 6개월 단위의 긴급고장 확률은 단계형분포를 활용하여 적합하였다. 추세와 확률을 곱하여 총수명 11,315일간의 일일단위 긴급고장 발생 기댓값을 도출하였다. 긴급고장의 발생가능성은 확률적으로 매우 낮다. 사건의 중요도와 확률을 고려하여 희귀사건으로 고려하였다. 과거의 연구들에서 희귀 사건은 베이지안 추정을 중심으로 시뮬레이션 되었으나, 본 연구의 긴급고장 데이터는 베이지안 추정을 위한 분포 적합조차 불가능할 정도로 데이터가 적었기 때문에 추세와 확률의 분할과 통합을 활용하였다. 긴급고장함수 추정 방법에 활용된 단계형 분포와 B-spline은 컴퓨터 기반 통계에서 간단하게 구할 수 있다. 희귀사건의 분석은 중소형 산업에서도 중요하다. 대형 산업체의 경우 데이터 관리가 가능하여 베이지안 추정을 통한 강건성 있는 분석이 가능하나, 중소형 산업체는 데이터 관리가 미흡할 수 있다. 이 경우 본 연구의 긴급고장함수 도출 과정을 적용하면 적은 데이터를 활용하여 희귀사건의 분석과 시뮬레이션이 가능하여 산업 분석에 유용하게 활용될 수 있다.

일반고장함수는 B-spline 기반의 계층형 베이지안 추정방법을 활용하였다. B-spline 기저함수를 계층형으로 구축하여 베이지안 추정하였다는 점에서 통계방법론들의 활용 법에 대한 기여가 있다. 이는 연구에 활용된 데이터와 같이 소량인 경우라도 계층적 구조화가 가능한 경우 적용 가능하다. 기저함수를 최상위 계층에서 최하위 계층까지

적용하고 모수들을 공유시켰고, 다른 예측방법보다 정확도 높은 일반고장함수를 추정하였다. 일반고장함수는 과거의 연구에서 밝혀진 일반적인 육조함수와 유사하였다. 다만 일반고장함수의 최초 5년의 기간에는 하자정비로 인한 데이터 부재로 실제보다 하향된 형태일 가능성이 높다.

일반고장함수를 적용하여 약전정비 정책을 제안하였다. 간격 최적화 정비(IOM)은 고장함수를 적용하여 총수명기간을 4분할하고 각 구간에서 주기 고정형 정비(PFM)를 수행하는 정비정책이다. IOM 모델들은 총수명기간 분할 방법에 따라 구분되었다. 3가지 모델 중 총수명기간을 고장함수에 따라 구분하는 경우 정비부대의 업무편차가 가장 작고, 함정이 항해중 노출되는 일반고장량이 가장 적었다. IOM 모델은 고장함수를 적용하여 발생하는 정비주기의 잦은 변화를 줄이기 위한 모델이다. 고장량 고정형 모델(FFM)은 상태기반정비와 같이 정비입고기준이 계속 변하였다. 총수명간의 고장량을 고장함수를 통해 알고 있기 때문에 일정한 수준의 일반고장이 축적되었을 때 정비를 수행하는 것으로 함정에 축적되는 고장량을 감소시킬 수 있었다. 정비부대의 입장에서도 함정 입고시 부여되는 정비량이 평준화되기 때문에 업무 부하가 크게 감소하였다.

FFM 모델은 함정의 입고시기가 계속 변하기 때문에 정비시기가 겹쳐 대기현상이 발생할 수 있다. 대기중인 함정은 추가적인 작전임무를 수행한다. 입고기준 이상의 일반고장이 축적될 수 있다. 상가대 2대와 함정 6척을 반영한 시스템 다이나믹스 모델에서 FFM 모델은 PFM 모델보다 함정 운용가용도, 정비창 업무부하 평준화 측면에서 유리하였다. 고장함수를 정비모델에 반영하면 함정의 대기현상이 발생하였다. 대기로 인해 기준 이상의 일반고장이 누적됨에도 불구하고 PFM 모델보다 효과가 좋았다.

완전정비는 현실적으로 불가능하다. 승조원 설문 결과를 사전분포로 설정하고 베이지안 추정을 통해 실제 완전 정비율을 추정하였다. 해군은 100% 완전정비를 가정하고 있으나, 베이지안 추정결과 평균 72% 수준의 정비효과가 있었다. 28%는 다음 정비에 다시 신청되어야 함을 의미한다. 이전에 도출한 일반고장함수에 정비율을 반영하여 불완전 정비로 인해 이월된 고장을 제거하였다.

한편 상태기반정비의 정비기간은 정비원의 업무속도와 정비량에 따라 결정된다. 과거의 연구에서 사람의 업무속도는 업무량에 따라 최대 25%까지 상승하거나 감소할 수 있다고 하였다. 일정압력 함수를 시스템 다이나믹스에 반영하면 함정의 입고에 따른 정비량이 정비시기를 결정하게 된다. 상태기반정비의 정비기간 결정 시스템이 반영되었다.

일반/긴급고장함수, 완전 정비율, 일정압력 함수를 시스템 다이나믹스 모델에 모두 반영하여 실제 해군 정비 시스템과 유사한 모델을 구축하였다. 모델은 총 4가지를 구

성하였다. PFM_FRP는 주기고정형 정비입고와 정비일수가 고정된 모델이다. FFM_NRP는 고장함수 기반의 정비입고와 정비일수가 정비량에 따라 유동적인 모델이다. PFM_NRP, FFM_FRP는 정비입고와 정비일수 둘중의 하나만 유동적인 모델이다. 4개의 모델에는 함정들의 수명을 포함한 10개의 독립변수가 반영된다. 시뮬레이션을 통해 임무 실패율, 함정 가동률, 총수명 비용 등을 포함한 23개의 종속변수가 도출된다. 독립변수 각각의 발생 범위가 넓어 유의미한 시뮬레이션을 위해 NOLH 샘플링을 적용하였다.

시뮬레이션 결과 함정 운용가용도는 함정의 작전수행기간과 비례하고, 정비기간과 반비례하였다. 작전수행 기간이 길면 일반고장의 함정 누적량이 많아지고 긴급고장의 발생확률도 높았다. 반대로 일반고장이 많은 경우는 작전수행 기간이 긴 경우이므로 긴급고장 확률도 높았다. 일반고장과 긴급고장은 같은 방향으로 증감하였다.

장비의 운용가용도를 결정할 때 일반 산업체는 비용대 효과를 중심으로 분석하지만 해군 함정은 임무 실패율이 적어야된다는 추가적인 조건이 고려되어야 한다. 독립변수와 종속변수들을 선형회귀로 관계 구성함에 있어 독립변수는 작전 운용기간, 정비 기간, 정비입고 기준 고장량, 정비원 수 4가지였다. 종속변수는 임무 실패율, 함정 운용가용도와 총수명 비용이었다. 선형회귀식은 컴퓨터 프로그래밍을 통한 신속한 계산이 가능하다. NOLH를 통해 간소화된 시뮬레이션은 선형회귀 독립변수들의 다양화를 통해 보완할 수 있다. 12억가지의 독립변수 구성을 시뮬레이션한 결과들 중 최적값을 선정하였다. 최적값 선정과정에서는 실무적으로 발생하면 안되는 시뮬레이션들을 제거하였다. 이런 시뮬레이션들을 비현실적이라 판단하고 제외하였다. 모델들의 최적값을 도출하여 비교하였다. 최적값 도출 목적함수는 분석 목표에 따라 수정가능하다. 선형회귀의 계산속도 이점을 활용하여 다양한 시뮬레이션을 신속하게 수행할 수 있다.

본 연구의 변수 추정과정은 통계적으로 검증된 방법들이다. 특히 2가지 고장함수의 추정방법은 이론적 활용적 기여도가 크다. 해군뿐만 아니라 산업체에서도 과학적인 장비 운용을 위해서는 장비 운용의 중심이 되는 고장현상에 대한 분석이 반드시 필요하다. 한편 시스템 다이나믹스 시뮬레이션은 각 변수 모듈들의 통합 형태로 구성된다. 군 뿐만 아니라 민간에서도 시스템에 포함되는 변수들은 무수히 많다. 예를들어 고장 예측을 위한 기술을 도입한다면 예측 정확도를 향상시키기 위한 연구를 진행할 뿐 연구의 결과가 시스템 전체에 미치는 영향을 분석하지 않는다. 해군의 경우 정비기간의 단축을 통해 함정 운용가용도를 향상시키고자 하지만 이와 같은 개선 결과의 최적점은 운용가용도를 향상시키지 못하였다. 본 연구의 시스템 다이나믹스 모델은 통계적으로 분석된 변수들을 포함하여 시스템 전체의 관점에서 분석하는 점에서 의의가 있다. 시스템 다이나믹스는 변수들은 실제와 유사성이 높아지고 많이 반영될수록 디지

털 트원스에 가까워진다. 연구모델은 해군 정비 시스템에서 나타나는 대부분의 현상이 반영되어 있다. 특히 FFM_NRP 모델은 스마트 네이비의 목표인 상태기반정비와 거의 같다. 스마트 네이비가 고려중인 모듈과 관련된 변수들을 시스템 다이나믹스에 추가 반영하고 시뮬레이션 하는 과정을 통해 미래 지향점을 조기에 분석하고 문제점을 식별할 수 있다.

제 2절 연구의 한계 및 향후 연구방향

본 연구는 실제와 유사한 수준의 시스템 다이나믹스 모델링을 통해 해군 정비 시스템을 분석하였으나 다음의 한계점들이 있다. 향후 추가 연구를 통한 보완을 통해 현실과 더 유사한 모델로의 발전이 가능할 것이다.

첫 번째, 해군의 정비정책은 디젤엔진의 정비주기를 기반으로 결정되었다. 본 연구에서는 이에 따라 해군 전투함의 추진용 디젤엔진 데이터를 활용하여 일반/긴급고장함수, 정비효과, 시스템 다이나믹스 모델링을 수행하였다. 해군 장비는 크게 4가지로 구분된다. 함정 장비의 과학화로 인해 고장 발생시 임무가 불가능한 장비들이 많아지는 추세다. 특히 전투체계나 무기체계 등에서 발생하는 고장은 수리부속 부재시 전투수행이 불가능한 경우가 많다. 따라서 이들에 대한 고장함수 도출도 필수적이다. 시스템 다이나믹스 모델에도 다양한 고장함수가 반영되어야 실제와의 유사성을 높일 수 있다.

두 번째, 일반고장과 긴급고장은 경험적으로 관계가 있음을 인지하고 있으나 통계적 이들의 관계 분석에 한계가 있었다. 일반고장은 작전 임무 수행이 가능하지만 장비의 상태는 일부 저하되는 고장이다. 예를들어 6기통 디젤엔진의 연료 분사기 1개가 작동하지 않는다면 작전 수행은 가능하지만 최대출력이 감소하는 문제가 생기는 것과 같다. 일반고장이 누적되면 작전 수행이 불가능한 수준이 된다는 것을 승조원들은 경험적으로 인지하고 있다. 그러나, 이들의 수학적 관계를 분석하기에는 데이터가 충분하지 않다. 어느 정도의 일반고장이 축적될 때 긴급고장이 되는가에 대한 분석이 불가능하였다. 이들의 관계를 정립하기 위해서는 모든 일반고장과 긴급고장의 발생 원인에 대한 데이터가 필요하다. 긴급고장의 경우 매 건이 임무 실패로 이어지므로 고장 원인에 대한 데이터가 존재한다. 일반고장은 작전 임무 수행은 가능하기 때문에 별도로 기록하지 않는다. 정비 요청서 내용도 포괄적으로 기술되어 구분하기 힘들다. 군의 데이터 관리 정책이 개선되어 모든 고장에 대한 원인과 내용이 기록된다면 일반고장과 긴급고장의 관계를 정립할 수 있을 것이다.

세 번째, 적용 가능한 통계 방법론들이 제한적이다. 긴급고장에 비해 많은 편이지만

일반고장 데이터도 적다. 함정의 고장들은 상호 인과적 관계를 가질 가능성이 크다. 장비를 구성하는 부품들은 병렬적 구성도 있지만 직렬적으로 구성되는 경우가 많기 때문이다. 함정에서는 매시간 장비의 상태를 순찰하고 수기로 기록하고 있다. 그러나 이는 기록물로서 보존되지 않고 일정기간 후 파기된다. 이 기록들이 유지되면 장비의 모든 상태를 확인할 수 있다. 6기통 디젤엔진의 인젝터 고장시 최대 출력의 저하에만 영향을 미칠것이라고 장담할 수 없다. 인젝터의 고장이 파이프 크랙에 의한 경우라면 연료 압력 저하나 누설로 인한 장비 셋다운의 문제도 동시에 발생할 수 있기 때문이다. 장비 순찰일지에는 엔진의 연료 온도, 공기 온도, 순찰 당시 함내 습도, 온도 등 많은 정보들이 기록된다. 이 데이터들이 보존되면 딥러닝 방법을 적용할 수 있다. 딥러닝의 은닉층에서 벌어지는 상호 연관성의 가중치는 고장들의 인과적 관계를 스스로 탐색하게 한다. 딥러닝을 적용하지 않는다면 모든 고장들의 선형 관계를 통계 모델에 모두 반영해주어야 정확한 모델이 된다. 이는 현실적으로 한계가 있다. 디젤엔진의 경우에도 장비를 구성하는 부품이 6,000여가지이기 때문이다. 6,000여가지의 직, 병렬적 관계의 경우의 수는 매우 큰 수이다. 딥러닝을 적용한다면 이들의 관계들중 중요한 관계를 식별하고 적절한 가중치를 자동으로 추정할 수 있다. 장비 순찰 일지의 보존은 반드시 필요하다.

다섯 번째, 시뮬레이션 결과 변수 분석시에는 선형회귀를 적용하였다. 선형회귀는 변수의 영향에 따른 종속변수 변화의 정도를 파악하기에는 적절하나, 정확도가 다소 저하된다. 보다 정확한 분석을 위해서는 NOLH 시나리오 외의 여러 가지 시나리오를 적용하여 결과 데이터를 추가적으로 확보한다. 시뮬레이션의 다양한 데이터가 확보되면 현실적으로 적용하기에 부적절한 결과 데이터들을 정제하는 작업을 거쳐야 한다. 정제된 데이터를 바탕으로 딥러닝을 구현할 수 있다. 비선형 회귀를 적용할 수도 있으나 본 연구에서와 같이 변수들의 다중공선성 문제로 독립변수 구성에 제한이 생긴다. 딥러닝 구현시에는 은닉층에서 변수들간의 다중공선성을 자동으로 제거하기 때문에 많은 독립변수들을 구성할 수 있다. 예를들어 본 연구의 독립변수는 4종으로 제한되었으나 딥러닝을 적용할 경우 종속변수 23종을 모두 독립변수로 구현할 수 있게 된다. 딥러닝 적용시 변수간 관계가 Black box가 되어 분석에 제한이 발생한다. 반면 정책적 검토를 위한 목적함수가 독립변수 설정에 따라 어떻게 변하는지에 대한 결과물의 정확도는 향상된다.

참 고 문 헌

- Abdel-Hamid, T. K. (1989). The dynamics of software project staffing: a system dynamics based simulation approach. *IEEE Transactions on Software engineering*, 15(2), 109-119.
- Abdel-Hamid, T. K., & Madnick, S. E. (1986). Special Feature: Impact of Schedule Estimation on Software Project Behavior. *IEEE Software*, 3(04), 70-75.
- Ager, D., & Ager, D. V. (1995). The new catastrophism: the importance of the rare event in geological history. *Cambridge University Press*.
- Asmussen, S., Laub, P. J., & Yang, H. (2019). Phase-type models in life insurance: Fitting and valuation of equity-linked benefits. *Risks*, 7(1),17.
- Asmussen, S., Nerman, O., & Olsson, M. (1996). Fitting phase-type distributions via the EM algorithm. *Scandinavian Journal of Statistics*, 419-441.
- Azar, A. T. (2012). System dynamics as a useful technique for complex systems. *International Journal of Industrial and Systems Engineering*, 10(4), 377-410.
- Belotti, P., Kirches, C., Leyffer, S., Linderoth, J., Luedtke, J., & Mahajan, A. (2013). Mixed-integer nonlinear optimization. *Acta Numerica*, 22, 1-131.
- Belotti, P., Lee, J., Liberti, L., Margot, F., & Wächter, A. (2009). Branching and bounds tightening techniques for non-convex MINLP. *Optimization Methods & Software*, 24(4-5), 597-634.
- Betancourt, M., & Girolami, M.(2015). Hamiltonian Monte Carlo for hierarchical models. *Current trends in Bayesian methodology with applications*, 79(30), 2-4.
- Betancourt, M. (2016). Diagnosing suboptimal cotangent disintegrations in Hamiltonian Monte Carlo. *arXiv preprint arXiv:1604.00695*.
- Betancourt, M. (2017). A conceptual introduction to Hamiltonian Monte Carlo. *arXiv preprint arXiv:1701.02434*.
- Bhat, U. N. (1990). Structured Stochastic Matrices of M/G/1 Type and Their Applications. *Journal of the American Statistical Association*, 85(412), 1176-1178.
- Bolstad, W. M., & Curran, J. M. (2016). *Introduction to Bayesian statistics*. John Wiley & Sons.

- Boxma, O. J., Cohen, J. W., and Huffels, N. (1979), Approximations of the mean waiting time in an M/G/s queueing system, *Operations Research*, 27, pp.1115-1127.
- Bragalli, C., D'Ambrosio, C., Lee, J., Lodi, A., & Toth, P. (2006, September). An MINLP solution method for a water network problem. In *European Symposium on Algorithms* (pp. 696-707). Springer, Berlin, Heidelberg.
- Bürkner P. C., Gabry J., & VehtariA. (2020). Approximate leave-future-out cross-validation for Bayesian timeseries models. *Journal of Statistical Computation and Simulation*.
- Carpenter, B., Gelman, A., Hoffman, M., Lee, D., Goodrich, B., Betancourt,M., Brubaker, M. A., Guo, J., Li, P. & Riddell, A. (2017), Stan: Aprobabilistic programming language, *Journalal of Statistical Software* 76(1).
- Chae K-C. and Lee H-W. (1995). Mx/G/1 Vacation Model with N-Policy: Heuristic Interpretation of mean Waiting Time. *Journal of Operational Research Society*. 46, pp.258-264.
- Choi, J. W., Moon, H. J., & Jo, W. Y. (2020) Preventive maintenance interval optimization based on life cycle failure prediction, *Korean Journal of Logistics*, 28(6), 57-70.
- Choi, J. W., Moon, S. A., & Jo, W. Y. (2021) A Study on the Probability-Based Planned Maintenance Effectiveness of Naval Combat Ships, *Journal of the Korean Institute of Industrial Engineers*, 47(2), 190-198.
- Choi, J. W., & Moon, S. A. (2021). Estimation of the Effectiveness of Planned Maintenance of Naval Battleships. *Journal of the Korean Institute of Industrial Engineers*, 47(6), 539-548.
- Choi, J W., Moon, S. A., & Kim, D. J. (2020). An Experiment of the Fatigue on Task Speed and Rework Ratio. *Journal of the Korean Production and Operations Management Society*, 31, 345-360.
- Choi, J. W., Park, J. S., Jo, W. Y., Jeong, S. G., & Choi, J. S. (2021). A Study on the Appropriateness of Time Required for PMS by ROK Navy. *Journal of the Korea Society for Naval Science and Technology*, 4(1), 67-71.
- Choi, Y-C., Park, G-H., Lee, S-R., & Cho, N-S. (2019), The study on balanced team assignment problem using the mixed integer non-linear programming, *Journal of military science and technology studies*, 12(2), 11-20.

- Coyle, R. G., and Gardiner, P. A. (1991). A System Dynamics Model of Submarine Operations and Maintenance Schedules, *The Journal of the Operational Research Society*, 42(6), pp.453-462.
- Cullen, A. C., Frey, H. C., & Frey, C. H. (1999). *Probabilistic techniques in exposure assessment: a handbook for dealing with variability and uncertainty in models and inputs*. Springer Science & Business Media.
- Dagum, E. B., & Bianconcini, S. (2016). *Seasonal adjustment methods and real time trend-cycle estimation*. Springer International Publishing.
- Demerouti, E., Bakker, A. B., Nachreiner, F., & Schaufeli, W. B. (2001). The job demands-resources model of burnout. *Journal of Applied psychology*, 86(3), 499.
- Eberlein, R. L., & Peterson, D. W. (1992). Understanding models with Vensim TM. *European journal of operational research*, 59(1), 216-219.
- Efron, B., Tibshirani, R., Storey, J. D., & Tusher, V. (2001). Empirical Bayes analysis of a microarray experiment. *Journal of the American statistical association*, 96(456), 1151-1160.
- Faddy, M. J. (1995). Phase-type distributions for failure times. *Mathematical and computer modelling*, 22(10-12), 63-70.
- Fang, L., and Zhaodong, H. (2015). System Dynamics Based Simulation Approach on Corrective Maintenance Cost of Aviation Equipments, *Procedia Engineering*, 99, pp.150-155.
- Floudas, C. A., Aggarwal, A., & Cincic, A. R. (1989). Global optimum search for nonconvex NLP and MINLP problems. *Computers & Chemical Engineering*, 13(10), 1117-1132.
- Geißler, B., Martin, A., Morsi, A., & Schewe, L. (2012). Using piecewise linear functions for solving minlp s. In *Mixed integer nonlinear programming* (pp. 287-314). Springer, New York, NY.
- Gajewski, B. J., Simon, S. D., & Carlson, S. E. (2008). Predicting accrual in clinical trials with Bayesian posterior predictive distributions. *Statistics in medicine*, 27(13), 2328-2340.
- Gelman, A., Carlin, J. B., Stern, H.S., Dunson, D. B., Vehtari, A., & Rubin, D. B. (2013). *Bayesian data analysis*. Chapman and Hall/CRC.
- Gelman, A., Lee, D., & Guo, J. (2015). Stan: A probabilistic programming language

- for Bayesian inference and optimization. *Journal of Educational and Behavioral Statistics*, 40(5), 530-543.
- Gelman, A. (2006). Multilevel(hierarchical) modeling: what it can and cannot do. *Technometrics*, 48(3), 432-435.
- Goossens, A. J., & Basten, R. J. (2015). Exploring maintenance policy selection using the Analytic Hierarchy Process: an application for naval ships. *Reliability Engineering & System Safety*, 142, 31-41.
- Gorunescu, F., McClean, S., and Millard, P. (2002). A queueing model for bed-occupancy management and planning of hospitals, *Journal of the Operational Research Society*, 53(1), pp.19-24.
- Hoffman, M. D., & Gelman, A. (2014). The No-U-Turn sampler: adaptively setting path lengths in Hamiltonian Monte Carlo. *J. Mach. Learn. Res.*, 15(1), 1593-1623.
- Homer, J. B. (1999). Macro-and micro-modeling of field service dynamics. *System Dynamics Review: The Journal of the System Dynamics Society*, 15(2), 139-162.
- Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: principles and practice*. OTexts.
- Jiang, Y., Simon, S., Mayo, M. S., & Gajewski, B. J. (2015). Modeling and validating Bayesian accrual models on clinical data and simulations using adaptive priors. *Statistics in medicine*, 34(4), 613-629.
- Jiang, W., & Zhang, C. H. (2010). EmpiricalBayes in season prediction of baseball batting averages. In Borrowing Strength: Theory Powering Applications-A Festschrift for Lawrence D.Brown (pp. 263-273). *Institute of Mathematical Statistics*.
- Jones, L. (2014). Vensim and the development of system dynamics. *Discrete-Event Simulation and System Dynamics for Management Decision Making*, 215-247.
- Jo, S. H., & Yoon, B. K. (2019). An Analysis on the Operation Level of the Dry Dock for Warship Maintenance Using Priority Queue. *Journal of The Korean Operations Research and Management Science Society*, 36(1), 37-49.
- Karnopp, D. C., Margolis, D. L., & Rosenberg, R. C. (2012). *System dynamics: modeling, simulation, and control of mechatronic systems*. John Wiley & Sons.
- Kim, H. S., & Kim, P. (2014). Optimization for inventory level of spare parts considering system availability. *Korean Management Science Review*, 31(2),

1-13.

- Kim, S. W., & Yoon, B. K. (2015). An Analysis on the Number of Maintenance Personnel in the Emergency Maintenance System with Deadline. *Korean Journal of Logistics*, 23(3), 69-81.
- Kim, T. H., Kim, H. J., Choi, S. M., & Moon, S. A. (2006). A System Dynamics Approach for Emergency Department Operation Considering the Effects of Schedule Pressure. *Korean Management Review*, 35(3), 783-804.
- Ko, S. H., & Yoon, B. K. (2020). An Analysis on the Operation of R.O.K.A Mortar Company with Queuing Model. *Journal of The Korean Operations Research and Management Science Society*, 37(1), 19-31.
- Ko, J. W., Kim, G. G., & Yoon, B. K. (2013). A Study on the Optimal Appointment Scheduling for the Ship Maintenance with Queueing System with Scheduled Arrivals. *Journal of the Korean Operations Research and Management Science Society*, 38(3), 13-22.
- Kruschke, J. (2014). *Doing Bayesian data analysis: A tutorial with R, JAGS, and Stan*, Elsevier, London.
- Kuha, J. (2004). AIC and BIC: Comparisons of assumptions and performance. *Sociological methods & research*, 33(2), 188-229.
- Kumar, V. S., Satpathi, D. K., Kumar, P. P., & Haragopal, V. V. (2020). Forecasting motor insurance claim amount using ARIMA model. In AIP Conference Proceedings (Vol. 2246, No. 1, p. 020005). AIP Publishing LLC.
- Linnéusson, G., Ng, A. H. C., and Aslam, T. (2018). Quantitative analysis of a conceptual system dynamics maintenance performance model using multi-objective optimisation. *Journal of Simulation*, 12(2), pp.171-189.
- Malik, M. A. K. (1979). Reliable preventive maintenance scheduling. *AIEE transactions*, 11(3), 221-228.
- Marçais, A., Jeannet, R., Hernandez, L., Soulier, J., Sigaux, F., Chan, S., & Kastner, P. (2010). Genetic inactivation of Ikaros is a rare event in human T-ALL. *Leukemia research*, 34(4), 426-429.
- Mcdevitt, M. E., Zabarouskas, M. W., and Crook, J. C. (2005). Workflow Ship Repair. *Journal of Simulation, Military Operations Research*, 10(3), pp.25-43.
- McElreath, R. (2020). *Statistical rethinking: A Bayesian course with examples in R and Stan*. CRC press.

- Mechefske, C. K. (2005). *Machine condition monitoring and fault diagnostics*. In *Vibration and Shock Handbook* (Vol. 25, pp. 1-35). Boca Raton, FL: CRC Press, Taylor and Francis Group.
- Mohammadi, H., & Rich, D. P. (2013). Dynamics of unemployment insurance claims: an application of ARIMA-GARCH models. *Atlantic Economic Journal*, 41(4), 413-425.
- Moon, H., & Choi, J. (2021). Hierarchical spline for time series prediction: An application to naval ship engine failure rate. *Applied AI Letters*, 2(1), e22.
- Moon, S. A., Park, J. S., & Kim, D. J. (2004). A System Dynamics Approach of Close Service Capability Considering Job Pressure and Fatigue in ROK Army. *Journal of the Korean Production and Operations Management Society*, 15(2), 155-187.
- Nepal, M. P., Park, M., & Son, B. (2006). Effects of schedule pressure on construction performance., 132(2), 182-188.
- Neuts, M. F., & Meier, K. S. (1981). On the use of phase type distributions in reliability modelling of systems with two components. *Operations-Research-Spektrum*, 2(4), 227-234.
- Okamura, H., Dohi, T., & Trivedi, K. S.(2011). A refined EM algorithm for PH distributions. *Performance Evaluation*, 68(10), 938-954.
- Okamura, H., Dohi, T., & Trivedi, K. S.(2013). Improvement of expectation-maximization algorithm for phase-type distributions with grouped and truncated data. *Applied Stochastic Models in Business and Industry*, 29(2),141-156.
- Ok, K., Cho, S., Jeon, J., Yang, J. & Cho, Y. (2014). A Study on an Efficient Size Dry Docks for Warship Maintenance using Queueing Problem. *Journal of the Korean Institute of Industrial Engineers*, 40(4), 428-434.
- Oliva, R., & Sterman, J. D. (2001). Cutting corners and working overtime: Quality erosion in the service industry. *Management Science*, 47(7), 894-914.
- Olson, M. H. (1980). Review of" Software Psychology: Human Factors in Computer and Information Systems, by Ben Shneiderman", Winthrop Computer Systems Series, 1980. *ACM SIGMIS Database: the DATABASE for Advances in Information Systems*, 11(4), 21-21.
- Osogami, T., & Harchol-Balter, M. (2006).Closed form solutions for mapping general distributions to quasi-minimal PH distributions. *Performance Evaluation*, 63(6),

524-552.

- Pai, P. F., & Lin, C. S. (2005). A hybrid ARIMA and support vector machines model in stock price forecasting. *Omega*, 33(6), 497-505.
- Park, J. S., Moon, S. A., & Choi, J. W. (2021). Planned Maintenance Queue Simulation based on Failure Probability: Focused on the Naval Battleship. *Journal of the Korean Institute of Industrial Engineers*, 1077-1095.
- Parkinson, C. N., & Osborn, R. C. (1957). *Parkinson's law, and other studies in administration* (Vol. 24). Boston: Houghton Mifflin.
- Prajapati, A., Bechtel, J., & Ganesan, S. (2012). Condition based maintenance: a survey. *Journal of Quality in Maintenance Engineering*.
- Putnam, L. H. (1978). A general empirical solution to the macro software sizing and estimating problem. *IEEE transactions on Software Engineering*, (4), 345-361.
- Rai, V. K., & Mahanty, B. (2002, July). Dynamics of schedule pressure in software projects. In *Proceedings of the 20th International Conference of the System Dynamics Society, The System Dynamics Society*, Palermo, July-August.
- Rao, V., Maulik, R., Constantinescu, E., and Anitescu, M.(2020). A machine-learning-based importance sampling method to compute rare event probabilities. In *International Conference on Computational Science* (pp. 169-182). Springer, Cham.
- Razali, N. M., & Wah, Y. B. (2011). Power comparisons of shapiro-wilk, kolmogorov-smirnov, lilliefors and anderson-darling tests. *Journal of statistical modeling and analytics*, 2(1), 21-33.
- ROK NAVY, (2018), *Ship's Maintenance System*, 9-10, Republic of Korea.
- Rowland, G., & Adams, A. M. (1999). *Systems thinking in instructional design. In Design approaches and tools in education and training* (pp. 29-44). Springer, Dordrecht.
- Rubin, D. B. (1981). The bayesian bootstrap. *The annals of statistics*, 130-134.
- Rubino, G., & Tuffin, B. (Eds.). (2009). *Rare event simulation using Monte Carlo methods*. John Wiley & Sons.
- Said, F., Afzal, U., & Turner, G. (2015). Risk taking and risk learning after a rare event: Evidence from a field experiment in Pakistan. *Journal of Economic Behavior & Organization*, 118, 167-183.
- Sakia, R. M. (1992). The Box-Cox transformation technique: a review. *Journal of the*

- Royal Statistical Society: Series D (The Statistician)*, 41(2), 169-17
- Sherbrooke, C. C. (2006). *Optimal inventory modeling of systems: multi-echelon techniques* (Vol. 72). Springer Science & Business Media.
- Shin, I., Lim, T. J., and Lie, C. H. (1996). Estimating parameters of intensity function and maintenance effect for repairable unit. *Reliability Engineering & System Safety*, 54(1), 1-10.
- Siami-Namini, S., & Namin, A. S. (2018). Forecasting economics and financial time series: ARIMA vs. LSTM. *arXiv preprint arXiv:1803.06386*.
- Sterman, J. (2000). *Business dynamics*. McGraw-Hill, Inc..
- Straub, D., Papaioannou, I., & Betz, W. (2016). Bayesian analysis of rare events. *Journal of Computational Physics*, 314, 538-556.
- Taylor, S. J., & Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1), 37-45.
- Taieb, S. B., Yu, J., Barreto, M. N., & Rajagopal, R. (2017). Regularization in hierarchical time series forecasting with application to electricity smart meter data. In *Thirty-First AAAI Conference on Artificial Intelligence*.
- Thibodeau, R., & Dodson, E. N. (1979). Life cycle phase interrelationships. *Journal of Systems and Software*, 1, 203-211.
- Tsang, A. H., Yeung, W. K., Jardine, A. K., & Leung, B. P. (2006). Data management for CBM optimization. *Journal of quality in maintenance engineering*.
- Vehtari, A., Gelman, A., & Gabry, J. (2017). Practical Bayesian model evaluation using leave-one-outcross-validation and WAIC. *Statistics and Computing*, 27(5), 1413-1432.
- Vehtari, A., Gelman, A., Simpson, D., Carpenter, B., & Bürkner, P. C. (2020). Rank-normalization, folding, andlocalization: An improved Rhat for assessing convergence of MCMC. *Bayesian Analysis*.
- Vehtari, A., & Lampinen, J. (2002). Bayesian model assessment and comparison using cross-validation predictive densities. *Neural computation*, 14(10), 2439-2468.
- Vrieze, S. I. (2012). Model selection and psychological theory: a discussion of the differences between the Akaike information criterion (AIC) and the Bayesian information criterion (BIC). *Psychological methods*, 17(2), 228.
- Wagner, F., Papaioannou, I., and Ullmann, E. (2021). The ensemble Kalman filter for rare event estimation. *arXiv preprint arXiv:2106.10062*.

- Wahal, S., & Biros, G. (2019). BIMC: The Bayesian Inverse Monte Carlo method for goal-oriented uncertainty quantification. Part I. *arXiv preprint arXiv:1911.00619*.
- Wang, J., & Yin, H. (2019). Failure rate prediction model of substation equipment based on Weibull distribution and time series analysis. *IEEE Access*, 7, 85298-85309.
- Weisberg, S. (2001). Yeo-Johnson power transformations. *Department of Applied Statistics*, University of Minnesota. Retrieved June, 1, 2003.
- Wipf, D. P., & Rao, B. D. (2007). An empirical Bayesian strategy for solving the simultaneous sparse approximationproblem. *IEEE Transactions on Signal Processing*, 55(7),3704-3716.
- Xu, J., Liang, Z., Li, Y. F., and Wang, K. (2021). Generalized condition-based maintenance optimization for multi-component systems considering stochastic dependency and imperfect maintenance. *Reliability Engineering & System Safety*, 211, 107592.
- Yoo, J. M., Yoon, S. W., & Lee, S.H. (2019). SNA-based Trend Analysis of Naval Ship Maintenance. *Journal of the Korea Society of Computer and Information*, 24(6), 165-174.
- Yoon, & Choi. (2021). An Analysis on the Non-punctual Scheduled Arrival System Using Discrete-time Phase-type Distribution. *Korean Journal of Logistics*, 29(5), 37-46.
- Zammori, F., Bertolini, M., & Mezzogori, D. (2020). A constructive algorithm to maximize the useful life of a mechanical system subjected to ageing, with non-resuppliable spares parts. *International Journal of Industrial Engineering Computations*, 11(1), 17-34.
- Zhang, C., Wang, X. and Li, J. (2009), Cooperative Cognitive Radio with Priority Queuing Analysis. in Proc. *IEEE International Conference on Communications*.
- Zhang, X., & Long, Q. (2010). Stochastic modeling and prediction for accrual in clinical trials. *Statistics in Medicine*, 29(6), 649-658.
- Zonta, T., da Costa, C. A., da Rosa Righi, R., de Lima, M. J., da Trindade, E. S., & Li, G. P. (2020). *Predictive maintenance in the Industry 4.0: A systematic literature review*. Computers & Industrial Engineering, 106889.

부 록

1. PFM_FRP 모델의 NOLH 시뮬레이션 결과

Scenario	M_N	Max	M	Nightwork days	Max
	CF	delays	CF		manpower
1	32.16		18.8	4506	1.633
2	35.83		14.66	6038	1.225
3	9.666		5.132	3359	0.6806
4	24.33		10.57	9503	0.6806
5	8.333		4.515	3985	1.769
6	3.5		1.974	2776	2.45
7	55.33		25.12	2066	2.586
8	15.83		5.111	3004	2.722
9	21.49		10.07	6510	0.9528
10	55.33		25.76	5462	1.361
11	15.33		3.579	4998	0.9528
12	10		5.954	4938	1.497
13	8.833		2.468	3198	2.314
14	9.666		4.79	3228	2.178
15	20.16		9.915	3463	2.178
16	23.49		9.973	3802	2.041
17	22.16		7.472	4079	1.633
18	5.166		2.656	3685	1.769
19	8.166		3.11	3217	2.041
20	47.33		23.38	2042	2.722
21	10.16		5.648	3052	2.586
22	22.16		8.38	4847	1.497
23	20.5		6.95	7748	0.8167
24	3.833		1.76	2347	0.8167
25	31		10.08	10844	0.5445
26	7.666		5.044	3493	2.314
27	6		2.808	2834	1.905
28	16.5		8.831	3108	2.45
29	9.833		2.015	3994	1.905
30	14.83		5.138	5829	1.089
31	47.83		21.25	6587	1.225
32	8.166		1.104	4103	1.089
33	5.666		2.721	4787	1.361

Scenario	M manpower	SD manpower	Manpower utilization	Probability CF	M cumulative delays
1	0.4914	0.7362	0.68985	0.0008837	99.33
2	0.4965	0.5882	0.697009615	0.00070696	81.16
3	0.1444	0.2783	0.202715385	0.0013	34.16
4	0.4268	0.3209	0.599161538	0.0008837	1416
5	0.5518	0.77	0.774642308	0.0013	20.5
6	0.4443	0.9352	0.623728846	0.0012	7.833
7	0.4102	0.9004	0.575857692	0.0008837	5435
8	0.5506	1.074	0.772957692	0.0014	48.33
9	0.395	0.4682	0.554519231	0.0016	56.83
10	0.5258	0.637	0.738142308	0.001	1714
11	0.301	0.4428	0.422557692	0.0012	34.5
12	0.5605	0.6821	0.786855769	0.0008837	18
13	0.5664	0.9426	0.795138462	0.0014	36
14	0.4501	0.8786	0.631871154	0.0012	32.33
15	0.5678	0.9104	0.797103846	0.0008837	73.5
16	0.525	0.8759	0.737019231	0.00097207	68.5
17	0.4562	0.7149	0.640434615	0.0015	44.83
18	0.4292	0.75	0.602530769	0.0013	8.166
19	0.417	0.8207	0.585403846	0.001	18.5
20	0.4447	0.9498	0.624290385	0.00070696	4335
21	0.5297	1.027	0.743617308	0.0013	57
22	0.4745	0.6891	0.666125	0.0011	87.5
23	0.4111	0.403	0.577121154	0.00097207	86
24	0.1209	0.29	0.169725	0.0016	14.66
25	0.3777	0.2484	0.530232692	0.00079533	2546
26	0.5894	0.9678	0.827426923	0.0014	32.33
27	0.3432	0.7311	0.4818	0.0014	19.33
28	0.5599	0.9864	0.786013462	0.0008837	64
29	0.5048	0.8288	0.708661538	0.0012	74.66
30	0.403	0.5247	0.56575	0.0016	61.83
31	0.5665	0.5857	0.795278846	0.0012	646.66
32	0.2828	0.4771	0.397007692	0.0011	29.66
33	0.4494	0.6231	0.630888462	0.00097207	24.5

Scenario	M_N maintenance	Max	M	SD	Max workload
		accumulated NF	accumulated NF	accumulated NF	
1	26.5	57.34	14.66	2.9	56.53
2	36.33	45.28	10	2.053	60.29
3	23	434.75	213.22	112.35	859.78
4	73.66	31.5	5.357	1.278	36.66
5	94	28.35	4.617	1.167	43.64
6	39	151.76	35.99	18.24	253.3
7	46.66	33.51	6.445	1.256	47.2
8	23	73.78	20.33	5.892	101.26
9	31.66	131.68	38.21	16.11	213.2
10	47.33	31.41	6.748	1.425	42.17
11	32	230.05	90.08	42.25	348
12	78.16	25.04	4.895	1.612	27.12
13	55	31.69	7.102	1.811	33.76
14	27.5	118.45	39.51	12.09	193.8
15	43.83	37.64	7.832	1.402	47.41
16	25.83	64.63	16.16	5.144	92.92
17	36.33	51.97	11.96	6.193	100.09
18	58	138.62	34.79	9.633	215.89
19	37	121.33	30.21	32.34	224.83
20	55.66	26.82	5.456	1.047	38.78
21	23	73.11	19.59	5.654	88.2
22	22.5	69.08	19.7	4.737	96.98
23	34.33	50.46	12.02	2.908	68.75
24	23	492.07	227.61	135.07	953.78
25	71	44.79	9.908	3.462	71.42
26	43	41.25	9.547	2.588	50.27
27	27	242.98	97.94	51.99	434.1
28	42.5	38.63	8.64	1.663	49.86
29	23.83	71.13	18.64	7.317	108.47
30	27	105.32	40.93	12.27	199.81
31	51	29.48	6.272	1.07	29.48
32	31	242.51	98.4	52.45	444.4
33	62	49.64	8.452	3.584	68.51

Scenario	M workload	SD workload	Repair shop utilization	Cost mechanics	Ao	Cost ship operating	Cost spare part	Life cycle cost
1	7.55	11.52	0.6275	48214	0.7879	1011000	148116	1207330
2	7.218	9.201	0.7955	64068	0.7315	938961	203077	1206106
3	111.79	204.88	0.25735	33665	0.9133	1172000	128553	1334218
4	7.249	6.309	0.9945	96393	0.6662	855180	411744	1363317
5	2.776	4.587	0.5985	55134	0.7996	1026000	525393	1606527
6	15.15	38.81	0.2287	29748	0.9234	1185000	217982	1432730
7	2.591	6.213	0.999	28401	0.662	849716	260833	1138950
8	7.606	15.33	0.34575	33937	0.8833	1133000	128553	1295490
9	36.89	51.07	0.5215	64220	0.8242	1057000	176994	1298214
10	4.79	6.333	0.9905	63551	0.6649	853420	264559	1181530
11	69.65	99.45	0.39145	48615	0.8681	1114000	178857	1341472
12	3.176	4.293	0.72255	63792	0.7572	971779	436896	1472467
13	3.152	5.665	0.643	43905	0.7848	1007000	307459	1358364
14	19.6	36.5	0.27655	32993	0.9069	1164000	153705	1350698
15	3.475	6.108	0.809	44860	0.7284	934913	244997	1224770
16	7.669	13.88	0.5245	41411	0.823	1056000	146301	1243712
17	6.981	12.7	0.531	46547	0.8209	1053000	206852	1306399
18	20.12	40.29	0.3088	39215	0.8966	1150000	324179	1513394
19	24.4	49.65	0.26475	32736	0.911	1168000	206803	1407539
20	2.134	4.874	0.998	29467	0.663	850982	311137	1191586
21	7.149	14.11	0.36095	34000	0.8787	1127000	128553	1289553
22	12.16	18.31	0.51	49850	0.8278	1062000	128601	1240451
23	12.86	13.67	0.796	77159	0.7328	940561	191899	1209619
24	82.44	200.68	0.17845	25043	0.9401	1206000	128553	1359596
25	17.07	13.68	0.9965	103897	0.665	853572	396839	1354308
26	4.173	7.32	0.5485	44227	0.8164	1047000	240339	1331566
27	42.73	92.06	0.2233	29288	0.925	1187000	150910	1367198
28	3.545	6.573	0.7215	39129	0.758	972861	237545	1249535
29	9.678	17.03	0.4733	42742	0.8413	1079000	133211	1254953
30	35.62	46.14	0.47405	57652	0.8406	1078000	154685	1290337
31	4.888	5.415	0.9845	75516	0.6675	856728	285054	1217298
32	63.44	112.47	0.33	40281	0.8892	1141000	173268	1354549
33	6.14	10.49	0.543	53362	0.8183	1050000	346536	1449898

2. PFM_NRP 모델의 시뮬레이션 결과

Scenario	M_N	Max	M	Nightwork	days	Max	
	CF	delays	CF	delays	CF	manpower	
1	3.166		7.833		5.856	4031	1.633
2	3.5		5.333		2.089	5265	1.225
3	2.5		43.66		15.97	8407	0.6806
4	3		15.33		5.509	8789	0.6806
5	3		4.666		2.412	3387	1.769
6	3		3		1.443	2644	2.45
7	3.166		22.16		11.08	2007	2.586
8	4		4		2.02	2370	2.722
9	3.333		21.83		10.59	6528	0.9528
10	2		6.5		3.388	4604	1.361
11	1.833		15.83		1.091	6637	0.9528
12	2.833		7.5		4.362	4043	1.497
13	3.5		4.166		1.829	2551	2.314
14	2.833		6.5		4.096	3150	2.178
15	2.666		2.666		0.8849	2875	2.178
16	1.6666		1.666		0.5761	3406	2.041
17	3.5		3.5		1.609	3943	1.633
18	2.833		4.5		2.215	3595	1.769
19	3.166		13.5		6.627	3293	2.041
20	3.666		5.5		2.248	1568	2.722
21	3.833		7.166		2.498	2651	2.586
22	3.166		10.5		5.254	4424	1.497
23	2.333		16		6.358	7426	0.8167
24	2.166		44.16		15.8	7199	0.8167
25	2.166		19.5		9.915	10346	0.5445
26	3.833		73666		4.69	2985	2.314
27	3.333		5.166		3.037	3552	1.905
28	2.333		4.833		2.329	2707	2.45
29	2.666		2.666		1.014	3611	1.905
30	2.166		9.833		7.341	5905	1.089
31	3		7.833		2.461	5224	1.225
32	2.5		13.66		3.34	5875	1.089
33	2.5		5.833		1.706	4921	1.361

Scenario	M manpower	SD manpower	Manpower utilization	Probability CF	M cumulative delays
1	0.4372	0.713	0.613761538	0.0016	5942
2	0.4281	0.5732	0.600986538	0.0018	3857
3	0.3645	0.3382	0.511701923	0.0013	6231
4	0.405	0.3229	0.568557692	0.0015	0
5	0.5045	0.7468	0.708240385	0.0015	0
6	0.4712	0.9373	0.661492308	0.0015	4994
7	0.6545	0.9267	0.918817308	0.0016	0
8	0.4539	0.9943	0.637205769	0.0021	7236
9	0.4047	0.4658	0.568136538	0.0017	5041
10	0.4574	0.6166	0.642119231	0.001	0.5
11	0.4086	0.4671	0.573611538	0.00097207	5253
12	0.4647	0.657	0.652367308	0.0015	0
13	0.4684	0.8857	0.657561538	0.0018	1471
14	0.4609	0.8758	0.647032692	0.0015	6541
15	0.4685	0.8604	0.657701923	0.0014	2698
16	0.4661	0.8453	0.654332692	0.0008837	6364
17	0.4436	0.7106	0.622746154	0.0018	4634
18	0.4643	1.7531	0.651805769	0.0015	2107
19	0.4633	0.8378	0.650401923	0.0016	5205
20	0.5468	0.903	0.767623077	0.0019	0
21	0.4615	0.9749	0.647875	0.002	7087
22	0.4317	0.6714	0.606040385	0.0016	4711
23	0.3922	0.4039	0.550588462	0.0012	3980
24	0.3758	0.4053	0.527565385	0.0011	6543
25	0.3672	0.2491	0.515492308	0.0011	27.5
26	0.4874	0.9154	0.684234615	0.002	3646
27	0.4507	0.7981	0.632713462	0.0017	6601
28	0.4899	0.9427	0.687744231	0.0012	3217
29	0.4532	0.801	0.636223077	0.0014	6731
30	0.4191	0.5245	0.588351923	0.0011	5863
31	0.4446	0.5704	0.62415	0.0015	60.33
32	0.4145	0.5232	0.581894231	0.0013	5535
33	0.4603	0.6246	0.646190385	0.0013	781.66

Scenario	M_N maintenance	Max	M	SD	Max workload
		accumulated NF	accumulated NF	accumulated NF	
1	30.33	61.25	15.7	3.359	61.25
2	43	45.46	10.8	2.423	55.46
3	18.5	74.31	22.41	4.038	102.59
4	97.16	17.85	4.068	0.7445	23.46
5	100	20.44	4.574	0.973	24.2
6	39.16	50.26	12.67	3.162	54.6
7	111.33	17.4	2.633	0.5959	17.4
8	24	75.68	20.84	4.666	82.61
9	32.16	52.53	14.09	3.222	71.7
10	78.66	25.51	5.829	1.333	32.43
11	30.66	56.24	14.81	2.831	72.79
12	88.16	23.16	5.171	1.557	27.54
13	63.66	31.54	7.523	1.812	36.88
14	27.83	66.81	17.71	4.222	79.63
15	54.83	38.41	8.822	1.817	38.41
16	28.66	64.9	17.16	5.422	89.2
17	40.33	48.14	12.04	5.313	80.31
18	57.83	35.58	8.248	1.78	45.17
19	36.66	52.71	13.24	3.396	62.08
20	163.33	15.18	2.664	0.5619	16.02
21	24.5	71.36	20.13	5.233	81.29
22	24.33	70.06	19.58	4.293	94.61
23	37.33	45.01	11.62	2.632	50.8
24	19.16	76.99	22.24	4.708	102.97
25	88.66	22.15	4.273	1.176	29.33
26	48	42.53	10.33	2.756	46.94
27	26.83	69.65	18.34	4.876	70.46
28	51	41.01	9.696	2.259	55.45
29	25.83	71.56	19.06	6.429	89.34
30	28	61.04	16.68	3.791	71.57
31	70	28.91	6.544	1.334	39.32
32	30.33	60.71	15.18	2.991	78.46
33	65.16	31.67	7.083	2.011	34.36

Scenario	M workload	SD workload	Repair shop utilization	Cost mechanics	Ao	Cost ship operating	Cost spare part	Life cycle cost
1	6.7	11.11	0.29265	44039	0.9017	1157000	169541	1370580
2	6.209	8.824	0.38625	57102	0.8707	1117000	240339	1414441
3	25	23.08	0.6465	81273	0.7806	1001000	107176	1189449
4	4.468	3.736	0.7665	94386	0.743	953680	543093	1591159
5	2.084	3.402	0.43455	51984	0.8547	1096000	558929	1706913
6	3.619	7.639	0.2327	33837	0.9221	1183000	218914	1435751
7	1.503	2.275	0.969	57472	0.6748	866215	622274	1545961
8	5.01	11.52	0.179	30229	0.9399	1206000	134143	1370372
9	10.54	12.59	0.4683	67042	0.8419	1080000	179788	1326830
10	3.163	4.617	0.43575	56184	0.8541	1096000	639691	1791875
11	11.51	13.74	0.4804	65790	0.8384	1076000	174247	1316037
12	2.612	4.103	0.43175	54326	0.8554	1097000	492789	1644115
13	2.285	4.664	0.2837	37565	0.905	1161000	355899	1554464
14	6.055	11.9	0.239	35368	0.9197	1180000	155568	1370936
15	2.927	5.758	0.28175	37865	0.9058	1162000	306479	1506344
16	6.628	12.35	0.26185	36425	0.9125	1171000	160274	1367699
17	4.914	8.656	0.2872	45820	0.9039	1160000	227346	1433166
18	3.45	6.073	0.33375	44808	0.8883	1140000	323247	1508055
19	4.948	9.328	0.2715	38488	0.9083	1165000	204988	1408476
20	1.205	2.015	0.5235	47470	0.8249	1058000	912918	2026890
21	5.75	12.26	0.20665	31464	0.9304	1194000	137917	1363381
22	9.436	14.94	0.3107	46615	0.8955	1149000	136006	1331621
23	10.65	11.14	0.5715	73920	0.808	1037000	208715	1319635
24	19.9	21.4	0.534	70004	0.818	1049000	107128	1226132
25	6.287	4.436	0.941	103428	0.6845	878647	495584	1477659
26	3.598	6.998	0.2743	37620	0.9078	1165000	268286	1470906
27	6.672	12.08	0.24965	39572	0.9163	1175000	150027	1364599
28	3.063	6.239	0.26815	35002	0.9101	1168000	285054	1488056
29	7.393	13.41	0.25775	38869	0.9138	1172000	144390	1355259
30	10.57	13.6	0.40005	59779	0.8657	1111000	156500	1327279
31	4.104	5.734	0.4584	60200	0.8465	1086000	391250	1537450
32	9.753	12.66	0.4063	59577	0.8633	1108000	169541	1337118
33	4.047	5.732	0.4196	55713	0.8596	1103000	364235	1522948

3. FFM_FRP 모델의 시뮬레이션 결과

Scenario	M_N	Max	M	Nightwork	days	Max	
	CF	delays	CF	delays	CF	manpower	
1	2.666		35.49		25.15	4573	1.633
2		3	23.83		10.2	5515	1.225
3	2.833		10.16		6.389	8523	0.6806
4	3.333		28		11.29	8633	0.6806
5	3.166		3.166		1.458	3691	1.769
6		3		3	1.487	2650	2.45
7	2.833		37.16		21.99	2776	2.586
8		2.5	38.83		12.34	2581	2.722
9		2		40	19.98	7734	0.9528
10		2		42	22.81	5693	1.361
11	2.833		5.833		1.826	6409	0.9528
12	2.333		5.5		3.359	4308	1.497
13		2		26	11.55	2594	2.314
14	1.666		9.333		5.391	3172	2.178
15	2.833		12.5		7.266	3357	2.178
16	2.166		19.5		8.884	3831	2.041
17		3	31.66		11.99	4354	1.633
18		3	4.833		2.531	3685	1.769
19	2.333		3.166		1.109	3273	2.041
20	2.666		16.5		6.787	2828	2.722
21	3.333		12		6.637	2916	2.586
22	2.333		46.5		20.03	5140	1.497
23	2.833		63.83		31.17	8140	0.8167
24	3.166		9.166		5.966	7482	0.8167
25	2.166		19.83		7.382	9771	0.5445
26	2.833		13.33		8.346	3030	2.314
27		3	7.333		4.426	3422	1.905
28	1.666		6.833		3.171	2994	2.45
29	1.166		7.666		3.358	4055	1.905
30	3.166		9.333		3.78	5709	1.089
31	2.833		6.5		2.776	5317	1.225
32	2.333		9.333		3.375	6385	1.089
33	2.666		2.666		0.9945	4773	1.361

Scenario	M manpower	SD manpower	Manpower utilization	Probability CF	M cumulative delays
1	0.5058	0.738	0.7101	0.0014	387.66
2	0.4379	0.5822	0.6147	0.0015	189.83
3	0.3697	0.3376	0.5190	0.0015	235.16
4	0.3788	0.3345	0.5318	0.0017	497.5
5	0.435	0.7512	0.6107	0.0016	27.16
6	0.447	0.928	0.6275	0.0015	18.33
7	0.5582	1.008	0.7836	0.0015	883.5
8	0.5954	1.033	0.8359	0.0013	641.5
9	0.507	0.4572	0.7118	0.00070696	2579
10	0.5517	0.6399	0.7745	0.001	4585
11	0.3939	0.4661	0.5530	0.0015	117.83
12	0.4284	0.6674	0.6014	0.0012	40.66
13	0.5955	0.8997	0.8360	0.001	2457
14	0.5688	0.8895	0.7985	0.001	403.16
15	0.4945	0.8971	0.6942	0.0015	85.5
16	0.5437	0.8763	0.7633	0.0011	326.66
17	0.4843	0.729	0.6799	0.0015	278
18	0.4412	0.7479	0.6194	0.0015	25
19	0.5332	0.8425	0.7485	0.0012	188.83
20	0.5489	1.05	0.7706	0.0014	168.66
21	0.5162	1.014	0.7247	0.0017	85
22	0.5387	0.694	0.7563	0.0012	1024
23	0.4377	0.3991	0.6145	0.0015	1608
24	0.386	0.4077	0.5419	0.0016	158.66
25	0.336	0.2646	0.4717	0.0011	543.33
26	0.471	0.9173	0.6612	0.0015	38.66
27	0.4281	0.787	0.6010	0.0015	30.66
28	0.5635	0.9836	0.7911	0.0008837	383.33
29	0.5455	0.8345	0.7658	0.00061859	466.5
30	0.3991	0.5223	0.5603	0.0016	96.66
31	0.4259	0.5772	0.5979	0.0015	75.16
32	0.4929	0.5186	0.6920	0.0012	669.33
33	0.4249	0.624	0.5965	0.0014	65

Scenario	M_N maintenance	Max	M	SD	Max workload
		accumulated NF	accumulated NF	accumulated NF	
1	28.16	33.2	12.73	1.954	49.73
2	23.83	34.3	17.1	2.884	60.84
3	53.5	19.3	10.83	1.249	33.73
4	54	16.71	7.131	0.8441	26.47
5	36.83	26.07	15.89	2.381	48.77
6	32	28.86	16.1	2.75	51.02
7	40.66	20.2	7.652	1.044	29.61
8	54.33	17.2	5.952	0.7981	23.02
9	58.5	16.89	5.394	1.082	23.89
10	47.33	24.26	6.34	1.412	24.64
11	35.66	26.24	15.51	2.074	47.36
12	37	23.08	12.88	1.881	43.06
13	81.66	12.9	3.693	0.6997	14.55
14	71	14.92	4.978	0.6749	18.47
15	23.33	34.13	17.85	3.017	60.96
16	31.66	28.52	11.66	1.699	43.43
17	35.33	25.5	11.4	2.059	46.02
18	50.5	17.92	10.39	1.53	33.22
19	73	13.11	5.595	0.81	1921
20	30	28.1	13.05	2.137	43.08
21	27	31.2	15.87	2.6	51.5
22	38.16	22.64	8.488	1.2	33.66
23	39	24.04	8.44	1.286	39.12
24	61.5	27.62	20.29	2.692	51.64
25	50.5	33.93	23.14	2.806	60.52
26	24	39.75	18.68	3.437	58.31
27	26.66	34.29	20.49	3.607	64.52
28	41.66	20.44	8.503	1.251	31.03
29	35	26.13	10.11	1.554	39.42
30	23.66	37.77	21	3.472	65.38
31	23.83	37.61	17.65	2.771	58.07
32	74.5	12.67	4.748	0.5868	20.93
33	42.16	22.18	11.29	1.75	35.77

Scenario	M workload	SD workload	Repair shop utilization	Cost mechanics	Ao	Cost ship operating	Cost spare part	Life cycle cost
1	5.96	8.751	0.673	50731	0.7724	991303	157431	1199465
2	9.941	13.05	0.5205	56453	0.8243	1058000	135122	1249575
3	11.2	8.897	0.5955	82796	0.8005	1027000	299027	1408823
4	7.246	5.868	0.729	86188	0.7544	968267	301821	1356276
5	6.001	10.29	0.2359	40781	0.921	1182000	205872	1428653
6	4.283	8.828	0.18805	31545	0.937	1202000	178857	1412402
7	2.572	4.671	0.8685	39309	0.707	907484	227297	1174090
8	1.978	3.465	0.82	42023	0.7232	928189	303684	1273896
9	4.661	4.258	0.9595	84950	0.6765	868276	326973	1280199
10	4.017	4.762	0.989	66874	0.6664	855389	264559	1186822
11	10.99	12.34	0.433	64256	0.8551	1097000	199351	1360607
12	5.737	8.807	0.34325	45795	0.885	1135000	206803	1387598
13	1.619	2.476	0.952	50827	0.6803	873170	456459	1380456
14	1.994	3.123	0.715	47204	0.7607	976232	396839	1420275
15	5.731	10.32	0.43245	37789	0.8547	1096000	131396	1265185
16	4.465	7.122	0.643	44286	0.7838	1005000	177974	1227260
17	5.683	8.661	0.5165	49137	0.8249	1058000	201262	1308399
18	4.026	6.728	0.2686	41990	0.91	1167000	282259	1491249
19	2.206	3.51	0.5225	46992	0.8254	1059000	408066	1514058
20	3.694	7.046	0.5415	35624	0.8179	1049000	167678	1272171
21	4.406	8.513	0.42385	34446	0.8576	1100000	150910	1285356
22	4.592	5.982	0.868	59305	0.7064	906695	213324	1179324
23	7.906	7.256	0.9065	83955	0.692	888246	217982	1190183
24	18.66	16.41	0.47435	72345	0.841	1079000	344721	1496066
25	31.65	17.44	0.7075	92278	0.7623	978456	282259	1352993
26	5.544	10.66	0.3069	34222	0.8965	1150000	134143	1318365
27	6.998	12.74	0.22065	37019	0.9257	1188000	149047	1374066
28	2.87	5.007	0.705	39786	0.7643	981009	232887	1253682
29	4.257	6.52	0.695	46465	0.7675	985063	198468	1229996
30	13.26	16.59	0.41555	57472	0.8606	1104000	132279	1293751
31	9.542	12.66	0.46255	55086	0.8452	1084000	133211	1272297
32	3.426	3.571	0.7895	74293	0.7359	944515	416402	1435210
33	5.655	8.043	0.3702	49739	0.8763	1124000	235681	1409420

4. FFM_NRP 모델의 시뮬레이션 결과

Scenario	M_N	Max	M	Nightwork	days	Max	
	CF	delays	CF	delays	CF	manpower	
1	4.666		12.33		4.745	3727	1.666
2	3.833		25.5		13.58	4983	1.225
3	3.5		66.33		28.32	8312	0.6806
4	3.166		32		12.33	8247	0.6806
5	3.833		36.16		19.9	3487	1.769
6	4.5		28.5		10.32	2430	2.45
7	4.166		12.33		6.319	1776	2.586
8	4		11.83		5.781	1538	2.722
9	1.833		5.833		3.718	5833	0.9528
10	2.333		6.833		3.836	3262	1.361
11	3.666		37.83		17.18	6323	0.9528
12	4.5		20.5		11.19	4120	1.497
13	3.833		13		5.232	210	2.314
14	4.5		12.5		5.363	1904	2.178
15	4.5		14		6.171	2762	2.178
16	5.333		16.16		7.852	2949	2.041
17	2.833		10.66		4.01	3697	1.633
18	4.333		15.5		8.429	3208	1.769
19	4.5		15		6.601	2422	2.041
20	4.666		12		4.32	2050	2.722
21	4.166		20.66		12.79	2192	2.586
22	4.166		18.16		6.526	3851	1.497
23	3.333		34		11.3	7.92	0.8167
24	4		12.66		5.665	7187	0.8167
25	2.333		54.33		26.87	9619	0.5445
26	3.833		5.166		3.131	2598	2.314
27	3		10.66		6.873	3248	1.905
28	3.666		10.66		4.717	1973	2.45
29	3.833		5		1.68	3066	1.905
30	3		19.16		10.38	5636	1.089
31	2.333		8.833		3.657	4986	1.225
32	3.333		22		7.818	4956	1.089
33	2.166		6.333		3.123	4464	1.361

Scenario	M manpower	SD manpower	Manpower utilization	Probability CF	M cumulative delays
1	0.4424	0.7124	0.6211	0.0024	68.16
2	0.4141	0.5755	0.5813	0.002	64.33
3	0.3754	0.3351	0.5270	0.0018	311.83
4	0.3789	0.334	0.5319	0.0016	545.16
5	0.4451	0.7534	0.6249	0.002	43
6	0.4521	0.9294	0.6347	0.0023	26.16
7	0.4864	0.9666	0.6828	0.0022	33.33
8	0.5217	1.003	0.7324	0.0021	46.33
9	0.4441	0.4585	0.6234	0.00097207	370.83
10	0.4838	0.6224	0.6792	0.0012	206.83
11	0.4025	0.4662	0.5650	0.0019	202.66
12	0.4395	0.6718	0.6170	0.0023	123.33
13	0.5715	0.8541	0.8023	0.002	188.66
14	0.5031	0.8662	0.7063	0.0023	85.16
15	0.4406	0.8599	0.6185	0.0023	30
16	0.4614	0.8335	0.6477	0.0028	39.16
17	0.445	0.7121	0.6247	0.0015	68.83
18	0.453	0.7518	0.6359	0.0022	58.66
19	0.5059	0.836	0.7102	0.0023	88.5
20	0.4668	0.9906	0.6553	0.0024	13.66
21	0.4529	0.9678	0.6358	0.0022	13.16
22	0.4546	0.6665	0.6382	0.0022	53.33
23	0.3998	0.4015	0.5613	0.0017	354.16
24	0.3832	0.405	0.5380	0.0021	315.66
25	0.3345	0.2642	0.4696	0.0012	525.16
26	0.445	0.8973	0.6247	0.002	13
27	0.4366	0.791	0.6129	0.0015	46
28	0.4669	0.9233	0.6555	0.0019	24.16
29	0.4557	0.7911	0.6397	0.002	71.66
30	0.4066	0.5239	0.5708	0.0015	61.33
31	0.4128	0.5732	0.5795	0.0012	70.16
32	0.4427	0.515	0.6215	0.0017	272.83
33	0.4349	0.6277	0.6105	0.0011	131

Scenario	M_N maintenance	Max	M	SD	Max workload
		accumulated NF	accumulated NF	accumulated NF	
1	35	25.9	13.3	2.153	41.82
2	25.83	32.02	17.6	2.785	56.51
3	40.83	27.63	9.859	1.203	34.66
4	54	21.72	7.215	0.9743	28.95
5	32	26.91	14.82	2.528	48.9
6	30	28.8	15.71	2.878	48.7
7	60.16	14.7	7.796	1.217	23.69
8	74.66	11.99	6.213	1.003	20.91
9	94.5	10.1	4.242	0.5728	14.26
10	113.66	8.814	3.598	0.4851	12.04
11	29.83	32.01	14.52	2.094	50.85
12	36	27.87	12.79	2.009	41.03
13	136.83	7.059	3.027	0.4335	10.25
14	87.5	10.22	5.175	0.8116	17.39
15	26	32.7	18.62	3.212	59.06
16	39	22.62	12.19	1.905	38.35
17	39.66	23.42	11.63	1.759	42.37
18	46.16	20.39	10.02	1.568	31.38
19	79.16	12.11	5.701	0.8917	19.18
20	35.33	24.42	13.76	2.189	45.33
21	29.83	31.6	16.44	2.754	51.44
22	54	17.31	8.391	1.239	26.15
23	54	18.69	7.596	1.013	30.37
24	26.66	38.28	15.78	2.54	56.35
25	20.83	45.16	17.97	2.311	62.91
26	25	33.03	19.04	3.127	61.15
27	24	36.52	19.44	3.617	62.87
28	53.33	17.22	8.92	1.381	29.72
29	44.16	19.74	10.55	1.717	33.41
30	22	37.96	20.29	3.405	64.44
31	25	36.18	18.04	2.819	59.2
32	87.16	11.82	4.749	0.6829	17.63
33	40.5	23.78	11.21	1.838	42.15

Scenario	M workload	SD workload	Repair shop utilization	Cost mechanics	Ao	Cost ship operating	Cost spare part	Life cycle cost
1	5.415	8.632	0.3134	46618	0.8944	1147000	195625	1389243
2	9.066	12.27	0.3572	54324	0.8786	1127000	144390	1325714
3	9.323	7.825	0.6420	85546	0.7799	1001000	228229	1314775
4	7.375	6.108	0.7010	86237	0.7633	979729	301821	1367787
5	5.492	9.343	0.2852	42849	0.9017	1157000	178857	1378706
6	4.205	8.701	0.2207	33738	0.9238	1185000	167678	1386416
7	2.197	4.277	0.2792	35473	0.9058	1162000	336289	1533762
8	1.819	3.486	0.3121	37570	0.8949	1148000	417333	1602903
9	3.335	3.276	0.6265	74597	0.7905	1014000	528188	1616785
10	2.085	2.571	0.5330	60013	0.8217	1054000	635316	1749329
11	10.04	11.36	0.4728	66853	0.839	1076000	166747	1309600
12	5.985	9.036	0.3479	49372	0.8822	1132000	201214	1382586
13	1.336	1.917	0.5075	52564	0.8296	1064000	764801	1881365
14	1.893	3.163	0.3692	43925	0.8758	1124000	489063	1656988
15	5.386	10.6	0.2250	35875	0.9237	1185000	145321	1366196
16	4.102	7.369	0.2798	41087	0.9052	1161000	217982	1420069
17	4.782	7.625	0.3217	45117	0.8918	1144000	221708	1410825
18	3.824	6.312	0.3179	44837	0.8926	1145000	258039	1447876
19	2.2	3.6	0.3815	46372	0.8715	1118000	442485	1606857
20	3.309	6.997	0.2143	32773	0.9275	1190000	197488	1450414
21	4.09	8.698	0.2050	31351	0.9298	1193000	166747	1391098
22	3.82	5.539	0.3773	52486	0.8726	1119000	301821	1473307
23	6.388	6.215	0.5980	77278	0.7976	1023000	301821	1402099
24	13.04	13.07	0.5465	73603	0.8165	1048000	149047	1270650
25	21.45	14.63	0.7545	92486	0.7436	954398	116443	1163327
26	5.243	10.58	0.2158	33679	0.9275	1190000	143506	1367185
27	6.865	12.41	0.2560	37881	0.9137	1172000	134143	1344024
28	2.531	5.004	0.2717	35094	0.9084	1165000	300938	1501032
29	3.908	6.736	0.3047	41625	0.8979	1152000	246908	1440533
30	12.34	15.41	0.4081	58397	0.8622	1106000	125807	1290204
31	9.545	12.99	0.3668	52865	0.8769	1125000	143506	1321371
32	3.23	3.669	0.5585	67596	0.8117	1041000	489111	1597707
33	5.63	7.873	0.3723	50301	0.8753	1123000	226366	1399667

Abstract

Failure function based Intermediate level maintenance system for Naval battleships

Choi, Jin Woo
Logistics and Procurement
Graduate School of Defense Management
Korea National Defense University

The goals of the Smart Navy include Condition based maintenance. In condition-based maintenance, the ship is monitored and maintenance is performed according to the condition of the equipment. The Smart Navy team is only focusing on introducing new technologies of the 4th industrial revolution to implement condition-based maintenance. Priority is not considered by reviewing technologies that can be introduced in parallel. If the navy is viewed from a systemic perspective, the core force, the ship, is located at the center. The fact that the ships are not operating well means that they cannot maintain the readiness posture to be put into battle in case of emergency. The reason why he cannot be put into battle is because of the occurrence of a breakdown. In order to prevent a failure in advance or to repair it quickly, an auxiliary means is a maintenance policy such as condition-based maintenance. In the end, the key to the Navy's system is to prevent malfunctions in order to operate the ships well.

It is necessary to study the failure function in order to understand the failure, which is the center of the naval system. The failure function is a failure function that draws a pattern of failures over the total life span using the failure data of the diesel engine for propulsion of naval battleships. There are two failure functions in this study. The general failure function is a pattern for failures that can be operated even if they occur. General failures are repaired during planned maintenance. The emergency failure function is a failure pattern that must be immediately judged as mission failure and must be repaired by entering the port of origin.

System dynamics is a method of visually representing and simulating a complex system composed of feedback loops. By introducing the failure function into the system dynamics, it is possible to simulate a naval maintenance system. If a failure function is introduced into the maintenance system, maintenance can be performed when a certain level of failure has accumulated. In other words, it is

possible to carry out planned maintenance according to the condition of the ship. Since the failure pattern during the total life span is included in the failure function, the maintenance policy reflecting the failure function is both state-based maintenance and predictive maintenance. When the major parameters of the naval system are reflected in the system dynamics, it becomes similar to the real naval system. It can be said that the more actual variables are reflected, the more system dynamics become digital twins.

The Navy assumes that when maintenance is performed, it will be completely repaired and in like-new condition. This is called complete overhaul. A complete overhaul is practically impossible. This is because, no matter how good a mechanic is, he cannot repair the wear and tear caused by natural winds and waves every time. Incompletely maintained general malfunctions remain on the ship and are requested again during the next planned maintenance. In this study, the maintenance capacity of maintenance units is estimated to be what percentage compared to 100% of complete maintenance and reflected in the system dynamics.

The system dynamics model, including the failure function and complete maintenance rate, is very similar to the real naval system. However, this cannot be called state-based maintenance. In condition-based maintenance, a fixed number of maintenance days is not given. At the same time as checking the status, the time required for maintenance, necessary repair parts, and the number of maintenance personnel are automatically selected. In order to implement condition-based maintenance, the number of maintenance days should be flexibly changeable. The number of maintenance days is determined according to the abilities of the maintenance personnel. The skill of the mechanic is related to the speed of maintenance. The ability to perform a lot of maintenance quickly can be said to be good. In previous studies, it was said that the work speed was determined by the amount of maintenance accumulated. In a situation where there is a large amount of maintenance due to the accumulation of a large number of general malfunctions of the ship, the work speed of the maintenance personnel is fast, and in the opposite case, the work speed is slow. The results of past research are reflected in the system dynamics.

The general failure function, which is the main variable in the system dynamics, is estimated by hierarchical Bayesian, and the emergency failure function is simulated by Monte Carlo by fitting a stepwise distribution. The complete maintenance rate of the maintenance unit is estimated by the Bayesian model composed of the prior distribution of the survey data. The maintenance speed of maintenance personnel realizes the contents of past research. The system dynamics model is a naval system in which two merchant units maintain six ships. When the maintenance times of the ships overlap, a standby is generated and additional operational missions are performed. The effect is analyzed by performing simulations and suggesting improvement policies. The optimal values of

maintenance policies are derived by analyzing the linear relationship of the dependent variables derived from the simulation.

The research model is very similar to the navy's maintenance system. It includes most of the elements that occur during the operation and maintenance of the ship. Therefore, it has great practical use value. The Navy can immediately use the research model to verify the effectiveness of maintenance policies. Meanwhile, the industry can implement a model suitable for the industry by referring to the estimation process of variables including the failure function and the system dynamics modeling procedure.

Key words: Failure function, Maintenance policy, System dynamics, Bayesian inference, Phase-type distribution, Queueing, Multi-variate linear regression